

Sumário

CLASSIFICAÇÃO AUTOMÁTICA MULTIMODELO DE CHAMADOS DE MANUTENÇÃO PREDIAL UNIVERSITÁRIA EM PORTUGUÊS BRASILEIRO: PROTOCOLO DE GOVERNANÇA PREDITIVA COM VALIDAÇÃO HUMANA SOB RÓTULOS HISTÓRICOS RUIDOSOS

Multi-model automatic classification of university building maintenance work orders in Brazilian Portuguese: a predictive governance protocol with human validation under noisy historical labels

Adinailson Guimarães de Oliveira

Universidade Federal do Sul da Bahia (UFSB), Programa de Pós-Graduação em Biossistemas

E-mail: adinailson.oliveira@cja.ufsb.edu.br

RESUMO

A classificação automática de chamados de manutenção predial constitui recurso estratégico para a qualificação da triagem operacional e para a ampliação da governança baseada em evidências em instituições públicas. Contudo, em bases históricas de sistemas informatizados de gestão de chamados, a categoria originalmente registrada não deve ser tratada como verdade absoluta, uma vez que pode refletir decisões operacionais ruidosas, taxonomias sobrepostas, registros incompletos e interpretações heterogêneas entre equipes de atendimento. O presente artigo propõe um protocolo multimodelo para classificação de chamados reais de manutenção predial universitária em português brasileiro, extraídos do sistema GLPI da Universidade Federal do Sul da Bahia. O experimento utiliza 13.965 chamados não vazios, organizados em 55 categorias históricas, e compara classificadores clássicos baseados em TF-IDF (Naive Bayes, Regressão Logística, LinearSVC, SGD, Random Forest e Extra Trees) e rede neural LSTM bidirecional. O BERTimbau permanece como extensão planejada, sem treino concluído ou métrica própria nesta consolidação. O diferencial metodológico reside na distinção entre concordância com o histórico administrativo e acerto validado por revisão humana, tratando a categoria histórica como referência preliminar imperfeita — distinção que se mostrou decisiva: o acerto validado por conferência humana (9.096 decisões travadas) revelou-se mais conservador do que a concordância com o histórico sugeria, à medida que a amostra de conferência cresceu. Como a seleção não é aleatória e prioriza divergências e casos críticos, esses resultados não estimam o desempenho da base completa (COCHRAN, 1977). Resultados indicam superioridade do LinearSVC tanto na concordância com o histórico (acurácia de 80,29%, IC95%: 79,62%–80,95%) quanto no acerto validado (94,93%, IC95%: 94,47%–95,38%), enquanto o LSTM apresentou concordância de 68,13% e acerto validado de 87,90% (números atualizados em 25/07/2026, após limpeza completa e rematerialização dos sete modelos comparáveis a partir do zero — ver Subseções 4.1, 4.2 e 4.9). A normalidade da concordância por turno foi rejeitada para todos os modelos, justificando testes não paramétricos (Friedman, Cochran Q, McNemar, bootstrap). O custo computacional é incorporado como dimensão de avaliação, evidenciando que modelos lineares podem oferecer melhor relação entre desempenho e viabilidade operacional em cenários de texto curto, ruidoso e desbalanceado.

Palavras-chave: manutenção predial; classificação de chamados; processamento de linguagem natural; rótulos ruidosos; validação humana; governança preditiva.

ABSTRACT

Automatic classification of building maintenance work orders is a strategic resource for qualifying operational triage and enhancing evidence-based governance in public institutions. However, in historical databases from computerized service management systems, the originally assigned category should not be treated as an unquestionable ground truth, since it may reflect noisy operational decisions, overlapping taxonomies, incomplete records, and heterogeneous interpretations across maintenance teams. This paper proposes a multi-model protocol for classifying real university building maintenance requests in Brazilian Portuguese, extracted from the GLPI system at the Federal University of Southern Bahia. The experiment uses 13,965 non-empty records organized into 55 historical categories and compares TF-IDF-based classical classifiers (Naive Bayes, Logistic Regression, LinearSVC, SGD, Random Forest, and Extra Trees) and a bidirectional LSTM neural network. The Portuguese pre-trained transformer (BERTimbau) remains a planned extension,

without completed training or its own metric in this consolidation. The methodological contribution lies in distinguishing agreement with administrative history from human-validated accuracy — a distinction that is necessary for the present protocol: human-validated accuracy (9,096 locked decisions) is reported only for the partial, non-random reviewed sample, which prioritizes divergences and critical cases. Results indicate LinearSVC superiority both in agreement with history (80.34% accuracy, 95%CI: 79.69%–80.97%) and in human-validated accuracy (79.89%, 95%CI: 78.99%–80.73%), while LSTM achieved 68.47% agreement and 74.71% validated accuracy. Normality was rejected for all models, supporting non-parametric tests (Friedman, Cochran Q, McNemar, bootstrap). Computational cost is incorporated as an evaluation dimension.

Keywords: building maintenance; work-order classification; natural language processing; noisy labels; human validation; predictive governance.

1. INTRODUÇÃO

A manutenção predial em instituições federais de ensino superior (IFES) envolve decisões recorrentes de triagem, categorização, priorização e alocação de equipes, agravadas pela dispersão territorial, pela diversidade de sistemas prediais e pela restrição orçamentária que historicamente limita o custeio dessas atividades a patamares inferiores a 2% do orçamento institucional (MARTINS; ESPEJO, 2024; PAMPANA *et al.*, 2022). Sistemas informatizados de registro de chamados, como plataformas GLPI e ambientes de *helpdesk*, tornaram-se, nesse contexto, não apenas instrumentos de solicitação, mas bases de conhecimento institucional sobre falhas, recorrências e padrões de uso, cujo potencial analítico permanece amplamente subutilizado (MORAIS; PAULA; REIS, 2023; MOHAMMED; AMOAH, 2025).

A exploração analítica dessas bases é limitada por ao menos três fatores estruturais. O primeiro reside na natureza textual curta, heterogênea e frequentemente incompleta dos registros, uma vez que chamados de manutenção predial são redigidos em linguagem técnica fragmentária, com abreviações locais e jargões de equipe que dificultam a aplicação direta de modelos genéricos de processamento de linguagem natural (PLN) (SUNDARAM; ZEID, 2025). O segundo fator é o desbalanceamento entre categorias, dado que demandas recorrentes de climatização, elétrica e hidrossanitária tendem a concentrar grande parte da base, ao passo que categorias raras dispõem de poucos exemplos para treinamento supervisionado (LI *et al.*, 2024). O terceiro fator, possivelmente o mais crítico do ponto de vista metodológico, é a qualidade dos rótulos históricos, pois a categoria registrada no momento do chamado pode resultar de interpretação rápida, classificação por conveniência operacional ou taxonomia ainda não estabilizada, de modo que o histórico administrativo constitui evidência importante, porém não verdade absoluta (ZHANG *et al.*, 2025; KEJRIWAL *et al.*, 2024).

A literatura recente sobre mineração textual de ordens de manutenção confirma a relevância de técnicas de PLN para transformar registros textuais em insumos de gestão. Li *et al.* (2024) demonstraram, em base hospitalar com 15.623 ordens de serviço, que a atribuição automática de equipes por PLN alcança acurácia de 0,83, reduzindo substancialmente a dependência de triagem manual. Sundaram e Zeid (2025) analisaram registros de *Maintenance Work Orders* sob a abordagem de *Technical Language Processing*, argumentando que textos técnicos de manutenção funcionam como *black holes* informacionais quando armazenam dados relevantes sem serem efetivamente utilizados na tomada de decisão. Bouabdallaoui *et al.* (2020), por sua vez, aplicaram modelos de PLN à classificação de requisições de manutenção em edificação hospitalar, reportando acurácia média de 78% com múltiplos métodos de representação textual. Contudo, a maior parte dessas aplicações concentra-se em bases em inglês ou chinês e em domínios industriais ou hospitalares, configurando lacuna relevante para corpora em português brasileiro no contexto da manutenção predial pública universitária.

O presente artigo parte de uma tese metodológica específica: em bases reais de chamados de manutenção, a avaliação de modelos não deve ser reduzida à pergunta sobre qual classificador mais concorda com a categoria histórica. Conforme Zhang *et al.* (2025), rótulos ruidosos em PLN afetam o desempenho dos classificadores e podem ampliar o consumo de recursos computacionais, exigindo métodos robustos de tratamento de ruído. Kejriwal *et al.* (2024) reforçam que *benchmarks* rotulados por humanos podem conter variabilidade relevante, questionando a prática de assumir uma única verdade absoluta quando há julgamento subjetivo envolvido. Dessa forma, a pergunta central deve ser mais ampla: em que medida os modelos reproduzem o histórico, em que medida auxiliam na identificação de inconsistências desse histórico e de que maneira a revisão humana pode converter divergências entre inteligência artificial e registro administrativo em melhoria progressiva da taxonomia institucional.

Com base em chamados reais da Universidade Federal do Sul da Bahia (UFSB), propõe-se uma comparação multimodelo de classificadores de texto aplicados a chamados de manutenção predial em português brasileiro. A base experimental contém 13.965 chamados não vazios (na consolidação vigente de 23/07/2026), distribuídos em 55 categorias históricas, e os campos textuais considerados agregam informações do título e da descrição do chamado, além de informações associadas à ordem de serviço. O estudo compara modelos clássicos baseados em TF-IDF (Naive Bayes, Regressão Logística, LinearSVC, SGD, Random Forest e Extra Trees) com abordagem neural LSTM bidirecional. O BERTimbau é mantido como extensão planejada, mas não integra as comparações enquanto não houver treino concluído e métricas próprias rastreáveis. O objeto de avaliação, portanto, não é apenas o classificador isolado, mas o protocolo de governança preditiva que articula aprendizado de máquina, auditoria estatística, custo computacional e validação humana, em consonância com a perspectiva de manutenção baseada em evidências preconizada pela NBR 5674 (ABNT, 2012).

Os objetivos específicos do estudo são: (i) apresentar um protocolo de comparação multimodelo para classificação de chamados reais de manutenção predial universitária em português brasileiro; (ii) distinguir concordância com rótulo histórico de acerto validado, evitando equiparar categoria histórica a *ground truth* incontestável; (iii) avaliar desempenho por métricas globais, métricas balanceadas, intervalos de confiança e testes estatísticos pareados adequados a dados não normais; (iv) incorporar custo computacional como dimensão de decisão operacional; e (v) transformar divergências entre IA e histórico em evidências para revisão taxonômica e retroalimentação da base de treino.

2. REFERENCIAL CONCEITUAL

2.1 Processamento de linguagem natural em ordens de manutenção

Ordens de manutenção constituem registros operacionais com valor informacional elevado, porém usualmente subutilizado. Elas documentam sintomas, locais, equipamentos, procedimentos, materiais e soluções executadas, acumulando-se ao longo de anos em sistemas informatizados cuja forma textual e semiestruturada dificulta o uso direto em planejamento e alocação de recursos (PAMPANA *et al.*, 2022; MORAIS; PAULA; REIS, 2023). Li *et al.* (2024) propuseram estrutura baseada em PLN para análise e atribuição automática de ordens de manutenção hospitalar, utilizando 15.623 registros de hospital municipal em Xangai e reportando acurácia de 0,83 na tarefa de atribuição de trabalhadores, resultado que evidencia a possibilidade de automatizar processos antes dependentes de triagem manual em contextos prediais. Esse trabalho constitui referência-âncora para a presente pesquisa por tratar diretamente da automação de ordens de manutenção predial, embora em idioma, tipologia institucional e estrutura taxonômica distintos.

Sundaram e Zeid (2025), ao analisar registros textuais de *Maintenance Work Orders* sob a abordagem de *Technical Language Processing*, defenderam que textos técnicos de manutenção funcionam como repositórios informacionais subutilizados quando não integrados a processos decisórios. Essa perspectiva é especialmente pertinente à manutenção predial universitária, na qual chamados curtos, abreviações locais, nomes de ambientes e descrições incompletas dificultam o uso de modelos genéricos sem adaptação ao domínio. Bouabdallaoui *et al.* (2020) reportaram acurácia média de 78% na classificação de requisições de manutenção predial hospitalar utilizando múltiplos métodos de PLN, resultado que reforça a viabilidade da abordagem, mas também evidencia a necessidade de adaptação lexical e semântica ao corpus específico.

2.2 Classificação de tickets e evolução dos modelos

A classificação automática de *tickets* em ambientes de suporte técnico e ITSM evoluiu de representações vetoriais baseadas em frequência lexical para *embeddings* e modelos de linguagem pré-treinados. Liu, Bengue e Jiang (2023) propuseram o Ticket-BERT para rotulagem de *tickets* de incidentes, enfatizando desafios como atualização contínua de rótulos e necessidade de aprendizado ativo. Entretanto, a transferência direta de achados do ITSM para a manutenção predial deve ser cautelosa, pois a semântica do domínio envolve sistemas físicos, ambientes e equipamentos prediais que não coincidem com categorias de incidentes de *software* ou infraestrutura digital (SUNDARAM; ZEID, 2025).

Modelos lineares com TF-IDF continuam competitivos em tarefas de texto curto, especialmente quando o corpus é de porte médio, o vocabulário possui alta especificidade técnica e as classes são desbalanceadas (GALKE; SCHERP, 2022). Nesses cenários, modelos profundos podem não compensar seu custo computacio-

nal caso não disponham de volume suficiente, balanceamento adequado ou *embeddings* fortemente adaptados ao domínio. Galke e Scherp (2022), em revisão comparativa abrangente de métodos para classificação textual, demonstraram que classificadores baseados em *bag-of-words* com TF-IDF e SVM permanecem altamente competitivos frente a redes neurais em múltiplos *benchmarks*, sobretudo quando o corpus é reduzido ou o vocabulário é altamente especializado. Esse achado é particularmente relevante para o contexto institucional de manutenção predial, onde a base operacional raramente atinge escala compatível com as exigências de modelos de linguagem de grande porte.

2.3 Rótulos ruidosos e verdade operacional

O problema de rótulos ruidosos é central em aprendizado supervisionado aplicado a bases administrativas. Em classificação textual, ruído de rótulo pode decorrer de ambiguidade semântica, polissemia, insuficiência de contexto, sobreposição taxonômica, julgamento subjetivo ou erro humano de registro (ZHANG *et al.*, 2025). Conforme levantamento de Zhang *et al.* (2025), rótulos ruidosos em PLN afetam o desempenho dos modelos e podem ampliar o consumo de recursos, exigindo métodos robustos de tratamento de ruído. Kejriwal *et al.* (2024) reforçam que *benchmarks* rotulados por humanos podem conter variabilidade relevante, questionando a prática de assumir uma única verdade absoluta quando há julgamento subjetivo envolvido. No contexto do presente artigo, a categoria histórica do chamado é tratada como referência administrativa, não como verdade final, e a verdade operacional deve ser construída por validação humana com registro explícito da decisão tomada.

2.4 Custo computacional e eficiência em PLN

A avaliação de modelos de PLN tem sido tradicionalmente orientada por métricas de desempenho, mas a literatura recente enfatiza que custo computacional, tempo de treino, consumo energético e reprodutibilidade também devem compor a decisão de adoção (TREVISIO *et al.*, 2023; SCHWARTZ *et al.*, 2020). Treviso *et al.* (2023) argumentam que a ampliação de escala em PLN tende a aumentar o consumo de dados, tempo, armazenamento e energia, motivando métodos eficientes especialmente em contextos de recursos limitados. Schwartz *et al.* (2020) cunharam o conceito de *Green AI*, propondo que a eficiência computacional seja reportada e valorizada na avaliação de modelos, não apenas a acurácia. Em uma instituição pública, essa dimensão é operacionalmente decisiva: um modelo que treina em segundos pode ser reexecutado frequentemente, auditado com facilidade e mantido sem infraestrutura dedicada, ao passo que um modelo que demanda dezenas de minutos exige *checkpoint*, controle de versão de pesos e justificativa robusta de ganho marginal (TREVISIO *et al.*, 2023).

3. MÉTODO

3.1 Delineamento geral

O estudo adota delineamento experimental aplicado, com base observacional retrospectiva de chamados de manutenção predial registrados no sistema GLPI institucional da UFSB, universidade multicampi com unidades em Itabuna, Ilhéus, Porto Seguro e Teixeira de Freitas (MORAIS; PAULA; REIS, 2023). A unidade de análise é o chamado individual de manutenção, representado por campos textuais concatenados e por uma categoria histórica registrada no sistema. O fluxo metodológico compõe-se de oito etapas sequenciais: (i) extração e consolidação da base; (ii) higienização textual; (iii) construção da matriz de atributos; (iv) treinamento e inferência multimodelo; (v) geração de previsões *out-of-fold*; (vi) comparação preliminar com categoria histórica; (vii) análise estatística não paramétrica; e (viii) validação humana das divergências e amostras críticas. A Figura 1 apresenta esse fluxo como *pipeline* de governança preditiva.

Figura 1 Pipeline de governança preditiva: fluxo metodológico completo, da extração da base à retroalimentação por validação humana.

Fonte: elaborado pelos autores (2026), gerado a partir da descrição desta subseção (04_artigo/figuras/fig1_pipeline_gove

3.2 Corpus e variáveis

O corpus experimental é composto por 13.965 chamados de manutenção predial não vazios, organizados em 55 categorias históricas, extraídos do ambiente institucional da UFSB. Os campos textuais previstos no protocolo incluem título do chamado, descrição GLPI, título da ordem de serviço e descrição da ordem de serviço, concatenados em uma única representação textual para fins de classificação. A categoria histórica é utilizada

Figura 1 - Pipeline de governança preditiva: fluxo metodológico completo




Figura 1: Figura 1 — Pipeline de governança preditiva: fluxo metodológico completo, da extração da base à retroalimentação por validação humana.

como referência preliminar de comparação, mas a avaliação conclusiva depende da base validada por revisão humana. O idioma dos registros é português brasileiro, com presença significativa de jargões técnicos, nomes de ambientes, abreviações locais e descrições incompletas, características que impõem desafios específicos de pré-processamento e representação textual (SUNDARAM; ZEID, 2025).

A base é dinâmica: novos chamados continuam sendo sincronizados e classificados em turnos. Na consolidação vigente (23/07/2026), o número de chamados elegíveis já cresceu para 13.965, em 55 categorias históricas (uma categoria adicional frente à contagem original de 54, em função de uma migração de nomenclatura registrada na auditoria técnica que acompanha este capítulo). Os resultados da Seção 4 utilizam esse recorte mais recente; eventuais diferenças frente a valores publicados em versões preliminares deste texto refletem o crescimento da base e a ampliação da conferência humana, não uma mudança metodológica dos scripts de análise (confirmado por conferência do histórico de commits dos scripts que produzem `avaliacao_final.json` e `estatistica.json`).

3.3 Pré-processamento textual

O pré-processamento textual foi documentado de modo reproduzível, uma vez que pequenas decisões sobre normalização podem alterar a matriz de atributos e, consequentemente, o desempenho dos modelos (SALTON; BUCKLEY, 1988). Para os classificadores clássicos, a representação principal é TF-IDF com *n-gramas* de uma e duas palavras e limite superior de 5.000 atributos para controle de dimensionalidade. Para o modelo neural LSTM, são utilizadas tokenizações específicas com vocabulário de 8.000 termos e comprimento máximo de sequência adequado à distribuição textual da base. Cabe ressaltar que a etapa de pré-processamento não elimina indiscriminadamente termos técnicos, códigos de ambientes, nomes de equipamentos ou expressões recorrentes da equipe, pois esses elementos possuem alto valor discriminativo em manutenção predial, onde palavras como *bomba*, *split*, *disjuntor*, *vazamento*, *infiltração* e *ar-condicionado* podem funcionar como âncoras semânticas relevantes para categorias específicas.

3.4 Modelos avaliados

O desenho experimental compara sete modelos materializados nesta consolidação. Os classificadores clássicos adotam representação TF-IDF e algoritmos de aprendizado supervisionado amplamente consolidados na literatura de classificação textual (JOACHIMS, 1998; PEDREGOSA *et al.*, 2011): Naive Bayes Multinomial, como *baseline* probabilístico; Regressão Logística, com calibração natural e boa interpretabilidade; LinearSVC, combinando margem linear e escores de decisão normalizados por *softmax* apenas para ordenação de confiança (sem calibrador de Platt ajustado; PLATT, 1999); SGD, como alternativa eficiente para matrizes esparsas de grande dimensão; Random Forest e Extra Trees, como representantes de métodos não lineares baseados em *ensemble* de árvores. A LSTM Bidirecional foi construída com camada de *embedding* de 8.000 termos e 128 dimensões, camada recorrente bidirecional de 64 unidades (GRAVES; SCHMIDHUBER, 2005), *dropout* de 0,5 e camada densa com ativação *softmax*, treinada com parada antecipada, avaliada tanto na comparação

out-of-fold (Subseção 4.1) quanto na Etapa 1 oficial de produção, com *fallback* de Random Forest.

O oitavo modelo planejado é um transformador pré-treinado em português (BERTimbau, `neuralmind/bert-base-portuguese`). Seu fluxo de ajuste fino é separado, condicionado ao avanço da base validada e pode recorrer a *fallback* técnico quando as dependências não estão disponíveis. O estado publicado em `bertimbau_training_state.json` nesta consolidação é `sem_dados`, com treino adiado; por isso o modelo não integra tabelas, rankings, testes inferenciais nem conclusões comparativas deste artigo.

3.4.1 Diferenças conceituais e operacionais entre os classificadores

Os sete modelos comparáveis desta consolidação cobrem quatro famílias com suposições distintas sobre os dados: um gerador probabilístico (Naive Bayes), discriminadores lineares (LinearSVC, Regressão Logística, SGD), *ensembles* não lineares baseados em árvores (Random Forest, Extra Trees) e uma rede neural sequencial (LSTM). Cada família responde de forma diferente a um corpus de texto curto, ruidoso e com forte desbalanceamento entre categorias (Subseção 3.2; Tabela S1), o que ajuda a explicar por que o desempenho não é uniforme entre elas nas Tabelas 1 e 2.

O **LinearSVC** otimiza uma fronteira de decisão linear por margem máxima sobre a representação TF-IDF esparsa de até 5.000 atributos (Subseção 3.3). Em espaços esparsos de alta dimensionalidade, classificadores lineares tendem a separar bem as classes quando o vocabulário carrega forte poder discriminativo (JOACHIMS, 1998; SALTON; BUCKLEY, 1988) — como ocorre aqui, em que termos técnicos do domínio (*bomba*, *split*, *disjuntor*, *vazamento*, *infiltração*, *ar-condicionado*; Subseção 3.3) funcionam como âncoras semânticas de categoria. Essa combinação é consistente com o LinearSVC liderando tanto a concordância com o histórico (0,8029; Tabela 1) quanto o acerto validado (0,9493; Tabela 2).

O **Naive Bayes** assume independência condicional entre atributos dado a classe — suposição estrutural que tende a ser violada em texto de manutenção predial, onde termos técnicos co-ocorrem de forma sistemática dentro de uma mesma categoria. Essa divergência entre a suposição do modelo e a estrutura real dos dados é uma explicação plausível para o Naive Bayes ocupar a última posição tanto na concordância com o histórico (0,6996; Tabela 1) quanto no acerto validado (0,8609; Tabela 2), sem que isso indique um problema de implementação — é o comportamento esperado do modelo mais simples da comparação.

Random Forest e **Extra Trees** capturam interações não lineares entre atributos por meio da estrutura de árvores, mas em espaços esparsos de alta dimensionalidade como o TF-IDF tendem a ajustar-se demais às co-ocorrências mais frequentes, o que se reflete no desempenho intermediário de ambos nas Tabelas 1 e 2 (entre o LinearSVC e o Naive Bayes). O custo computacional dessa família também é o mais alto entre os modelos clássicos medidos: 19,45 s (Random Forest) e 21,30 s (Extra Trees) de treino por lote de 1.000 registros, entre 7,6 e 8,4 vezes o tempo do LinearSVC (2,55 s) e entre 17,1 e 18,7 vezes o do Naive Bayes (1,14 s) no mesmo lote (Tabela 7) — um custo que só se justifica se revertido em ganho de acerto validado, o que não se confirma nesta consolidação (SCHWARTZ *et al.*, 2020; TREVISIO *et al.*, 2023).

A **LSTM Bidirecional** foi projetada para modelar dependências sequenciais no texto, mas nesta consolidação seus *embeddings* são inicializados aleatoriamente e treinados do zero — não há incorporação de vetores pré-treinados em português no código de treino (`src/modelo_lstm.py`). A camada de *embedding* (8.000 termos $\times$ 128 dimensões) concentra sozinha cerca de 1,02 milhão de parâmetros, uma ordem de grandeza próxima do número de exemplos disponíveis por partição de treino nesta consolidação (13.965 chamados, dos quais cerca de 11.172 compõem cada partição de treino em $k=5$ folds; Subseção 3.5) — um cenário consistente com a hipótese de que modelos lineares tendem a igualar ou superar redes neurais em corpora de porte médio e ruidosos quando não há *embeddings* pré-treinados disponíveis no idioma (GALKE; SCHERP, 2022), sem que isso configure uma falha da arquitetura em si (Subseção 4.9 detalha a investigação da discrepância do *ablation* do LSTM).

Na Etapa 1 oficial de produção — distinta da comparação *out-of-fold* desta seção —, o mecanismo de *fallback* opera no nível da base de treino, não por chamado individual: a LSTM só é treinada quando a base rotulada disponível atinge um mínimo de 200 exemplos (`MIN_BASE_LSTM`, `src/classificador_producao.py`); abaixo desse limiar, um classificador Random Forest sobre TF-IDF é treinado e usado no lugar da rede neural para toda a base naquele momento. Um segundo par de limiares (`LIMIAR_BAIXA` = 0,70; `LIMIAR_ALTA` = 0,95) não troca de modelo, mas rotula a confiança de cada predição em três faixas (abaixo de 70%, entre 70% e 95%,

acima de 95%) usadas para priorização de conferência humana e para as métricas de calibração da Subseção 4.4 — distinção relevante porque uma leitura apressada do código poderia confundir os dois mecanismos.

A avaliação foi realizada por predições fora da amostra em protocolo *out-of-fold* com *KFold* embaralhado ($k = 5$ partições, `src/classificacao_multimodelo.py`), `random_state=42` e mesma partição determinística para todos os modelos. A partição não é estratificada; esta é uma limitação do desenho implementado. O procedimento reduz viés de comparação e permite testes pareados (SOKOLOVA; LAPALME, 2009). As métricas principais são acurácia, *macro*-F1, F1 ponderado, *balanced accuracy* e intervalo de confiança por *bootstrap* com 95% de confiança. A *macro*-F1 e a *balanced accuracy* são essenciais face ao desbalanceamento entre categorias, dado que a acurácia isolada pode superestimar desempenho em classes majoritárias e mascarar falhas em categorias raras (SOKOLOVA; LAPALME, 2009). A correlação entre confiança e acerto é avaliada por Spearman; diferenças globais entre classificadores são avaliadas por Cochran Q e Friedman; comparações pareadas são avaliadas por McNemar (1947); e incerteza de acurácia é estimada por *bootstrap*. Quando múltiplas comparações são realizadas, aplica-se correção de Nemenyi no contexto de *ranks*.

3.6 Validação humana

A validação humana constitui a etapa que diferencia o presente estudo de uma simples comparação de classificadores contra histórico. A revisão registra, para cada caso auditado, a categoria histórica, a categoria sugerida por cada modelo, a confiança associada, a decisão humana e a categoria travada. A priorização recai sobre chamados em que há divergência entre modelos, alta confiança da IA contra histórico, baixa confiança generalizada, classes raras e pares de categorias com alta confusão recíproca. A decisão humana pode produzir quatro resultados: manter o histórico; aceitar a sugestão do modelo; definir terceira categoria; ou marcar o caso como ambíguo ou taxonômico. Essa estrutura permite mensurar se a IA errou, se o histórico estava inconsistente ou se a própria taxonomia institucional necessita de revisão, em consonância com a perspectiva de que a verdade operacional deve ser construída progressivamente (ZHANG *et al.*, 2025).

3.7 Memória de decisão: veto e trava por chamado

À medida que a conferência humana avança, o protocolo incorpora uma memória de decisão por chamado, que evita o reprocessamento de casos já resolvidos e impede a repetição de erros já identificados. Quando a conferência confirma que uma categoria está correta, essa decisão é travada e reaproveitada diretamente nas rodadas seguintes de reclassificação, sem novo treinamento ou nova predição para aquele chamado. Quando a conferência identifica que uma categoria está incorreta, essa categoria passa a ser vetada especificamente para aquele chamado: os modelos do repositório de classificadores passam a escolher a melhor categoria alternativa fora do conjunto vetado, com a confiança renormalizada sobre as categorias remanescentes. Essa regra é aplicada de forma consistente na seleção de candidatos à reclassificação e no cálculo do ganho líquido, que passa a comparar o resultado da reclassificação contra a verdade validada quando ela está travada, e contra o histórico apenas quando ainda não há decisão humana. O objetivo metodológico da memória de decisão é impedir que o sistema corrija um erro apenas para reincidir nele em ciclos futuros, convertendo cada conferência manual em conhecimento persistente sobre o experimento, não em um evento isolado.

3.8 Camada de entropia de Shannon e divergência de Jensen-Shannon

Como dimensão complementar às métricas supervisionadas, o protocolo incorporou uma camada de análise informacional baseada em entropia de Shannon e divergência de Jensen-Shannon (SHANNON, 1948; LIN, 1991), calculada exclusivamente sobre os arquivos públicos e sanitizados do painel (sem identificador, título ou texto livre do chamado). Essa camada não substitui acurácia, calibração ou validação humana; responde a uma pergunta distinta, sobre onde modelos, categorias e chamados individuais concentram maior incerteza estrutural. No nível dos modelos, a entropia de Shannon sobre a distribuição de categorias previstas indica se um classificador dispersa suas predições por muitas classes ou as concentra excessivamente em poucas; a divergência de Jensen-Shannon mede a distância entre essa distribuição prevista e a distribuição histórica da base, funcionando como indicador de deslocamento distributivo. No nível das categorias, a entropia evidencia classes históricas cujas predições se espalham entre múltiplas categorias, sinalizando candidatas prioritárias a revisão taxonômica. No nível do chamado individual, a entropia de votos entre os modelos identifica registros em que há desacordo estrutural entre arquiteturas distintas, formando uma fila de auditoria orientada por ambiguidade, e não apenas por baixa confiança isolada de um único modelo.

3.9 Disponibilidade de dados e scripts

Os artefatos que sustentam os resultados relatados neste capítulo são gerados por scripts versionados no repositório público github.com/adinailson88/classificacao-chamados (branch `main`), independente do repositório operacional Malha IA. Os números citados nas Subseções 4.1 a 4.6 correspondem aos arquivos JSON publicados em `docs/dados/` (por exemplo, `estatistica.json`, `avaliacao_final.json`, `calibracao.json`, `reclass_resumo.json`, `shannon_resumo.json`, `jensen_shannon_modelos.json`), regenerados automaticamente por *workflows* do GitHub Actions a cada rodada do experimento e publicados também via GitHub Pages. Nenhum identificador pessoal, título ou texto livre de chamado é versionado nesses arquivos; a camada Shannon/Jensen-Shannon (Subseção 3.8) opera exclusivamente sobre agregados sanitizados. **Pen-dência explícita desta subseção:** consolidar, em rodada futura, a correspondência exata entre cada subseção de resultado e o script que a gera (por exemplo, `src/avaliacao_final.py`, `src/calibracao.py`, `src/analise_shannon.py`), hoje mapeada em `PLANO_ARTIGO_CAPITULO.md` mas ainda não transcrita para o corpo do artigo.

4. RESULTADOS

Esta seção apresenta dois conjuntos de resultados, deliberadamente segregados: a concordância com a categoria histórica (Subseção 4.1), que trata o registro do GLPI como referência preliminar e não como verdade absoluta; e o desempenho validado por conferência humana (Subseções 4.2 e 4.3), calculado exclusivamente sobre os chamados com decisão travada pela memória M/N/P. Na consolidação vigente (23/07/2026), a base elegível contém 13.965 chamados e a conferência humana já cobre 9.534 chamados (68,3% da base), dos quais 9.096 com decisão travada e sem conflito (65,1% da base) e 438 casos restritos (categoria eliminada, ainda sem decisão travada). Esse crescimento — de 4.737 conferências (33,9% da base) em 16/07/2026 para 9.534 (68,3%) nesta consolidação — quase dobra a cobertura em relação à versão anterior deste protocolo e, como discutido na Subseção 4.2 e na Seção 5, revela um padrão de desempenho sensivelmente mais conservador do que a amostra menor sugeria.

4.1 Concordância com o histórico (base completa)

Nota de rastreabilidade (25/07/2026): os sete modelos comparáveis foram **rematerializados por completo** nesta data (abas `CLASSIF__<modelo>` limpas e reclassificadas do zero, `run` via workflow com credencial), depois de a Subseção 4.9 revelar que a materialização anterior (16-17/07) estava desatualizada. Os números abaixo refletem essa rematerialização.

A comparação contra a categoria histórica, sobre a base completa ($n = 13.965$, com intervalo de confiança por bootstrap a 95%), mantém o LinearSVC na liderança, com acurácia de 0,8029 (IC95%: 0,7962–0,8095), seguido por Extra Trees (0,7885), Random Forest (0,7799), SGD (0,7765), Regressão Logística (0,7677), Naive Bayes (0,6996) e LSTM (0,6813). O teste de Cochran Q confirma diferença global entre os sete modelos materializados ($Q = 2680,70$; $p < 0,001$); a comparação exclui o BERTimbau, cujo estado é `sem_dados`. O Kappa de Cohen entre cada modelo e o histórico acompanha ordenamento muito próximo (LinearSVC 0,7880; Extra Trees 0,7707; Random Forest 0,7612; SGD 0,7603; Regressão Logística 0,7513; Naive Bayes 0,6703; LSTM 0,6598). A ordem entre os sete modelos permanece a mesma da consolidação anterior — a rematerialização não alterou o ranking, só o patamar absoluto. A oitava fonte de classificação, a Etapa 1 oficial (executor LSTM/RF de produção, coluna G da planilha), mantém concordância de 77,65% e confiança média de 71,67% nesta consolidação, posicionando-se entre SGD e Regressão Logística nesta métrica — não é diretamente comparável ao LSTM *out-of-fold* da Tabela 1, pois combina LSTM com *fallback* de Random Forest conforme a regra de produção (Subseção 3.4), não um único modelo isolado. Essa fonte não foi rematerializada nesta rodada e pode estar sujeita à mesma defasagem temporal identificada na Subseção 4.9.

Tabela 1 Concordância com a categoria histórica, base completa ($n = 13.965$)

Modelo	Acurácia	IC95% bootstrap	Kappa vs. histórico
LinearSVC	0,8029	0,7962 – 0,8095	0,7880
Extra Trees	0,7885	0,7817 – 0,7949	0,7707
Random Forest	0,7799	0,7732 – 0,7864	0,7612
SGD	0,7765	0,7697 – 0,7833	0,7603

Modelo	Acurácia	IC95% bootstrap	Kappa vs. histórico
Regressão Logística	0,7677	0,7608 – 0,7745	0,7513
Naive Bayes	0,6996	0,6921 – 0,7070	0,6703
LSTM (out-of-fold)	0,6813	0,6733 – 0,6888	0,6598

Fonte: `estatistica.json`, gerado em 25/07/2026 02:07 (n = 13.965), a partir da rematerialização completa dos sete modelos no mesmo dia. A linha legada de `transformer_ft` foi deliberadamente excluída por não representar treino BERTimbau concluído.

A concordância com o histórico não é uniforme entre as 55 categorias. A Tabela Suplementar S1 (04_artigo/figuras/tabela_S1_metricas_por_categoria.csv, gerada por `src/exportar_tabela_por_categoria.py`) passou a refletir a aba viva TABELA_S1_METRICAS (gid=1862157493), cujos cabeçalhos reais são **Categoria**, **Support**, **Precision**, **Recall** e **F1-Score**. Portanto, nesta tabela suplementar o indicador por categoria já é precision/recall/F1 real, não apenas concordância vs. histórico do JSON público. As cinco categorias com menor F1 são Elétrica > Sistema Fotovoltaico (FV) (F1 = 0,0000; suporte = 7), Manutenção Preventiva sem subcategoria (F1 = 0,0000; suporte = 2), Estrutura Predial > Instalações Especiais (gás, ar comprimido, etc.) (F1 = 0,0732; suporte = 3), Suprimentos / Apoio Técnico > Transporte (F1 = 0,1053; suporte = 1) e Área Externa e Ambiental > Drenagem (F1 = 0,1333; suporte = 3). As cinco categorias com maior F1 são Manutenção Preventiva > Extintor (F1 = 1,0000; suporte = 14), Manutenção Preventiva > Gerador (F1 = 0,9908; suporte = 1.211), Manutenção Preventiva > Sistemas de combate a incêndio (extintores, hidrantes) (F1 = 0,9890; suporte = 45), Manutenção Preventiva > Quadros Elétricos (F1 = 0,9869; suporte = 576) e Manutenção Preventiva > Ar condicionado central (F1 = 0,9849; suporte = 165). A leitura das categorias de menor F1 deve ser cautelosa porque quatro das cinco têm suporte menor ou igual a sete registros; nesses casos, uma pequena variação absoluta altera fortemente a métrica.

4.2 Ranking validado por conferência humana

Nota de rastreabilidade (25/07/2026): esta subseção foi **regenerada apos a rematerializacao completa** dos sete modelos (ver nota da Subseção 4.1). A tabela anterior (gerada em 24/07/2026 04:55, a partir da materializacao de 16-17/07/2026) reportava acerto validado entre 0,71 e 0,80; a diferenca em relacao aos numeros atuais confirma a hipotese registrada na Subseção 4.9 – a materializacao antiga estava desatualizada, nao havia um problema de metodologia na avaliacao em si.

A avaliação contra a verdade validada pela memória de decisão M/N/P (n = 9.096 decisões travadas) confirma a mesma liderança da Subseção 4.1: o LinearSVC permanece o melhor modelo isolado, com acerto validado de 0,9493 (IC95%: 0,9447–0,9538), seguido por SGD (0,9392), Regressão Logística (0,9355), Extra Trees (0,9274), Random Forest (0,9227), LSTM (0,8790) e Naive Bayes (0,8609). A diferença entre o primeiro e o segundo colocado é pequena em termos absolutos (1,01 ponto percentual), mas estatisticamente significativa (McNemar, $p \sim 3,21 \times 10^{-5}$). Com os sete modelos comparáveis já consistentes (sem a linha legada `transformer_ft`), os ensembles puderam ser avaliados: maioria ponderada (0,9445), confiança calibrada máxima (0,9436) e maioria simples (0,9422) — nenhum supera o LinearSVC isolado com significância (McNemar $p < 0,05$ em favor do LinearSVC nos três casos). Conclusão: **não vale combinar modelos nesta consolidação**; usar LinearSVC isolado, com calibração.

Vies estrutural da seleção da amostra validada (achado de 25/07/2026): o número pontual de acerto validado acima é o **limite superior** de um intervalo, não uma estimativa isenta de viés. A “verdade validada” usada neste cálculo (`decisao_validada.py`) só existe para um chamado quando pelo menos uma conferência (M, N ou P) marca “Correto” — ou seja, quando o histórico, a IA oficial ou a reclassificação está confirmadamente certa. Dos 9.534 chamados com alguma conferência preenchida, 438 (4,6%) caem no status “restrito”: o avaliador julgou **todas** as fontes conferidas erradas para aquele chamado (344 casos só com o histórico marcado errado; 94 com histórico e IA oficial marcados errados simultaneamente), sem indicar qual seria a categoria certa. Esses 438 casos são **excluídos do denominador** de qualquer acerto validado por modelo, porque não existe categoria de referência contra a qual comparar a predição. Isso torna a amostra de 9.096 decisões, por construção, um subconjunto em que pelo menos uma fonte (histórico ou IA) estava correta — o que infla mecanicamente o acerto validado de qualquer modelo que tenda a concordar com o histórico ou

com a IA oficial, independentemente da qualidade real do modelo nos casos mais difíceis (exatamente os que ficaram de fora).

Para tornar esse viés visível sem descartar a métrica, calculamos um **limite inferior** de sensibilidade: o acerto de cada modelo caso os 438 restritos fossem incluídos no denominador e contados como erro para **todos** os modelos (pior caso possível, já que não sabemos a categoria certa desses casos — nenhum modelo pode receber crédito neles). O intervalo [**limite inferior**, **limite superior**] substitui o número pontual como leitura honesta do acerto validado: LinearSVC 0,9057–0,9493 (amplitude 4,36 p.p.), SGD 0,8961–0,9392 (4,31 p.p.), Regressão Logística 0,8925–0,9355 (4,30 p.p.), Extra Trees 0,8848–0,9274 (4,26 p.p.), Random Forest 0,8803–0,9227 (4,24 p.p.), LSTM 0,8386–0,8790 (4,04 p.p.) e Naive Bayes 0,8214–0,8609 (3,96 p.p.). O achado metodologicamente mais importante desta análise de sensibilidade é que o **ranking relativo entre os sete modelos não muda em nenhum ponto do intervalo** — mesmo no pior caso, o LinearSVC permanece à frente e o Naive Bayes permanece atrás de todos. Isso significa que a conclusão qualitativa (qual modelo usar) é robusta ao viés identificado, mas o valor absoluto do acerto validado não deve ser citado como um número único sem essa ressalva.

Tabela 2 Acerto validado contra a verdade decidida M/N/P (n = 9.096) e intervalo de sensibilidade ao viés de seleção (n = 9.096 a 9.534)

Modelo	Acerto validado (limite superior)	IC95%	Limite inferior (pior caso)
LinearSVC	0,9493	0,9447 – 0,9538	0,9057
SGD	0,9392	0,9343 – 0,9440	0,8961
Regressão Logística	0,9355	0,9302 – 0,9404	0,8925
Extra Trees	0,9274	0,9222 – 0,9325	0,8848
Random Forest	0,9227	0,9171 – 0,9280	0,8803
LSTM	0,8790	0,8724 – 0,8857	0,8386
Naive Bayes	0,8609	0,8533 – 0,8680	0,8214

Fonte: `avaliacao_final.json`, gerado em 25/07/2026 12:52, após limpeza completa e rematerialização dos 8 modelos a partir do zero (rodada 15). O limite inferior foi recalculado por derivação matemática direta a partir do novo `acerto_validado` (mesma fórmula do script `analise_sensibilidade_vies_validacao.py`: `corretos / (n_decididas + n_restritas)`, com `n_restritas` = 438 — inalterado, pois depende só das conferências M/N/P, não da rematerialização dos modelos), não por nova execução do workflow `sensibilidade_vies`; a composição dos restritos (344 só histórico errado, 94 histórico+IA errados) permanece a publicada em `04_artigo/figuras/sensibilidade_vies_validacao.json`, gerado em 25/07/2026 11:14. A tabela exclui a linha legada `transformer_ft`: além de `bertimbau_training_state.json` registrar `sem_dados`, a rodada 15 confirmou e corrigiu a causa raiz (fallback silencioso para LSTM — ver Limitações).

Nota metodológica sobre a resolução da discrepância do LSTM (ver Figura 6/Subseção 4.9): a Subseção 4.9 havia sinalizado que o ablation study do LSTM (86,35%–87,68% conforme o particionamento) discordava em ~11-13 pontos percentuais do valor oficial então vigente (0,7471). A rematerialização completa desta subseção confirma a causa: o valor de 0,7471 vinha de uma materialização de `CLASSIF__lstm` datada de 16-17/07/2026, mais de uma semana desatualizada. O novo valor oficial do LSTM (0,8790, rematerializado em 25/07/2026) está muito mais próximo do que o ablation já indicava, confirmando que **o ablation nunca teve um bug de vazamento residual relevante** — o problema real era a defasagem temporal da materialização oficial usada como referência, não uma falha metodológica do ablation em si. A ressalva de “resultado suspeito” da Figura 6 é mantida apenas como registro histórico da investigação (ver Subseção 4.9), não como pendência ativa.

Nota metodológica sobre a mudança de patamar entre consolidações (92–96% em 16/07/2026 → 71–80% em 24/07/2026 → 86–95% em 25/07/2026): a primeira queda (16/07 → 24/07) refletiu o crescimento genuíno da amostra validada (4.681 → 9.096 decisões); a leitura mais provável, retomada na Seção 5, é que a amostra menor de 16/07 estava mais concentrada em casos já fáceis de confirmar como corretos, e a ampliação da cobertura revelou uma taxa de acerto real mais baixa nessa consolidação. A segunda mudança

(24/07 → 25/07), documentada acima, foi causada por uma materialização desatualizada dos modelos, não por crescimento de amostra (a amostra validada permanece 9.096 nas duas consolidações). Ainda assim, como a seleção da conferência humana não é probabilística, a comparação entre consolidações continua sendo descritiva, não inferencial (COCHRAN, 1977); não é possível estimar, a partir dessas consolidações, o desempenho da base completa.

4.3 A classificação oficial frente ao histórico: matriz de confusão validada

Um resultado adicional, obtido comparando a categoria histórica e a classificação da IA oficial (coluna G, executor LSTM/RF) contra a mesma verdade decidida pela memória M/N/P, qualifica a tese de rótulos ruidosos apresentada na Introdução. Sobre as 9.096 decisões travadas desta consolidação, a categoria histórica (GLPI) coincide com a decisão em 96,49% dos casos (8.777 de 9.096), acima do acerto da IA oficial frente à mesma verdade (90,15%; 8.200 de 9.096) — repetindo, em magnitude renovada, o padrão já observado em 16/07/2026 (98,54% contra 95,08%, sobre uma amostra bem menor). A matriz de confusão IA×histórico mostra 8.200 casos em que ambos coincidem com a decisão, 319 em que nenhum dos dois coincide, 577 em que o histórico acerta e a IA erra, e **nenhum** caso, nesta consolidação, em que a IA corrige uma categoria histórica que a decisão considerou incorreta. Diferentemente da observação anterior (13 casos de correção da IA sobre 4.737 conferências), a ausência total dessa célula nesta base maior tem explicação estrutural discutida abaixo, não deve ser lida automaticamente como “a IA nunca corrige o histórico”. O que o resultado sustenta com mais segurança é a outra metade da premissa: existe ruído real no histórico — 319 dos 9.096 casos conferidos (3,51%, quase o triplo da proporção observada em 16/07/2026) têm categoria histórica que não coincide com a decisão final —, mas esse ruído é proporcionalmente menor do que o risco de erro isolado da IA nesta mesma amostra (577 casos, 6,34%). A implicação prática permanece: a IA deve ser tratada como instrumento de triagem e auditoria complementar ao histórico, não como substituto ou árbitro superior a ele.

Tabela 4 Matriz de confusão IA×histórico contra a verdade decidida (M/N/P) (n = 9.096)

	Histórico correto	Histórico incorreto
IA correta	8.200	0
IA incorreta	577	319

Fonte: `calibracao.json`, gerado em 23/07/2026 21:53. Leitura: 8.200 casos em que ambos (IA e histórico) coincidem com a categoria decidida; 319 em que nenhum dos dois coincide; 577 em que o histórico acerta e a IA erra; e **zero** casos em que a IA acerta e o histórico erra. A ausência total de casos na célula “IA correta / histórico incorreto” chama atenção e tem explicação estrutural, não é necessariamente evidência de que a IA nunca corrige o histórico: quando a categoria decidida vem de confirmação da própria categoria histórica (fonte `conferencia_glpi`), a célula “histórico incorreto” fica automaticamente descartada para aquela linha; a memória de decisão (Subseção 3.7) também reaproveita categorias já travadas em rodadas anteriores, o que tende a alinhar a classificação vigente da IA (coluna G no momento do snapshot) com decisões já confirmadas. Antes de tratar essa célula-zero como achado substantivo (ex.: “a IA nunca corrige o histórico”), recomenda-se auditoria dirigida da fonte de decisão (fonte `decisao`) por linha — não realizada nesta rodada.

4.4 Confiança, calibração e faixas de decisão

A calibração bruta da Etapa 1 oficial mantém ECE histórico de 0,0598 nesta consolidação. Quando segmentada por faixa de confiança e cruzada com a verdade decidida pela memória M/N/P — não mais com a marcação bruta de uma única coluna de conferência, correção aplicada em `src/calibracao.py` nesta rodada (ver observação metodológica adiante) —, a faixa igual ou superior a 95% de confiança (n = 4.808; 34,4% da base) apresenta concordância de 99,08% com o histórico e, mais relevante, acerto validado de 96,79% sobre os 4.698 casos já com decisão travada nessa faixa — resultado que fica muito próximo da meta de referência do experimento (confiança calibrada $\geq 95\%$ associada a acerto real $\geq 95\%$), embora não a atinja com folga. Nas faixas inferiores, a degradação de desempenho acompanha a queda de confiança de forma consistente (90–95%: acerto validado 91,48%; 80–90%: 93,92%; 70–80%: 94,95%; 50–70%: 83,94%; inferior a 50%: 49,89%), o que corrobora a correlação positiva entre confiança bruta e acerto — quantificada nesta consolidação por Spearman entre 0,45 e 0,56 conforme o modelo (Subseção 4.1, `estatistica.json`) —, mesmo sem

calibração formal (Platt/isotônica) aplicada a essa camada. A faixa 80–90% (93,92%) supera ligeiramente a faixa 90–95% (91,48%) — pequena inversão de monotonia plausível em dados reais com amostras desse tamanho, mas que merece acompanhamento nas próximas consolidações antes de ser tratada como padrão estável.

Tabela 3 Acerto validado por faixa de confiança bruta, executor oficial (Etapa 1), contra a verdade decidida M/N/P (n = 9.096 decisões travadas)

Faixa	n total	Concord. histórico	n validados	Acerto validado
< 50%	3.972	42,35%	876	49,89%
50–70%	1.504	73,40%	741	83,94%
70–80%	972	87,45%	654	94,95%
80–90%	1.499	87,99%	1.118	93,92%
90–95%	1.210	92,98%	1.009	91,48%
>= 95%	4.808	99,08%	4.698	96,79%

Fonte: `calibracao.json`, gerado em 23/07/2026 21:53. A amostra de conferência prioriza divergências e casos de menor confiança na composição original, não é aleatória — a leitura acima deve ser tomada como piso/teto conforme o desenho da conferência, não como taxa de acerto sobre amostra representativa.

Nota metodológica: até 22/07/2026, esta tabela comparava a classificação do executor apenas contra a marcação bruta da coluna N (CONFERÊNCIA IA) isolada, o que produzia acerto validado artificialmente igual a 100% em toda faixa de confiança, inclusive abaixo de 50% — a coluna N, no uso real, quase nunca recebe marcação “Errado” (o erro da IA costuma ficar registrado via M, sem tocar N). Corrigido em `src/calibracao.py` no commit 21258deb (23/07/2026): a comparação passou a usar a categoria decidida pela memória M/N/P (`decisao_validada.verdade_validada`), a mesma verdade da Subseção 4.2, eliminando o viés de seleção. Teste de regressão em `tests/test_calibracao.py`.

4.5 Reclassificação e ganho líquido

A reclassificação dos chamados já conferidos produz resultados heterogêneos entre modelos, medidos contra a verdade validada quando travada e contra o histórico nos demais casos. Na consolidação de 24/07/2026, o LSTM apresenta o maior ganho líquido absoluto (+99; 670 corrigidos e 571 prejudicados), seguido por Regressão Logística (+92) e LinearSVC (+73). Todos os sete modelos materializados apresentam ganho líquido positivo nesta execução. Esse resultado não autoriza aplicação indiscriminada: o ganho combina parcelas comparadas contra verdade validada e contra histórico, e pode mudar a cada rodada. Reforça-se a decisão de não aplicar reclassificação em massa de forma indiscriminada por modelo, tratando o ganho líquido, e não apenas a acurácia agregada, como critério de decisão operacional por classificador — e de reavaliar esse critério a cada rodada, não como veredito permanente: a execução de 30/06/2026 havia apontado SGD e Random Forest como negativos; ambos passaram a positivo nesta consolidação.

Tabela 5 Ganho líquido de reclassificação por modelo (execução de 24/07/2026)

Modelo	Total reclassificado	Corrigidos	Prejudicados	Ganho líquido	Reuso de decisão humana
LSTM	13.905	670	571	+99	8.805
Regressão Logística	13.932	245	153	+92	8.727
LinearSVC	13.965	291	218	+73	8.856
Random Forest	13.912	234	186	+48	8.719
SGD	13.965	201	163	+38	8.771
Naive Bayes	13.826	158	132	+26	8.623
Extra Trees	13.899	237	226	+11	8.713

Fonte: `reclass_resumo.json`, gerado em 24/07/2026 16:14. *Nota metodológica:* o total reclassificado do Random Forest chegava a 18.049 nesta mesma tabela em versão anterior deste texto, valor que excedia o tamanho da base (13.965) — matematicamente impossível sob a premissa de uma linha por chamado. Diagnóstico direto da planilha (workflow de diagnóstico de uso único, 23/07/2026) confirmou 4.737 linhas duplicadas na aba `RECLASS__random_forest` (18.049 linhas brutas para 13.312 identificadores de linha distintos), enquanto a aba de referência `RECLASS__linear_svc` não apresentou nenhuma duplicata (13.451 = 13.451) — descartando erro de leitura genérico e localizando o problema especificamente na aba do Random Forest. Corrigido em `src/exportar_dashboard.py` (commit `a244b59b`): a agregação agora deduplica por identificador de linha antes de contar, mantendo a última ocorrência. A causa raiz foi identificada e corrigida no commit `098c477e`: `_append_resiliente()` reenviava o lote inteiro após erro transitório de API, sem confirmar se a escrita anterior já havia sido aceita. O JSON vigente é posterior à correção e registra a remoção das 4.737 linhas duplicadas históricas.

4.6 Diagnóstico de taxonomia e ambiguidade estrutural (Shannon/Jensen-Shannon)

O diagnóstico de Shannon foi recalculado sobre oito fontes comparáveis: a Etapa 1 oficial e os sete modelos materializados. O artefato legado `transformer_ft` foi excluído porque `bertimbau_training_state.json` registra `sem_dados`. A Etapa 1 oficial apresenta a maior diversidade de categorias previstas e a menor divergência de Jensen-Shannon frente à distribuição histórica. No nível de chamado individual, 3.277 dos 13.965 registros (23,5%) apresentam alta entropia de votos entre as oito fontes, ou seja, desacordo estrutural relevante entre arquiteturas distintas — um critério de priorização de auditoria diferente e complementar à simples baixa confiança de um único modelo. No nível de categoria, a análise aponta 76 ocorrências de alta ambiguidade nas predições (com suporte mínimo de 30 registros por categoria); a interpretação detalhada de quais categorias específicas concentram essa ambiguidade, e sua sobreposição com os pares de maior confusão recíproca identificados na etapa de cruzamento de taxonomia, permanece como candidata a inspeção qualitativa dirigida — nesta consolidação, essa sobreposição não pôde ser detalhada com exemplos de categorias por causa da corrupção de acentuação identificada na Subseção 4.8. O que a camada Shannon oferece é a priorização estatística de onde essa inspeção deve começar, não a decisão de fusão ou desambiguação de categorias, que continua sendo humana. Naive Bayes chama atenção por combinar a menor cobertura de categorias (19, ante 47–53 dos demais modelos) com entropia normalizada relativamente alta (0,7848) — provável reflexo de concentração extrema em poucas categorias com alguma dispersão residual, não investigado em detalhe nesta rodada.

Tabela 6 Entropia de Shannon e divergência de Jensen-Shannon por fonte de classificação (24/07/2026)

Fonte	Categorias previstas	Entropia (nats)	Entropia normalizada	JS vs. histórico
Etapa 1 oficial	53	4,6758	0,8163	0,0286
LSTM	52	4,6201	0,8105	0,0847
Regressão Logística	52	4,4490	0,7805	0,0716
SGD	53	4,4363	0,7745	0,0639
LinearSVC	53	4,3356	0,7569	0,0575
Extra Trees	47	3,9955	0,7193	0,0761
Random Forest	47	3,9574	0,7124	0,0804
Naive Bayes	19	3,3340	0,7848	0,1755

Fonte: `shannon_modelos.json`, `jensen_shannon_modelos.json` e `shannon_resumo.json`, regenerados em 24/07/2026 por `src/analise_shannon.py`. O `transformer_ft` foi excluído explicitamente por não haver treino BERTimbau concluído. No nível de categoria, o resumo aponta 76 ocorrências de alta ambiguidade e 3.277 chamados com alta entropia de votos entre modelos. Naive Bayes chama atenção por combinar a menor cobertura de categorias (19, ante 47–53 dos demais) com entropia normalizada relativamente alta (0,7848) — provável reflexo de concentração extrema em poucas categorias com alguma dispersão residual, não investigado em detalhe nesta rodada.

4.7 Custo computacional

Nos recortes de comparação por lote (1.000 registros cada), os seis modelos clássicos tiveram tempos de treino entre 1,14 s e 21,30 s. Não há medição comparável de custo para LSTM ou BERTimbau nesta consolidação; portanto, não é possível ordenar o custo desses dois modelos frente aos demais. A tabela informa exclusivamente as medições disponíveis para os modelos clássicos.

Tabela 7 Custo computacional por lote de 1.000 registros

Modelo	Tempo de treino (s)	Tempo de inferência (s)	Acurácia neste lote
Naive Bayes	1,14	0,07	0,539
LinearSVC	2,55	0,06	0,655
SGD	2,60	0,09	0,624
Regressão Logística	9,43	0,09	0,624
Random Forest	19,45	0,13	0,597
Extra Trees	21,30	0,14	0,610

Fonte: `comparacao_modelos.json`, execução mais recente por modelo em 18/07/2026 03:30 — não reexecutado nesta consolidação; único registro de custo computacional disponível no painel para os modelos clássicos. LSTM e BERTimbau não constam deste arquivo. A acurácia reportada aqui é sobre um lote de 1.000 registros (não a base completa) e serve só para contextualizar o trade-off custo×desempenho desta subseção — não usar como substituto das Tabelas 1 e 2.

4.8 Figuras

Atualização de dados (24/07/2026): as figuras foram geradas a partir dos JSONs vigentes do painel, da aba viva de métricas por categoria e dos treinos executados por workflow com credencial (scripts `matplotlib`, ver `04_artigo/figuras/`). A Figura 4 usa códigos de categoria para preservar a legibilidade; o mapeamento completo código-categoria está na Tabela Suplementar S2.

Figura 2 Confiança bruta × concordância com o histórico × acerto validado, por faixa de confiança (executor oficial, Etapa 1). Mesmos números da Tabela 3 (Subseção 4.4), em forma gráfica.

Fonte: `calibracao.json`, gerado em 23/07/2026 21:53.

Figura 3 Trade-off entre acerto validado (conferência humana, 23/07/2026) e custo computacional (tempo de treino, lote de 1.000 registros, 18/07/2026), modelos clássicos. LSTM e BERTimbau não constam desta figura por não terem registro de tempo de treino no mesmo arquivo (Tabela 7, Subseção 4.7).

Fonte: `comparacao_modelos.json` (custo) e `avaliacao_final.json` (acerto validado).

Figura 4 Top 15 pares de maior confusão entre categorias, agregados a partir do campo `top_confusoes` de `estatistica.json`. O par mais recorrente foi Climatização > Ar condicionado → Manutenção Preventiva > Ar condicionado split (1.310 ocorrências agregadas), seguido por Instalação de Acessórios e Mobiliário > Instalação/reparo de equipamentos (Suportes de TV, acessórios de banheiro e quadro branco) → Estrutura Predial > Alvenaria / Pisos / Estrutura (799) e Estrutura Predial > Alvenaria / Pisos / Estrutura → Estrutura Predial > Esquadrias, porta, portão e janelas (726). Os códigos C01-C10 usados no eixo vertical são descritos na Tabela Suplementar S2 (`04_artigo/figuras/tabela_S2_codigos_categorias_fig4.csv`).

Fonte: `estatistica.json`, campo `top_confusoes`, gerado em 24/07/2026 20:52; figura gerada por `src/gerar_figura4_confusoes.py`.

Figura 5 Curva real de aprendizado do LSTM gerada pelo workflow 30137383907, com 13.965 exemplos e 53 categorias. O treino foi interrompido por `EarlyStopping` após 11 épocas. O menor `val_loss` ocorreu na época 8 (`val_loss` = 1,4374; `accuracy` = 0,7073; `val_accuracy` = 0,6492), enquanto o maior `val_accuracy` ocorreu na época 10 (`val_accuracy` = 0,6722; `val_loss` = 1,4767).

Fonte: `04_artigo/figuras/lstm_history.json`, gerado por `src/modelo_lstm.py`.

Figura 2 - Confiança bruta x concordância x acerto validado, por faixa
(executor oficial, Etapa 1 - 23/07/2026)




Figura 2: Figura 2 — Confiança bruta × concordância com o histórico × acerto validado, por faixa de confiança (executor oficial, Etapa 1, 23/07/2026).

Figura 6 — discrepância investigada e resolvida (atualizado em 25/07/2026): a auditoria das rodadas 10-11 investigou por que este ablation reportava acerto validado muito acima do valor oficial então vigente para a mesma arquitetura do LSTM. Duas causas foram identificadas, em ordem de descoberta. Primeiro, um vazamento metodológico real, mas de magnitude modesta: no KFold aleatório por linha usado originalmente, 4.250 de 9.096 linhas validadas de teste (46,72%) tinham duplicata textual normalizada no treino (`diagnostico_ablation_lstm_duplicatas.json`). O ablation foi refeito com GroupKFold por hash de texto normalizado, excluindo do treino grupos textuais presentes no teste — isso reduziu a configuração atual (`units = 64`, `dropout = 0,5`) de 87,68% para 86,35% (7.854/9.096), uma correção pequena (1,33 ponto percentual). Segundo, e principal: o valor oficial de referência usado na comparação (0,7471, Subseção 4.2) vinha de uma materialização de `CLASSIF_lstm` datada de 16-17/07/2026, mais de uma semana desatualizada em relação à base viva. A rematerialização completa dos sete modelos em 25/07/2026 (ver nota de rastreabilidade na Subseção 4.2) produziu um novo valor oficial do LSTM de 0,8790 (confirmado após limpeza completa e rematerialização de todos os 8 modelos na rodada 15, 25/07/2026) — muito mais próximo dos 0,8635 deste ablation corrigido (diferença residual de 1,55 pontos percentuais, plausivelmente atribuível a diferenças remanescentes de protocolo: `k_folds=3` no ablation contra `k_folds=5` na materialização oficial, e treino por fold isolado contra o esquema *out-of-fold* padrão). **Conclusão:** o ablation nunca teve um problema metodológico grave; a maior parte da discrepância original vinha de comparar um resultado fresco com uma referência oficial desatualizada. A ordenação relativa das quatro variantes testadas (`units=128`, `dropout=0,3` como melhor, seguida de `units=128`, `dropout=0,5`, `units=64`, `dropout=0,5` e `units=64`, `dropout=0,3`) é interpretada como evidência preliminar de baixa sensibilidade do LSTM a esses hiperparâmetros nesta base (diferença total entre a melhor e a pior variante inferior a 4 pontos percentuais), não como indicação forte de que a arquitetura atual esteja subotimizada.

Fonte: `04_artigo/figuras/diagnostico_ablation_lstm_duplicatas.json`, `04_artigo/figuras/ablation_lstm_result`, `04_artigo/figuras/diagnostico_materializacao_lstm_nova.json` e `04_artigo/figuras/tabela_S3_ablation_lstm.c` gerados por `src/ablation_lstm.py`. Ver `PLANO_ARTIGO_CAPITULO.md`, “Estado desta rodada”, para o registro completo da investigação.




Figura 3: Figura 3 — Trade-off entre acerto validado e custo computacional (tempo de treino), modelos clássicos.




Figura 4: Figura 4 — Top 15 pares de maior confusão entre categorias, agregados a partir dos top pares por modelo.




Figura 5: Figura 5 — Curva de aprendizado do LSTM por época.




Figura 6: Figura 6 — Ablation study do LSTM: unidades recorrentes e dropout.

5. DISCUSSÃO

A comparação entre concordância histórica (Subseção 4.1) e desempenho validado (Subseção 4.2) revela um padrão que mudou de magnitude ao longo da elaboração deste capítulo e que, por isso, merece registro explícito antes de qualquer outra leitura, agora em três consolidações: na de 16/07/2026, sobre 4.681 decisões travadas, o acerto validado (92–96%) superava com folga a concordância com o histórico (70–80%); na de 23-24/07/2026, sobre 9.096 decisões — quase o dobro —, os dois patamares se aproximaram (concordância 68–80%, acerto validado 71–80%), com o LinearSVC em 80,34% de concordância e 79,89% de acerto validado; na consolidação vigente (25/07/2026), após a rematerialização completa dos sete modelos ter corrigido uma defasagem de mais de uma semana na materialização anterior (Subseção 4.9), o acerto validado voltou a superar a concordância histórica (concordância 68–80%, acerto validado 86–95%), com o LinearSVC em 80,29% de concordância e 94,93% de acerto validado. A primeira transição (16/07 → 24/07) refletiu crescimento genuíno da amostra validada; a segunda (24/07 → 25/07) refletiu correção de uma materialização desatualizada dos modelos, não mudança na amostra validada (9.096 nas duas consolidações). Nenhuma das mudanças observadas entre consolidações permite estimar o desempenho real da base completa: a conferência humana não é aleatória e prioriza divergências e casos críticos. Portanto, os resultados devem ser lidos como descrição da amostra conferida, não como estimativa representativa da população de chamados (COCHRAN, 1977).

Além da não aleatoriedade da amostra, identificamos nesta rodada um segundo mecanismo de viés, estrutural e mais específico: a própria regra de decisão da verdade validada (Subseção 3.7) exclui do denominador de qualquer acerto validado os chamados em que o avaliador humano julgou todas as fontes conferidas erradas (“restritos”). Dos 9.534 chamados com alguma conferência preenchida nesta consolidação, 438 (4,6%) estão nessa condição e ficam fora dos 9.096 usados na Subseção 4.2. Como não existe, para esses 438 casos, uma categoria de referência contra a qual comparar a predição de cada modelo, o acerto validado reportado como número pontual é, na verdade, um limite superior: mede o desempenho apenas nos casos em que pelo menos uma fonte (histórico ou IA) já estava certa, por construção. A análise de sensibilidade publicada em `04_artigo/figuras/sensibilidade_vies_validacao.json` recalcula um limite inferior (pior caso, contando os 438 restritos como erro de todos os modelos) e mostra que a amplitude do intervalo é de 3,95 a 4,36 pontos percentuais conforme o modelo — relevante em termos absolutos, mas sem alterar o

ranking relativo entre os sete modelos em nenhum ponto do intervalo. A implicação para a leitura deste capítulo é dupla: a conclusão qualitativa (qual modelo priorizar) é robusta a esse viés, mas o valor pontual de acerto validado não deveria ser citado isoladamente, nem comparado a benchmarks externos, sem a ressalva do intervalo. Esse mecanismo também ajuda a explicar por que a célula “IA correta / histórico incorreto” da matriz de confusão (Subseção 4.3) permanece em zero: casos em que o avaliador não confirma nenhuma fonte como correta — justamente onde a IA teria mais chance de estar certa sozinha, sem confirmação do histórico — são os que ficam de fora da amostra decidida por construção, não porque a IA de fato nunca acerte quando o histórico erra.

Ainda assim, a distinção entre concordância e acerto validado continua metodologicamente necessária, e a matriz IA×histórico (Subseção 4.3) mostra por quê: quando os dois discordam da decisão final, o histórico está correto com frequência muito maior (577 casos) do que a IA corrige um erro genuíno do histórico (0 casos nesta consolidação — com a ressalva estrutural já registrada na Subseção 4.3 sobre essa célula específica). Esse achado não invalida a premissa metodológica de que a categoria histórica não deve ser tratada como verdade absoluta — ainda existe uma taxa real de erro confirmado no registro original (3,51% dos casos conferidos nesta consolidação, quase o triplo do 1,2% observado em 16/07/2026, o que por si só recomenda cautela contra tratar mesmo esse número como estabilizado) —, mas recomenda cautela contra a leitura oposta e igualmente equivocada, de que baixa concordância com o histórico implica automaticamente acerto da IA. A validação humana, portanto, cumpre função insubstituível: sem ela, seria impossível distinguir as duas situações apenas observando a taxa de concordância — e, como o achado acima demonstra, seria impossível também saber se uma amostra de validação já é grande o bastante para ser tratada como representativa.

Na amostra conferida, o LinearSVC lidera tanto a concordância histórica quanto o acerto validado (Subseções 4.1 e 4.2). Isso descreve o resultado desta base e desta amostra, sem demonstrar superioridade generalizável de classificadores lineares sobre arquiteturas neurais. A comparação de custo também permanece restrita aos seis modelos clássicos da Tabela 7. Os ensembles serão reavaliados somente após a regeneração de `avaliacao_final.json` sem `transformer_ft`.

O resultado da reclassificação (Subseção 4.5) introduz uma nuance operacional importante: o ganho líquido de corrigir chamados já classificados não é uniforme entre modelos nem estável ao longo do tempo. Na execução de 30/06/2026, três dos seis classificadores clássicos avaliados (SGD, Random Forest e Extra Trees) tinham ganho líquido negativo; na execução de 23/07/2026, com o LSTM incluído na comparação, apenas Extra Trees e Naive Bayes permanecem negativos — SGD e Random Forest passaram a positivo. Essa oscilação, por si só, reforça o argumento: decisões de reclassificação em produção devem ser tomadas por modelo e reavaliadas a cada rodada, com base no ganho líquido medido naquele momento, e não generalizadas a partir do desempenho médio de concordância ou acerto validado, nem tratadas como um veredito permanente sobre determinado classificador — um modelo pode ser competitivo na classificação inicial e, ainda assim, não ser um bom candidato a reclassificar decisões já tomadas em todas as rodadas.

A camada de entropia de Shannon e divergência de Jensen-Shannon (Subseção 4.6) não substitui as métricas supervisionadas ou a validação humana, mas amplia o repertório de governança do experimento ao separar três fenômenos que a acurácia isolada tende a confundir: erro de modelo, ambiguidade genuína da taxonomia institucional e heterogeneidade natural da distribuição de chamados. A identificação de 3.277 chamados (23,5% da base) com alto desacordo estrutural entre as oito fontes comparáveis (Etapa 1 oficial e os sete modelos materializados) oferece um critério de priorização de auditoria distinto do simples corte por baixa confiança de um único classificador, e complementa a fila já construída a partir da conferência M/N/P. O achado de que a Etapa 1 oficial, não o LSTM isolado, lidera tanto a diversidade de predições quanto a menor divergência frente ao histórico (Subseção 4.6) descreve o resultado desta consolidação. Esse diagnóstico não substitui acurácia ou validação humana.

A meta de confiança calibrada igual ou superior a 95% associada a acerto real igual ou superior a 95% (Subseção 4.4), estabelecida como critério de sucesso deste protocolo, fica próxima de ser atingida, mas não é mais alcançada com folga como sugeria a consolidação anterior: a faixa alta de confiança da Etapa 1 oficial chega a 96,79% de acerto validado sobre 4.698 casos conferidos (ante 99,73% sobre 3.284 casos em 16/07/2026), ainda que a confiança utilizada seja bruta (softmax/decision_function), não formalmente calibrada por Platt ou isotônica (PLATT, 1999; GUO *et al.*, 2017). Essa queda de 99,73% para 96,79% na própria faixa de mais alta confiança, à medida que a conferência quase dobrou de tamanho, é o mesmo padrão discutido acima

para o acerto validado geral, e reforça a mesma cautela: a amostra validada, embora agora cubra 68,3% da base (ante 33,9% em 16/07/2026), ainda prioriza divergências e casos de menor confiança na sua composição original, o que pode ter inflado artificialmente o acerto validado nas faixas de alta confiança das consolidações anteriores, onde a conferência tendia a simplesmente confirmar o que já era esperado. A confirmação definitiva da meta depende da conclusão da conferência humana sobre a fração ainda não conferida da base (31,7%), e a trajetória observada entre 16/07 e 23/07/2026 recomenda que a leitura de “meta já atingida” só seja aceita quando essa conferência estiver substancialmente mais completa, não a cada consolidação intermediária.

As limitações do estudo foram atualizadas em relação à versão anterior, com seis ajustes relevantes. Primeiro, a amostra validada deixou de ser uma amostra piloto de 305 casos (2,2% da base) e passou a cobrir 9.534 conferências (68,3% da base, 9.096 decisões travadas sem conflito), o que aumenta substancialmente a robustez estatística das Subseções 4.2 a 4.4 — mas, como discutido acima, essa mesma ampliação já revelou que a robustez estatística de uma amostra intermediária não garante estabilidade da magnitude do resultado, apenas de sua direção geral (a ordem entre modelos manteve-se; o patamar de acerto, não). Segundo, os conflitos de conferência identificados em versões anteriores do protocolo (casos em que duas colunas de conferência confirmam categorias diferentes) permanecem em zero nos dados publicados (`conflitos = 0` em `avaliacao_final.json`), o que não elimina a possibilidade de novos conflitos surgirem à medida que a conferência avança sobre os 31,7% da base ainda sem decisão travada. Terceiro, o BERTimbau permanece pendente: o estado publicado é `sem_dados`, sem treino concluído nem métricas próprias. Assim, o artefato legado `transformer_ft` foi excluído de rankings, testes e diagnósticos comparativos; não há evidência suficiente para concluir sobre seu desempenho neste domínio. Investigação nesta rodada (25/07/2026) identificou a causa raiz: o fluxo automático de classificação (executado a cada 15 minutos) nunca instala as dependências pesadas (`torch`, `transformers`) necessárias para o fine-tuning real, e o código, ao não encontrá-las, cai silenciosamente para o mesmo classificador LSTM usado em outra parte do experimento — sem registrar esse desvio em nenhum artefato publicado. Confirmado em log de execução real (17/07/2026): a materialização inteira então publicada sob o rótulo `transformer_ft` (13.954 dos 13.965 chamados) foi produzida por esse caminho de contingência, não por fine-tuning do BERTimbau. Essa causa já foi corrigida no código (o fluxo agora recusa publicar resultados sob o nome de um modelo quando suas dependências de fato não estão disponíveis, em vez de substituí-los silenciosamente); os artefatos publicados anteriormente sob `transformer_ft` continuam a ser tratados como não confiáveis e devem ser desconsiderados até uma rematerialização real com as dependências corretas instaladas. Quarto, uma suspeita de corrupção de acentuação (mojibake) nos nomes de categoria de arquivos-fonte usados para análises de confusão entre categorias (Subseção 4.8), registrada em rodada anterior como pendência técnica, foi investigada nesta rodada e **não se confirmou**: verificação byte a byte dos quatro arquivos envolvidos mostrou UTF-8 válido em sua totalidade; os caracteres corrompidos observados antes eram artefato de exibição do terminal usado para inspecionar os dados, não corrupção do dado publicado. A quarta figura planejada deixa de estar bloqueada por qualidade de dado. Quinto, a discrepância do ablation study do LSTM (registrada em rodada anterior como pendência técnica) foi investigada e resolvida em 25/07/2026: uma fração pequena vinha de vazamento por duplicatas (corrigido via `GroupKFold`), e a maior parte vinha da avaliação oficial de referência estar desatualizada. A rematerialização completa dos sete modelos comparáveis (Subseção 4.2) substituiu o valor histórico do LSTM (74,71%) pelo valor atual (87,90%, reconfirmado após limpeza completa e nova rematerialização na rodada 15), muito mais próximo do ablation corrigido (86,35%). O ablation deixa de ser tratado como diagnóstico isolado e passa a ser lido como evidência preliminar de baixa sensibilidade do LSTM aos hiperparâmetros testados, consistente com a nova avaliação oficial. Sexto, identificamos e quantificamos um viés estrutural de seleção na própria amostra validada, discutido em detalhe na Seção 5: a regra de decisão da verdade validada exclui do denominador de acerto validado os 438 chamados (4,6% dos 9.534 conferidos) em que nenhuma fonte conferida foi confirmada como correta, o que infla mecanicamente o número pontual reportado na Subseção 4.2. Publicamos um intervalo de sensibilidade (04_artigo/figuras/sensibilidade_vies_validacao.json) com amplitude de 3,95 a 4,36 pontos percentuais conforme o modelo; o ranking relativo entre os sete modelos permanece estável em todo o intervalo, mas o valor absoluto de acerto validado não deve ser interpretado como uma estimativa isenta de viés, nem comparado ponto a ponto com benchmarks externos sem essa ressalva. Persistem também como limitações a dependência de uma única instituição como caso empírico e a intermitência observada na publicação automática do painel no GitHub Pages, discutida na auditoria técnica que acompanha este capítulo.

6. CONSIDERAÇÕES FINAIS

O presente capítulo atualizou o protocolo de classificação automática multimodelo de chamados de manutenção predial universitária em português brasileiro com os resultados acumulados até 24 de julho de 2026, incluindo sete modelos materializados, uma camada de memória de decisão por veto e trava de categorias já conferidas, e uma camada de análise informacional baseada em entropia de Shannon e divergência de Jensen-Shannon. O BERTimbau permanece como extensão planejada, sem treino concluído ou métricas próprias. A contribuição central permanece metodológica: não apenas identificar o melhor classificador, mas estruturar um protocolo em que aprendizado de máquina, estatística não paramétrica, memória de decisão e auditoria humana qualificam progressivamente a base de dados e revelam inconsistências taxonômicas — e, como esta rodada demonstrou, também revelam e corrigem inconsistências no próprio pipeline de avaliação (Subseções 4.3 e 4.4).

Na amostra parcial, não aleatória, de 9.096 chamados com decisão travada e sem conflito, o LinearSVC obteve o maior acerto validado entre os sete modelos comparáveis: 94,93% (IC95%: 94,47%–95,38%), seguido de SGD (93,92%), Regressão Logística (93,55%), Extra Trees (92,74%), Random Forest (92,27%), LSTM (87,90%) e Naive Bayes (86,09%) — números rematerializados em 25/07/2026, incluindo uma limpeza completa e reproprocessamento do zero dos oito modelos na rodada 15 (a materialização anterior, de 16-17/07, havia sido identificada como desatualizada; Subseção 4.9). Nenhum dos três ensembles avaliados (maioria ponderada, confiança calibrada máxima, maioria simples) supera o LinearSVC isolado com significância estatística; a recomendação é usar o LinearSVC isolado, com calibração, em vez de combinar modelos. Esses números não estimam o desempenho da base completa, pois a seleção da conferência prioriza divergências e casos críticos (COCHRAN, 1977). A matriz IA $\times$ histórico registra que o histórico administrativo também contém erros confirmados, o que mantém a validação humana como parte necessária do protocolo; a proporção observada nessa amostra não deve ser generalizada sem desenho probabilístico (COCHRAN, 1977).

A meta original do experimento — confiança calibrada igual ou superior a 95% associada a acerto validado igual ou superior a 95% — fica próxima de ser atingida na faixa de alta confiança da classificação oficial (96,79% de acerto validado, ante 99,73% na consolidação anterior sobre amostra menor), resultado que recomenda cautela redobrada em relação à já registrada na versão anterior deste texto: a trajetória entre 16/07 e 23/07/2026 mostrou que mesmo a leitura “meta atingida” pode reverter quando a amostra de conferência cresce, o que reforça — e não apenas repete — a recomendação de não tratar a meta como cumprida para fins de liberação em produção sem revisão antes da conclusão da conferência humana sobre uma fração bem mais representativa da base. A curva real de aprendizado do LSTM (Subseção 4.9, Figura 5) é consistente com o restante do capítulo. O ablation study do mesmo modelo (Figura 6) teve sua discrepância original investigada e resolvida nas rodadas 10-11: um vazamento por duplicatas textuais entre folds (46,72% das linhas validadas de teste) explicou uma fração pequena da diferença (corrigido com `GroupKFold`, de 87,68% para 86,35%); a maior parte da discrepância vinha da avaliação oficial de referência estar desatualizada (materialização de 16-17/07/2026). A rematerialização completa dos sete modelos em 25/07/2026 (Subseção 4.2, reconfirmada após limpeza completa e reproprocessamento do zero na rodada 15) produziu um novo valor oficial do LSTM (87,90%) próximo do ablation corrigido (86,35%, diferença residual de 1,55 pontos percentuais, atribuível a `k_folds` distinto entre os dois protocolos). Com a discrepância principal resolvida, a ordenação relativa das quatro variantes do ablation é lida como evidência preliminar de baixa sensibilidade do LSTM a unidades/dropout nesta base (diferença entre melhor e pior variante inferior a 4 pontos percentuais), não como indicação de que a arquitetura atual esteja mal ajustada. Os próximos passos deste protocolo incluem a conclusão da conferência humana pendente (31,7% da base ainda sem decisão travada), a calibração formal por modelo (Platt/isotônica/temperatura) condicionada a essa conferência, a realização do treino e da avaliação comparativa do transformador BERTimbau, a revisão taxonômica dirigida pelos candidatos identificados na etapa de cruzamento de taxonomia e na entropia de Shannon, e a estabilização da publicação automática do painel, cuja intermitência técnica está documentada na auditoria que acompanha este capítulo. Como direções de trabalho futuro mais amplas, este protocolo também aponta para (i) a validação externa do modelo em outras instituições federais de ensino superior, testando se o padrão de desempenho observado na UFSB se mantém sob taxonomias e volumes de chamados distintos, e (ii) a integração dos dados de chamados tratados e validados como entrada para um modelo multicritério (MCDM/TOPSIS) de priorização de manutenção, conectando este capítulo empírico à lacuna identificada no capítulo de revisão integrativa sobre o uso raro de dados operacionais de chamados nesse tipo de modelo. Com isso, o protocolo pretende seguir contribuindo

tanto para a literatura de *facility management* e processamento de linguagem natural aplicado quanto para a melhoria concreta e continuamente auditável da gestão de manutenção predial em instituições públicas — inclusive como exemplo de que a própria prática de reconferir dados vivos antes de publicar, defendida ao longo deste capítulo, é capaz de encontrar e corrigir falhas no pipeline de avaliação, não apenas nos rótulos históricos que motivaram o estudo.

REFERÊNCIAS

- ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. ABNT NBR 5674: Manutenção de edificações: Requisitos para o sistema de gestão de manutenção. Rio de Janeiro: ABNT, 2012.
- BOUABDALLAOUI, Y.; LAFHAJ, Z.; YIM, P.; DUCOULOMBIER, L.; BENNADJI, B. Natural Language Processing Model for Managing Maintenance Requests in Buildings. *Buildings*, v. 10, n. 9, art. 160, 2020.
- COCHRAN, W. G. Sampling techniques. 3. ed. New York: John Wiley & Sons, 1977.
- GALKE, L.; SCHERP, A. Bag-of-words vs. graph vs. sequence in text classification: questioning the necessity of text-graphs and the surprising strength of a wide MLP. In: ANNUAL MEETING OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS, 60., 2022, Dublin. Proceedings [...]. Dublin: ACL, 2022. p. 4038–4051.
- GRAVES, A.; SCHMIDHUBER, J. Framewise phoneme classification with bidirectional LSTM and other neural network architectures. *Neural Networks*, v. 18, n. 5-6, p. 602–610, 2005.
- GUO, C.; PLEISS, G.; SUN, Y.; WEINBERGER, K. Q. On calibration of modern neural networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 34., 2017, Sydney. Proceedings [...]. Sydney: PMLR, 2017. p. 1321–1330.
- JOACHIMS, T. Text categorization with support vector machines: learning with many relevant features. In: EUROPEAN CONFERENCE ON MACHINE LEARNING, 10., 1998, Chemnitz. Proceedings [...]. Berlin: Springer, 1998. p. 137–142.
- KEJRIWAL, M.; SANTOS, H.; SHEN, K.; MULVEHILL, A. M.; MCGUINNESS, D. L. A noise audit of human-labeled benchmarks for machine commonsense reasoning. *Scientific Reports*, v. 14, art. 8609, 2024.
- LIN, J. Divergence measures based on the Shannon entropy. *IEEE Transactions on Information Theory*, v. 37, n. 1, p. 145–151, 1991. DOI: 10.1109/18.61115.
- LI, Y.; LIU, Y.; ZHANG, J.; CAO, L.; WANG, Q. Automated analysis and assignment of maintenance work orders using natural language processing. *Automation in Construction*, v. 165, art. 105501, 2024.
- LIU, Z.; BENGE, C.; JIANG, S. Ticket-BERT: labeling incident management tickets with language models. arXiv:2307.00108, 2023.
- MARTINS, R. F. B.; ESPEJO, M. M. S. B. Análise de custos de manutenção predial em uma universidade federal brasileira com uso do modelo de SES. *ABCustos*, São Leopoldo, v. 19, n. 1, p. 79–98, 2024.
- MCNEMAR, Q. Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, v. 12, n. 2, p. 153–157, 1947.
- MOHAMMED, A. S.; AMOAH, C. Integration of technology in decision-making in university facilities management: a literature review. *Facilities*, v. 43, n. 13/14, p. 1018–1052, 2025.
- MORAIS, L. S. R. de; PAULA, H. M. de; REIS, R. P. A. Promoção da eficiência da manutenção predial em edificações públicas: abordagem baseada em registros de ordens de serviço. *Paranoá*, Brasília, v. 16, n. 34, p. 1–18, 2023. DOI: 10.18830/issn.1679-0944.n34.2023.08.
- PAMPANA, A. K. et al. Data-driven analysis for facility management in higher education institution. *Buildings*, v. 12, art. 2094, 2022.
- PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.

- PLATT, J. C. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. In: SMOLA, A. J. et al. (Ed.). *Advances in Large Margin Classifiers*. Cambridge: MIT Press, 1999. p. 61–74.
- SALTON, G.; BUCKLEY, C. Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, v. 24, n. 5, p. 513–523, 1988.
- SCHWARTZ, R.; DODGE, J.; SMITH, N. A.; ETZIONI, O. Green AI. *Communications of the ACM*, v. 63, n. 12, p. 54–63, 2020.
- SHANNON, C. E. A mathematical theory of communication. *Bell System Technical Journal*, v. 27, n. 3, p. 379–423, jul. 1948; v. 27, n. 4, p. 623–656, out. 1948.
- SOKOLOVA, M.; LAPALME, G. A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, v. 45, n. 4, p. 427–437, 2009.
- SUNDARAM, S.; ZEID, A. Technical Language Processing for Prognostics and Health Management: applying text similarity and topic modeling to maintenance work orders. *Journal of Intelligent Manufacturing*, v. 36, p. 1637–1657, 2025.
- TREVISIO, M. et al. Efficient methods for Natural Language Processing: a survey. *Transactions of the Association for Computational Linguistics*, v. 11, p. 826–860, 2023.
- ZHANG, H.; ZHANG, Y.; LI, J.; LIU, J.; JI, L. A survey on learning with noisy labels in Natural Language Processing: how to train models with label noise. *Engineering Applications of Artificial Intelligence*, v. 146, art. 110157, 2025.

APÊNDICES

Apêndice A — Dicionário de colunas da planilha experimental (A:P)

A aba experimental (CHAMADOS_ESQUELETO_REDUZIDO) segue o esquema fixo A:P, descrito em `AGENTS.md` do repositório:

Coluna	Campo
A	ID Chamado
B	TÍTULO
C	CATEGORIA COMPLETA (rótulo histórico)
D	DESCRIÇÃO GLPI
E	TÍTULO O.S.M.
F	DESCRIÇÃO O.S.M.
G	Classificação IA
H	Avaliação (%) — gravada como fração 0–1, formatada como %
I	Executor
J	Criticidade Atribuída por IA
K	Comparação — fórmula $=SE(G="";"";G=C)$
L	Classificado_Confiança_IA
M	CONFERÊNCIA GLPI
N	CONFERÊNCIA IA
O	Classificação IA - 2
P	CONFERÊNCIA IA - 2

Apêndice B — Checklist de itens reportados

Adaptado do espírito do checklist tipo PRISMA-ScR do artigo-modelo de revisão (MCDM/TOPSIS/ODS/ESG) para relato de experimento de classificação supervisionada com validação humana. Cada item indica a subseção onde é reportado e o status na data de publicação; **não substitui a reconferência de números**

antes da submissão — os status “Sim” abaixo atestam que o item é reportado em algum lugar do texto, não que o número citado já foi revalidado contra os JSONs vigentes.

Item	Subseção	Reportado?
Fonte de dados e sistema de origem declarados	3.1, 3.2	Sim (GLPI/UFSB)
Tamanho da amostra e período/corte de consolidação	3.2	Sim, mas com data de corte a reconferir
Critério de inclusão/exclusão de registros	3.2	Parcial — “chamados não vazios” declarado; demais critérios não detalhados
Pré-processamento textual	3.3	Sim
Modelos avaliados e hiperparâmetros principais	3.4	Sim (7 materializados + 1 em extensão)
Justificativa conceitual das diferenças de desempenho entre modelos	3.4.1	Sim
Método de particionamento (out-of-fold, k-fold, seed)	3.5	Sim (out-of-fold, KFold embaralhado, <code>random_state=42</code> ; sem estratificação)
Métricas reportadas e justificativa	3.5	Sim (acurácia, macro-F1, balanced accuracy, IC95% bootstrap)
Testes estatísticos e correção para múltiplas comparações	3.5	Sim (Cochran Q, Friedman, McNemar, Nemenyi)
Critério de calibração de confiança (bruta vs. calibrada) e meta de desempenho	3.8, 4.4	Parcial — meta declarada ($\geq 95\%$); calibração formal (Platt/isotônica) ainda não aplicada
Protocolo de validação humana	3.6	Sim
Cobertura da validação humana na data de publicação (n e % da base)	4 (abertura)	Sim, mas desatualizada — ver nota de revalidação de dados
Tratamento de conflitos de conferência	3.7	Sim (regra de veto/trava)
Reprodutibilidade (scripts e dados versionados)	3.9	Sim (repositório público, JSONs sanitizados)
Limitações declaradas	5, 6	Sim
Figuras/tabelas geradas a partir de dados verificáveis	4.8	Não — pendência explícita registrada

Apêndice C — Matriz de decisão M/N/P

Contagens agregadas disponíveis nos JSONs públicos do painel (23/07/2026):

Métrica	n
Chamados com ao menos uma conferência (M, N ou P)	9.534
Decisões travadas (categoria decidida sem conflito)	9.096
Casos restritos (categoria eliminada, sem decisão travada)	438
Conflitos (M e N confirmam categorias diferentes)	0
Conferências da coluna N (CONFERÊNCIA IA) preenchidas	9.096
Conferências da coluna M (CONFERÊNCIA GLPI) preenchidas	9.534

Métrica	n
Conferências da coluna P (CONFERÊNCIA IA - 2) preenchidas	0

Fonte: `auditoria_conferencias.json` e `calibracao.json`, gerados em 23/07/2026. A coluna P (reclassificação conferida) está zerada nesta consolidação — nenhuma reclassificação foi conferida via essa coluna especificamente até esta data.

Pendência explícita: o cruzamento fino de 3 vias (contagem por combinação exata de valores de $M \times N \times P$ — ex.: quantos casos têm M =Correto e N =Errado simultaneamente) **não está disponível em nenhum JSON público atual** e exige extração direta da planilha experimental (**Informação insuficiente para verificar** com os dados hoje publicados). O que se aproxima disso é a matriz 2×2 IA $\times$ histórico da Tabela 4 (Subseção 4.3), que cruza acerto da IA e do histórico contra a verdade decidida — não é o mesmo cruzamento $M \times N \times P$ bruto, mas cobre a mesma pergunta de fundo (quando IA e histórico concordam ou divergem da decisão final).