

CLASSIFICAÇÃO AUTOMÁTICA MULTIMODELO DE CHAMADOS DE MANUTENÇÃO PREDIAL UNIVERSITÁRIA EM PORTUGUÊS BRASILEIRO COM VALIDAÇÃO HUMANA

Multi-model automatic classification of university building maintenance work orders in Brazilian Portuguese with human validation

Adinailson Guimarães de Oliveira - adinailson.oliveira@cja.ufsb.edu.br **Fabício Berton Zanchi** - fabricao.berton@ufsb.edu.br

Universidade Federal do Sul da Bahia (UFSB), Programa de Pós-Graduação em Biosistemas

RESUMO

A classificação automática de chamados de manutenção predial constitui recurso estratégico para qualificar a triagem operacional e ampliar a governança baseada em evidências em instituições públicas. Em bases históricas de sistemas informatizados de gestão de chamados, contudo, a categoria originalmente registrada não deve ser tratada como referência definitiva, pois pode refletir decisões operacionais ruidosas, taxonomias sobrepostas, registros incompletos e interpretações heterogêneas entre equipes. Este artigo propõe um protocolo multimodelo para classificação de chamados reais de manutenção predial universitária em português brasileiro, extraídos do sistema institucional da Universidade Federal do Sul da Bahia. O experimento utiliza 14.060 chamados não vazios, organizados em 50 categorias históricas. A comparação principal avalia seis classificadores clássicos baseados em TF-IDF e uma rede neural LSTM bidirecional por predições *out-of-fold* sob validação cruzada agrupada por texto, o que impede que chamados de texto idêntico atravessem treino e teste. O BERTimbau, transformador pré-treinado em português, fica fora da comparação por custo medido, uma vez que o ajuste fino projeta 6,44 horas por dobra em processador sem acelerador gráfico. O diferencial metodológico reside na distinção entre concordância com o histórico administrativo e acerto contra a referência humana revisada, obtida por auditoria de rótulo conduzida por especialista único sobre a totalidade do corpus e apurada sobre as 13.972 linhas de 41 categorias com suporte nas cinco dobras. O LinearSVC lidera as duas leituras, com acordo bruto de 79,61% frente ao histórico e acurácia de 82,53% frente à referência humana. O achado central contraria a expectativa que motivou o estudo: o ganho líquido de reclassificação da base histórica é negativo em todos os sete modelos, de -1.846 no melhor deles a -3.474 no pior, porque o especialista manteve a categoria histórica em 95,75% dos registros e divergir do histórico significa, quase sempre, divergir também da referência; sob função de utilidade com custos assimétricos, a reescrita só compensaria se estragar um registro valesse menos de um quinto do que vale corrigir outro. A mesma divergência serve, porém, à priorização da auditoria humana, com enriquecimento de cerca de quatro vezes sobre a revisão aleatória. Uma camada explícita de regras de periodicidade, avaliada nas mesmas partições, mostra-se redundante e melhora o F1 macro de apenas três dos sete modelos. O custo computacional permanece dimensão relevante da decisão e favorece modelos lineares em cenários de texto curto, ruidoso e desbalanceado: o LinearSVC treina em 2,44 s, contra 83,44 s da rede recorrente no mesmo ambiente. O F1 macro de 0,6684 resulta da composição da métrica, pois o mesmo modelo alcança 0,8207 nas 12 categorias que concentram 81,83% do volume e distingue manutenção preventiva de corretiva com F1 de 0,9742 e 0,9547.

Palavras-chave: manutenção predial; classificação de chamados; processamento de linguagem natural; rótulos ruidosos; validação humana.

ABSTRACT

Automatic classification of building maintenance work orders is a strategic resource for improving operational triage and evidence-based governance in public institutions. However, the originally assigned category in historical service-management databases should not be treated as a definitive reference because it may reflect noisy operational decisions, overlapping taxonomies, incomplete records, and heterogeneous interpretations. This paper proposes a multi-model protocol for classifying real university building maintenance requests in Brazilian Portuguese from the Federal University of Southern Bahia. The experiment uses 14,060 non-empty records organized into 50 historical categories. The main comparison evaluates six TF-IDF-based classical classifiers and a bidirectional LSTM through out-of-fold predictions under text-grouped cross-validation, which prevents work orders sharing identical text from crossing the train-test boundary. BERTimbau, a Portuguese pre-trained transformer, is excluded from the main comparison on measured cost grounds, as fine-tuning

projects 6.44 hours per fold on a processor without graphics acceleration. The methodological contribution is the distinction between agreement with the administrative history and accuracy against the revised human reference, obtained through a label-audit review carried out by a single specialist over the entire corpus and computed over 13,972 records in the 41 categories with support across all five folds. LinearSVC leads both readings, with 79.61% raw agreement against the history and 82.53% accuracy against the human reference. The central finding contradicts the expectation that motivated the study: the net gain from reclassifying the historical base is negative for all seven models, from $-1,846$ in the best to $-3,474$ in the worst, because the specialist retained the historical category in 95.75% of records, so departing from the history almost always means departing from the reference as well; under an explicit utility function with asymmetric costs, rewriting would only pay off if damaging a record were worth less than a fifth of correcting another. The same divergence does, however, serve to prioritise the human audit queue, with about a fourfold enrichment over random review. An explicit periodicity rule layer, evaluated on the same partitions, proves redundant and improves macro F1 for only three of the seven models. Computational cost remains a relevant decision dimension and favors linear models in short, noisy, and imbalanced text settings: LinearSVC trains in 2.44 s, against 83.44 s for the recurrent network in the same environment. The macro F1 of 0.6684 stems from how the metric is composed, since the same model reaches 0.8207 on the 12 categories that concentrate 81.83% of the volume and tells preventive from corrective maintenance with F1 of 0.9742 and 0.9547.

Keywords: building maintenance; work-order classification; natural language processing; noisy labels; human validation.

1. INTRODUÇÃO

Um campus universitário pode ser descrito como um biossistema construído, isto é, a integração dinâmica entre infraestrutura física, atividade humana, sistemas tecnológicos e condicionantes ambientais, cuja persistência ao longo do tempo depende de mecanismos de retroalimentação contínua entre uso, falha e reparo (CAPRA, 1996; ODUM, 1971). A ecologia urbana descreve esse tipo de sistema como um organismo em troca permanente de matéria, energia e informação com seu entorno, cuja governança bem-sucedida depende da capacidade institucional de captar sinais operacionais e convertê-los em decisão (GRIMM *et al.*, 2008). Em instituições federais de ensino superior (IFES), esse sinal assume, na prática, a forma de registros textuais de chamados de manutenção predial, matéria-prima do *feedback* operacional do biossistema construído. Esses registros, no entanto, nascem aprisionados em linguagem não estruturada, fragmentária e sujeita a interpretação individual no momento do atendimento, o que impede seu uso direto por qualquer mecanismo de decisão automatizada (MORAIS; PAULA; REIS, 2023; MOHAMMED; AMOAH, 2025).

A exploração analítica dessas bases enfrenta três obstáculos estruturais, agravados pela restrição orçamentária que historicamente limita o custeio da manutenção predial em IFES a patamares inferiores a 2% do orçamento institucional (MARTINS; ESPEJO, 2024; PAMPANA *et al.*, 2022). O primeiro é a natureza textual curta e heterogênea dos registros, redigidos em linguagem técnica fragmentária, com abreviações locais e jargões de equipe que dificultam a aplicação direta de modelos genéricos de processamento de linguagem natural (PLN) (SUNDARAM; ZEID, 2025). O segundo é o desbalanceamento entre categorias, dado que demandas recorrentes de climatização, elétrica e hidrossanitária concentram grande parte da base, ao passo que categorias raras dispõem de poucos exemplos para treinamento supervisionado (LI *et al.*, 2024). O terceiro, e o mais consequente do ponto de vista metodológico, é a qualidade do próprio rótulo histórico, que pode resultar de interpretação rápida, conveniência operacional ou taxonomia ainda não estabilizada, de modo a constituir evidência importante, mas não referência definitiva (ZHANG *et al.*, 2025; KEJRIWAL *et al.*, 2024).

A literatura recente confirma a relevância do PLN para converter esses registros em insumo de gestão: Li *et al.* (2024) alcançam acurácia de 0,83 na atribuição automática de equipes sobre 15.623 ordens de serviço hospitalares, Bouabdallaoui *et al.* (2020) reportam 78% na classificação de requisições em edificação hospitalar, e Sundaram e Zeid (2025) argumentam que textos técnicos de manutenção funcionam como *black holes* informacionais quando armazenam dados relevantes sem serem utilizados na decisão. A maior parte dessas aplicações concentra-se, contudo, em bases em inglês ou chinês e em domínios industriais ou hospitalares, o que configura lacuna para corpora em português brasileiro no contexto da manutenção predial pública universitária.

Diante desse quadro, a pergunta que orienta este artigo não é qual classificador mais concorda com a categoria

histórica, e sim como extrair de texto ruidoso, de forma confiável e auditável, o dado estruturado capaz de alimentar um sistema de governança preditiva sem herdar acriticamente as inconsistências do histórico que lhe deu origem, de modo que divergências entre modelo e histórico sejam tratadas como evidência de revisão taxonômica, e não como ruído a descartar.

Com base em chamados reais da Universidade Federal do Sul da Bahia (UFSB), este artigo propõe uma comparação multimodelo de classificadores de texto aplicada a chamados de manutenção predial em português brasileiro. A base experimental contém 14.060 chamados não vazios em 50 categorias históricas, e os campos textuais agregam título e descrição do chamado, além de informações da ordem de serviço. O estudo compara modelos clássicos baseados em TF-IDF com uma rede neural LSTM bidirecional; o BERTimbau é ajustado, mas fica fora da comparação principal por custo medido. O objeto de avaliação não é o classificador isolado, mas o protocolo de governança que articula aprendizado de máquina, auditoria estatística, custo computacional e revisão humana, formulação consoante à manutenção baseada em evidências preconizada pela NBR 5674 (ABNT, 2012) e à integração físico-humano-tecnológico-ambiental que caracteriza um biosistema construído.

Quatro objetivos específicos orientam o trabalho: apresentar um protocolo de classificação que produza dado estruturado auditável a partir de texto livre; distinguir a concordância com o rótulo histórico do acerto contra a referência humana revisada; avaliar o desempenho por métricas balanceadas, intervalos e testes pareados que respeitem a dependência entre chamados de texto repetido, incorporando o custo computacional como dimensão de decisão; e determinar, por medição e não por presunção, se a classificação automática é capaz de corrigir retroativamente a base histórica.

2. REFERENCIAL CONCEITUAL

2.1 Processamento de linguagem natural em ordens de manutenção

Ordens de manutenção constituem registros operacionais de valor informacional elevado e uso habitualmente reduzido, pois documentam sintomas, locais, equipamentos e soluções executadas em forma textual e semi-estruturada que dificulta o emprego direto no planejamento e na alocação de recursos (PAMPANA *et al.*, 2022; MORAIS; PAULA; REIS, 2023). Li *et al.* (2024) constituem a referência-âncora desta pesquisa por tratarem diretamente da automação de ordens de manutenção predial, ainda que em idioma, tipologia institucional e estrutura taxonômica distintos, e Sundaram e Zeid (2025) acrescentam a perspectiva pertinente ao caso universitário, na qual chamados curtos, abreviações locais e descrições incompletas inviabilizam modelos genéricos sem adaptação lexical e semântica ao corpus específico.

2.2 Classificação de tickets e evolução dos modelos

A classificação automática de *tickets* em ambientes de suporte técnico e ITSM evoluiu de representações vetoriais baseadas em frequência lexical para *embeddings* e modelos de linguagem pré-treinados. Liu, Bengue e Jiang (2023) propuseram o Ticket-BERT para rotulagem de *tickets* de incidentes, enfatizando desafios como atualização contínua de rótulos e necessidade de aprendizado ativo. Entretanto, a transferência direta de achados do ITSM para a manutenção predial deve ser cautelosa, pois a semântica do domínio envolve sistemas físicos, ambientes e equipamentos prediais que não coincidem com categorias de incidentes de *software* ou infraestrutura digital (SUNDARAM; ZEID, 2025).

Modelos lineares com TF-IDF permanecem competitivos em tarefas de texto curto, sobretudo quando o corpus é de porte médio, o vocabulário possui alta especificidade técnica e as classes são desbalanceadas. Galke e Scherp (2022), em revisão comparativa de métodos para classificação textual, demonstraram que classificadores baseados em *bag-of-words* com TF-IDF e SVM sustentam desempenho equivalente ao de redes neurais em múltiplos *benchmarks* quando o corpus é reduzido ou o vocabulário é especializado. O achado é particularmente pertinente à manutenção predial institucional, cuja base operacional raramente atinge escala compatível com as exigências de modelos de linguagem de grande porte.

2.3 Rótulos ruidosos e referência operacional

O ruído de rótulo é problema central do aprendizado supervisionado sobre bases administrativas e, em classificação textual, decorre de ambiguidade semântica, polissemia, insuficiência de contexto, sobreposição taxonômica ou erro de registro (ZHANG *et al.*, 2025). Kejriwal *et al.* (2024) acrescentam que *benchmarks*

rotulados por humanos contêm variabilidade relevante, o que questiona a prática de assumir referência única onde há julgamento subjetivo. Neste artigo, por conseguinte, a categoria histórica é tratada como registro administrativo sujeito a auditoria, e a referência de avaliação é construída por revisão humana com registro explícito da decisão.

2.4 Custo computacional e eficiência em PLN

A avaliação de modelos de PLN tem sido tradicionalmente orientada por métricas de desempenho, mas a literatura recente enfatiza que custo computacional, tempo de treino, consumo energético e reprodutibilidade também devem compor a decisão de adoção (TREVISIO *et al.*, 2023; SCHWARTZ *et al.*, 2020). Treviso *et al.* (2023) argumentam que a ampliação de escala em PLN aumenta o consumo de dados, tempo, armazenamento e energia, motivando métodos eficientes em contextos de recursos limitados, e Schwartz *et al.* (2020) cunharam o conceito de *Green AI*, pelo qual a eficiência computacional deve ser reportada e valorizada na avaliação de modelos, não apenas a acurácia. Em uma instituição pública, essa dimensão é operacionalmente decisiva. Um modelo que treina em segundos pode ser reexecutado frequentemente, auditado com facilidade e mantido sem infraestrutura dedicada, ao passo que um modelo que demanda dezenas de minutos exige *checkpoint*, controle de versão de pesos e justificativa robusta de ganho marginal (TREVISIO *et al.*, 2023).

Os modelos de linguagem de grande porte não integram esta comparação. Operam sobre representações contextuais em arquitetura de transformador (VASWANI *et al.*, 2017) e dispensam ajuste supervisionado, pois inferem a tarefa de instruções e de poucos exemplos no próprio enunciado (BROWN *et al.*, 2020), do que decorre a expectativa de maior acurácia em chamados de redação atípica. Sua adoção esbarra, contudo, em três restrições diante do critério de eficiência aqui adotado: a execução exige aceleradores dedicados ou serviços tarifados por uso, incompatíveis com a reexecução frequente que o fluxo institucional pressupõe; o processamento por terceiros desloca as descrições dos chamados para fora do domínio da universidade; e a variabilidade das respostas entre versões do serviço compromete a reprodutibilidade exigida pelo delineamento (BENDER *et al.*, 2021). Como a tarefa é fechada e institucionalmente delimitada, condição na qual classificadores baseados em *bag-of-words* permanecem competitivos (GALKE; SCHERP, 2022), a avaliação desses modelos fica indicada como desdobramento futuro.

3. MÉTODO

3.1 Delineamento geral

O estudo adota delineamento experimental aplicado, com base observacional retrospectiva de chamados de manutenção predial registrados no sistema GLPI institucional da UFSB, universidade multicampi com unidades em Itabuna, Ilhéus, Porto Seguro e Teixeira de Freitas (MORAIS; PAULA; REIS, 2023). A unidade de análise é o chamado individual de manutenção, representado por campos textuais concatenados e por uma categoria histórica registrada no sistema. O fluxo metodológico compõe-se de oito etapas sequenciais: (i) extração e consolidação da base; (ii) revisão humana do corpus integral, da qual resulta a categoria de referência; (iii) higienização textual; (iv) construção da matriz de atributos; (v) partições agrupadas por texto e treinamento com predições *out-of-fold*; (vi) comparação com a categoria histórica e com a referência revisada; (vii) inferência estatística não paramétrica; e (viii) calibração e automação seletiva por confiança. A Figura 1 apresenta esse fluxo como *pipeline* de governança preditiva. A posição da revisão humana não é acessória: ela precede o treinamento, porque é dela que sai o rótulo com que os modelos são treinados e contra o qual são avaliados.

3.2 Corpus e variáveis

O corpus experimental é composto por 14.060 chamados de manutenção predial não vazios, organizados em 50 categorias históricas, extraídos do ambiente institucional da UFSB. Os campos textuais são o título e a descrição do chamado e o título e a descrição da ordem de serviço, concatenados em uma única representação. A categoria histórica é referência preliminar de comparação, mas a avaliação conclusiva depende da referência revisada por humano. O idioma é o português brasileiro, com presença significativa de jargões técnicos, nomes de ambientes, abreviações locais e descrições incompletas, características que impõem desafios de pré-processamento e representação (SUNDARAM; ZEID, 2025).

Como a base operacional é alimentada continuamente pelo sistema de atendimento, todos os resultados da Seção 4 referem-se a um corte único de extração, que totaliza 14.060 registros elegíveis. Os artefatos que




Figura 1: Pipeline de governança preditiva, do fluxo de extração da base à retroalimentação por validação humana.

sustentam cada número foram materializados sobre esse mesmo corte e estão versionados, de modo que a reprodução não depende do estado corrente do sistema institucional. O corte não carrega, contudo, a data de abertura do chamado: as variáveis congeladas são o identificador reduzido, a categoria histórica, a referência revisada e sua origem, de sorte que o corpus não admite ordenação cronológica, restrição cuja consequência para o alcance dos resultados é tratada na Subseção 5.3. A distribuição completa entre as 50 categorias históricas é apresentada no Apêndice A.

3.3 Pré-processamento textual

Pequenas decisões de normalização alteram a matriz de atributos e, com ela, o desempenho dos modelos (SALTON; BUCKLEY, 1988), de modo que o pré-processamento é documentado de modo reprodutível. Para os classificadores clássicos, a representação principal é TF-IDF com *n-gramas* de uma e duas palavras e limite superior de 30.000 atributos; para a LSTM, tokenização própria com vocabulário de 8.000 termos e comprimento máximo de 120 *tokens*. O vetorizador, o tokenizador e o vocabulário são ajustados dentro de cada dobra, sobre a partição de treino, de modo que nenhuma estatística do conjunto de teste participa da representação. A etapa não elimina indiscriminadamente termos técnicos, códigos de ambientes ou nomes de equipamentos, pois palavras como *bomba*, *split*, *disjuntor*, *vazamento* e *infiltração* funcionam como âncoras semânticas de categorias específicas.

3.4 Modelos avaliados

O desenho experimental compara sete modelos, organizados em três famílias conceituais, cada uma escolhida por um motivo específico ligado às características do domínio, ou seja, texto curto, vocabulário técnico e forte desbalanceamento entre categorias (Subseção 3.2).

A família linear (LinearSVC, Regressão Logística e SGD) opera diretamente sobre a representação TF-IDF esparsa (Subseção 3.3). Em espaços de alta dimensionalidade, fronteiras lineares tendem a separar bem as classes quando o vocabulário carrega forte poder discriminativo (JOACHIMS, 1998; SALTON; BUCKLEY, 1988), como é o caso dos termos técnicos de manutenção predial, que funcionam como âncoras semânticas de categoria. A família de *ensembles* de árvores (Random Forest e Extra Trees) captura interações não lineares entre atributos, a um custo computacional maior. O **Naive Bayes Multinomial** entra como *baseline* probabilístico mais simples, útil para calibrar a expectativa de desempenho mínimo (JOACHIMS, 1998; PEDREGOSA *et al.*, 2011). A rede neural (LSTM Bidirecional) modela dependências sequenciais no texto, mas treina seus *embeddings* do zero, sem incorporar vetores pré-treinados em português (GRAVES; SCHMIDHUBER, 2005). Os sete modelos são avaliados na comparação *out-of-fold* (Subseção 4.1). Em paralelo, a classificação automática em produção opera com uma regra de contingência que aciona o Random Forest quando a base rotulada disponível é insuficiente para treinar a rede neural.

Um oitavo modelo, o BERTimbau-Base, incorpora representações contextuais pré-treinadas em português

brasileiro e é ajustado para as 50 categorias do corpus (DEVLIN *et al.*, 2019; SOUZA; NOGUEIRA; LOTUFO, 2020). O treino foi concluído em modo automático, com subamostragem estratificada e parada antecipada por restrição computacional. Como o modelo não possui predições *out-of-fold* materializadas sobre toda a base, ele não é inserido artificialmente no ranking integral dos sete modelos. Sua viabilidade computacional é examinada na Subseção 4.3.

Duas suposições de família explicam boa parte da dispersão de desempenho observada adiante. O Naive Bayes assume independência condicional entre atributos dada a classe, suposição violada em texto de manutenção predial, no qual termos técnicos co-ocorrem sistematicamente dentro de uma mesma categoria; daí sua última posição nas duas leituras e o colapso do F1 macro em 0,2951, com predições restritas a 22 das 41 categorias. A LSTM, por sua vez, concentra na camada de *embedding* cerca de 1,02 milhão de parâmetros, ordem de grandeza próxima do número de exemplos por partição de treino, já que dos 13.972 chamados cerca de 11.178 compõem cada uma das cinco. O cenário é consoante à hipótese de que modelos lineares igualam ou superam redes neurais em corpora de porte médio e ruidosos, quando não há *embeddings* pré-treinados disponíveis no idioma (GALKE; SCHERP, 2022), e a curva de aprendizado da Subseção 4.8 mostra saturação precoce, e não instabilidade de treino.

3.5 Desenho de avaliação

A avaliação se dá por predições fora da amostra em protocolo *out-of-fold* com **StratifiedGroupKFold**, cinco dobras e semente fixa, estratificado pela referência humana e agrupado pelo hash do texto normalizado, de modo que nenhum grupo textual atravessa a fronteira entre treino e teste. As partições são geradas uma única vez, versionadas e reutilizadas por todos os modelos e pela camada de regras, o que reduz o viés de comparação e legitima os testes pareados (SOKOLOVA; LAPALME, 2009). A validação cruzada foi preferida a um conjunto de teste fixo porque produz estimativas de menor variância em bases desbalanceadas, ao avaliar cada exemplo em alguma dobra em vez de descartar uma fração constante do treino (KOHAVI, 1995), condição pertinente a um corpus em que várias categorias apresentam suporte de dígito único. Cabe delimitar o que esse desenho estima. A separação entre treino e teste é textual, e não cronológica, de modo que as métricas da Seção 4 medem generalização para grupos de texto não vistos dentro do mesmo corte de extração, e não desempenho sobre chamados posteriores, sujeitos a deriva de vocabulário e a alteração de taxonomia.

São reportadas acurácia, *macro-F1*, *balanced accuracy* e intervalo de confiança a 95% por *bootstrap*, reamostragem com reposição que estima a distribuição de uma estatística sem pressupor sua forma paramétrica (EFRON, 1979; EFRON; TIBSHIRANI, 1993; DICICCIO; EFRON, 1996). A *macro-F1* e a *balanced accuracy* respondem ao desbalanceamento entre categorias, dado que a acurácia isolada superestima o desempenho nas classes majoritárias e mascara falhas nas raras (SOKOLOVA; LAPALME, 2009).

A unidade de análise da inferência é o grupo textual, e não o chamado individual. Chamados de manutenção repetem-se: 4.586 das 14.060 linhas, ou 32,62%, compartilham texto normalizado com outra linha, a base congelada resolve-se em 9.786 grupos, dos quais 9.474 são unitários, e 9.735 desses grupos sobrevivem ao recorte das 13.972 linhas avaliadas. Registros de texto idêntico recebem a mesma predição de qualquer classificador textual e não constituem evidências independentes, de modo que tratá-los como tal declara mais informação do que a amostra contém e estreita artificialmente qualquer intervalo ou valor de p (COCHRAN, 1977). É a mesma dependência que justifica o particionamento agrupado, e seria incoerente controlá-la no treino e ignorá-la na inferência.

Daí decorre a ordem declarada dos testes. A hipótese global de que os sete classificadores têm a mesma taxa de acerto é apurada pela estatística Q de Cochran (COCHRAN, 1950), pareada e adequada a resposta binária, mas a distribuição qui-quadrado tabelada é substituída por uma distribuição de referência empírica: sob a hipótese nula os modelos são permutáveis, e a permutação do rótulo de modelo é aplicada ao grupo inteiro, o que preserva a dependência interna (GOOD, 2005; ANDERSON; TER BRAAK, 2003). Rejeitada a igualdade, cada um dos 21 pares é comparado por permutação pareada com troca de sinal da diferença de acertos por grupo, com correção sequencial de Holm-Bonferroni sobre a família, que controla a taxa de erro familiar sem o conservadorismo da correção de Bonferroni simples (HOLM, 1979). Os intervalos das métricas e das diferenças vêm de *bootstrap* de conglomerados, no qual se sorteiam grupos com reposição e se reconstrói a amostra com todos os registros de cada grupo sorteado (FIELD; WELSH, 2007; CAMERON;

GELBACH; MILLER, 2008). O protocolo de Demšar (2006) recomenda o *post-hoc* de Nemenyi sobre postos médios (NEMENYI, 1963), mas Benavoli, Corani e Mangili (2016) demonstram que o teste de postos médios pode ser inconsistente e recomendam comparações pareadas diretas, razão pela qual a inferência repousa nestas. A estimação da incerteza por *bootstrap* em métricas preditivas permanece em refinamento (NOMA *et al.*, 2021), o que recomenda ler os intervalos ao lado dos testes, e não em substituição a eles.

A divisão aleatória por linha permanece apenas como análise de sensibilidade, cujo protocolo próprio e cujos resultados constam do material suplementar (Subseção 4.8).

O agrupamento impõe um custo de cobertura que precisa ser declarado. Uma categoria só entra na avaliação se dispuser de grupos textuais distintos em número suficiente para figurar nas cinco dobras, pois um grupo inteiro ocupa uma única dobra. Nove das 50 categorias não satisfazem essa condição, quatro por aritmética, tendo menos grupos distintos que dobras, e cinco por ausência efetiva em alguma dobra após a estratificação. Elas somam 88 linhas, ou 0,63% da base congelada, e sua exclusão reduz o denominador das métricas de 14.060 para 13.972 registros em 41 categorias. **O desempenho principal deste artigo não cobre, portanto, as 50 categorias da taxonomia: vale para as 41 com suporte nas cinco dobras, e as nove ausentes são justamente as de menor frequência.** Excluir rótulos de baixa frequência é prática corrente na classificação hierárquica de chamados (MARCUIZZO *et al.*, 2022), ainda que o limiar daqueles autores seja de cem ocorrências e o critério aqui adotado seja o suporte por dobra.

Três alternativas foram examinadas antes de manter o protocolo. Reduzir o número de dobras recupera categorias apenas por aritmética, e poucas: quatro dobras recuperariam uma categoria e quatro linhas, três dobras recuperariam três categorias e dez linhas, ao custo de menos treino por dobra e, sobretudo, de uma decisão de protocolo tomada depois de observado o resultado. Uma política de abstenção não recupera categoria alguma, porque o modelo não pode abster-se a favor de uma classe que não conhece, e o que ela oferece já é medido como automação seletiva por confiança na Subseção 4.4. A avaliação hierárquica fecha a lacuna de cobertura de categorias, uma vez que as nove excluídas pertencem a famílias com suporte, e sua versão útil à gestão, a tarefa de tipo de manutenção, já integra a Subseção 4.11. O efeito de cada convenção sobre o *macro*-F1 consta da Subseção 4.9, e a Tabela A3 discrimina as categorias excluídas.

O BERTimbau seria submetido ao mesmo protocolo, e a decisão de mantê-lo fora da comparação principal apoia-se em medição de custo, não em preferência editorial. O procedimento e o resultado dessa medição constam da Subseção 4.3.

3.6 Revisão humana e referência revisada

A revisão humana é a etapa que diferencia este estudo de uma comparação de classificadores contra histórico, e seu desenho delimita o que a referência autoriza afirmar. Trata-se de auditoria administrativa de rótulo, e não de anotação independente: a pergunta submetida ao especialista é se a categoria já registrada é adequada ao chamado. Para cada registro, o avaliador examinou o título e a descrição do chamado, o título e a descrição da ordem de serviço, quando existentes, e a categoria histórica; previsões e níveis de confiança dos modelos não estavam visíveis. Confirmada a categoria, ela permanece como referência; rejeitada, o avaliador registra outra categoria da mesma taxonomia. O resultado é a categoria de referência revisada, usada no treinamento e na avaliação dos modelos.

A revisão cobriu a totalidade do corpus: os 14.060 chamados receberam decisão do especialista, sendo 13.462 de manutenção da categoria histórica e 598 de substituição, taxa de alteração de 4,25%, sem que restasse chamado sem referência. Três desfechos não devem ser confundidos: manter a categoria é confirmação administrativa, isto é, o revisor não encontrou motivo para alterar o registro; concordância entre avaliadores exigiria segundo julgamento independente; e correção factual, no sentido de comprovar qual intervenção foi executada, exigiria evidência externa ao texto, como inspeção em campo, que este desenho não mobiliza.

A revisão foi conduzida por um único especialista, sem segunda avaliação, independente ou cega, e sem adjudicação de divergências, pela razão elementar de que existe uma única decisão por registro. Nenhuma medida de confiabilidade entre avaliadores é, portanto, reportada, e a segunda avaliação fica registrada como validação futura na Subseção 5.3. Pelo mesmo motivo não se reporta Kappa entre a referência revisada e a categoria histórica: o pressuposto de independência não se sustenta quando o revisor decide vendo o rótulo que audita.

Ver a categoria histórica é constitutivo da auditoria, já que julgar um rótulo inadequado pressupõe conhecê-lo, mas o efeito de ancoragem daí decorrente precisa ser explicitado: a exposição prévia ao rótulo eleva a probabilidade de mantê-lo, de modo que a taxa de confirmação de 95,75% reflete, em proporção não separável neste desenho, tanto a estabilidade do registro quanto o próprio procedimento. Dois elementos contextualizam a leitura sem resolvê-la. A categoria histórica não é atribuição isolada do demandante, pois resulta de registro seguido de verificação por equipe técnica de triagem, e a auditoria de rótulo é o procedimento pertinente ao uso pretendido, que é a governança de uma base administrativa existente, não a construção de um corpus anotado do zero.

Uma medida da consistência interna da referência está disponível sem segundo avaliador. Entre os grupos de texto idêntico, 17 receberam mais de uma categoria de referência, afetando 85 linhas, ou 0,61% das linhas avaliadas. A caracterização desses grupos desaconselha lê-los como taxa de erro de anotação: em 14 deles, somando 74 linhas, as categorias em disputa pertencem a tipos distintos de manutenção, e o par mais frequente opõe Hidrossanitária > Hidráulica a Manutenção Preventiva > Reservatório, com 11 grupos e 65 linhas. Chamados de texto idêntico podem, portanto, corresponder a intervenções de naturezas diferentes, distinção ausente do texto e irrecuperável por qualquer classificador textual. Separar as três origens possíveis, a saber, contexto não textual, erro de registro e inconsistência de anotação, exigiria reexame caso a caso, não realizado. O valor delimita um teto de desempenho atribuível à ambiguidade documentada, e não um piso de erro irredutível de anotação.

3.7 Camada de entropia de Shannon e divergência de Jensen-Shannon

Como dimensão complementar às métricas supervisionadas, o protocolo incorporou uma camada de análise informacional baseada em entropia de Shannon e divergência de Jensen-Shannon (SHANNON, 1948; LIN, 1991), calculada exclusivamente sobre agregados sanitizados. Ela responde a pergunta distinta da acurácia, a saber, onde se concentra a incerteza estrutural, e o que localiza não é erro de modelo, mas a região da taxonomia em que o próprio sistema de registro perdeu capacidade de discriminar. A camada opera em três níveis: no dos modelos, mede se um classificador dispersa ou concentra suas predições e a que distância a distribuição prevista fica da histórica; no das categorias, evidencia classes cujas predições se espalham entre múltiplas alternativas, candidatas prioritárias a revisão taxonômica; no do chamado individual, a entropia de votos entre modelos forma uma fila de auditoria orientada por ambiguidade, e não por baixa confiança isolada de um único classificador.

3.8 Governança e disponibilidade dos dados

Os chamados analisados têm origem no sistema institucional GLPI da UFSB e constituem registros administrativos de manutenção predial, produzidos na rotina de atendimento da instituição. A base de trabalho não é publicamente disponível, por restrição de privacidade institucional, e os campos textuais permanecem restritos ao ambiente do pesquisador. Os artefatos publicados são sanitizados na origem: nenhum identificador pessoal, identificador de chamado em texto claro, título ou descrição livre é gravado nos agregados versionados, e os mapas por registro usam o resumo criptográfico SHA-256 do identificador, o que preserva a junção entre etapas sem expor o dado. A camada de entropia da Subseção 3.7 opera exclusivamente sobre esses agregados. Essas medidas atendem ao princípio da necessidade previsto na Lei Geral de Proteção de Dados Pessoais (BRASIL, 2018), uma vez que a análise não requer dado pessoal e nenhum é retido nos produtos públicos da pesquisa.

Cabe registrar, para transparência, que o repositório não guarda documento de autorização institucional formal, de aprovação por comitê de ética ou de dispensa de apreciação ética, de modo que nada é aqui afirmado a esse respeito. O acesso à base decorre da atuação do primeiro autor na gestão da manutenção predial da própria instituição, e a formalização documental do consentimento institucional para uso científico dos registros é providência recomendada antes da submissão.

As métricas derivadas e o código que produz cada figura, tabela e estatística deste artigo são de acesso público no repositório <https://github.com/adinailson88/classificacao-chamados>, que também descreve a estrutura completa dos dados e o material suplementar citado neste artigo. Os artefatos são gerados por processo automatizado e reproduzível, reexecutado a cada atualização do experimento.

4. RESULTADOS

Esta seção segrega deliberadamente dois conjuntos de resultados: a concordância dos sete modelos com a categoria histórica, em que o registro administrativo opera como referência preliminar (Subseção 4.1), e o desempenho desses mesmos modelos contra a referência humana revisada (Subseção 4.2). Dois denominadores convivem no texto e não devem ser confundidos: a base congelada contém 14.060 chamados, todos com referência humana, e é o número pertinente sempre que a frase trata do corpus ou da cobertura da revisão, ao passo que as métricas são apuradas sobre as 13.972 linhas em 41 categorias que compõem as partições (Subseção 3.5; Tabela A3).

Quatro achados resumem a seção: o LinearSVC lidera tanto a concordância histórica quanto a acurácia contra a referência humana, e mantém vantagem de custo; o ganho líquido de reclassificação é negativo em todos os modelos, o que desautoriza a correção automática da base histórica em massa; a camada explícita de regras de periodicidade é redundante diante de um classificador competente; e a calibração viabiliza automação seletiva de cerca de dois terços do volume com acurácia próxima de 0,95.

4.1 Concordância com a categoria histórica

A comparação contra a categoria histórica, sobre as predições *out-of-fold* da rodada canônica ($n = 13.972$), mantém o LinearSVC na liderança, com acordo bruto de 0,7961, seguido por Extra Trees (0,7844), SGD (0,7781), Random Forest (0,7747), Regressão Logística (0,7738), LSTM (0,7017) e Naive Bayes (0,6954). A comparação exclui o BERTimbau, que não possui predições *out-of-fold* sobre as 13.972 linhas pelo motivo computacional exposto na Subseção 4.3. O Kappa de Cohen (COHEN, 1960) entre cada modelo e o histórico reproduz ordenação semelhante, variando de 0,7807 (LinearSVC) a 0,6653 (Naive Bayes), faixa que Landis e Koch (1977) classificam como concordância substancial. As duas medidas divergem em uma única troca de posição, entre Random Forest e Regressão Logística, decorrente da sensibilidade do coeficiente à prevalência das categorias, o que recomenda lê-lo ao lado do acordo bruto (WONGPAKARAN *et al.*, 2013). O coeficiente é aplicável aqui porque modelo e categoria histórica são fontes independentes de classificação, o que não vale entre a referência revisada e o histórico (Subseção 3.6).

Tabela 1 Concordância com a categoria histórica por modelo ($n = 13.972$).

Modelo	Acordo bruto	Kappa de Cohen
LinearSVC	0,7961	0,7807
Extra Trees	0,7844	0,7665
SGD	0,7781	0,7618
Random Forest	0,7747	0,7559
Regressão Logística	0,7738	0,7574
LSTM	0,7017	0,6809
Naive Bayes	0,6954	0,6653

O desempenho não é uniforme entre as 41 categorias avaliadas e concentra-se nas classes de maior volume: as de maior F1 pertencem todas à Manutenção Preventiva, com Ar condicionado split em 0,9972 sobre suporte de 1.987, ao passo que Projeto e Manutenção Preventiva sem subcategoria hidráulica não alcançam acerto algum, sobre suporte entre 13 e 65 registros, condição em que pequena variação absoluta altera fortemente a métrica. O desempenho por categoria, com suporte, tipo e classe de volume, consta da Tabela A2.

4.2 Acerto contra a referência humana revisada

A revisão humana estabeleceu categoria de referência para a totalidade dos 14.060 chamados da base congelada, e a avaliação incide sobre os 13.972 que compõem as partições canônicas. O LinearSVC é o melhor modelo em acurácia, com 0,8253 (IC95%: 0,8115–0,8378), seguido por SGD (0,8093), Extra Trees (0,8073), Regressão Logística (0,8050), Random Forest (0,7970), LSTM (0,7287) e Naive Bayes (0,7088). A vantagem sobre o SGD, segundo colocado, é de 1,60 ponto percentual, com 536 linhas de acerto exclusivo do LinearSVC contra 312 do SGD; a inferência que a sustenta, conduzida no nível do grupo textual, consta da Subseção 4.9.

A cobertura integral da revisão elimina o viés de seleção: a acurácia relatada não constitui limite superior de amostra conferida, e as ressalvas remanescentes, de outra natureza, estão declaradas na Subseção 5.3.

A leitura por acurácia deve ser acompanhada do F1 macro, que pondera igualmente todas as categorias e revela comportamento distinto entre os modelos. As três melhores marcas de F1 macro ficam a menos de três milésimos umas das outras, com Regressão Logística em 0,6689, LinearSVC em 0,6684 e SGD em 0,6669, e seus intervalos de confiança se sobrepõem integralmente. Os três modelos não devem ser ordenados por essa métrica. A leitura pertinente é outra: o LinearSVC lidera a acurácia sem pagar por isso em desempenho na cauda, ao contrário dos *ensembles* de árvores, que perdem cerca de três centésimos de F1 macro na mesma faixa de acurácia.

Tabela 2 Acurácia e F1 macro por modelo contra a referência humana final ($n = 13.972$; 41 categorias). As duas métricas são a estimativa observada na amostra inteira; os intervalos vêm de *bootstrap* de grupo textual, com mil repetições sobre os 9.735 grupos congelados. A média das reamostragens é grandeza distinta da estimativa observada e não ocupa estas colunas: para o LinearSVC, por exemplo, a média do F1 macro é 0,6664, contra os 0,6684 observados. O F1 macro pondera igualmente todas as categorias, independentemente do suporte.

Modelo	Acurácia	IC95%	F1 macro	IC95%
LinearSVC	0,8253	0,8115 – 0,8378	0,6684	0,6526 – 0,6804
SGD	0,8093	0,7950 – 0,8227	0,6669	0,6510 – 0,6788
Extra Trees	0,8073	0,7923 – 0,8211	0,6362	0,6177 – 0,6498
Regressão Logística	0,8050	0,7907 – 0,8189	0,6689	0,6534 – 0,6812
Random Forest	0,7970	0,7812 – 0,8111	0,6152	0,5971 – 0,6288
LSTM	0,7287	0,7080 – 0,7480	0,5240	0,5107 – 0,5343
Naive Bayes	0,7088	0,6860 – 0,7311	0,2951	0,2887 – 0,3099

4.3 Viabilidade computacional do BERTimbau

O BERTimbau não integra a comparação principal, e o motivo é computacional. O ajuste fino foi cronometrado no mesmo ambiente dos demais modelos, um executor de quatro processadores sem acelerador gráfico, e custou 10,774 segundos por passo, com variação de 0,12 segundo entre o passo mais rápido e o mais lento. São 2.103 passos por dobra, o que projeta 6,44 horas para uma única dobra e 32,2 horas para as cinco. O teto de execução disponível é de seis horas, de modo que nem uma dobra completa cabe na infraestrutura do estudo.

A limitação é de infraestrutura, não do modelo. O BERTimbau não foi avaliado sob o protocolo agrupado desta rodada e nada se afirma aqui sobre seu desempenho relativo; uma comparação integral exigiria aceleração por unidade de processamento gráfico e permanece como trabalho futuro. Um experimento exploratório avaliou o transformador em lote de mil chamados, dos quais 983 com referência humana, e seus valores constam do material suplementar. Eles não são comparáveis aos das Tabelas 1 e 2, pois o lote corresponde aos primeiros registros elegíveis, não é probabilístico, não cobre o corpus, e o ajuste empregou subamostragem estratificada com parada antecipada.

4.4 Calibração e automação seletiva por confiança

A confiança bruta dos classificadores não é probabilidade e não pode sustentar decisão operacional sem tratamento. O erro de calibração esperado (ECE) do LinearSVC alcança 0,6925 sobre o escore bruto, porque a transformação da margem por função *softmax* produz valores que não correspondem a frequências de acerto; a calibração isotônica, ajustada em dobra interna, reduz esse valor a 0,0178 e o escore de Brier de 0,6052 para 0,1034. O procedimento reduz o ECE de cinco dos sete modelos, com melhor resultado no Extra Trees, em 0,0108. O Naive Bayes e o LSTM são exceção e pioram levemente, consequência esperada de ajustar um calibrador sobre amostra menor quando a confiança original já era adequada.

A calibração viabiliza a automação seletiva, em que o classificador decide sozinho acima de um limiar de confiança e encaminha o restante à revisão humana. Ao alvo de 0,95 de acurácia, o Extra Trees automatiza 67,32% dos chamados com acurácia seletiva de 0,9502 e encaminha 32,68% ao revisor; o LinearSVC automatiza

68,90% com 0,9464. Elevar o alvo a 0,99 reduz a cobertura à faixa de 31,94% a 47,04%, e o Naive Bayes só alcança o limiar em duas das cinco dobras, o que o desqualifica para esse regime.

Parte das acurácias seletivas fica pouco abaixo do alvo, como os 0,9464 do LinearSVC contra a meta de 0,95, e a cobertura é média entre as cinco dobras. Ambos são consequência esperada de escolher o limiar em dobra interna: um procedimento que atingisse o alvo exatamente em todas as dobras indicaria que o limiar teve acesso ao conjunto de teste.

Tabela 3 Calibração e automação seletiva por modelo ($n = 13.972$). O ECE e o Brier referem-se ao escore antes e depois da calibração isotônica; a cobertura e a acurácia seletiva correspondem ao alvo de 0,95.

Modelo	ECE bruto	ECE calibrado	Brier calibrado	Cobertura	Acurácia seletiva
Extra Trees	0,0859	0,0108	0,1057	0,6732	0,9502
SGD	0,3046	0,0109	0,1124	0,6162	0,9531
Random Forest	0,0913	0,0145	0,1082	0,6580	0,9495
LinearSVC	0,6925	0,0178	0,1034	0,6890	0,9464
Regressão Logística	0,2351	0,0189	0,1173	0,6237	0,9415
Naive Bayes	0,0144	0,0206	0,1280	0,5518	0,9306
LSTM	0,0158	0,0479	0,1221	0,6545	0,9210

A Figura 2 apresenta a curva de confiabilidade do Extra Trees calibrado, tornando visível a aderência entre confiança declarada e acerto observado ao longo das dez faixas.




Figura 2: Curva de confiabilidade do Extra Trees após calibração isotônica, com confiança média e acurácia observada por faixa.

4.5 Reclassificação e ganho líquido

A hipótese operacional que motiva esta subseção é a de que um classificador competente possa corrigir a base histórica em massa. A medição a refuta. O ganho líquido de reclassificação é negativo em todos os

sete modelos, variando de -1.846 no LinearSVC a -3.474 no Naive Bayes (Tabela 4). O procedimento é direto: conta-se apenas onde a predição diverge da categoria histórica, e a referência revisada arbitra cada divergência, de modo que corrigido é o caso em que o modelo coincide com a referência e o histórico dela se afasta, e prejudicado o caso inverso. O melhor modelo produz 2.849 divergências, das quais apenas 475 representam correção contra 2.321 que degradariam o registro, razão que piora monotonicamente à medida que cai o desempenho do modelo, até o Naive Bayes, que diverge 4.256 vezes para acertar 309.

A explicação não está em falha de cálculo, e sim na estabilidade da referência. O especialista manteve a categoria histórica em 13.462 dos 14.060 chamados, ou 95,75% do corpus, e a substituiu em 598 registros. Um histórico que a revisão preserve em mais de nove décimos dos casos oferece pouca margem de correção e muita margem de dano: divergir do histórico significa, na maior parte das vezes, divergir também da referência. O teto de correção mensurável neste desenho corresponde aos 4,25% de registros cuja categoria foi alterada, e nenhum modelo se aproxima dele sem produzir um volume de alterações indevidas várias vezes maior.

A reclassificação automática em massa não é, portanto, desaconselhada por cautela metodológica, mas por evidência de que degradaria a base em que fosse aplicada. O ganho líquido, e não a acurácia agregada, é o critério adequado para essa decisão, e deve ser recalculado a cada atualização da base.

O ganho líquido, contudo, pressupõe que corrigir um registro e estragar outro valham o mesmo, e que revisar não custe nada. Nenhuma das duas hipóteses é neutra em gestão pública, e ambas estavam implícitas na subtração. A qualificação decisória adota, por isso, a função de utilidade $U = b \times \text{corrigidos} - c \times \text{prejudicados} - r \times \text{revisados}$, normalizada pelo benefício da correção, o que dispensa atribuir valor monetário e reduz o problema a duas razões adimensionais: c/b , o custo do prejuízo em unidades de benefício da correção, e r/b , o custo da revisão humana na mesma unidade. O ganho líquido simples é o caso particular $c/b = 1$ e $r/b = 0$, e permanece o resultado principal por ser transparente.

Sob aplicação direta, em que o modelo reescreve a categoria sempre que diverge, a utilidade só é positiva se ficar abaixo da razão de equilíbrio corrigidos/prejudicados, que vale 0,2047 no LinearSVC e cai a 0,0817 no Naive Bayes. A reclassificação exigiria, portanto, que estragar um registro custasse menos de um quinto do que vale corrigir outro, condição que a natureza do dano não sustenta: o registro corrompido propaga para a série temporal da categoria e para a alocação de recurso que dela deriva (Subseção 5.4), ao passo que a correção apenas recupera o valor que o registro já deveria ter. Em toda a faixa examinada, de $c/b = 0,25$ a $c/b = 4$, a utilidade é negativa nos sete modelos, de modo que o veredito não depende da hipótese de custos iguais.

A mesma predição sustenta, entretanto, uma política diferente. Se a divergência não reescreve o rótulo e apenas enfileira o chamado para revisão humana, não há prejudicados por construção, e o benefício é o número de registros da fila cujo histórico de fato estava errado: 18,53% no LinearSVC, contra a taxa de alteração de 4,25% na base congelada, o que faz da divergência um critério de priorização com enriquecimento de cerca de quatro vezes sobre a revisão aleatória. Os dois denominadores diferem em 88 linhas e não devem ser fundidos, mas a ordem de grandeza não depende disso. O limite de equilíbrio de c/b coincide com essa precisão: a triagem paga enquanto revisar um chamado custar menos de 18,5% do que vale corrigir um registro, valor que supõe a revisão devolvendo a referência, verdadeiro por construção, e é portanto teto da política. A consequência operacional é discutida na Subseção 5.2, e os valores por modelo constam do material suplementar.

Tabela 4 Ganho líquido de reclassificação por modelo, contado apenas onde a predição diverge da categoria histórica e arbitrado pela referência humana revisada ($n = 13.972$).

Modelo	Divergências	Corrigidos	Prejudicados	Neutros	Ganho líquido
LinearSVC	2.849	475	2.321	53	-1.846
SGD	3.100	489	2.559	52	-2.070
Extra Trees	3.012	422	2.519	71	-2.097
Regressão Logística	3.161	492	2.621	48	-2.129
Random Forest	3.148	416	2.658	74	-2.242
LSTM	4.168	426	3.621	121	-3.195

Modelo	Divergências	Corrigidos	Prejudicados	Neutros	Ganho líquido
Naive Bayes	4.256	309	3.783	164	-3.474

4.6 Diagnóstico de taxonomia e ambiguidade estrutural (Shannon/Jensen-Shannon)

O diagnóstico de Shannon abrange os sete modelos com predições *out-of-fold* sobre a totalidade das linhas avaliadas. O BERTimbau fica de fora pelo motivo exposto na Subseção 4.3. Dispersão de predições e aderência distributiva ao histórico não caminham juntas neste corpus: o LSTM apresenta a maior diversidade de categorias previstas, com entropia normalizada de 0,8362, ao passo que o LinearSVC, de melhor acurácia, é o de distribuição mais próxima da base, com divergência de Jensen-Shannon de 0,0055.

No nível de chamado individual, os sete modelos são unânimes em 8.444 dos 13.972 registros, ou 60,44%, e 2.285 registros, ou 16,35%, distribuem os votos por três ou mais categorias distintas. Esse segundo conjunto caracteriza desacordo estrutural entre arquiteturas, em que a divergência deixa de ser escolha entre duas alternativas e passa a indicar ausência de sinal textual suficiente, e constitui critério de priorização de auditoria complementar à baixa confiança de um único modelo.

No nível de categoria, o contraste é acentuado entre as 33 categorias com suporte mínimo de trinta registros. A Figura 3 contrasta as dez de maior e as dez de menor F1 do LinearSVC: nas dez melhores, o F1 varia de 0,9139 a 0,9972 sobre 6.271 chamados; nas dez piores, cai à faixa de 0,2162 a 0,6288 sobre 2.403 chamados, porte comparável em ordem de grandeza, de modo que a diferença não decorre de escassez de exemplos.




Figura 3: F1 do LinearSVC e suporte, para as dez categorias de maior e de menor desempenho entre as 33 com suporte mínimo de 30 chamados.

O padrão que emerge é sistemático, não aleatório. Oito das dez categorias de maior desempenho pertencem a Manutenção Preventiva, cujos chamados nascem de rotina programada e recebem descrição padronizada. As de menor desempenho concentram rótulos de fronteira aberta, como Telhados preventivos (0,2162), Reforma (0,2407), Erro de chamado (0,3978) e Alvenaria, Pisos e Estrutura (0,4610), que competem por vocabulário com categorias vizinhas. Trata-se, portanto, de ambiguidade estrutural da taxonomia, não apenas de erro do modelo, na linha do que Zhang *et al.* (2025) descrevem para rótulos ruidosos em processamento de linguagem natural.

A Figura 4 recorta a matriz de confusão sobre as oito categorias mais envolvidas em troca recíproca e mostra que os erros não se espalham pela taxonomia. A célula dominante registra 1.066 chamados de Instalação e reparo de equipamentos preditos como Alvenaria, Pisos e Estrutura, com 937 no sentido inverso, o que faz

desse par a maior fronteira do corpus, com 2.003 trocas somadas. Seguem-se Alvenaria contra Esquadrias, com 1.097 trocas, e Alvenaria contra Hidráulica, com 940. Alvenaria, Pisos e Estrutura comparece nos cinco maiores pares e se comporta como categoria absorvente, para a qual convergem chamados cuja descrição não delimita o sistema predial afetado. A leitura da matriz é assimétrica em vários pares, o que sugere absorção de uma categoria por outra, e não simples permuta.

A fronteira entre climatização corretiva e preventiva, que descreve o mesmo equipamento sob naturezas distintas de intervenção, não figura entre as maiores confusões: a ambiguidade que resta é a de escopo entre sistemas prediais, não a de natureza do serviço, resultado coerente com a facilidade da tarefa de tipo reportada na Subseção 4.11.




Figura 4: Recorte da matriz de confusão sobre as oito categorias mais envolvidas em troca recíproca, com contagens agregadas entre modelos.

Esses recortes sustentam a mesma conclusão operacional. Quando a queda de desempenho se concentra em fronteiras taxonômicas específicas, e não de modo difuso, a resposta adequada não é substituir o classificador, mas revisar a taxonomia, decisão que permanece humana e para a qual a camada de Shannon oferece apenas a priorização estatística. O Naive Bayes sintetiza o diagnóstico ao combinar a menor cobertura de categorias, apenas 22 contra 39 a 41 dos demais modelos, com a menor entropia normalizada e a maior divergência frente ao histórico, o que explica seu F1 macro de 0,2951 apesar de acurácia próxima de 0,71. O ordenamento completo dos quinze pares de maior confusão recíproca consta do material suplementar.

4.7 Custo computacional

O custo de treino e de inferência foi medido para os sete modelos sobre a base completa, no mesmo ambiente computacional, um processador de quatro núcleos sem acelerador gráfico, com mediana de três execuções

por modelo. O desenho é o de treino único sobre a base inteira, e não a soma das cinco dobras, de modo que os valores medem o custo de colocar cada modelo em operação; os tempos absolutos variam conforme a máquina, mas as razões entre modelos permanecem estáveis e constituem o dado relevante para a decisão de adoção.

Os modelos lineares treinam em poucos segundos, de 1,12 s no Naive Bayes a 8,43 s na Regressão Logística, os *ensembles* de árvores exigem entre vinte e trinta segundos, e a rede neural LSTM consome 83,44 s, cerca de 34 vezes o tempo do LinearSVC. A faixa entre a execução mais rápida e a mais lenta é estreita em todos os modelos, com exceção do LSTM, o que permite distinguir diferença real de ruído do executor. O BERTimbau não figura na tabela por estar em outra ordem de grandeza, com 6,44 horas por dobra (Subseção 4.3), e por não corresponder a treino único sobre a base inteira.

Tabela 5 Custo computacional por modelo sobre a base completa ($n = 13.972$), mediana de três execuções em processador de quatro núcleos.

Modelo	Tempo de treino (s)	Faixa	Tempo de inferência (s)
Naive Bayes	1,12	1,12 – 1,12	0,89
SGD	2,28	2,27 – 2,28	0,93
LinearSVC	2,44	2,41 – 2,46	0,89
Regressão Logística	8,43	8,43 – 8,46	0,92
Random Forest	22,62	22,62 – 22,66	1,34
Extra Trees	26,69	26,63 – 26,72	1,46
LSTM	83,44	70,38 – 83,63	4,89

A Figura 5 cruza essas medições de custo com a acurácia da Tabela 2 e mostra que o LinearSVC ocupa a posição mais favorável, com a maior acurácia a um custo de treino próximo do menor observado. O argumento de eficiência da Subseção 2.4 se sustenta em duas frentes. Contra o LSTM, a comparação é direta e desfavorável ao modelo neural, que custa 34 vezes mais para perder 9,7 pontos percentuais de acurácia. Contra o BERTimbau, o que se afirma é mais restrito: o custo medido inviabiliza a validação cruzada agrupada no ambiente do estudo, sem que disso decorra juízo sobre seu desempenho.




Figura 5: Trade-off entre acurácia e tempo de treino, modelos clássicos.

4.8 Comportamento do LSTM e justificativa do protocolo agrupado

A Figura 6 mostra a curva de aprendizado do LSTM. O treino parou por interrupção antecipada após 11 épocas, com menor perda de validação na época 8 e maior acurácia de validação na época 10 (0,6722). O padrão indica saturação precoce, consistente com a hipótese de que *embeddings* treinados do zero são insuficientes para um corpus deste porte (Subseção 3.4). A curva provém de um treino único sobre a base inteira, com validação interna de 10%, e descreve a dinâmica de convergência da arquitetura, não o desempenho reportado na Tabela 2, que é a união das predições *out-of-fold* das cinco dobras.




Figura 6: Curva de aprendizado do LSTM por época, perda e acurácia em treino e validação.

A justificativa do particionamento agrupado é anterior a qualquer medição de desempenho e repousa na estrutura do corpus (Subseção 3.5): a partição por linha permitiria ao mesmo texto ocupar treino e teste, e duas estimativas da magnitude do efeito indicam ganho espúrio entre 0,89 e 1,84 ponto percentual de acurácia. Elas constam do material suplementar com o protocolo declarado e não são comparáveis às Tabelas 1 e 2, por terem outra base, outro denominador e outro rótulo de treino, assim como o estudo de sensibilidade a unidades recorrentes e *dropout*, que separa as quatro variantes por menos de quatro pontos percentuais.

4.9 Inferência sob dependência textual

A dependência entre registros de texto idêntico não é detalhe de implementação: ela determina quanta informação a amostra de fato contém. As 13.972 linhas avaliadas distribuem-se por 9.735 grupos textuais congelados, e 4.546 delas, ou 32,54%, pertencem a grupos com mais de um membro. O efeito de desenho, razão entre a variância da acurácia sob reamostragem de conglomerados e a variância binomial que a suposição de independência produziria (COCHRAN, 1977), fica entre 4,47 no LinearSVC e 8,83 no Naive Bayes. Em erro padrão, isso significa que a precisão declarada por linha era de 2,1 a 3,0 vezes maior do que a amostra sustenta: para o LinearSVC, 0,0032 contra 0,0068. Toda inferência desta subseção adota, por isso, o grupo como unidade.

O teste global rejeita a igualdade entre os sete modelos. A estatística Q de Cochran vale 2.661,04 sobre seis graus de liberdade, e sua significância é apurada contra distribuição empírica de duas mil permutações do rótulo de modelo dentro de cada grupo, o que preserva a dependência interna: nenhuma permutação alcançou o valor observado, de modo que $p < 0,0005$. Só então os 21 pares foram comparados, por permutação pareada com troca de sinal da diferença de acertos por grupo, com dez mil permutações e correção de Holm sobre a família. Sem o teste global, 21 comparações constituiriam pesca de significância.

A Tabela 6 apresenta as seis comparações do LinearSVC, que é o modelo líder, contra cada um dos demais. O LinearSVC supera os seis com significância, e a leitura por grupos qualifica a magnitude: contra o SGD, a vantagem de 1,60 ponto percentual corresponde a 533 grupos favoráveis ao LinearSVC contra 308 ao SGD, com 8.894 grupos empatados. Vantagem estatisticamente estabelecida e vantagem prática são, portanto, coisas distintas, e nove de cada dez grupos não distinguem os dois modelos. O d pareado por grupo, que padroniza a diferença média pelo desvio das diferenças, fica entre 0,07 e 0,31, faixa de efeito pequeno.

Tabela 6 Comparações pareadas do LinearSVC contra os demais modelos, com o grupo textual como unidade (13.972 linhas em 9.735 grupos). A diferença de acurácia é a estimativa observada; o intervalo vem de

bootstrap de conglomerados com duas mil reamostragens; o valor de p vem de permutação pareada com dez mil repetições e correção de Holm sobre os 21 pares. Nenhuma permutação alcançou a diferença observada nestes seis pares, de modo que os valores de p são limites superiores impostos pelo número de repetições, e não estimativas pontuais. Os 15 pares restantes constam do material suplementar.

Comparação	Δ acurácia (p.p.)	IC95% da dife- rença	Grupos a favor	Grupos contra	Empates	d pareado	p ajustado
× SGD	1,60	0,0118 – 0,0204	533	308	8.894	0,077	0,0021
× Extra Trees	1,80	0,0130 – 0,0232	759	515	8.461	0,071	0,0021
× Re- gressão Logís- tica	2,03	0,0156 – 0,0248	598	314	8.823	0,094	0,0021
× Random Forest	2,83	0,0229 – 0,0341	896	503	8.336	0,108	0,0021
× LSTM	9,66	0,0875 – 0,1061	1.682	349	7.704	0,313	0,0021
× Naive Bayes	11,65	0,1028 – 0,1329	1.961	549	7.225	0,164	0,0021

Dos 21 pares, 19 são significativos após a correção e 2 não são: Extra Trees contra Regressão Logística e Extra Trees contra SGD, ambos com p ajustado de 0,842 e intervalo da diferença contendo o zero. Esses dois pares devem ser lidos como empate dentro do poder do teste, e não como ordenação, o que é coerente com a sobreposição dos intervalos de F1 macro apontada na Subseção 4.2.

Cabe registrar o alcance da correção de unidade. Nenhum dos 21 vereditos muda ao passar da linha para o grupo: repetida a família de comparações por McNemar sobre linhas (MCNEMAR, 1947), os mesmos 19 pares permanecem significativos e os mesmos 2 permanecem empatados. O que muda é a magnitude do valor de p , e a diferença é de ordens de grandeza em vários pares. A conclusão substantiva do artigo, portanto, não dependia da suposição incorreta, mas a precisão anteriormente declarada dependia, e a permanência do veredito é resultado da análise, não sua premissa.

A cauda de categorias raras impõe uma segunda qualificação, agora sobre a composição da métrica e não sobre a incerteza. O *macro*-F1 de 0,6684 do LinearSVC é média sobre as 41 categorias avaliadas. Projetado sobre as 50 categorias da taxonomia, com F1 igual a zero nas nove ausentes das partições, ele cai a 0,5481, valor que é o limite inferior honesto, pois nenhum modelo prevê categoria que não esteve no treino. Agregado às 14 famílias do primeiro nível da taxonomia, sobe a 0,6816, e nessa granularidade o LinearSVC assume também a liderança do *macro*-F1, que na leitura por categoria pertencia à Regressão Logística por três milésimos. A ordenação dos modelos é estável nas três convenções, à exceção dessa troca de posição no topo. Os valores por modelo constam do material suplementar.

4.10 Duplicação taxonômica e recomendação de governança

A acurácia dos sete modelos varia entre 0,7088 e 0,8253, faixa de 12 pontos percentuais, ao passo que o F1 macro varia de 0,2951 a 0,6689, faixa de 37 pontos: os modelos se diferenciam sobretudo no tratamento das categorias de baixa frequência, e o padrão de fronteira da Subseção 4.6 reaparece no LinearSVC isoladamente, o que caracteriza o desequilíbrio como propriedade da taxonomia e não de um indutor particular.

Soma-se a esse quadro a duplicação taxonômica. A categoria **Ar condicionado split** existe simultaneamente sob **Manutenção Preventiva**, com 1.798 chamados, e sob **Climatização**, com 1.640, e o mesmo desdobramento ocorre com **Ar condicionado central**, **Gerador**, **Nobreak**, **Elevador**, **Telhados**, **calhas**,

rufos e Sistemas de combate a incêndio. O critério que separa esses pares é a natureza preventiva ou corretiva da intervenção, informação que o texto do chamado frequentemente não explicita, de modo que uma fração do erro medido não decorre de limitação do classificador, mas da exigência de inferir do texto uma distinção que nele não está registrada. A cauda de categorias raras impõe restrição análoga: das 50 categorias históricas, 14 reúnem menos de trinta chamados e 6 reúnem menos de dez, suporte em que um único acerto desloca o F1 em dezenas de pontos percentuais.

Depreende-se daí uma recomendação de governança anterior à escolha do modelo. Antes de perseguir ganho de acurácia por meio de arquiteturas mais custosas, convém revisar a taxonomia institucional, unificando os pares que nomeiam o mesmo objeto e explicitando o critério de natureza da manutenção no formulário de abertura do chamado. Essa intervenção atua sobre a origem do erro, enquanto a substituição do classificador atua apenas sobre seu efeito.

4.11 Desempenho por volume de categoria e por natureza da manutenção

O F1 macro atribui o mesmo peso a uma categoria de dois chamados e a outra de dois mil, o que torna a métrica agregada pouco informativa quando a distribuição de volume é acentuadamente desigual. Aplicou-se, por conseguinte, uma curva ABC sobre o suporte das 41 categorias avaliadas. A classe A reúne o menor conjunto de categorias que acumula ao menos 80% do volume, a classe B corresponde ao intervalo entre 80% e 95%, e a classe C abrange o restante. A partição resultante concentra 11.433 chamados, equivalentes a 81,83% do total, em apenas 12 categorias; a classe B reúne outras 12 categorias e 1.912 chamados; a classe C reúne 17 categorias e 627 chamados, ou 4,49% do total.

O F1 macro recalculado dentro de cada classe demonstra que a distância entre acurácia e F1 macro decorre da composição da métrica, e não de falha generalizada do classificador: o LinearSVC alcança 0,8207 na classe A e 0,5018 na classe C, de modo que o valor agregado de 0,6684 é média entre dois regimes distintos. A ordenação dos modelos permanece estável nas três classes, e o Naive Bayes é o único cujo colapso alcança a classe B, com 0,2527, ao passo que os demais preservam desempenho superior a 0,63 nas duas primeiras. Os valores por modelo e classe constam do material suplementar.

O segundo recorte separa os chamados pela natureza da intervenção, em três tipos e não na dicotomia usual entre preventivo e corretivo, porque a taxonomia institucional abriga famílias que não descrevem serviço de manutenção: o registro indevido de chamado, a contratação de posto de trabalho, o fornecimento de materiais e a execução de reformas. Elas somam 585 chamados, ou 4,19% das linhas avaliadas, e sua atribuição indiscriminada à manutenção corretiva elevaria o denominador desta em cerca de 7% relativos, com efeito direto sobre qualquer razão calculada entre as duas naturezas. Sob o critério adotado, a preventiva responde por 4.902 chamados (35,09%) e a corretiva por 8.485 (60,73%).

A projeção da referência revisada e das predições para o nível de tipo eleva o desempenho a outro patamar. O LinearSVC alcança 0,9443 de acurácia nessa granularidade, contra 0,8253 na tarefa de 41 categorias, com F1 de 0,9742 na preventiva e de 0,9547 na corretiva, de modo que a distinção apontada na Subseção 4.10 como origem taxonômica de parte do erro resolve-se com folga no nível em que a decisão de gestão ocorre. Toda a perda concentra-se no terceiro tipo, cujo F1 não ultrapassa 0,5330 em nenhum modelo e recua a 0,2684 no Naive Bayes, coerente com categorias cuja atribuição depende de juízo administrativo sobre a pertinência do chamado, e não de sua descrição técnica. Cabe registrar a inversão de ordenação nessa granularidade: o Extra Trees lidera a acurácia, com 0,9497, e o LinearSVC lidera o F1 macro, com 0,8180, precisamente por ir melhor na classe difícil, o que faz a escolha do classificador depender tanto do nível de agregação da decisão quanto da métrica que ela privilegia.

A curva ABC recalculada dentro de cada tipo delimita o conjunto mínimo de categorias que sustenta cada leitura: quatro categorias preventivas cobrem 83,46% do tipo com F1 macro de 0,9727, sete corretivas cobrem 81,76% com 0,7835, e as quatro de não manutenção que cobrem 89,06% alcançam apenas 0,5184, o que confirma a dificuldade como propriedade do tipo, e não da cauda de baixa frequência. O detalhamento consta do material suplementar.

Depreende-se do conjunto dessas medições uma hierarquia de confiabilidade: a contagem por tipo de manutenção é a leitura mais segura, com erro agregado inferior a 2% na classe preventiva; a leitura por categoria só se sustenta nas categorias de classe A do respectivo tipo, condição satisfeita por quatro categorias preventivas

e sete corretivas, que reúnem 11.028 chamados e estão discriminadas na Tabela A2. Nas classes B e C, e em toda a família de não manutenção, o desempenho medido não autoriza uso automático. A consequência para indicadores institucionais é tratada na Subseção 5.4.

4.12 Camada explícita de regras de periodicidade

O desenho do estudo previa medir, e não presumir, o valor de uma camada de regras de domínio sobre a predição estatística. A regra implementada atribui categoria preventiva quando o chamado reúne, no mesmo texto, um termo de periodicidade e um termo de equipamento, e abstém-se nos demais casos. São 19 termos de periodicidade e 31 de equipamento. A avaliação usa as mesmas partições e os mesmos registros da comparação principal, e em nenhuma configuração a referência humana é alterada.

A regra dispara em 4.487 dos 13.972 registros, quase um terço do corpus, e ainda assim melhora o F1 macro de apenas três dos sete modelos. O ganho concentra-se onde o classificador é fraco: o Naive Bayes sobe 0,0586 no F1 macro, ao passo que Extra Trees e Random Forest perdem 0,0038 cada, e o LinearSVC perde 0,0017. Nos chamados de referência preventiva a acurácia sobe em todos os modelos, mas o efeito é de segunda ordem fora do Naive Bayes, entre 0,0020 e 0,0060.

O número que explica o padrão é o de conflitos: como a regra depende apenas do texto, ela dispara no mesmo conjunto de registros para os sete modelos, e o que varia é a predição que ela substitui. No LinearSVC, os 4.487 disparos produzem apenas 31 divergências; no Naive Bayes, produzem 219, com a regra acertando 201 contra 9 do modelo.

A leitura correta, portanto, não é que regras de domínio funcionam, e sim que elas são redundantes diante de um classificador estatístico competente. Os modelos já capturam implicitamente os sinais de periodicidade presentes no texto, e a camada explícita apenas repete o que eles fazem, com o custo adicional de manter uma tabela de termos. Trata-se de resultado negativo, contrário à expectativa que motivou o teste, e com implicação de desenho: o ganho do fluxo híbrido está no eixo humano-IA, tratado na Subseção 4.4, e não no eixo regra-modelo.

5. DISCUSSÃO

5.1 Concordância histórica, acerto contra a referência e custo do BERTimbau

A comparação entre concordância histórica (Subseção 4.1) e desempenho contra a referência humana (Subseção 4.2) revela que as duas grandezas não são intercambiáveis. A acurácia do LinearSVC (82,53%) supera sua concordância com o histórico (79,61%) em 2,92 pontos percentuais. A diferença mede o efeito das 598 correções sobre a avaliação: ao substituir a categoria histórica pela categoria revisada, parte das divergências que seriam contabilizadas como erro do modelo passa a ser reconhecida como erro do registro administrativo.

Com a revisão estendida ao corpus integral, a diferença deixa de depender de qualquer recorte amostral e passa a ser propriedade medida da base. Em 598 dos 14.060 chamados, ou 4,25%, o avaliador rejeitou a categoria registrada e definiu outra. A grandeza é uma taxa de alteração do rótulo histórico sob auditoria administrativa, e não uma estimativa da prevalência de erro do registro: ela mede quantas categorias um especialista único decidiu trocar tendo o rótulo à vista, o que é compatível com a hipótese de rótulos ruidosos da literatura (KEJRIWAL *et al.*, 2024; ZHANG *et al.*, 2025) sem quantificá-la. O valor é específico deste corpus e desta taxonomia, e sua transposição a outras instituições exige nova revisão. A taxa é baixa por duas causas que a Subseção 3.6 discrimina sem que o desenho permita separá-las, o rótulo produzido sob verificação de equipe técnica e a ancoragem do procedimento de auditoria; seja qual for a proporção entre elas, o que os modelos acompanham não é um rótulo ingênuo, e é essa estabilidade da linha de base que torna negativo o ganho de reclassificação discutido na Subseção 5.2.

O BERTimbau não integra essa comparação por motivo computacional medido (Subseção 4.3), e nada se afirma aqui sobre sua qualidade relativa, pois rankings produzidos sob protocolos distintos não sustentam comparação direta.

5.2 Reclassificação, ambiguidade taxonômica e calibração

O resultado da reclassificação (Subseção 4.5) contraria a expectativa que motivou o estudo e tem consequência operacional direta. O ganho líquido de corrigir chamados já classificados é negativo em todos os sete modelos,

e a magnitude do prejuízo acompanha, na ordem inversa, o desempenho de cada um. Não se trata de nuance entre modelos, e sim de veredito sobre a tarefa: nenhum classificador aqui avaliado é candidato a reclassificar a base histórica em massa. A explicação é aritmética antes de ser metodológica, pois, estreito o espaço de alteração da referência (Subseção 5.1), qualquer divergência sistemática entre modelo e histórico tende a cair fora dele, e o melhor modelo diverge 2.849 vezes para acertar 475, cerca de um acerto para cada cinco prejuízos. O resultado depende de a referência cobrir todo o corpus, pois arbitrar parte das divergências pelo próprio histórico premiaria o modelo por concordar com o rótulo que se pretendia auditar. O veredito tampouco é artefato de contabilidade: sob a função de utilidade da Subseção 4.5, a reclassificação direta só compensaria se estragar um registro custasse menos de um quinto do que vale corrigir outro, hipótese que a assimetria do dano contradiz, e é a inversa, a de que o prejuízo custa tanto ou mais que a correção, que descreve o caso da manutenção predial.

Disso não decorre que a classificação automática seja inútil neste domínio, e sim que seu uso defensável é seletivo. Sobre chamados novos não há rótulo prévio correto a ser degradado, o que retira o risco medido na Subseção 4.5, mas não transporta para o futuro a acurácia aqui reportada: ela foi estimada entre grupos textuais de um mesmo corte de extração, e não ao longo do tempo (Subseção 5.3), de modo que o uso prospectivo é recomendação condicional. Sobre a base histórica, dois encaminhamentos se sustentam. O primeiro é a automação condicionada à confiança da Subseção 4.4, que preserva o registro nas faixas em que o modelo não tem vantagem demonstrável sobre ele. O segundo inverte o papel da divergência: em vez de autorizar a reescrita, ela prioriza a fila de auditoria humana, e nessa função a mesma predição que perde por larga margem sustenta enriquecimento de cerca de quatro vezes sobre a revisão aleatória. A predição que não substitui o revisor pode dirigi-lo, e essa é a leitura operacional que o resultado negativo autoriza.

A camada de entropia de Shannon e divergência de Jensen-Shannon (Subseção 4.6) não substitui as métricas supervisionadas ou a revisão humana, mas amplia o repertório de governança ao separar três fenômenos que a acurácia isolada tende a confundir: o erro de modelo, a ambiguidade genuína da taxonomia institucional e a heterogeneidade natural da distribuição de chamados.

A calibração transforma essa leitura em procedimento operável (Subseção 4.4). Escores brutos não são probabilidade, e o ajuste isotônico em dobra interna (PLATT, 1999; GUO *et al.*, 2017) é o que permite associar confiança alta a acerto alto sem depender de faixas cuja escala não tem interpretação probabilística, condição do regime seletivo discutido acima.

Uma ressalva qualifica a leitura: o calibrador é ajustado sobre escores de um modelo treinado em três dobras e aplicado a escores de um modelo treinado em quatro, troca deliberada entre ausência de vazamento e casamento exato de distribuição.

5.3 Limitações

Os dados provêm de uma única instituição federal de ensino superior, com textos em português brasileiro e taxonomia institucional própria. Estender o desempenho relatado a outras instituições, taxonomias ou idiomas exige validação externa.

A revisão humana cobre o corpus integral, o que afasta o viés de seleção que limitaria a leitura caso apenas parte dos chamados tivesse sido revista, mas seu desenho impõe três restrições que precisam ser lidas em conjunto. A primeira é o avaliador único: não houve segunda avaliação independente nem cega, nenhuma medida de concordância entre avaliadores foi apurada e a reprodutibilidade da referência por outro especialista permanece não testada. A literatura registra variabilidade relevante entre anotadores em tarefas dessa natureza, de modo que a referência aqui utilizada não deve ser tratada como isenta de erro. A segunda é a ancoragem: o revisor decidiu com a categoria histórica à vista, condição constitutiva da auditoria de rótulo e incompatível com anotação independente, de sorte que a taxa de confirmação de 95,75% expressa conjuntamente a estabilidade do registro e o efeito do procedimento, sem que este desenho permita atribuir peso a cada parcela. A terceira é consequência das duas anteriores: a taxa de alteração de 4,25% não autoriza estimar a prevalência de categorias históricas incorretas na base, e nenhuma afirmação desse tipo é feita neste artigo. Uma segunda avaliação sobre amostra estratificada, com registro de divergências e adjudicação por terceiro revisor, é a validação futura pertinente, sobretudo nos pares taxonômicos ambíguos.

A taxonomia institucional apresenta pares de categorias que nomeiam o mesmo objeto sob famílias distintas

(Subseção 4.6), e a divergência interna medida na Subseção 3.6 confirma o problema no próprio dado. Nesses pares, a atribuição depende de um critério de natureza da intervenção que o texto do chamado nem sempre permite inferir, o que impõe teto ao desempenho alcançável por qualquer classificador textual.

As métricas valem para as 41 categorias com suporte nas cinco dobras, e não para a taxonomia inteira. As nove categorias excluídas são justamente as mais raras, e o efeito é quantificado na Subseção 4.9: sobre as 50 categorias, o *macro*-F1 do melhor modelo cai de 0,6684 a 0,5481. A cobertura de linhas permanece alta, 99,37%, mas a de categorias é de 82%, e nenhuma afirmação deste artigo se estende às nove ausentes. A Tabela A3 torna a diferença auditável, e a Subseção 3.5 registra as alternativas examinadas, sem que qualquer delas elimine a restrição.

Uma restrição adicional decorre do congelamento: as partições são fixadas por um mapa versionado de grupos textuais, o que garante reprodutibilidade mas dissocia o experimento do crescimento da base operacional, e dois registros tiveram o texto editado depois, o que basta para explicar diferenças de última casa decimal em execuções futuras.

A limitação mais consequente para o uso prospectivo é a ausência de validação temporal. O corpus congelado não dispõe de data de abertura por chamado, restrição verificada sobre o contrato de colunas da base e sobre os artefatos da rodada canônica, de modo que treino, calibração e teste não puderam ser separados em períodos sucessivos. Segue-se que a validação cruzada agrupada estima generalização entre grupos textuais de um mesmo corte de extração, e não desempenho futuro sob deriva temporal: nenhum número deste artigo prevê o comportamento do classificador sobre chamados posteriores, e toda recomendação de uso prospectivo é condicional.

Os mecanismos que essa lacuna deixa por medir operam na direção do desempenho reportado. A deriva de vocabulário desloca a matriz de atributos à medida que entram equipamentos, edificações e jargões ausentes do treino; cada fusão, criação ou renomeação de categoria, providência recomendada na Subseção 4.10, altera o próprio espaço de saída, incluído aí o caso extremo da categoria nova, para a qual não há exemplo e não pode haver predição; mudanças no formulário de abertura e na composição da equipe de triagem alteram a distribuição do texto de entrada e do rótulo administrativo que lhe corresponde. Implantação defensável pressupõe, por conseguinte, monitoramento da acurácia sobre amostra auditada, recalibração periódica dos escores, dado que o limiar da Subseção 4.4 é solidário à distribuição de confiança observada, e retreinamento a cada mudança de taxonomia. A avaliação em períodos sucessivos depende de extração que preserve a data de abertura e constitui validação futura prioritária, anterior a qualquer decisão de automação em regime.

Quanto às arquiteturas, o BERTimbau não foi avaliado sob este protocolo, por limitação de infraestrutura, e a execução *out-of-fold* integral com aceleração gráfica permanece como trabalho futuro; a LSTM, por sua vez, treina *embeddings* do zero, sem vetores pré-treinados em português, condição que limita a comparação entre arquiteturas neurais.

5.4 Contribuição para a governança preditiva da manutenção

Ao converter texto livre em categoria e confiança auditáveis, o protocolo produz a camada de dados estruturados sobre a qual a gestão pública de manutenção predial pode operar de forma preditiva, e não apenas reativa. Previsão de demanda por categoria, priorização de intervenções segundo critérios de sustentabilidade e leitura territorial do parque edificado dependem, todas, de uma base classificada de modo confiável, e a medição aqui reportada mostra que essa confiabilidade exige revisão humana.

A exigência tem razão específica quando a camada classificada alimenta modelos de série temporal por categoria. Um chamado atribuído à categoria incorreta subtrai uma ocorrência da série de uma categoria e a acrescenta à de outra, deslocando duas séries em sentidos opostos, e o efeito propaga-se à estimativa de demanda e de custo e ao ordenamento de prioridades que dela deriva, de sorte que o erro de classificação se converte em erro de alocação de recurso. É essa a razão pela qual o acerto contra a referência revisada opera como requisito de engenharia da camada preditiva, e não apenas como métrica de comparação entre modelos, e também a que dá assimetria aos custos da Subseção 4.5: corromper um registro correto custa mais do que vale recuperar um incorreto.

O recorte da Subseção 4.11 indica em que ordem essa camada pode ser incorporada a indicadores institucionais. A razão entre manutenção preventiva e corretiva, que expressa a maturidade da gestão do parque edificado, é

a leitura de menor erro medido e dispensa revisão caso a caso, desde que o erro seja reaverificado periodicamente sobre amostra auditada, uma vez que o valor medido vale para o corte avaliado; já os indicadores desagregados por categoria exigem restrição às classes de maior volume dentro de cada tipo, sob pena de atribuir a frações residuais do corpus uma precisão que a medição não sustenta. A hierarquia converte o diagnóstico de desempenho em critério de publicação de indicador, e não apenas em ressalva metodológica.

6. CONSIDERAÇÕES FINAIS

A contribuição central deste artigo é metodológica. O protocolo separa a concordância com o rótulo histórico do acerto contra a referência humana revisada e mede as duas grandezas sobre a mesma execução, com partições agrupadas por texto que impedem a repetição de chamados entre treino e teste. Essa separação evita tratar o histórico como referência inquestionável e, ao mesmo tempo, impede concluir que toda divergência da classificação automática representa correção do registro original.

Na avaliação sobre 13.972 chamados em 41 categorias, o LinearSVC alcança 82,53% de acurácia (IC95%: 81,15%–83,78%) e supera os demais modelos com significância estatística, ao custo de treino de 2,44 s sobre a base inteira. A recomendação operacional é usá-lo com calibração isotônica e automação condicionada à confiança, regime em que cerca de dois terços do volume podem ser decididos automaticamente com acurácia próxima de 0,95 e o terço restante encaminhado à revisão humana. A recomendação é condicional quanto a chamados futuros, pois o corpus congelado, desprovido de data de abertura, não permitiu separar treino, calibração e teste no tempo: estender o regime seletivo à operação corrente pressupõe monitoramento do desempenho e recalibração periódica.

O achado que mais altera a orientação prática é negativo. A reclassificação automática da base histórica produz prejuízo líquido em todos os sete modelos, porque a revisão manteve a categoria registrada em 95,75% dos casos e o espaço de alteração é estreito demais para compensar os erros introduzidos. O veredito não depende da hipótese de custos iguais: sob função de utilidade explícita, a reescrita só compensaria se estragar um registro valesse menos de um quinto do que vale corrigir outro. A mesma divergência que não autoriza a reescrita presta-se, porém, à priorização da auditoria humana, com enriquecimento de cerca de quatro vezes sobre a revisão aleatória. Também é negativo, e igualmente útil, o resultado da camada explícita de regras de periodicidade: ela é redundante diante de um classificador estatístico competente, que já captura esses sinais a partir do texto.

A finalização metodológica exige reconhecer o que os dados não respondem. A referência provém de auditoria administrativa conduzida por avaliador único, com a categoria histórica à vista e sem segunda avaliação independente, de modo que o estudo não estima a prevalência de erro do rótulo histórico nem a reprodutibilidade da referência por outro especialista, e o desempenho medido não cobre as nove categorias mais raras da taxonomia. Tampouco há validação temporal, pela ausência de data de abertura no corpus congelado, de sorte que a estabilidade do desempenho sob deriva de vocabulário e sob alteração da taxonomia permanece por medir. A próxima etapa deve incorporar segunda avaliação, com adjudicação de divergências nos pares ambíguos, submeter a própria taxonomia a revisão e reconstituir o corte com a data de abertura preservada, o que viabiliza avaliação em períodos sucessivos. Em paralelo, a validação externa em outras instituições e a execução *out-of-fold* integral do BERTimbau, viável em infraestrutura com acelerador gráfico, poderão testar a estabilidade dos resultados sob taxonomias e volumes distintos. A camada classificada poderá então alimentar modelos de previsão de demanda e de priorização multicritério de intervenções sobre uma base cuja incerteza e origem das decisões permanecem auditáveis.

REFERÊNCIAS

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. ABNT NBR 5674: Manutenção de edificações: Requisitos para o sistema de gestão de manutenção. Rio de Janeiro: ABNT, 2012.

ANDERSON, M. J.; TER BRAAK, C. J. F. Permutation tests for multi-factorial analysis of variance. *Journal of Statistical Computation and Simulation*, v. 73, n. 2, p. 85–113, 2003.

BENAVOLI, A.; CORANI, G.; MANGILI, F. Should we really use post-hoc tests based on mean-ranks? *Journal of Machine Learning Research*, v. 17, n. 5, p. 1–10, 2016.

BENDER, E. M.; GEBRU, T.; McMILLAN-MAJOR, A.; SHMITCHELL, S. On the dangers of stochas-

- tic parrots: can language models be too big? In: Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency (FAccT '21). New York: ACM, 2021. p. 610–623.
- BOUABDALLAOUI, Y.; LAFHAJ, Z.; YIM, P.; DUCOULOMBIER, L.; BENNADJI, B. Natural Language Processing Model for Managing Maintenance Requests in Buildings. *Buildings*, v. 10, n. 9, art. 160, 2020.
- BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Brasília: Presidência da República, 2018.
- BROWN, T. B.; MANN, B.; RYDER, N.; SUBBIAH, M.; KAPLAN, J.; DHARIWAL, P.; NEELAKANTAN, A. et al. Language models are few-shot learners. In: *Advances in Neural Information Processing Systems 33* (NeurIPS 2020). Red Hook: Curran Associates, 2020. p. 1877–1901.
- CAMERON, A. C.; GELBACH, J. B.; MILLER, D. L. Bootstrap-based improvements for inference with clustered errors. *The Review of Economics and Statistics*, v. 90, n. 3, p. 414–427, 2008.
- CAPRA, F. A teia da vida: uma nova compreensão científica dos sistemas vivos. São Paulo: Cultrix, 1996.
- COCHRAN, W. G. The comparison of percentages in matched samples. *Biometrika*, v. 37, n. 3-4, p. 256–266, 1950.
- COCHRAN, W. G. Sampling techniques. 3. ed. New York: John Wiley & Sons, 1977.
- COHEN, J. A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, v. 20, n. 1, p. 37–46, 1960.
- DEMŠAR, J. Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, v. 7, p. 1–30, 2006.
- DEVLIN, J.; CHANG, M.-W.; LEE, K.; TOUTANOVA, K. BERT: Pre-training of deep bidirectional transformers for language understanding. In: *CONFERENCE OF THE NORTH AMERICAN CHAPTER OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS*, 2019, Minneapolis. Proceedings [...]. Minneapolis: ACL, 2019. p. 4171–4186.
- DICICCIO, T. J.; EFRON, B. Bootstrap confidence intervals. *Statistical Science*, v. 11, n. 3, p. 189–228, 1996.
- EFRON, B. Bootstrap methods: another look at the jackknife. *The Annals of Statistics*, v. 7, n. 1, p. 1–26, 1979.
- EFRON, B.; TIBSHIRANI, R. J. An introduction to the bootstrap. New York: Chapman & Hall/CRC, 1993.
- FIELD, C. A.; WELSH, A. H. Bootstrapping clustered data. *Journal of the Royal Statistical Society: Series B*, v. 69, n. 3, p. 369–390, 2007.
- GALKE, L.; SCHERP, A. Bag-of-words vs. graph vs. sequence in text classification: questioning the necessity of text-graphs and the surprising strength of a wide MLP. In: *ANNUAL MEETING OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS*, 60., 2022, Dublin. Proceedings [...]. Dublin: ACL, 2022. p. 4038–4051.
- GOOD, P. Permutation, parametric and bootstrap tests of hypotheses. 3. ed. New York: Springer, 2005.
- GRAVES, A.; SCHMIDHUBER, J. Framewise phoneme classification with bidirectional LSTM and other neural network architectures. *Neural Networks*, v. 18, n. 5-6, p. 602–610, 2005.
- GRIMM, N. B.; FAETH, S. H.; GOLUBIEWSKI, N. E.; REDMAN, C. L.; WU, J.; BAI, X.; BRIGGS, J. M. Global change and the ecology of cities. *Science*, v. 319, n. 5864, p. 756–760, 2008.
- GUO, C.; PLEISS, G.; SUN, Y.; WEINBERGER, K. Q. On calibration of modern neural networks. In: *INTERNATIONAL CONFERENCE ON MACHINE LEARNING*, 34., 2017, Sydney. Proceedings [...]. Sydney: PMLR, 2017. p. 1321–1330.

- HOLM, S. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, v. 6, n. 2, p. 65–70, 1979.
- JOACHIMS, T. Text categorization with support vector machines: learning with many relevant features. In: *EUROPEAN CONFERENCE ON MACHINE LEARNING*, 10., 1998, Chemnitz. *Proceedings [...]*. Berlin: Springer, 1998. p. 137–142.
- KEJRIWAL, M.; SANTOS, H.; SHEN, K.; MULVEHILL, A. M.; MCGUINNESS, D. L. A noise audit of human-labeled benchmarks for machine commonsense reasoning. *Scientific Reports*, v. 14, art. 8609, 2024.
- KOHAVI, R. A study of cross-validation and bootstrap for accuracy estimation and model selection. In: *INTERNATIONAL JOINT CONFERENCE ON ARTIFICIAL INTELLIGENCE*, 14., 1995, Montreal. *Proceedings [...]*. San Francisco: Morgan Kaufmann, 1995. p. 1137–1143.
- LANDIS, J. R.; KOCH, G. G. The measurement of observer agreement for categorical data. *Biometrics*, v. 33, n. 1, p. 159–174, 1977.
- LIN, J. Divergence measures based on the Shannon entropy. *IEEE Transactions on Information Theory*, v. 37, n. 1, p. 145–151, 1991. DOI: 10.1109/18.61115.
- LI, Y.; LIU, Y.; ZHANG, J.; CAO, L.; WANG, Q. Automated analysis and assignment of maintenance work orders using natural language processing. *Automation in Construction*, v. 165, art. 105501, 2024.
- LIU, Z.; BENGE, C.; JIANG, S. Ticket-BERT: labeling incident management tickets with language models. *arXiv:2307.00108*, 2023.
- MARCUZZO, M.; ZANGARI, A.; GIUDICE, L.; GASPARETTO, A.; SCHIAVINATO, M.; ALBARELLI, A. A multi-level approach for hierarchical Ticket Classification. In: *PROCEEDINGS OF THE 8TH WORKSHOP ON NOISY USER-GENERATED TEXT (W-NUT 2022)*, 2022. *Anais [...]*. Association for Computational Linguistics, 2022. p. 201–214.
- MARTINS, R. F. B.; ESPEJO, M. M. S. B. Análise de custos de manutenção predial em uma universidade federal brasileira com uso do modelo de SES. *ABCustos*, São Leopoldo, v. 19, n. 1, p. 79–98, 2024.
- MCNEMAR, Q. Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, v. 12, n. 2, p. 153–157, 1947.
- MOHAMMED, A. S.; AMOAH, C. Integration of technology in decision-making in university facilities management: a literature review. *Facilities*, v. 43, n. 13/14, p. 1018–1052, 2025.
- MORAIS, L. S. R. de; PAULA, H. M. de; REIS, R. P. A. Promoção da eficiência da manutenção predial em edificações públicas: abordagem baseada em registros de ordens de serviço. *Paranoá*, Brasília, v. 16, n. 34, p. 1–18, 2023. DOI: 10.18830/issn.1679-0944.n34.2023.08.
- NEMENYI, P. B. Distribution-free multiple comparisons. 1963. Tese (Doutorado em Estatística) — Princeton University, Princeton, 1963.
- NOMA, H.; SHINOZAKI, T.; IBA, K.; TERAMUKAI, S.; FURUKAWA, T. A. Confidence intervals of prediction accuracy measures for multivariable prediction models based on the bootstrap-based optimism correction methods. *Statistics in Medicine*, v. 40, n. 26, p. 5691–5701, 2021.
- ODUM, H. T. *Environment, power, and society*. New York: Wiley-Interscience, 1971.
- PAMPANA, A. K. et al. Data-driven analysis for facility management in higher education institution. *Buildings*, v. 12, art. 2094, 2022.
- PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.
- PLATT, J. C. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. In: SMOLA, A. J. et al. (Ed.). *Advances in Large Margin Classifiers*. Cambridge: MIT Press, 1999. p. 61–74.

- SALTON, G.; BUCKLEY, C. Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, v. 24, n. 5, p. 513–523, 1988.
- SCHWARTZ, R.; DODGE, J.; SMITH, N. A.; ETZIONI, O. Green AI. *Communications of the ACM*, v. 63, n. 12, p. 54–63, 2020.
- SHANNON, C. E. A mathematical theory of communication. *Bell System Technical Journal*, v. 27, n. 3, p. 379–423, jul. 1948; v. 27, n. 4, p. 623–656, out. 1948.
- SOKOLOVA, M.; LAPALME, G. A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, v. 45, n. 4, p. 427–437, 2009.
- SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. BERTimbau: pretrained BERT models for Brazilian Portuguese. In: *BRAZILIAN CONFERENCE ON INTELLIGENT SYSTEMS*, 9., 2020. *Proceedings [...]*. Cham: Springer, 2020. p. 403–417. DOI: 10.1007/978-3-030-61377-8_28.
- SUNDARAM, S.; ZEID, A. Technical Language Processing for Prognostics and Health Management: applying text similarity and topic modeling to maintenance work orders. *Journal of Intelligent Manufacturing*, v. 36, p. 1637–1657, 2025.
- TREVISIO, M. et al. Efficient methods for Natural Language Processing: a survey. *Transactions of the Association for Computational Linguistics*, v. 11, p. 826–860, 2023.
- VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; KAISER, L.; POLOSUKHIN, I. Attention is all you need. In: *Advances in Neural Information Processing Systems 30 (NIPS 2017)*. Red Hook: Curran Associates, 2017. p. 5998–6008.
- WONGPAKARAN, N.; WONGPAKARAN, T.; WEDDING, D.; GWET, K. L. A comparison of Cohen’s Kappa and Gwet’s AC1 when calculating inter-rater reliability coefficients: a study conducted with personality disorder samples. *BMC Medical Research Methodology*, v. 13, art. 61, 2013.
- ZHANG, H.; ZHANG, Y.; LI, J.; LIU, J.; JI, L. A survey on learning with noisy labels in Natural Language Processing: how to train models with label noise. *Engineering Applications of Artificial Intelligence*, v. 146, art. 110157, 2025.

APÊNDICE A — CATEGORIAS DO CORPUS E DAS PARTIÇÕES

A Tabela A1 apresenta as 50 categorias históricas presentes nos 14.060 chamados da base congelada, ordenadas por frequência decrescente e distribuídas em dois blocos paralelos para reduzir a extensão do apêndice. As Tabelas A2 e A3 decompõem o denominador das métricas: a primeira lista as 41 categorias que sustentaram suporte nas cinco dobras e compõem as 13.972 linhas avaliadas, e a segunda, as 9 que ficaram de fora.

Tabela A1 Distribuição dos chamados por categoria histórica.

Categoria histórica	Quantidade	Categoria histórica	Quantidade
Manutenção Preventiva > Ar condicionado split	1.798	Manutenção Preventiva > Sistemas de combate a incêndio (extintores, hidrantes)	66
Climatização > Ar condicionado split	1.640	Estrutura Predial > Pintura	58
Estrutura Predial > Alvenaria / Pisos / Estrutura	1.302	Instalação de Acessórios e Mobiliário > Placas de identificação	54
Hidrossanitária > Hidráulica	1.282	Manutenção Preventiva > Telhados, calhas, rufos, etc.	44
Manutenção Preventiva > Gerador	1.215	TI / Dados / Rede > Coleta de dados	40
Estrutura Predial > Esquadrias, porta, portão e janelas	977	Elétrica > Gerador	38
Elétrica > Instalações elétricas	945	Hidrossanitária > Bomba	38
Elétrica > Iluminação	758	Climatização > Ar condicionado central	37
Manutenção Preventiva > Quadros Elétricos	578	Manutenção Preventiva > Esgoto	33
TI / Dados / Rede > Ponto de rede / fibra ótica / Wi-fi	404	Manutenção Preventiva > Hidráulica	33
Instalação de Acessórios e Mobiliário > Instalação/reparo de equipamentos (Suportes de TV, acessórios de banheiro e quadro branco)	290	Outros > Outros	33
Manutenção Preventiva > Reservatório	279	Segurança contra Incêndio > Sistemas de combate a incêndio (extintores, hidrantes)	29
Manutenção Preventiva > Vistoria em Instalações	247	Projetos e Reformas > Projeto	25
Outros > Erro de chamado	245	Equipamentos de Transporte > Elevador	22
Estrutura Predial > Infiltração	215	Elétrica > Subestação	18
Estrutura Predial > Telhados, calhas, rufos, etc.	207	Hidrossanitária > ETA / ETE	16
Manutenção Preventiva > Ar condicionado central	165	Suprimentos / Apoio Técnico > Limpeza de equipamentos, ambiente e mobiliário	14
Estrutura Predial > Forro	146	Manutenção Preventiva > Poços artesianos	13
Manutenção Preventiva > Iluminação	132	Manutenção Preventiva > Nobreak	10
Elétrica > Nobreak	128	Elétrica > Sistema Fotovoltaico (FV)	7
Área Externa e Ambiental > Manutenção área externa / meio ambiente / Poda de árvore / Roçagem	109	Área Externa e Ambiental > Drenagem	4
Posto de trabalho > Contratação de Posto de trabalho	102	Estrutura Predial > Instalações Especiais (gás, ar comprimido, etc.)	3
Manutenção Preventiva > Elevador	86	Manutenção Preventiva > Aplicação cupinizada	3
Suprimentos / Apoio Técnico > Materiais	85	Manutenção Preventiva > Bomba	3
Projetos e Reformas > Reforma	83	Suprimentos / Apoio Técnico > Transporte	1
Total geral	14.060		

Fonte: elaboração própria a partir do corpus analisado.

Tabela A2 Categorias da referência revisada avaliadas na rodada, por tipo de manutenção e classe da curva ABC interna ao tipo (n = 13.972; 41 categorias). O percentual é relativo ao volume do próprio tipo e o F1 corresponde ao LinearSVC. P, preventiva; C, corretiva; NM, não manutenção. Enquadram-se em não manutenção as famílias que não descrevem serviço de manutenção predial, a saber, Outros, Suprimentos / Apoio Técnico, Posto de trabalho e Projetos e Reformas. A família TI / Dados / Rede permanece em manutenção corretiva por consistir predominantemente em reparo de infraestrutura predial.

Categoria de referência	Tipo	n	% do tipo	Classe	F1
Preventiva	P	4.902	100,00		
Manutenção Preventiva > Ar condicionado split	P	1.987	40,53	A	0,9972
Manutenção Preventiva > Gerador	P	1.208	24,64	A	0,9954
Manutenção Preventiva > Quadros Elétricos	P	578	11,79	A	0,9843
Manutenção Preventiva > Reservatório	P	318	6,49	A	0,9139
Manutenção Preventiva > Vistoria em Instalações	P	244	4,98	B	0,9419
Manutenção Preventiva > Ar condicionado central	P	168	3,43	B	0,9970
Manutenção Preventiva > Iluminação	P	132	2,69	B	0,9535
Manutenção Preventiva > Elevador	P	86	1,75	B	0,9655
Manutenção Preventiva > Sistemas de combate a incêndio (extintores, hidrantes)	P	66	1,35	C	0,8905
Manutenção Preventiva > Telhados, calhas, rufos, etc.	P	44	0,90	C	0,2162
Manutenção Preventiva > Esgoto	P	31	0,63	C	0,4286
Manutenção Preventiva > Hidráulica	P	27	0,55	C	0,0000
Manutenção Preventiva > Poços artesianos	P	13	0,27	C	1,0000
Corretiva	C	8.485	100,00		
Climatização > Ar condicionado split	C	1.448	17,07	A	0,9550
Hidrossanitária > Hidráulica	C	1.263	14,89	A	0,8651
Estrutura Predial > Alvenaria / Pisos / Estrutura	C	1.138	13,41	A	0,4610
Estrutura Predial > Esquadrias, porta, portão e janelas	C	1.003	11,82	A	0,8712
Elétrica > Instalações elétricas	C	909	10,71	A	0,7248
Elétrica > Iluminação	C	764	9,00	A	0,8901
TI / Dados / Rede > Ponto de rede / fibra ótica / Wi-fi	C	412	4,86	A	0,7173
Instalação de Acessórios e Mobiliário > Instalação/reparo de equipamentos (Suportes de TV, acessórios de banheiro e quadro branco)	C	405	4,77	B	0,4730
Estrutura Predial > Telhados, calhas, rufos, etc.	C	203	2,39	B	0,4962
Estrutura Predial > Infiltração	C	202	2,38	B	0,6493
Estrutura Predial > Forro	C	168	1,98	B	0,7746
Elétrica > Nobreak	C	150	1,77	B	0,7855
Área Externa e Ambiental > Manutenção área externa / meio ambiente / Poda de árvore / Roçagem	C	103	1,21	C	0,6288
Instalação de Acessórios e Mobiliário > Placas de identificação	C	69	0,81	C	0,6494
Estrutura Predial > Pintura	C	60	0,71	C	0,5890
Elétrica > Gerador	C	43	0,51	C	0,7723
Hidrossanitária > Bomba	C	43	0,51	C	0,7238
Climatização > Ar condicionado central	C	33	0,39	C	0,7324
Segurança contra Incêndio > Sistemas de combate a incêndio (extintores, hidrantes)	C	29	0,34	C	0,4815
Equipamentos de Transporte > Elevador	C	21	0,25	C	0,7692
Elétrica > Subestação	C	19	0,22	C	0,6061
Não manutenção	NM	585	100,00		
Outros > Erro de chamado	NM	258	44,10	A	0,3978
Posto de trabalho > Contratação de Posto de trabalho	NM	102	17,44	A	0,9561
Suprimentos / Apoio Técnico > Materiais	NM	96	16,41	A	0,4790
Projetos e Reformas > Reforma	NM	65	11,11	A	0,2407
Outros > Outros	NM	28	4,79	B	0,3404
Projetos e Reformas > Projeto	NM	23	3,93	B	0,0000
Suprimentos / Apoio Técnico > Limpeza de equipamentos, ambiente e mobiliário	NM	13	2,22	C	0,0909
Total avaliado		13.972			

As nove categorias restantes da taxonomia não sustentam suporte nas cinco dobras e ficam fora das partições, conforme o critério da Subseção 3.5. Somam 88 linhas, ou 0,63% da base congelada, e estão discriminadas na Tabela A3 para que a diferença entre os dois denominadores permaneça auditável.

Tabela A3 Categorias fora das partições canônicas.

Categoria de referência	Linhas	Motivo da exclusão
TI / Dados / Rede > Coleta de dados	40	ausente de ao menos uma dobra após a estratificação
Hidrossanitária > ETA / ETE	15	ausente de ao menos uma dobra após a estratificação
Manutenção Preventiva > Nobreak	9	ausente de ao menos uma dobra após a estratificação
Elétrica > Sistema Fotovoltaico (FV)	7	ausente de ao menos uma dobra após a estratificação
Estrutura Predial > Instalações Especiais (gás, ar comprimido, etc.)	5	ausente de ao menos uma dobra após a estratificação
Área Externa e Ambiental > Drenagem	4	suporte insuficiente para as cinco dobras
Manutenção Preventiva > Aplicação cupinicida	3	suporte insuficiente para as cinco dobras
Manutenção Preventiva > Bomba	3	suporte insuficiente para as cinco dobras
Suprimentos / Apoio Técnico > Transporte	2	suporte insuficiente para as cinco dobras
Total	88	

Fonte: elaboração própria a partir do corpus analisado.