

CLASSIFICAÇÃO AUTOMÁTICA MULTIMODELO DE CHAMADOS DE MANUTENÇÃO PREDIAL UNIVERSITÁRIA EM PORTUGUÊS BRASILEIRO: PROTOCOLO DE GOVERNANÇA PREDITIVA COM VALIDAÇÃO HUMANA SOB RÓTULOS HISTÓRICOS RUÍDOSOS

Multi-model automatic classification of university building maintenance work orders in Brazilian Portuguese: a predictive governance protocol with human validation under noisy historical labels

Adinailson Guimarães de Oliveira - adinailson.oliveira@cja.ufsb.edu.br **Fabício Berton Zanchi** - fabricao.berton@ufsb.edu.br

Universidade Federal do Sul da Bahia (UFSB), Programa de Pós-Graduação em Biossistemas

RESUMO

A classificação automática de chamados de manutenção predial constitui recurso estratégico para a qualificação da triagem operacional e para a ampliação da governança baseada em evidências em instituições públicas. Contudo, em bases históricas de sistemas informatizados de gestão de chamados, a categoria originalmente registrada não deve ser tratada como verdade absoluta, uma vez que pode refletir decisões operacionais ruidosas, taxonomias sobrepostas, registros incompletos e interpretações heterogêneas entre equipes de atendimento. O presente artigo propõe um protocolo multimodelo para classificação de chamados reais de manutenção predial universitária em português brasileiro, extraídos do sistema GLPI da Universidade Federal do Sul da Bahia. O experimento utiliza 13.965 chamados não vazios, organizados em 55 categorias históricas, e compara classificadores clássicos baseados em TF-IDF (Naive Bayes, Regressão Logística, LinearSVC, SGD, Random Forest e Extra Trees) e rede neural LSTM bidirecional. O BERTimbau permanece como extensão planejada, sem treino concluído ou métrica própria nesta consolidação. O diferencial metodológico reside na distinção entre concordância com o histórico administrativo e acerto validado por revisão humana, tratando a categoria histórica como referência preliminar imperfeita. A avaliação humana cobre 9.534 chamados, com 9.044 decisões travadas e 52 conflitos explicitamente excluídos da verdade validada. Como a seleção não é aleatória e prioriza divergências e casos críticos, esses resultados não estimam o desempenho da base completa (COCHRAN, 1977). O LinearSVC lidera tanto a concordância com o histórico (80,31%, IC95%: 79,63%–80,97%) quanto o acerto validado (95,02%, IC95%: 94,58%–95,46%), enquanto o LSTM apresenta concordância de 67,18% e acerto validado de 88,11%. A normalidade da concordância por turno foi rejeitada para todos os modelos, justificando testes não paramétricos. O custo computacional é incorporado como dimensão de avaliação, evidenciando que modelos lineares podem oferecer melhor relação entre desempenho e viabilidade operacional em cenários de texto curto, ruidoso e desbalanceado.

Palavras-chave: manutenção predial; classificação de chamados; processamento de linguagem natural; rótulos ruidosos; validação humana; governança preditiva.

ABSTRACT

Automatic classification of building maintenance work orders is a strategic resource for operational triage and evidence-based governance in public institutions. Historical labels, however, may reflect noisy decisions, overlapping taxonomies, incomplete records and heterogeneous interpretations. This paper proposes a multi-model protocol for 13,965 real university building-maintenance work orders in Brazilian Portuguese, organized into 55 historical categories. The comparison includes TF-IDF-based classifiers and a bidirectional LSTM; BERTimbau remains a planned extension without completed fine-tuning. The methodological contribution is the explicit distinction between agreement with administrative history and accuracy against human-validated decisions. Human review covers 9,534 records, with 9,044 locked decisions and 52 conflicts excluded from the validated ground truth. Because the reviewed sample is non-random and prioritizes disagreements and critical cases, the results do not estimate performance over the complete database. LinearSVC leads both historical agreement (80.31%, 95% CI: 79.63%–80.97%) and human-validated accuracy (95.02%, 95% CI: 94.58%–95.46%), whereas LSTM achieves 67.18% historical agreement and 88.11% validated accuracy. Normality is rejected for all models, supporting non-parametric comparisons. Computational cost is included as an evaluation dimension, indicating that linear models provide a favorable balance between performance and operational feasibility for short, noisy and imbalanced technical text.

Keywords: *building maintenance; work-order classification; natural language processing; noisy labels; human validation; predictive governance.*

1. INTRODUÇÃO

Um campus universitário pode ser descrito como um biosistema construído: a integração dinâmica entre infraestrutura física, atividade humana, sistemas tecnológicos e condicionantes ambientais, cuja persistência ao longo do tempo depende de mecanismos de retroalimentação contínua entre uso, falha e reparo (CAPRA, 1996; ODUM, 1971). A ecologia urbana descreve esse tipo de sistema como um organismo em troca permanente de matéria, energia e informação com seu entorno, cuja governança bem-sucedida depende da capacidade institucional de captar sinais operacionais e convertê-los em decisão (GRIMM *et al.*, 2008). Em instituições federais de ensino superior (IFES), esse sinal assume, na prática, a forma de registros textuais de chamados de manutenção predial — a matéria-prima do *feedback* operacional do biosistema construído. Esses registros, no entanto, nascem aprisionados em linguagem não estruturada, fragmentária e sujeita a interpretação individual no momento do atendimento, o que impede seu uso direto por qualquer mecanismo de decisão automatizada (MORAIS; PAULA; REIS, 2023; MOHAMMED; AMOAH, 2025).

A exploração analítica dessas bases enfrenta ao menos três obstáculos estruturais, agravados pela restrição orçamentária que historicamente limita o custeio da manutenção predial em IFES a patamares inferiores a 2% do orçamento institucional (MARTINS; ESPEJO, 2024; PAMPANA *et al.*, 2022). O primeiro é a natureza textual curta, heterogênea e frequentemente incompleta dos registros: chamados de manutenção predial são redigidos em linguagem técnica fragmentária, com abreviações locais e jargões de equipe que dificultam a aplicação direta de modelos genéricos de processamento de linguagem natural (PLN) (SUNDARAM; ZEID, 2025). O segundo é o desbalanceamento entre categorias: demandas recorrentes de climatização, elétrica e hidrossanitária concentram grande parte da base, enquanto categorias raras dispõem de poucos exemplos para treinamento supervisionado (LI *et al.*, 2024). O terceiro, talvez o mais crítico do ponto de vista metodológico, é a qualidade do próprio rótulo histórico: a categoria registrada no momento do chamado pode resultar de interpretação rápida, conveniência operacional ou taxonomia ainda não estabilizada, de modo que o histórico administrativo constitui evidência importante, mas não verdade absoluta (ZHANG *et al.*, 2025; KEJRIWAL *et al.*, 2024).

A literatura recente sobre mineração textual de ordens de manutenção confirma a relevância de técnicas de PLN para transformar registros textuais em insumos de gestão. Li *et al.* (2024) demonstraram, em base hospitalar com 15.623 ordens de serviço, que a atribuição automática de equipes por PLN alcança acurácia de 0,83, reduzindo substancialmente a dependência de triagem manual. Sundaram e Zeid (2025) analisaram registros de *Maintenance Work Orders* sob a abordagem de *Technical Language Processing*, argumentando que textos técnicos de manutenção funcionam como *black holes* informacionais quando armazenam dados relevantes sem serem efetivamente utilizados na tomada de decisão. Bouabdallaoui *et al.* (2020), por sua vez, aplicaram modelos de PLN à classificação de requisições de manutenção em edificação hospitalar, reportando acurácia média de 78% com múltiplos métodos de representação textual. Contudo, a maior parte dessas aplicações concentra-se em bases em inglês ou chinês e em domínios industriais ou hospitalares, configurando lacuna relevante para corpora em português brasileiro no contexto da manutenção predial pública universitária.

Diante desse quadro, a pergunta que orienta este capítulo não é qual classificador mais concorda com a categoria histórica, mas outra, mais ampla e mais alinhada à função de governança que esses dados devem cumprir: como extrair, de forma confiável e auditável, dado estruturado a partir de texto ruidoso, de modo que esse dado possa alimentar um sistema de governança preditiva sem herdar acriticamente os erros do próprio histórico que lhe deu origem? Rótulos ruidosos em PLN não apenas reduzem o desempenho de classificadores, como também podem ampliar o consumo de recursos computacionais necessários para tratá-los (ZHANG *et al.*, 2025); mais importante, *benchmarks* anotados por humanos frequentemente carregam variabilidade relevante, o que torna questionável a prática de tratar qualquer rótulo — humano ou histórico — como verdade absoluta e não sujeita a julgamento (KEJRIWAL *et al.*, 2024). A classificação automática apresentada neste capítulo é, portanto, a primeira camada de um protocolo maior — não seu produto final: uma camada que precisa produzir dado auditável o bastante para que divergências entre inteligência artificial e histórico administrativo sejam tratadas como evidência de revisão taxonômica, não como ruído a ser descartado.

Com base em chamados reais da Universidade Federal do Sul da Bahia (UFSB), este capítulo propõe uma

comparação multimodelo de classificadores de texto aplicada a chamados de manutenção predial em português brasileiro. A base experimental contém 13.965 chamados não vazios, distribuídos em 55 categorias históricas; os campos textuais considerados agregam título e descrição do chamado, além de informações associadas à ordem de serviço. O estudo compara modelos clássicos baseados em TF-IDF (Naive Bayes, Regressão Logística, LinearSVC, SGD, Random Forest e Extra Trees) com uma rede neural LSTM bidirecional; o BERTimbau é mantido como extensão planejada, mas não integra as comparações enquanto não houver treino concluído e métricas próprias rastreáveis. O objeto de avaliação, portanto, não é o classificador isolado, mas o protocolo de governança preditiva que articula aprendizado de máquina, auditoria estatística, custo computacional e validação humana — em consonância com a manutenção baseada em evidências preconizada pela NBR 5674 (ABNT, 2012) e com a integração físico-humano-tecnológico-ambiental que caracteriza um biossistema construído.

Os objetivos específicos deste capítulo são: (i) apresentar um protocolo de classificação automática que produza dado estruturado auditável a partir de texto livre, como primeira camada de um sistema de governança preditiva; (ii) distinguir concordância com rótulo histórico de acerto validado, evitando equiparar categoria histórica a *ground truth* incontestável; (iii) avaliar desempenho por métricas globais, métricas balanceadas, intervalos de confiança e testes estatísticos pareados adequados a dados não normais; (iv) incorporar custo computacional como dimensão de decisão operacional; e (v) transformar divergências entre inteligência artificial e histórico em evidência para revisão taxonômica e retroalimentação da base de treino.

2. REFERENCIAL CONCEITUAL

2.1 Processamento de linguagem natural em ordens de manutenção

Ordens de manutenção constituem registros operacionais com valor informacional elevado, porém usualmente subutilizado. Elas documentam sintomas, locais, equipamentos, procedimentos, materiais e soluções executadas, acumulando-se ao longo de anos em sistemas informatizados cuja forma textual e semiestruturada dificulta o uso direto em planejamento e alocação de recursos (PAMPANA *et al.*, 2022; MORAIS; PAULA; REIS, 2023). Li *et al.* (2024) propuseram estrutura baseada em PLN para análise e atribuição automática de ordens de manutenção hospitalar, utilizando 15.623 registros de hospital municipal em Xangai e reportando acurácia de 0,83 na tarefa de atribuição de trabalhadores, resultado que evidencia a possibilidade de automatizar processos antes dependentes de triagem manual em contextos prediais. Esse trabalho constitui referência-âncora para a presente pesquisa por tratar diretamente da automação de ordens de manutenção predial, embora em idioma, tipologia institucional e estrutura taxonômica distintos.

Sundaram e Zeid (2025), ao analisar registros textuais de *Maintenance Work Orders* sob a abordagem de *Technical Language Processing*, defenderam que textos técnicos de manutenção funcionam como repositórios informacionais subutilizados quando não integrados a processos decisórios. Essa perspectiva é especialmente pertinente à manutenção predial universitária, na qual chamados curtos, abreviações locais, nomes de ambientes e descrições incompletas dificultam o uso de modelos genéricos sem adaptação ao domínio. Bouabdallaoui *et al.* (2020) reportaram acurácia média de 78% na classificação de requisições de manutenção predial hospitalar utilizando múltiplos métodos de PLN, resultado que reforça a viabilidade da abordagem, mas também evidencia a necessidade de adaptação lexical e semântica ao corpus específico.

2.2 Classificação de tickets e evolução dos modelos

A classificação automática de *tickets* em ambientes de suporte técnico e ITSM evoluiu de representações vetoriais baseadas em frequência lexical para *embeddings* e modelos de linguagem pré-treinados. Liu, Bengue e Jiang (2023) propuseram o Ticket-BERT para rotulagem de *tickets* de incidentes, enfatizando desafios como atualização contínua de rótulos e necessidade de aprendizado ativo. Entretanto, a transferência direta de achados do ITSM para a manutenção predial deve ser cautelosa, pois a semântica do domínio envolve sistemas físicos, ambientes e equipamentos prediais que não coincidem com categorias de incidentes de *software* ou infraestrutura digital (SUNDARAM; ZEID, 2025).

Modelos lineares com TF-IDF continuam competitivos em tarefas de texto curto, especialmente quando o corpus é de porte médio, o vocabulário possui alta especificidade técnica e as classes são desbalanceadas (GALKE; SCHERP, 2022). Nesses cenários, modelos profundos podem não compensar seu custo computacional caso não disponham de volume suficiente, balanceamento adequado ou *embeddings* fortemente adaptados

ao domínio. Galke e Scherp (2022), em revisão comparativa abrangente de métodos para classificação textual, demonstraram que classificadores baseados em *bag-of-words* com TF-IDF e SVM permanecem altamente competitivos frente a redes neurais em múltiplos *benchmarks*, sobretudo quando o corpus é reduzido ou o vocabulário é altamente especializado. Esse achado é particularmente relevante para o contexto institucional de manutenção predial, onde a base operacional raramente atinge escala compatível com as exigências de modelos de linguagem de grande porte.

2.3 Rótulos ruidosos e verdade operacional

O problema de rótulos ruidosos é central em aprendizado supervisionado aplicado a bases administrativas. Em classificação textual, ruído de rótulo pode decorrer de ambiguidade semântica, polissemia, insuficiência de contexto, sobreposição taxonômica, julgamento subjetivo ou erro humano de registro (ZHANG *et al.*, 2025). Conforme levantamento de Zhang *et al.* (2025), rótulos ruidosos em PLN afetam o desempenho dos modelos e podem ampliar o consumo de recursos, exigindo métodos robustos de tratamento de ruído. Kejriwal *et al.* (2024) reforçam que *benchmarks* rotulados por humanos podem conter variabilidade relevante, questionando a prática de assumir uma única verdade absoluta quando há julgamento subjetivo envolvido. No contexto do presente artigo, a categoria histórica do chamado é tratada como referência administrativa, não como verdade final, e a verdade operacional deve ser construída por validação humana com registro explícito da decisão tomada.

2.4 Custo computacional e eficiência em PLN

A avaliação de modelos de PLN tem sido tradicionalmente orientada por métricas de desempenho, mas a literatura recente enfatiza que custo computacional, tempo de treino, consumo energético e reprodutibilidade também devem compor a decisão de adoção (TREVISIO *et al.*, 2023; SCHWARTZ *et al.*, 2020). Treviso *et al.* (2023) argumentam que a ampliação de escala em PLN tende a aumentar o consumo de dados, tempo, armazenamento e energia, motivando métodos eficientes especialmente em contextos de recursos limitados. Schwartz *et al.* (2020) cunharam o conceito de *Green AI*, propondo que a eficiência computacional seja reportada e valorizada na avaliação de modelos, não apenas a acurácia. Em uma instituição pública, essa dimensão é operacionalmente decisiva: um modelo que treina em segundos pode ser reexecutado frequentemente, auditado com facilidade e mantido sem infraestrutura dedicada, ao passo que um modelo que demanda dezenas de minutos exige *checkpoint*, controle de versão de pesos e justificativa robusta de ganho marginal (TREVISIO *et al.*, 2023).

3. MÉTODO

3.1 Delineamento geral

O estudo adota delineamento experimental aplicado, com base observacional retrospectiva de chamados de manutenção predial registrados no sistema GLPI institucional da UFSB, universidade multicampi com unidades em Itabuna, Ilhéus, Porto Seguro e Teixeira de Freitas (MORAIS; PAULA; REIS, 2023). A unidade de análise é o chamado individual de manutenção, representado por campos textuais concatenados e por uma categoria histórica registrada no sistema. O fluxo metodológico compõe-se de oito etapas sequenciais: (i) extração e consolidação da base; (ii) higienização textual; (iii) construção da matriz de atributos; (iv) treinamento e inferência multimodelo; (v) geração de predições *out-of-fold*; (vi) comparação preliminar com categoria histórica; (vii) análise estatística não paramétrica; e (viii) validação humana das divergências e amostras críticas. A Figura 1 apresenta esse fluxo como *pipeline* de governança preditiva.

Figura 1 Pipeline de governança preditiva: fluxo metodológico completo, da extração da base à retroalimentação por validação humana.

Fonte: elaborado pelos autores (2026), a partir do fluxo metodológico descrito nesta subseção.

3.2 Corpus e variáveis

O corpus experimental é composto por 13.965 chamados de manutenção predial não vazios, organizados em 55 categorias históricas, extraídos do ambiente institucional da UFSB. Os campos textuais previstos no protocolo incluem título do chamado, descrição GLPI, título da ordem de serviço e descrição da ordem de serviço, concatenados em uma única representação textual para fins de classificação. A categoria histórica é utilizada como referência preliminar de comparação, mas a avaliação conclusiva depende da base validada por revisão




Figura 1: Figura 1 — Pipeline de governança preditiva: fluxo metodológico completo, da extração da base à retroalimentação por validação humana.

humana. O idioma dos registros é português brasileiro, com presença significativa de jargões técnicos, nomes de ambientes, abreviações locais e descrições incompletas, características que impõem desafios específicos de pré-processamento e representação textual (SUNDARAM; ZEID, 2025).

A base é dinâmica: novos chamados continuam sendo sincronizados e classificados em turnos, e a taxonomia institucional pode ser revisada ao longo do tempo. Os resultados da Seção 4 utilizam sempre o recorte mais recente disponível; eventuais diferenças frente a consolidações anteriores refletem o crescimento da base e a ampliação da conferência humana, não uma mudança metodológica.

3.3 Pré-processamento textual

O pré-processamento textual foi documentado de modo reproduzível, uma vez que pequenas decisões sobre normalização podem alterar a matriz de atributos e, consequentemente, o desempenho dos modelos (SALTON; BUCKLEY, 1988). Para os classificadores clássicos, a representação principal é TF-IDF com n -gramas de uma e duas palavras e limite superior de 5.000 atributos para controle de dimensionalidade. Para o modelo neural LSTM, são utilizadas tokenizações específicas com vocabulário de 8.000 termos e comprimento máximo de sequência adequado à distribuição textual da base. Cabe ressaltar que a etapa de pré-processamento não elimina indiscriminadamente termos técnicos, códigos de ambientes, nomes de equipamentos ou expressões recorrentes da equipe, pois esses elementos possuem alto valor discriminativo em manutenção predial, onde palavras como *bomba*, *split*, *disjuntor*, *vazamento*, *infiltração* e *ar-condicionado* podem funcionar como âncoras semânticas relevantes para categorias específicas.

3.4 Modelos avaliados

O desenho experimental compara sete modelos materializados, organizados em três famílias conceituais, cada uma escolhida por um motivo específico ligado às características do domínio: texto curto, vocabulário técnico e forte desbalanceamento entre categorias (Subseção 3.2).

A família **linear** (LinearSVC, Regressão Logística e SGD) opera diretamente sobre a representação TF-IDF esparsa (Subseção 3.3): em espaços de alta dimensionalidade, fronteiras lineares tendem a separar bem as classes quando o vocabulário carrega forte poder discriminativo (JOACHIMS, 1998; SALTON; BUCKLEY, 1988), como é o caso dos termos técnicos de manutenção predial, que funcionam como âncoras semânticas de categoria. A família de **ensembles de árvores** (Random Forest e Extra Trees) captura interações não lineares entre atributos, a um custo computacional maior. O **Naive Bayes Multinomial** entra como *baseline* probabilístico mais simples, útil para calibrar a expectativa de desempenho mínimo (JOACHIMS, 1998; PEDREGOSA *et al.*, 2011). A **rede neural** (LSTM Bidirecional) modela dependências sequenciais no texto, mas, nesta consolidação, treina seus *embeddings* do zero, sem incorporar vetores pré-treinados em português (GRAVES; SCHMIDHUBER, 2005) — a Subseção 3.4.1 discute por que essa escolha tende a penalizar o desempenho em corpora de porte médio como o deste estudo. Todos os sete modelos são avaliados

tanto na comparação *out-of-fold* (Subseção 4.1) quanto na Etapa 1 oficial de produção, onde a LSTM opera com *fallback* para Random Forest quando a base rotulada disponível é insuficiente.

Um oitavo modelo, o transformador pré-treinado em português BERTimbau, permanece como extensão planejada: seu ajuste fino depende do avanço da base validada e, nesta consolidação, o treino ainda não foi concluído — por isso o modelo não integra tabelas, rankings, testes inferenciais nem conclusões comparativas deste capítulo.

3.4.1 Diferenças conceituais e operacionais entre os classificadores

Os sete modelos comparáveis desta consolidação cobrem quatro famílias com suposições distintas sobre os dados: um gerador probabilístico (Naive Bayes), discriminadores lineares (LinearSVC, Regressão Logística, SGD), *ensembles* não lineares baseados em árvores (Random Forest, Extra Trees) e uma rede neural sequencial (LSTM). Cada família responde de forma diferente a um corpus de texto curto, ruidoso e com forte desbalanceamento entre categorias (Subseção 3.2; Tabela S1), o que ajuda a explicar por que o desempenho não é uniforme entre elas nas Tabelas 1 e 2.

O **LinearSVC** otimiza uma fronteira de decisão linear por margem máxima sobre a representação TF-IDF esparsa de até 5.000 atributos (Subseção 3.3). Em espaços esparsos de alta dimensionalidade, classificadores lineares tendem a separar bem as classes quando o vocabulário carrega forte poder discriminativo (JOACHIMS, 1998; SALTON; BUCKLEY, 1988) — como ocorre aqui, em que termos técnicos do domínio (*bomba*, *split*, *disjuntor*, *vazamento*, *infiltração*, *ar-condicionado*; Subseção 3.3) funcionam como âncoras semânticas de categoria. Essa combinação é consistente com o LinearSVC liderando tanto a concordância com o histórico (0,8031; Tabela 1) quanto o acerto validado (0,9502; Tabela 2).

O **Naive Bayes** assume independência condicional entre atributos dado a classe — suposição estrutural que tende a ser violada em texto de manutenção predial, onde termos técnicos co-ocorrem de forma sistemática dentro de uma mesma categoria. Essa divergência entre a suposição do modelo e a estrutura real dos dados é uma explicação plausível para o Naive Bayes ocupar a última posição tanto na concordância com o histórico (0,6997; Tabela 1) quanto no acerto validado (0,8627; Tabela 2), sem que isso indique um problema de implementação — é o comportamento esperado do modelo mais simples da comparação.

Random Forest e **Extra Trees** capturam interações não lineares entre atributos por meio da estrutura de árvores, mas em espaços esparsos de alta dimensionalidade como o TF-IDF tendem a ajustar-se demais às co-ocorrências mais frequentes, o que se reflete no desempenho intermediário de ambos nas Tabelas 1 e 2 (entre o LinearSVC e o Naive Bayes). O custo computacional dessa família também é o mais alto entre os modelos clássicos medidos: 19,45 s (Random Forest) e 21,30 s (Extra Trees) de treino por lote de 1.000 registros, entre 7,6 e 8,4 vezes o tempo do LinearSVC (2,55 s) e entre 17,1 e 18,7 vezes o do Naive Bayes (1,14 s) no mesmo lote (Tabela 7) — um custo que só se justifica se revertido em ganho de acerto validado, o que não se confirma nesta consolidação (SCHWARTZ *et al.*, 2020; TREVISIO *et al.*, 2023).

A **LSTM Bidirecional** foi projetada para modelar dependências sequenciais no texto, mas nesta consolidação seus *embeddings* são inicializados aleatoriamente e treinados do zero — não há incorporação de vetores pré-treinados em português. A camada de *embedding* (8.000 termos $\times$ 128 dimensões) concentra sozinha cerca de 1,02 milhão de parâmetros, uma ordem de grandeza próxima do número de exemplos disponíveis por partição de treino nesta consolidação (13.965 chamados, dos quais cerca de 11.172 compõem cada partição de treino em $k=5$ *folds*; Subseção 3.5) — um cenário consistente com a hipótese de que modelos lineares tendem a igualar ou superar redes neurais em corpora de porte médio e ruidosos quando não há *embeddings* pré-treinados disponíveis no idioma (GALKE; SCHERP, 2022), sem que isso configure uma falha da arquitetura em si (Subseção 4.9 detalha a investigação da discrepância do *ablation* do LSTM).

Na Etapa 1 oficial de produção — distinta da comparação *out-of-fold* desta seção —, o mecanismo de *fallback* opera no nível da base de treino, não por chamado individual: a LSTM só é treinada quando a base rotulada disponível atinge um mínimo de 200 exemplos; abaixo desse limiar, um classificador Random Forest sobre TF-IDF é usado no lugar da rede neural para toda a base naquele momento. Um segundo critério, sem relação com essa troca de modelo, classifica a confiança de cada predição em três faixas (abaixo de 70%, entre 70% e 95%, acima de 95%), usadas para priorização de conferência humana e para as métricas de calibração da Subseção 4.4.

3.5 Desenho de avaliação

A avaliação foi realizada por predições fora da amostra em protocolo *out-of-fold* com *KFold* embaralhado (5 partições, semente fixa) e mesma partição determinística para todos os modelos. A partição não é estratificada; esta é uma limitação do desenho implementado. O procedimento reduz viés de comparação e permite testes pareados (SOKOLOVA; LAPALME, 2009). As métricas principais são acurácia, *macro-F1*, *F1* ponderado, *balanced accuracy* e intervalo de confiança por *bootstrap* — reamostragem com reposição para estimar a distribuição de uma estatística sem pressupor sua forma paramétrica (EFRON, 1979; EFRON; TIBSHIRANI, 1993), cuja variedade de métodos de construção de intervalo (percentil, BCa, *bootstrap-t*) e respectivas propriedades de cobertura é revisada em detalhe por DiCiccio e Efron (1996) — com 95% de confiança.

A *macro-F1* e a *balanced accuracy* são essenciais face ao desbalanceamento entre categorias, dado que a acurácia isolada pode superestimar desempenho em classes majoritárias e mascarar falhas em categorias raras (SOKOLOVA; LAPALME, 2009). A correlação entre confiança e acerto é avaliada por Spearman (SPEARMAN, 1904) e por correlação ponto-bisserial, apropriada quando uma das variáveis é binária (TATE, 1954); diferenças globais entre os sete classificadores são avaliadas por Cochran Q, teste não paramétrico para proporções pareadas em três ou mais condições (COCHRAN, 1950), e por Friedman, teste baseado em postos que dispensa o pressuposto de normalidade da ANOVA (FRIEDMAN, 1937); comparações pareadas são avaliadas por McNemar (MCNEMAR, 1947); e incerteza de acurácia é estimada por *bootstrap* (EFRON, 1979), abordagem cuja utilidade para intervalos de confiança de métricas de modelos preditivos continua sendo estudada e refinada recentemente (NOMA *et al.*, 2021).

Quando múltiplas comparações são realizadas, aplica-se o teste de Nemenyi sobre os postos médios (NEMENYI, 1963), seguindo o protocolo consolidado por Demšar (2006) para comparação estatística de classificadores em múltiplos conjuntos de dados — protocolo cujas limitações já foram apontadas por trabalho mais recente: Benavoli, Corani e Mangili (2016) mostram que o teste de postos médios (base do Nemenyi) pode ser inconsistente e recomendam testes pareados diretos como complemento, razão pela qual este trabalho também reporta o McNemar par a par (Subseção 4.10) em vez de depender apenas do Nemenyi; comparações pareadas adicionais entre os sete modelos são corrigidas pelo método sequencial de Holm-Bonferroni, que controla a taxa de erro familiar sem o conservadorismo excessivo da correção de Bonferroni simples (HOLM, 1979).

Escolha entre validação cruzada e *holdout* fixo: optou-se deliberadamente por *k-fold out-of-fold* em vez de um conjunto de teste fixo separado antes do treino. A literatura de avaliação de modelos indica que a validação cruzada tende a produzir estimativas de menor variância que um único *holdout*, sobretudo em bases pequenas ou desbalanceadas, precisamente por avaliar cada exemplo em algum *fold* em vez de descartar uma fração fixa dos dados do treino (KOHAVI, 1995) — e esta base é desbalanceada por natureza, com várias das 55 categorias históricas tendo suporte de dígito único (Tabela Suplementar S1).

Essa recomendação foi verificada empiricamente, não apenas invocada em abstrato: comparou-se o protocolo *k-fold* com um *holdout* fixo de 15% sobre os sete modelos comparáveis e a mesma base completa. A tentativa de estratificar esse *holdout* por categoria — prática padrão na maioria dos protocolos — falhou de imediato, pois a base tem categorias com um único exemplo; no *holdout* aleatório que a substituiu, várias categorias raras ficaram sem nenhum exemplo de teste, tornando sua métrica de desempenho indefinida, um problema que o *k-fold* evita por avaliar todo exemplo em algum *fold* (Tabela Suplementar S1). A acurácia global variou pouco entre os dois protocolos, mas a *macro-F1* — que pondera todas as categorias igualmente, e não apenas as mais frequentes — piorou no *holdout* na maioria dos modelos (detalhamento completo na Tabela Suplementar S4). Em suma, um *holdout* fixo não melhora a estimativa de desempenho global nesta base e piora sistematicamente a avaliação das categorias raras — o padrão que a literatura antecipa para corpora pequenos e desbalanceados como este (KOHAVI, 1995), confirmando o *k-fold* como a escolha metodologicamente mais adequada, não apenas a mais conveniente.

3.6 Validação humana

A validação humana constitui a etapa que diferencia o presente estudo de uma simples comparação de classificadores contra histórico. A revisão registra, para cada caso auditado, a categoria histórica, a categoria sugerida por cada modelo, a confiança associada, a decisão humana e a categoria travada. A priorização recai sobre chamados em que há divergência entre modelos, alta confiança da IA contra histórico, baixa confiança

generalizada, classes raras e pares de categorias com alta confusão recíproca. A decisão humana pode produzir quatro resultados: manter o histórico; aceitar a sugestão do modelo; definir terceira categoria; ou marcar o caso como ambíguo ou taxonômico. Essa estrutura permite mensurar se a IA errou, se o histórico estava inconsistente ou se a própria taxonomia institucional necessita de revisão, em consonância com a perspectiva de que a verdade operacional deve ser construída progressivamente (ZHANG *et al.*, 2025).

3.7 Memória de decisão: veto e trava por chamado

À medida que a conferência humana avança, o protocolo incorpora uma memória de decisão por chamado, que evita o reprocessamento de casos já resolvidos e impede a repetição de erros já identificados. Quando a conferência confirma que uma categoria está correta, essa decisão é travada e reaproveitada diretamente nas rodadas seguintes de reclassificação, sem novo treinamento ou nova predição para aquele chamado. Quando a conferência identifica que uma categoria está incorreta, essa categoria passa a ser vetada especificamente para aquele chamado: os modelos do repositório de classificadores passam a escolher a melhor categoria alternativa fora do conjunto vetado, com a confiança renormalizada sobre as categorias remanescentes. Essa regra é aplicada de forma consistente na seleção de candidatos à reclassificação e no cálculo do ganho líquido, que passa a comparar o resultado da reclassificação contra a verdade validada quando ela está travada, e contra o histórico apenas quando ainda não há decisão humana. O objetivo metodológico da memória de decisão é impedir que o sistema corrija um erro apenas para reincidir nele em ciclos futuros, convertendo cada conferência manual em conhecimento persistente sobre o experimento, não em um evento isolado.

3.8 Camada de entropia de Shannon e divergência de Jensen-Shannon

Como dimensão complementar às métricas supervisionadas, o protocolo incorporou uma camada de análise informacional baseada em entropia de Shannon e divergência de Jensen-Shannon (SHANNON, 1948; LIN, 1991), calculada exclusivamente sobre os arquivos públicos e sanitizados do painel (sem identificador, título ou texto livre do chamado). Essa camada não substitui acurácia, calibração ou validação humana; responde a uma pergunta distinta, sobre onde modelos, categorias e chamados individuais concentram maior incerteza estrutural. No nível dos modelos, a entropia de Shannon sobre a distribuição de categorias previstas indica se um classificador dispersa suas predições por muitas classes ou as concentra excessivamente em poucas; a divergência de Jensen-Shannon mede a distância entre essa distribuição prevista e a distribuição histórica da base, funcionando como indicador de deslocamento distributivo. No nível das categorias, a entropia evidencia classes históricas cujas predições se espalham entre múltiplas categorias, sinalizando candidatas prioritárias a revisão taxonômica. No nível do chamado individual, a entropia de votos entre os modelos identifica registros em que há desacordo estrutural entre arquiteturas distintas, formando uma fila de auditoria orientada por ambiguidade, e não apenas por baixa confiança isolada de um único modelo.

3.9 Disponibilidade de dados e scripts

Os artefatos que sustentam os resultados relatados neste capítulo são gerados por um pipeline automatizado, reproduzido a cada nova consolidação do experimento. Nenhum identificador pessoal, título ou texto livre de chamado é armazenado nos agregados publicados; a camada Shannon/Jensen-Shannon (Subseção 3.8) opera exclusivamente sobre agregados sanitizados.

4. RESULTADOS

Esta seção apresenta dois conjuntos de resultados, deliberadamente segregados: a concordância com a categoria histórica (Subseção 4.1), que trata o registro do GLPI como referência preliminar, e o desempenho validado por conferência humana (Subseções 4.2 e 4.3). A base elegível contém 13.965 chamados; a conferência humana cobre 9.534 chamados (68,3% da base), dos quais 9.044 têm decisão travada (64,8% da base). Os 490 casos restantes não possuem verdade validada; esse conjunto inclui 52 conflitos entre fontes conferidas.

Três achados resumem esta seção. Primeiro, os classificadores lineares, liderados pelo LinearSVC, superam os ensembles de árvores e a rede neural LSTM em concordância e acerto validado, com vantagem adicional de custo computacional. Segundo, a validação humana confirma ruído real no rótulo histórico, justificando a conferência dupla. Terceiro, a faixa de confiança igual ou superior a 95% supera a meta de 95% de acerto validado na amostra conferida, mas a confiança permanece bruta e a seleção da amostra não é probabilística.

4.1 Concordância com o histórico (base completa)

A comparação contra a categoria histórica, sobre a base completa ($n = 13.965$), mantém o LinearSVC na liderança, com acurácia de 0,8031 (IC95%: 0,7963–0,8097), seguido por Extra Trees (0,7894), Random Forest (0,7816), SGD (0,7767), Regressão Logística (0,7682), Naive Bayes (0,6997) e LSTM (0,6718). O teste de Cochran Q confirma diferença global entre os sete modelos ($Q = 2984,066$; $p < 0,001$). O BERTimbau permanece excluído por não possuir treino concluído.

Tabela 1 Concordância com a categoria histórica, base completa ($n = 13.965$)

Modelo	Acurácia	IC95% bootstrap	Kappa vs. histórico
LinearSVC	0,8031	0,7963 – 0,8097	0,7881
Extra Trees	0,7894	0,7825 – 0,7961	0,7716
Random Forest	0,7816	0,7749 – 0,7881	0,7630
SGD	0,7767	0,7700 – 0,7835	0,7604
Regressão Logística	0,7682	0,7613 – 0,7751	0,7518
Naive Bayes	0,6997	0,6923 – 0,7071	0,6705
LSTM (out-of-fold)	0,6718	0,6637 – 0,6796	0,6496

Fonte: elaborado pelos autores (2026), com base nos agregados vigentes da comparação multimodelo.

A concordância com o histórico não é uniforme entre as 55 categorias. A Tabela Suplementar S1 reporta suporte, precisão, revocação e F1-Score por categoria. As cinco categorias com menor F1 são Elétrica > Sistema Fotovoltaico (FV) ($F1 = 0,0000$; suporte = 7), Manutenção Preventiva sem subcategoria ($F1 = 0,0000$; suporte = 2), Estrutura Predial > Instalações Especiais (gás, ar comprimido, etc.) ($F1 = 0,0732$; suporte = 3), Suprimentos / Apoio Técnico > Transporte ($F1 = 0,1053$; suporte = 1) e Área Externa e Ambiental > Drenagem ($F1 = 0,1333$; suporte = 3). As cinco categorias com maior F1 são Manutenção Preventiva > Extintor ($F1 = 1,0000$; suporte = 14), Manutenção Preventiva > Gerador ($F1 = 0,9908$; suporte = 1.211), Manutenção Preventiva > Sistemas de combate a incêndio (extintores, hidrantes) ($F1 = 0,9890$; suporte = 45), Manutenção Preventiva > Quadros Elétricos ($F1 = 0,9869$; suporte = 576) e Manutenção Preventiva > Ar condicionado central ($F1 = 0,9849$; suporte = 165). A leitura das categorias de menor F1 deve ser cautelosa porque quatro das cinco têm suporte menor ou igual a sete registros; nesses casos, uma pequena variação absoluta altera fortemente a métrica.

4.2 Ranking validado por conferência humana

A avaliação contra a verdade validada pela memória de decisão M/N/P ($n = 9.044$) mantém a liderança do LinearSVC, com acerto validado de 0,9502 (IC95%: 0,9458–0,9546). A ordenação completa é LinearSVC (95,02%), SGD (94,11%), Regressão Logística (93,71%), Extra Trees (92,86%), Random Forest (92,41%), LSTM (88,11%) e Naive Bayes (86,27%). A diferença entre o primeiro e o segundo colocado é de 0,91 ponto percentual, com McNemar $p = 5,70 \times 10^{-5}$. Os *ensembles* avaliados foram maioria ponderada (0,9467), confiança calibrada máxima (0,9458) e maioria simples (0,9445); nenhum supera o LinearSVC isolado. A recomendação permanece utilizar o LinearSVC com calibração, sem combinar modelos nesta consolidação.

Viés estrutural da seleção da amostra validada: a verdade validada só existe quando ao menos uma fonte conferida é confirmada como correta. Dos 9.534 chamados com alguma conferência, 490 não possuem categoria de referência, incluindo 52 conflitos. Por isso, o acerto validado é apresentado como limite superior, acompanhado de um limite inferior conservador que inclui todos esses casos no denominador como erros. A amplitude varia de 4,43% a 4,88%, sem alterar o ranking relativo dos sete modelos.

Tabela 2 Acerto validado contra a verdade decidida M/N/P ($n = 9.044$) e intervalo de sensibilidade

Modelo	Acerto validado (limite superior)	IC95%	Limite inferior (pior caso)
LinearSVC	0,9502	0,9458 – 0,9546	0,9014
SGD	0,9411	0,9363 – 0,9459	0,8927
Regressão Logística	0,9371	0,9321 – 0,9421	0,8889

Modelo	Acerto validado (limite superior)	IC95%	Limite inferior (pior caso)
Extra Trees	0,9286	0,9234 – 0,9335	0,8808
Random Forest	0,9241	0,9186 – 0,9295	0,8767
LSTM	0,8811	0,8743 – 0,8880	0,8359
Naive Bayes	0,8627	0,8558 – 0,8696	0,8183

Fonte: elaborado pelos autores (2026). O limite inferior é uma análise de pior caso; os conflitos e demais linhas sem verdade validada não recebem crédito para nenhum modelo.

A rematerialização completa também resolveu uma discrepância antes registrada entre o *ablation study* do LSTM (Subseção 4.9, 86,35%–87,68% conforme o particionamento) e o valor oficial então vigente: o valor antigo vinha de uma materialização desatualizada; o valor oficial atual do LSTM (0,8811) está muito mais próximo do que o *ablation* já indicava. Isso confirma que o *ablation* nunca teve um problema metodológico de vazamento residual relevante — a discrepância vinha da defasagem temporal da materialização de referência, não de uma falha do *ablation* em si; a ressalva de “resultado suspeito” da Figura 6 é mantida apenas como registro histórico da investigação, não como pendência ativa.

O patamar de acerto validado mudou de magnitude ao longo de consolidações sucessivas deste protocolo, por dois motivos distintos: primeiro, o crescimento genuíno da amostra validada revelou uma taxa de acerto real mais conservadora do que amostras menores — mais concentradas em casos fáceis de confirmar — sugeriam; segundo, uma materialização desatualizada dos modelos, já corrigida, havia subestimado o desempenho real numa consolidação intermediária. Como a seleção da conferência humana não é probabilística, a comparação entre consolidações continua sendo descritiva, não inferencial (COCHRAN, 1977); não é possível estimar, a partir dela, o desempenho da base completa.

4.3 A classificação oficial frente ao histórico: matriz de confusão validada

A classificação oficial e a categoria histórica foram comparadas contra a mesma verdade validada em 9.044 decisões. O histórico coincide com a decisão em 99,90%, enquanto a IA oficial coincide em 93,72%. A matriz contém 8.476 casos em que ambos acertam, 9 em que ambos divergem da decisão, 559 em que o histórico acerta e a IA erra e 0 em que a IA corrige o histórico.

Tabela 4 Matriz de confusão IA × histórico contra a verdade decidida (M/N/P) (n = 9.044)

	Histórico correto	Histórico incorreto
IA correta	8.476	0
IA incorreta	559	9

Fonte: elaborado pelos autores (2026), usando a mesma verdade decidida da Subseção 4.2.

4.4 Confiança, calibração e faixas de decisão

A calibração bruta da Etapa 1 oficial apresenta ECE histórico de 0,0656. Na faixa igual ou superior a 95% de confiança (n = 4.810), a concordância com o histórico é de 98,75% e o acerto validado alcança 99,94% sobre 4.675 decisões. A confiança permanece bruta, sem Platt, isotônica ou *temperature scaling*; portanto, a meta deve ser interpretada como diagnóstico da amostra conferida.

Tabela 3 Acerto validado por faixa de confiança bruta, executor oficial

Faixa	n total	Concord. histórico	n validados	Acerto validado
<50%	4.058	43,05%	880	51,93%
50-70%	1.443	75,12%	712	87,50%
70-80%	946	87,10%	653	96,78%

Faixa	n total	Concord. histórico	n validados	Acerto validado
80-90%	1.484	82,82%	1.065	97,84%
90-95%	1.224	95,59%	1.059	99,15%
>= 95%	4.810	98,75%	4.675	99,94%

Fonte: elaborado pelos autores (2026). O snapshot foi deduplicado por `linha_planilha`, mantendo a ocorrência mais recente. A amostra de conferência não é probabilística.

4.5 Reclassificação e ganho líquido

A reclassificação dos chamados já conferidos produz resultados heterogêneos entre modelos, medidos contra a verdade validada quando travada e contra o histórico nos demais casos. Nesta consolidação, o LSTM apresenta o maior ganho líquido absoluto (+99; 670 corrigidos e 571 prejudicados), seguido por Regressão Logística (+92) e LinearSVC (+73); todos os sete modelos materializados apresentam ganho líquido positivo. Esse resultado não autoriza aplicação indiscriminada: o ganho combina parcelas comparadas contra verdade validada e contra histórico, e já mudou de sinal para alguns modelos entre consolidações anteriores e esta. Reforça-se, portanto, a decisão de não aplicar reclassificação em massa por modelo, tratando o ganho líquido — e não apenas a acurácia agregada — como critério de decisão operacional a ser reavaliado a cada consolidação, não como veredito permanente sobre um classificador.

Tabela 5 Ganho líquido de reclassificação por modelo

Modelo	Total reclassificado	Corrigidos	Prejudicados	Ganho líquido	Reuso de decisão humana
LSTM	13.905	670	571	+99	8.805
Regressão Logística	13.932	245	153	+92	8.727
LinearSVC	13.965	291	218	+73	8.856
Random Forest	13.912	234	186	+48	8.719
SGD	13.965	201	163	+38	8.771
Naive Bayes	13.826	158	132	+26	8.623
Extra Trees	13.899	237	226	+11	8.713

Fonte: elaborado pelos autores (2026). *Nota metodológica:* o total reclassificado do Random Forest chegava a 18.049 nesta mesma tabela em versão anterior deste texto, valor que excedia o tamanho da base (13.965) — matematicamente impossível sob a premissa de uma linha por chamado. Um diagnóstico direto identificou 4.737 linhas duplicadas, concentradas no registro do Random Forest, enquanto o registro de referência (LinearSVC) não apresentou nenhuma duplicata — descartando erro de leitura genérico e localizando o problema especificamente nesse modelo. A causa raiz foi uma reenvio integral de lote após erro transitório de API de escrita, sem confirmação prévia de que o envio anterior já havia sido aceito; a agregação foi corrigida para deduplicar por identificador antes de contar, mantendo a última ocorrência. Os números atuais já refletem a remoção das 4.737 linhas duplicadas históricas.

4.6 Diagnóstico de taxonomia e ambiguidade estrutural (Shannon/Jensen-Shannon)

O diagnóstico de Shannon foi recalculado sobre oito fontes comparáveis: a Etapa 1 oficial e os sete modelos materializados. O BERTimbau foi excluído por não ter treino concluído. A Etapa 1 oficial apresenta a maior diversidade de categorias previstas e a menor divergência de Jensen-Shannon frente à distribuição histórica. No nível de chamado individual, 3.277 dos 13.965 registros (23,5%) apresentam alta entropia de votos entre as oito fontes, ou seja, desacordo estrutural relevante entre arquiteturas distintas — um critério de priorização de auditoria diferente e complementar à simples baixa confiança de um único modelo.

No nível de categoria, a análise aponta 76 ocorrências de alta ambiguidade nas predições (com suporte mínimo de 30 registros por categoria); a interpretação detalhada de quais categorias específicas concentram

essa ambiguidade, e sua sobreposição com os pares de maior confusão recíproca identificados na etapa de cruzamento de taxonomia, permanece como candidata a inspeção qualitativa dirigida futura. O que a camada Shannon oferece é a priorização estatística de onde essa inspeção deve começar, não a decisão de fusão ou desambiguação de categorias, que continua sendo humana. Naive Bayes chama atenção por combinar a menor cobertura de categorias (19, ante 47–53 dos demais modelos) com entropia normalizada relativamente alta (0,7848) — provável reflexo de concentração extrema em poucas categorias com alguma dispersão residual, não investigado em detalhe neste capítulo.

Tabela 6 Entropia de Shannon e divergência de Jensen-Shannon por fonte de classificação

Fonte	Categorias previstas	Entropia (nats)	Entropia normalizada	JS vs. histórico
Etapa 1 oficial	53	4,6758	0,8163	0,0286
LSTM	52	4,6201	0,8105	0,0847
Regressão Logística	52	4,4490	0,7805	0,0716
SGD	53	4,4363	0,7745	0,0639
LinearSVC	53	4,3356	0,7569	0,0575
Extra Trees	47	3,9955	0,7193	0,0761
Random Forest	47	3,9574	0,7124	0,0804
Naive Bayes	19	3,3340	0,7848	0,1755

Fonte: elaborado pelos autores (2026). O BERTimbau foi excluído explicitamente por não haver treino concluído. No nível de categoria, o resumo aponta 76 ocorrências de alta ambiguidade e 3.277 chamados com alta entropia de votos entre modelos.

4.7 Custo computacional

Nos recortes de comparação por lote (1.000 registros cada), os seis modelos clássicos tiveram tempos de treino entre 1,14 s e 21,30 s. Não há medição comparável de custo para LSTM ou BERTimbau nesta consolidação; portanto, não é possível ordenar o custo desses dois modelos frente aos demais. A tabela informa exclusivamente as medições disponíveis para os modelos clássicos.

Tabela 7 Custo computacional por lote de 1.000 registros

Modelo	Tempo de treino (s)	Tempo de inferência (s)	Acurácia neste lote
Naive Bayes	1,14	0,07	0,539
LinearSVC	2,55	0,06	0,655
SGD	2,60	0,09	0,624
Regressão Logística	9,43	0,09	0,624
Random Forest	19,45	0,13	0,597
Extra Trees	21,30	0,14	0,610

Fonte: elaborado pelos autores (2026), execução mais recente por modelo disponível — não reexecutada nesta consolidação; único registro de custo computacional disponível para os modelos clássicos. LSTM e BERTimbau não constam deste arquivo. A acurácia reportada aqui é sobre um lote de 1.000 registros (não a base completa) e serve só para contextualizar o trade-off custo×desempenho desta subseção — não usar como substituto das Tabelas 1 e 2.

4.8 Figuras

As figuras foram geradas a partir dos dados vigentes do painel público e dos registros de treino de cada modelo. A Figura 4 usa códigos de categoria para preservar a legibilidade; o mapeamento completo código-categoria está na Tabela Suplementar S2.




Figura 2: Figura 2 — Confiança bruta × concordância com o histórico × acerto validado, por faixa de confiança (executor oficial, Etapa 1).

Figura 2 Confiança bruta × concordância com o histórico × acerto validado, por faixa de confiança (executor oficial, Etapa 1). Mesmos números da Tabela 3 (Subseção 4.4), em forma gráfica.

Fonte: elaborado pelos autores (2026).

Figura 3 Trade-off entre acerto validado (conferência humana) e custo computacional (tempo de treino, lote de 1.000 registros), modelos clássicos. LSTM e BERTimbau não constam desta figura por não terem registro de tempo de treino no mesmo arquivo (Tabela 7, Subseção 4.7).

Fonte: elaborado pelos autores (2026), cruzando custo computacional e acerto validado.

Figura 4 Top 15 pares de maior confusão entre categorias. O par mais recorrente foi Climatização > Ar condicionado → Manutenção Preventiva > Ar condicionado split (1.310 ocorrências agregadas), seguido por Instalação de Acessórios e Mobiliário > Instalação/reparo de equipamentos (Suportes de TV, acessórios de banheiro e quadro branco) → Estrutura Predial > Alvenaria / Pisos / Estrutura (799) e Estrutura Predial > Alvenaria / Pisos / Estrutura → Estrutura Predial > Esquadrias, porta, portão e janelas (726). Os códigos C01-C10 usados no eixo vertical são descritos na Tabela Suplementar S2.

Fonte: elaborado pelos autores (2026).

Figura 5 Curva real de aprendizado do LSTM, com 13.965 exemplos e 53 categorias. O treino foi interrompido por EarlyStopping após 11 épocas. O menor val_loss ocorreu na época 8 (val_loss = 1,4374; accuracy = 0,7073; val_accuracy = 0,6492), enquanto o maior val_accuracy ocorreu na época 10 (val_accuracy = 0,6722; val_loss = 1,4767).

Fonte: elaborado pelos autores (2026).

Figura 6 Ablation study do LSTM: quatro variantes de unidades recorrentes (64/128) e dropout (0,3/0,5),




Figura 3: Figura 3 — Trade-off entre acerto validado e custo computacional (tempo de treino), modelos clássicos.




Figura 4: Figura 4 — Top 15 pares de maior confusão entre categorias, agregados a partir dos top pares por modelo.




Figura 5: Figura 5 — Curva de aprendizado do LSTM por época.




Figura 6: Figura 6 — Ablation study do LSTM: unidades recorrentes e dropout.

avaliadas por `GroupKFold` contra a verdade validada humana. Discussão completa da investigação da discrepância deste *ablation* na Subseção 4.9.

Fonte: elaborado pelos autores (2026).

4.9 Investigação da discrepância do *ablation* do LSTM

Uma auditoria investigou por que o *ablation* da Figura 6 reportava acerto validado muito acima do valor oficial então vigente para a mesma arquitetura do LSTM. Duas causas foram identificadas. Primeiro, um vazamento metodológico real, mas de magnitude modesta: no *KFold* aleatório por linha usado originalmente, 4.250 de 9.096 linhas validadas de teste (46,72%) tinham duplicata textual normalizada no treino. O *ablation* foi refeito com *GroupKFold* por hash de texto normalizado, excluindo do treino grupos textuais presentes no teste — isso reduziu a configuração atual (64 unidades, *dropout* de 0,5) de 87,68% para 86,35% (7.854/9.096), uma correção pequena (1,33 ponto percentual). Esses denominadores pertencem à coorte congelada do estudo de ablação e não devem ser confundidos com a contagem corrente de decisões travadas. Segundo, e principal: o valor oficial de referência usado na comparação (0,7471, Subseção 4.2) vinha de uma materialização desatualizada em relação à base viva. A rematerialização completa dos sete modelos (ver Subseção 4.2) produziu um novo valor oficial do LSTM de 0,8811 — muito mais próximo dos 0,8635 deste *ablation* corrigido (diferença residual de 1,76 pontos percentuais, plausivelmente atribuível a diferenças remanescentes de protocolo entre o número de *folds* e o esquema de treino usados em cada avaliação).

Conclusão: o *ablation* nunca teve um problema metodológico grave; a maior parte da discrepância original vinha de comparar um resultado fresco com uma referência oficial desatualizada. A ordenação relativa das quatro variantes testadas — variando número de unidades recorrentes e taxa de *dropout* — é interpretada como evidência preliminar de baixa sensibilidade do LSTM a esses hiperparâmetros nesta base (diferença total entre a melhor e a pior variante inferior a 4 pontos percentuais), não como indicação forte de que a arquitetura atual esteja subotimizada.

Fonte: elaborado pelos autores (2026).

4.10 Robustez estatística: pressupostos e testes de sensibilidade

Antes de qualquer teste inferencial, verificamos os pressupostos de robustez estatística usuais — outliers,

homogeneidade de variância, normalidade, desbalanceamento entre categorias, colinearidade entre modelos, relação entre confiança e acerto, e independência das observações —, adaptando o protocolo de exploração de dados de Zuur, Ieno e Elphick (2010) da resposta contínua da ecologia para a resposta categórica de classificação de chamados ($n = 13.965$). O teste de Shapiro-Wilk (SHAPIRO; WILK, 1965) rejeita a normalidade a 5% para os sete modelos sobre a concordância por turno, confirmando com números a justificativa não paramétrica já adotada na Subseção 3.5; a variância de confiança entre modelos também é fortemente heterogênea, reforçando essa escolha. O teste de Friedman (FRIEDMAN, 1937) confirma diferença global entre os modelos comparáveis, e o *post-hoc* de Nemenyi (NEMENYI, 1963) reproduz a mesma ordem das Tabelas 1 e 2, com poder estatístico menor que o McNemar par a par (MCNEMAR, 1947) — que, corrigido por Holm-Bonferroni (HOLM, 1979), é significativo em praticamente todas as 21 comparações entre os sete modelos, confirmando que o **LinearSVC é estatisticamente superior ao LSTM e ao Naive Bayes** (a única exceção, sem significância, é o par SGD vs. Random Forest). A verificação de colinearidade mostra um efeito colateral relevante: quatro dos sete modelos têm confiança altamente correlacionada entre si (Fator de Inflação de Variância elevado; MARQUARDT, 1970), o que ajuda a explicar por que nenhum *ensemble* supera o LinearSVC isolado (Subseção 4.2) — modelos redundantes contribuem pouco em informação independente a um comitê (DIETTERICH, 2000). A correlação entre confiança bruta e acerto é positiva e significativa em todos os sete modelos (Spearman e ponto-bisserial, $p < 0,001$), pré-requisito para a calibração discutida na Subseção 4.4 (GUO *et al.*, 2017). A verificação completa dos oito pressupostos, item a item, com as tabelas de correlação, autocorrelação e o Kappa de Fleiss entre modelos, está disponível como Material Suplementar.

5. DISCUSSÃO

A comparação entre concordância histórica e desempenho validado mantém o LinearSVC na liderança: 95,02% de acerto validado na amostra decidida e 80,31% de concordância com o histórico. A conferência humana não é aleatória e prioriza divergências e casos críticos; assim, os resultados descrevem a amostra conferida, não a população completa (COCHRAN, 1977).

A regra de decisão exclui do denominador os 490 chamados sem verdade validada (5,14% dos conferidos), conjunto que inclui 52 conflitos. A análise de sensibilidade mantém o ranking dos sete modelos, mas mostra que o valor pontual de acerto validado é um limite superior e não deve ser comparado isoladamente a benchmarks externos.

Ainda assim, a distinção entre concordância e acerto validado continua metodologicamente necessária. Na matriz IA $\times$ histórico da Subseção 4.3, o histórico acerta e a IA erra em 559 casos, enquanto a IA corrige o histórico em 0 casos. Há ainda 9 casos em que ambos divergem da decisão, correspondentes a 0,10% de erro confirmado no rótulo histórico entre as decisões válidas. Essa proporção descreve a amostra conferida e não deve ser generalizada para a base completa. A validação humana permanece indispensável para distinguir erro do modelo, erro histórico e conflito taxonômico.

Na amostra conferida, o LinearSVC lidera tanto a concordância histórica quanto o acerto validado (Subseções 4.1 e 4.2). Isso descreve o resultado desta base e desta amostra, sem demonstrar superioridade generalizável de classificadores lineares sobre arquiteturas neurais. A comparação de custo também permanece restrita aos seis modelos clássicos da Tabela 7. Os três ensembles avaliados não superam o LinearSVC isolado; a recomendação é manter o classificador linear com calibração.

O resultado da reclassificação (Subseção 4.5) deve ser interpretado por modelo e por consolidação. Todos os modelos apresentam ganho líquido positivo (Naive Bayes, Regressão Logística, LinearSVC, SGD, Extra Trees, Random Forest, LSTM). O ganho combina comparações contra verdade validada e contra histórico; por isso, não autoriza reclassificação indiscriminada nem constitui veredito permanente sobre um classificador.

A camada de entropia de Shannon e divergência de Jensen-Shannon (Subseção 4.6) não substitui as métricas supervisionadas ou a validação humana, mas amplia o repertório de governança do experimento ao separar três fenômenos que a acurácia isolada tende a confundir: erro de modelo, ambiguidade genuína da taxonomia institucional e heterogeneidade natural da distribuição de chamados. A identificação de 3.277 chamados (23,5% da base) com alto desacordo estrutural entre as oito fontes comparáveis (Etapa 1 oficial e os sete modelos materializados) oferece um critério de priorização de auditoria distinto do simples corte por baixa confiança de um único classificador, e complementa a fila já construída a partir da conferência M/N/P. O achado de que a Etapa 1 oficial, não o LSTM isolado, lidera tanto a diversidade de predições quanto a menor

divergência frente ao histórico (Subseção 4.6) descreve o resultado desta consolidação. Esse diagnóstico não substitui acurácia ou validação humana.

A faixa igual ou superior a 95% de confiança da Etapa 1 oficial alcança 99,94% de acerto validado sobre 4.675 decisões. O resultado supera a meta nominal de 95% nesta amostra, mas não encerra a validação: a confiança é bruta e 4.921 chamados (35,2% da base) ainda não possuem decisão travada.

Limitações

As limitações deste estudo organizam-se em três dimensões.

Quanto à cobertura, os dados provêm de uma única instituição federal de ensino superior, com textos em português brasileiro e taxonomia institucional própria; a generalização do desempenho relatado para outras instituições, taxonomias ou idiomas depende de validação externa ainda não realizada.

Quanto à validação, a amostra conferida por avaliadores humanos não é probabilística — prioriza divergências entre modelo e histórico e casos de maior criticidade —, de modo que os números de acerto validado devem ser lidos como descrição da amostra conferida, não como estimativa inferencial do desempenho da base completa (COCHRAN, 1977). Uma regra de decisão adicional exclui do denominador de acerto validado os casos em que nenhuma fonte conferida foi confirmada como correta (5,14% dos chamados conferidos, incluindo 52 conflitos); a análise de sensibilidade correspondente mostra uma amplitude de poucos pontos percentuais entre o cenário mais otimista e o mais conservador, sem alterar o ranking relativo entre os modelos.

Quanto ao modelo, o BERTimbau — único classificador contextual testado neste protocolo — não teve o ajuste fino concluído até esta consolidação e foi excluído de todas as comparações; de forma mais geral, classificadores neurais sem *embeddings* pré-treinados de domínio tendem a ser penalizados por bases de porte médio como a analisada aqui, o que é consistente com o desempenho relativamente inferior do LSTM frente aos modelos lineares. Persiste também, como limitação operacional, a dependência de uma única instituição como caso empírico.

Papel no modelo de governança preditiva

Este capítulo constitui o Eixo 1 de um modelo mais amplo de governança preditiva para manutenção predial, que trata o campus universitário como um biossistema construído — a integração entre infraestrutura física, atividade humana, sistemas tecnológicos e condicionantes ambientais. A contribuição central não termina na categoria atribuída a cada chamado: os dados estruturados e auditáveis produzidos aqui (categoria, criticidade, confiança bruta e indicadores de calibração) são a entrada necessária para três desenvolvimentos subsequentes do mesmo programa de pesquisa. Primeiro, alimentam modelos de séries temporais (ARIMA, suavização exponencial) para previsão de custos e demanda de manutenção por categoria. Segundo, compõem a base factual de uma matriz multicritério (MCDM/TOPSIS) que prioriza intervenções segundo critérios de sustentabilidade técnica, ambiental, social e institucional (ESG/ODS). Terceiro, tornam-se espacializáveis via geoprocessamento (Google Earth Engine), permitindo leitura territorial do biossistema construído. Sem uma camada confiável e auditável de classificação — o objeto deste capítulo —, nenhum desses três desenvolvimentos teria dado de entrada válido; este capítulo entrega, portanto, a fundação de dados sobre a qual o modelo de governança preditiva se torna possível.

6. CONSIDERAÇÕES FINAIS

O presente capítulo consolida um protocolo multimodelo de classificação de chamados de manutenção predial universitária em português brasileiro, com sete modelos comparáveis, memória de decisão por validação humana e análise de incerteza informacional. O BERTimbau permanece como extensão planejada, sem ajuste fino concluído ou métricas próprias. A contribuição central é produzir dado estruturado e auditável para a governança preditiva, distinguindo concordância com o histórico de acerto contra decisões humanas.

Na amostra parcial e não probabilística de 9.044 decisões travadas, o LinearSVC obteve 95,02%, seguido por SGD (94,11%), Regressão Logística (93,71%), Extra Trees (92,86%), Random Forest (92,41%), LSTM (88,11%) e Naive Bayes (86,27%). Nenhum dos três ensembles supera o LinearSVC isolado; a recomendação é utilizar o LinearSVC com calibração. Os 52 conflitos permanecem fora da verdade validada até revisão humana específica.

A faixa de confiança igual ou superior a 95% da classificação oficial apresenta 99,94% de acerto validado. O valor supera a meta nominal na amostra conferida, mas a confiança ainda é bruta e 4.921 chamados não possuem decisão travada; portanto, o resultado não autoriza liberação automática irrestrita em produção.

A curva real de aprendizado do LSTM (Subseção 4.9, Figura 5) é consistente com o restante do capítulo. A discrepância do *ablation* do mesmo modelo (Figura 6), discutida em detalhe na Subseção 4.9, não indica arquitetura mal ajustada: com a causa principal corrigida, a ordenação relativa das quatro variantes testadas mostra baixa sensibilidade do LSTM a unidades e *dropout* nesta base (diferença entre melhor e pior variante inferior a 4 pontos percentuais).

Os próximos passos deste protocolo incluem a conclusão da conferência humana pendente (35,2% da base ainda sem decisão travada), a calibração formal por modelo (Platt, isotônica ou temperatura) condicionada a essa conferência, o treino e a avaliação comparativa do BERTimbau, a revisão taxonômica dirigida pelos candidatos identificados na etapa de cruzamento de taxonomia e na entropia de Shannon, e a estabilização da publicação automática do painel de acompanhamento.

Como direções de trabalho futuro mais amplas, este protocolo também aponta para: (i) a validação externa do modelo em outras instituições federais de ensino superior, testando se o padrão de desempenho observado na UFSB se mantém sob taxonomias e volumes de chamados distintos; e (ii) a integração dos dados de chamados tratados e validados como entrada para um modelo multicritério (MCDM/TOPSIS) de priorização de manutenção, conectando este capítulo empírico à lacuna, já identificada na literatura de revisão integrativa correlata, sobre o uso raro de dados operacionais de chamados nesse tipo de modelo. Com isso, o protocolo pretende seguir contribuindo tanto para a literatura de *facility management* e processamento de linguagem natural aplicado quanto para a melhoria concreta e auditável da gestão de manutenção predial em instituições públicas.

Contribuições dos autores: conceituação, Oliveira e Zanchi; metodologia, software, análise formal, investigação, curadoria de dados e redação do rascunho original, Oliveira; redação — revisão e edição, Oliveira e Zanchi; supervisão e administração do projeto, Zanchi. Todos os autores leram e concordaram com a versão publicada do manuscrito.

Financiamento: esta pesquisa não recebeu financiamento externo.

Comitê de ética e consentimento informado: não se aplica. O estudo não envolveu pesquisa com seres humanos, procedimento clínico ou divulgação de dados pessoais; analisa registros institucionais de chamados de manutenção (títulos e descrições operacionais curtos) e decisões internas de conferência de qualidade tomadas pela equipe no exercício de suas funções rotineiras, não um protocolo experimental com participantes humanos.

Disponibilidade de dados: os dados de chamados de manutenção analisados neste estudo têm origem no sistema institucional GLPI da Universidade Federal do Sul da Bahia (UFSB) e não estão publicamente disponíveis, por restrição de privacidade e confidencialidade institucional. As métricas derivadas e o código utilizados para produzir cada figura, tabela e estatística deste artigo são de acesso público, disponibilizados pelos autores em repositório de código aberto.

Agradecimentos: os autores agradecem à Universidade Federal do Sul da Bahia pelo apoio institucional.

Conflitos de interesse: os autores declaram não haver conflitos de interesse.

REFERÊNCIAS

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. ABNT NBR 5674: Manutenção de edificações: Requisitos para o sistema de gestão de manutenção. Rio de Janeiro: ABNT, 2012.

BENAVOLI, A.; CORANI, G.; MANGILI, F. Should we really use post-hoc tests based on mean-ranks? *Journal of Machine Learning Research*, v. 17, n. 5, p. 1–10, 2016.

BOUABDALLAOUI, Y.; LAFHAJ, Z.; YIM, P.; DUCOULOMBIER, L.; BENNADJI, B. Natural Language Processing Model for Managing Maintenance Requests in Buildings. *Buildings*, v. 10, n. 9, art. 160, 2020.

- BOX, G. E. P.; JENKINS, G. M. Time series analysis: forecasting and control. San Francisco: Holden-Day, 1970.
- CAPRA, F. A teia da vida: uma nova compreensão científica dos sistemas vivos. São Paulo: Cultrix, 1996.
- CHAN, J. Y.-L.; LEOW, S. M. H.; BEA, K. T.; CHENG, W. K.; PHOONG, S. W.; HONG, Z.-W.; CHEN, Y.-L. Mitigating the multicollinearity problem and its machine learning approach: a review. *Mathematics*, v. 10, n. 8, art. 1283, 2022.
- COCHRAN, W. G. The comparison of percentages in matched samples. *Biometrika*, v. 37, n. 3-4, p. 256–266, 1950.
- COCHRAN, W. G. Sampling techniques. 3. ed. New York: John Wiley & Sons, 1977.
- DEMŠAR, J. Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, v. 7, p. 1–30, 2006.
- DICICCIO, T. J.; EFRON, B. Bootstrap confidence intervals. *Statistical Science*, v. 11, n. 3, p. 189–228, 1996.
- DIETTERICH, T. G. Ensemble methods in machine learning. In: INTERNATIONAL WORKSHOP ON MULTIPLE CLASSIFIER SYSTEMS, 1., 2000, Cagliari. Proceedings [...]. Berlin: Springer, 2000. p. 1–15. (Lecture Notes in Computer Science, v. 1857).
- DURBIN, J.; WATSON, G. S. Testing for serial correlation in least squares regression, I. *Biometrika*, v. 37, n. 3-4, p. 409–428, 1950.
- EFRON, B. Bootstrap methods: another look at the jackknife. *The Annals of Statistics*, v. 7, n. 1, p. 1–26, 1979.
- EFRON, B.; TIBSHIRANI, R. J. An introduction to the bootstrap. New York: Chapman & Hall/CRC, 1993.
- FLEISS, J. L. Measuring nominal scale agreement among many raters. *Psychological Bulletin*, v. 76, n. 5, p. 378–382, 1971.
- FRIEDMAN, M. The use of ranks to avoid the assumption of normality implicit in the analysis of variance. *Journal of the American Statistical Association*, v. 32, n. 200, p. 675–701, 1937.
- GALKE, L.; SCHERP, A. Bag-of-words vs. graph vs. sequence in text classification: questioning the necessity of text-graphs and the surprising strength of a wide MLP. In: ANNUAL MEETING OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS, 60., 2022, Dublin. Proceedings [...]. Dublin: ACL, 2022. p. 4038–4051.
- GRAVES, A.; SCHMIDHUBER, J. Framewise phoneme classification with bidirectional LSTM and other neural network architectures. *Neural Networks*, v. 18, n. 5-6, p. 602–610, 2005.
- GRIMM, N. B.; FAETH, S. H.; GOLUBIEWSKI, N. E.; REDMAN, C. L.; WU, J.; BAI, X.; BRIGGS, J. M. Global change and the ecology of cities. *Science*, v. 319, n. 5864, p. 756–760, 2008.
- GUO, C.; PLEISS, G.; SUN, Y.; WEINBERGER, K. Q. On calibration of modern neural networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 34., 2017, Sydney. Proceedings [...]. Sydney: PMLR, 2017. p. 1321–1330.
- HODGE, V. J.; AUSTIN, J. A survey of outlier detection methodologies. *Artificial Intelligence Review*, v. 22, n. 2, p. 85–126, 2004.
- HOLM, S. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, v. 6, n. 2, p. 65–70, 1979.
- JOACHIMS, T. Text categorization with support vector machines: learning with many relevant features. In: EUROPEAN CONFERENCE ON MACHINE LEARNING, 10., 1998, Chemnitz. Proceedings [...]. Berlin: Springer, 1998. p. 137–142.

- KEJRIWAL, M.; SANTOS, H.; SHEN, K.; MULVEHILL, A. M.; MCGUINNESS, D. L. A noise audit of human-labeled benchmarks for machine commonsense reasoning. *Scientific Reports*, v. 14, art. 8609, 2024.
- KOHAVI, R. A study of cross-validation and bootstrap for accuracy estimation and model selection. In: *INTERNATIONAL JOINT CONFERENCE ON ARTIFICIAL INTELLIGENCE*, 14., 1995, Montreal. Proceedings [...]. San Francisco: Morgan Kaufmann, 1995. p. 1137–1143.
- KORNBROT, D. Point biserial correlation. In: *Wiley StatsRef: Statistics Reference Online*. Chichester: Wiley, 2014.
- LANDIS, J. R.; KOCH, G. G. The measurement of observer agreement for categorical data. *Biometrics*, v. 33, n. 1, p. 159–174, 1977.
- LIMA, L. F. M.; MAROLDI, A. M.; SILVA, D. V. O. da; HAYASHI, C. R. M.; HAYASHI, M. C. P. I. Métricas científicas em estudos bibliométricos: detecção de outliers para dados univariados. *Em Questão*, Porto Alegre, v. 23, p. 254–273, 2017.
- LIN, J. Divergence measures based on the Shannon entropy. *IEEE Transactions on Information Theory*, v. 37, n. 1, p. 145–151, 1991. DOI: 10.1109/18.61115.
- LI, Y.; LIU, Y.; ZHANG, J.; CAO, L.; WANG, Q. Automated analysis and assignment of maintenance work orders using natural language processing. *Automation in Construction*, v. 165, art. 105501, 2024.
- LIU, Z.; BENGE, C.; JIANG, S. Ticket-BERT: labeling incident management tickets with language models. *arXiv:2307.00108*, 2023.
- MARQUARDT, D. W. Generalized inverses, ridge regression, biased linear estimation, and nonlinear estimation. *Technometrics*, v. 12, n. 3, p. 591–612, 1970.
- MARTINS, R. F. B.; ESPEJO, M. M. S. B. Análise de custos de manutenção predial em uma universidade federal brasileira com uso do modelo de SES. *ABCustos*, São Leopoldo, v. 19, n. 1, p. 79–98, 2024.
- MCNEMAR, Q. Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, v. 12, n. 2, p. 153–157, 1947.
- MINDERER, M.; DJOLONGA, J.; ROMIJNDERS, R.; HUBIS, F.; ZHAI, X.; HOULSBY, N.; TRAN, D.; LUCIC, M. Revisiting the calibration of modern neural networks. In: *CONFERENCE ON NEURAL INFORMATION PROCESSING SYSTEMS*, 35., 2021. *Advances in Neural Information Processing Systems*, v. 34, 2021.
- MOHAMMED, A. S.; AMOAH, C. Integration of technology in decision-making in university facilities management: a literature review. *Facilities*, v. 43, n. 13/14, p. 1018–1052, 2025.
- MORAIS, L. S. R. de; PAULA, H. M. de; REIS, R. P. A. Promoção da eficiência da manutenção predial em edificações públicas: abordagem baseada em registros de ordens de serviço. *Paranoá*, Brasília, v. 16, n. 34, p. 1–18, 2023. DOI: 10.18830/issn.1679-0944.n34.2023.08.
- NEMENYI, P. B. Distribution-free multiple comparisons. 1963. Tese (Doutorado em Estatística) — Princeton University, Princeton, 1963.
- NOMA, H.; SHINOZAKI, T.; IBA, K.; TERAMUKAI, S.; FURUKAWA, T. A. Confidence intervals of prediction accuracy measures for multivariable prediction models based on the bootstrap-based optimism correction methods. *Statistics in Medicine*, v. 40, n. 26, p. 5691–5701, 2021.
- O'BRIEN, R. M. A caution regarding rules of thumb for variance inflation factors. *Quality & Quantity*, v. 41, n. 5, p. 673–690, 2007.
- ODUM, H. T. *Environment, power, and society*. New York: Wiley-Interscience, 1971.
- OGUNLEYE, L. I.; OYEJOLA, B. A.; OBISESAN, K. O. Comparison of some common tests for normality. *International Journal of Probability and Statistics*, v. 7, n. 5, p. 130–137, 2018.
- PAMPANA, A. K. et al. Data-driven analysis for facility management in higher education institution. *Buildings*, v. 12, art. 2094, 2022.

- PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.
- PLATT, J. C. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. In: SMOLA, A. J. et al. (Ed.). *Advances in Large Margin Classifiers*. Cambridge: MIT Press, 1999. p. 61–74.
- RAZALI, N. M.; WAH, Y. B. Power comparisons of Shapiro-Wilk, Kolmogorov-Smirnov, Lilliefors and Anderson-Darling tests. *Journal of Statistical Modeling and Analytics*, v. 2, n. 1, p. 21–33, 2011.
- SALTON, G.; BUCKLEY, C. Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, v. 24, n. 5, p. 513–523, 1988.
- SCHWARTZ, R.; DODGE, J.; SMITH, N. A.; ETZIONI, O. Green AI. *Communications of the ACM*, v. 63, n. 12, p. 54–63, 2020.
- SHANNON, C. E. A mathematical theory of communication. *Bell System Technical Journal*, v. 27, n. 3, p. 379–423, jul. 1948; v. 27, n. 4, p. 623–656, out. 1948.
- SHAPIRO, S. S.; WILK, M. B. An analysis of variance test for normality (complete samples). *Biometrika*, v. 52, n. 3-4, p. 591–611, 1965.
- SOKOLOVA, M.; LAPALME, G. A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, v. 45, n. 4, p. 427–437, 2009.
- SPEARMAN, C. The proof and measurement of association between two things. *American Journal of Psychology*, v. 15, n. 1, p. 72–101, 1904.
- SUNDARAM, S.; ZEID, A. Technical Language Processing for Prognostics and Health Management: applying text similarity and topic modeling to maintenance work orders. *Journal of Intelligent Manufacturing*, v. 36, p. 1637–1657, 2025.
- TATE, R. F. Correlation between a discrete and a continuous variable. Point-biserial correlation. *The Annals of Mathematical Statistics*, v. 25, n. 3, p. 603–607, 1954.
- TREVISIO, M. et al. Efficient methods for Natural Language Processing: a survey. *Transactions of the Association for Computational Linguistics*, v. 11, p. 826–860, 2023.
- TUKEY, J. W. *Exploratory data analysis*. Reading: Addison-Wesley, 1977.
- WONGPAKARAN, N.; WONGPAKARAN, T.; WEDDING, D.; GWET, K. L. A comparison of Cohen’s Kappa and Gwet’s AC1 when calculating inter-rater reliability coefficients: a study conducted with personality disorder samples. *BMC Medical Research Methodology*, v. 13, art. 61, 2013.
- ZHANG, H.; ZHANG, Y.; LI, J.; LIU, J.; JI, L. A survey on learning with noisy labels in Natural Language Processing: how to train models with label noise. *Engineering Applications of Artificial Intelligence*, v. 146, art. 110157, 2025.
- ZUUR, A. F.; IENO, E. N.; ELPHICK, C. S. A protocol for data exploration to avoid common statistical problems. *Methods in Ecology and Evolution*, v. 1, n. 1, p. 3–14, 2010.

APÊNDICES

A estrutura completa dos dados, incluindo a arquitetura das planilhas e a memória de decisão, está disponível no repositório público do experimento.

Apêndice A — Checklist de itens reportados

Adaptado do espírito do checklist tipo PRISMA-ScR do artigo-modelo de revisão (MCDM/TOPSIS/ODS/ESG) para relato de experimento de classificação supervisionada com validação humana. Cada item indica a subseção onde é reportado e o status na data de publicação; **não substitui a reconferência de números antes da submissão** — os status “Sim” abaixo atestam que o item é reportado em algum lugar do texto, não que o número citado já foi revalidado contra os JSONs vigentes.

Item	Subseção	Reportado?
Fonte de dados e sistema de origem declarados	3.1, 3.2	Sim (GLPI/UFSB)
Tamanho da amostra e período/corte de consolidação	3.2	Sim, mas com data de corte a reconferir
Critério de inclusão/exclusão de registros	3.2	Parcial — “chamados não vazios” declarado; demais critérios não detalhados
Pré-processamento textual	3.3	Sim
Modelos avaliados e hiperparâmetros principais	3.4	Sim (7 materializados + 1 em extensão)
Justificativa conceitual das diferenças de desempenho entre modelos	3.4.1	Sim
Método de particionamento (out-of-fold, k-fold, seed)	3.5	Sim (out-of-fold, KFold embaralhado, <code>random_state=42</code> ; sem estratificação)
Justificativa da escolha k-fold vs. holdout fixo, com comparação empírica	3.5	Sim (KOHAVI, 1995; Tabela Suplementar S4)
Métricas reportadas e justificativa	3.5	Sim (acurácia, macro-F1, balanced accuracy, IC95% bootstrap)
Testes estatísticos e correção para múltiplas comparações	3.5, 4.10	Sim — resultados numéricos completos em 4.10
Verificação explícita de pressupostos (normalidade, homogeneidade, colinearidade, independência)	4.10	Sim — protocolo de Zuur, Ieno e Elphick (2010) adaptado; detalhamento completo em Material Suplementar
Critério de calibração de confiança (bruta vs. calibrada) e meta de desempenho	3.8, 4.4	Parcial — meta declarada ($\geq 95\%$ / $\geq 95\%$); calibração formal (Platt/isotônica) ainda não aplicada
Protocolo de validação humana	3.6	Sim
Cobertura da validação humana na data de publicação (n e % da base)	4 (abertura)	Sim, mas desatualizada — ver nota de revalidação de dados
Tratamento de conflitos de conferência	3.7	Sim (regra de veto/trava)
Reprodutibilidade (scripts e dados versionados)	3.9	Sim (repositório público, JSONs sanitizados)
Limitações declaradas	5, 6	Sim
Figuras/tabelas geradas a partir de dados verificáveis	4.8	Sim (scripts leem os JSONs vigentes do painel)

Apêndice B — Matriz de decisão M/N/P

Contagens agregadas disponíveis nos JSONs públicos do painel:

Métrica	n
Chamados com ao menos uma conferência (M, N ou P)	9.534
Decisões travadas (categoria decidida sem conflito)	9.096

Métrica	n
Casos restritos (categoria eliminada, sem decisão travada)	438
Conflitos (M e N confirmam categorias diferentes)	0
Conferências da coluna N (CONFERÊNCIA IA) preenchidas	9.096
Conferências da coluna M (CONFERÊNCIA GLPI) preenchidas	9.534
Conferências da coluna P (CONFERÊNCIA IA - 2) preenchidas	0

Fonte: elaborado pelos autores (2026). A coluna P (reclassificação conferida) está zerada nesta consolidação — nenhuma reclassificação foi conferida via essa coluna especificamente até o momento.

Pendência explícita: o cruzamento fino de 3 vias (contagem por combinação exata de valores de $M \times N \times P$ — ex.: quantos casos têm $M=Correto$ e $N=Errado$ simultaneamente) **não está disponível em nenhum JSON público atual** e exige extração direta da planilha experimental (**Informação insuficiente para verificar** com os dados hoje publicados). O que se aproxima disso é a matriz 2×2 IA $\times$ histórico da Tabela 4 (Subseção 4.3), que cruza acerto da IA e do histórico contra a verdade decidida — não é o mesmo cruzamento $M \times N \times P$ bruto, mas cobre a mesma pergunta de fundo (quando IA e histórico concordam ou divergem da decisão final).