

Sumário

CLASSIFICAÇÃO AUTOMÁTICA MULTIMODELO DE CHAMADOS DE MANUTENÇÃO PREDIAL UNIVERSITÁRIA EM PORTUGUÊS BRASILEIRO: PROTOCOLO DE GOVERNANÇA PREDITIVA COM VALIDAÇÃO HUMANA SOB RÓTULOS HISTÓRICOS RUIDOSOS

Multi-model automatic classification of university building maintenance work orders in Brazilian Portuguese: a predictive governance protocol with human validation under noisy historical labels

Adinailson Guimarães de Oliveira

Universidade Federal do Sul da Bahia (UFSB), Programa de Pós-Graduação em Biossistemas

E-mail: adinailson.oliveira@cja.ufsb.edu.br

RESUMO

A classificação automática de chamados de manutenção predial constitui recurso estratégico para a qualificação da triagem operacional e para a ampliação da governança baseada em evidências em instituições públicas. Contudo, em bases históricas de sistemas informatizados de gestão de chamados, a categoria originalmente registrada não deve ser tratada como verdade absoluta, uma vez que pode refletir decisões operacionais ruidosas, taxonomias sobrepostas, registros incompletos e interpretações heterogêneas entre equipes de atendimento. O presente artigo propõe um protocolo multimodelo para classificação de chamados reais de manutenção predial universitária em português brasileiro, extraídos do sistema GLPI da Universidade Federal do Sul da Bahia. O experimento utiliza 13.825 chamados não vazios, organizados em 54 categorias históricas, e compara classificadores clássicos baseados em TF-IDF (Naive Bayes, Regressão Logística, LinearSVC calibrado, SGD, Random Forest e Extra Trees), rede neural LSTM bidirecional e, como extensão planejada, transformador pré-treinado em português. O diferencial metodológico reside na distinção entre concordância com o histórico administrativo e acerto validado por revisão humana, tratando a categoria histórica como referência preliminar imperfeita. Resultados preliminares indicam superioridade do LinearSVC calibrado, com acurácia de 80,26% (IC95%: 79,59%–80,92%), enquanto a LSTM apresentou concordância de 67,57%. A normalidade da concordância por turno foi rejeitada para todos os modelos, justificando testes não paramétricos (Friedman, Cochran Q, McNemar, bootstrap). O custo computacional é incorporado como dimensão de avaliação, evidenciando que modelos lineares podem oferecer melhor relação entre desempenho e viabilidade operacional em cenários de texto curto, ruidoso e desbalanceado.

Palavras-chave: manutenção predial; classificação de chamados; processamento de linguagem natural; rótulos ruidosos; validação humana; governança preditiva.

ABSTRACT

Automatic classification of building maintenance work orders is a strategic resource for qualifying operational triage and enhancing evidence-based governance in public institutions. However, in historical databases from computerized service management systems, the originally assigned category should not be treated as an unquestionable ground truth, since it may reflect noisy operational decisions, overlapping taxonomies, incomplete records, and heterogeneous interpretations across maintenance teams. This paper proposes a multi-model protocol for classifying real university building maintenance requests in Brazilian Portuguese, extracted from the GLPI system at the Federal University of Southern Bahia. The experiment uses 13,825 non-empty records organized into 54 historical categories and compares TF-IDF-based classical classifiers (Naive Bayes, Logistic Regression, calibrated LinearSVC, SGD, Random Forest, and Extra Trees), a bidirectional LSTM neural network, and, as a planned extension, a Portuguese pre-trained transformer. The methodological contribution lies in distinguishing agreement with administrative history from human-validated accuracy. Preliminary results indicate calibrated LinearSVC superiority, with 80.26% accuracy (95%CI: 79.59%–80.92%), while LSTM achieved 67.57%. Normality was rejected for all models, supporting non-parametric tests (Friedman, Cochran Q, McNemar, bootstrap). Computational cost is incorporated as an evaluation dimension.

Keywords: building maintenance; work-order classification; natural language processing; noisy labels; human validation; predictive governance.

1. INTRODUÇÃO

A manutenção predial em instituições federais de ensino superior (IFES) envolve decisões recorrentes de triagem, categorização, priorização e alocação de equipes, agravadas pela dispersão territorial, pela diversidade de sistemas prediais e pela restrição orçamentária que historicamente limita o custeio dessas atividades a patamares inferiores a 2% do orçamento institucional (MARTINS; ESPEJO, 2024; PAMPANA *et al.*, 2022). Sistemas informatizados de registro de chamados, como plataformas GLPI e ambientes de *helpdesk*, tornaram-se, nesse contexto, não apenas instrumentos de solicitação, mas bases de conhecimento institucional sobre falhas, recorrências e padrões de uso, cujo potencial analítico permanece amplamente subutilizado (MORAIS; PAULA; REIS, 2023; MOHAMMED; AMOAH, 2025).

A exploração analítica dessas bases é limitada por ao menos três fatores estruturais. O primeiro reside na natureza textual curta, heterogênea e frequentemente incompleta dos registros, uma vez que chamados de manutenção predial são redigidos em linguagem técnica fragmentária, com abreviações locais e jargões de equipe que dificultam a aplicação direta de modelos genéricos de processamento de linguagem natural (PLN) (SUNDARAM; ZEID, 2025). O segundo fator é o desbalanceamento entre categorias, dado que demandas recorrentes de climatização, elétrica e hidrossanitária tendem a concentrar grande parte da base, ao passo que categorias raras dispõem de poucos exemplos para treinamento supervisionado (LI *et al.*, 2024). O terceiro fator, possivelmente o mais crítico do ponto de vista metodológico, é a qualidade dos rótulos históricos, pois a categoria registrada no momento do chamado pode resultar de interpretação rápida, classificação por conveniência operacional ou taxonomia ainda não estabilizada, de modo que o histórico administrativo constitui evidência importante, porém não verdade absoluta (ZHANG *et al.*, 2025; KEJRIWAL *et al.*, 2024).

A literatura recente sobre mineração textual de ordens de manutenção confirma a relevância de técnicas de PLN para transformar registros textuais em insumos de gestão. Li *et al.* (2024) demonstraram, em base hospitalar com 15.623 ordens de serviço, que a atribuição automática de equipes por PLN alcança acurácia de 0,83, reduzindo substancialmente a dependência de triagem manual. Sundaram e Zeid (2025) analisaram registros de *Maintenance Work Orders* sob a abordagem de *Technical Language Processing*, argumentando que textos técnicos de manutenção funcionam como *black holes* informacionais quando armazenam dados relevantes sem serem efetivamente utilizados na tomada de decisão. Bouabdallaoui *et al.* (2020), por sua vez, aplicaram modelos de PLN à classificação de requisições de manutenção em edificação hospitalar, reportando acurácia média de 78% com múltiplos métodos de representação textual. Contudo, a maior parte dessas aplicações concentra-se em bases em inglês ou chinês e em domínios industriais ou hospitalares, configurando lacuna relevante para corpora em português brasileiro no contexto da manutenção predial pública universitária.

O presente artigo parte de uma tese metodológica específica: em bases reais de chamados de manutenção, a avaliação de modelos não deve ser reduzida à pergunta sobre qual classificador mais concorda com a categoria histórica. Conforme Zhang *et al.* (2025), rótulos ruidosos em PLN afetam o desempenho dos classificadores e podem ampliar o consumo de recursos computacionais, exigindo métodos robustos de tratamento de ruído. Kejriwal *et al.* (2024) reforçam que *benchmarks* rotulados por humanos podem conter variabilidade relevante, questionando a prática de assumir uma única verdade absoluta quando há julgamento subjetivo envolvido. Dessa forma, a pergunta central deve ser mais ampla: em que medida os modelos reproduzem o histórico, em que medida auxiliam na identificação de inconsistências desse histórico e de que maneira a revisão humana pode converter divergências entre inteligência artificial e registro administrativo em melhoria progressiva da taxonomia institucional.

Com base em chamados reais da Universidade Federal do Sul da Bahia (UFSB), propõe-se uma comparação multimodelo de classificadores de texto aplicados a chamados de manutenção predial em português brasileiro. A base experimental contém 13.825 chamados não vazios, distribuídos em 54 categorias históricas, e os campos textuais considerados agregam informações do título e da descrição do chamado, além de informações associadas à ordem de serviço. O estudo compara modelos clássicos baseados em TF-IDF (Naive Bayes, Regressão Logística, LinearSVC, SGD, Random Forest e Extra Trees) com abordagem neural LSTM bidirecional e extensão planejada para transformadores pré-treinados em português. O objeto de avaliação, portanto, não é apenas o classificador isolado, mas o protocolo de governança preditiva que articula aprendizado de máquina, auditoria estatística, custo computacional e validação humana, em consonância com a perspectiva de manutenção baseada em evidências preconizada pela NBR 5674 (ABNT, 2012).

Os objetivos específicos do estudo são: (i) apresentar um protocolo de comparação multimodelo para classificação de chamados reais de manutenção predial universitária em português brasileiro; (ii) distinguir concordância com rótulo histórico de acerto validado, evitando equiparar categoria histórica a *ground truth* incontestável; (iii) avaliar desempenho por métricas globais, métricas balanceadas, intervalos de confiança e testes estatísticos pareados adequados a dados não normais; (iv) incorporar custo computacional como dimensão de decisão operacional; e (v) transformar divergências entre IA e histórico em evidências para revisão taxonômica e retroalimentação da base de treino.

2. REFERENCIAL CONCEITUAL

2.1 Processamento de linguagem natural em ordens de manutenção

Ordens de manutenção constituem registros operacionais com valor informacional elevado, porém usualmente subutilizado. Elas documentam sintomas, locais, equipamentos, procedimentos, materiais e soluções executadas, acumulando-se ao longo de anos em sistemas informatizados cuja forma textual e semiestruturada dificulta o uso direto em planejamento e alocação de recursos (PAMPANA *et al.*, 2022; MORAIS; PAULA; REIS, 2023). Li *et al.* (2024) propuseram estrutura baseada em PLN para análise e atribuição automática de ordens de manutenção hospitalar, utilizando 15.623 registros de hospital municipal em Xangai e reportando acurácia de 0,83 na tarefa de atribuição de trabalhadores, resultado que evidencia a possibilidade de automatizar processos antes dependentes de triagem manual em contextos prediais. Esse trabalho constitui referência-âncora para a presente pesquisa por tratar diretamente da automação de ordens de manutenção predial, embora em idioma, tipologia institucional e estrutura taxonômica distintos.

Sundaram e Zeid (2025), ao analisar registros textuais de *Maintenance Work Orders* sob a abordagem de *Technical Language Processing*, defenderam que textos técnicos de manutenção funcionam como repositórios informacionais subutilizados quando não integrados a processos decisórios. Essa perspectiva é especialmente pertinente à manutenção predial universitária, na qual chamados curtos, abreviações locais, nomes de ambientes e descrições incompletas dificultam o uso de modelos genéricos sem adaptação ao domínio. Bouabdallaoui *et al.* (2020) reportaram acurácia média de 78% na classificação de requisições de manutenção predial hospitalar utilizando múltiplos métodos de PLN, resultado que reforça a viabilidade da abordagem, mas também evidencia a necessidade de adaptação lexical e semântica ao corpus específico.

2.2 Classificação de tickets e evolução dos modelos

A classificação automática de *tickets* em ambientes de suporte técnico e ITSM evoluiu de representações vetoriais baseadas em frequência lexical para *embeddings* e modelos de linguagem pré-treinados. Liu, Bengue e Jiang (2023) propuseram o Ticket-BERT para rotulagem de *tickets* de incidentes, enfatizando desafios como atualização contínua de rótulos e necessidade de aprendizado ativo. Entretanto, a transferência direta de achados do ITSM para a manutenção predial deve ser cautelosa, pois a semântica do domínio envolve sistemas físicos, ambientes e equipamentos prediais que não coincidem com categorias de incidentes de *software* ou infraestrutura digital (SUNDARAM; ZEID, 2025).

Modelos lineares com TF-IDF continuam competitivos em tarefas de texto curto, especialmente quando o corpus é de porte médio, o vocabulário possui alta especificidade técnica e as classes são desbalanceadas (GALKE; SCHERP, 2022). Nesses cenários, modelos profundos podem não compensar seu custo computacional caso não disponham de volume suficiente, balanceamento adequado ou *embeddings* fortemente adaptados ao domínio. Galke e Scherp (2022), em revisão comparativa abrangente de métodos para classificação textual, demonstraram que classificadores baseados em *bag-of-words* com TF-IDF e SVM permanecem altamente competitivos frente a redes neurais em múltiplos *benchmarks*, sobretudo quando o corpus é reduzido ou o vocabulário é altamente especializado. Esse achado é particularmente relevante para o contexto institucional de manutenção predial, onde a base operacional raramente atinge escala compatível com as exigências de modelos de linguagem de grande porte.

2.3 Rótulos ruidosos e verdade operacional

O problema de rótulos ruidosos é central em aprendizado supervisionado aplicado a bases administrativas. Em classificação textual, ruído de rótulo pode decorrer de ambiguidade semântica, polissemia, insuficiência de contexto, sobreposição taxonômica, julgamento subjetivo ou erro humano de registro (ZHANG *et al.*, 2025). Conforme levantamento de Zhang *et al.* (2025), rótulos ruidosos em PLN afetam o desempenho dos modelos

e podem ampliar o consumo de recursos, exigindo métodos robustos de tratamento de ruído. Kejriwal *et al.* (2024) reforçam que *benchmarks* rotulados por humanos podem conter variabilidade relevante, questionando a prática de assumir uma única verdade absoluta quando há julgamento subjetivo envolvido. No contexto do presente artigo, a categoria histórica do chamado é tratada como referência administrativa, não como verdade final, e a verdade operacional deve ser construída por validação humana com registro explícito da decisão tomada.

2.4 Custo computacional e eficiência em PLN

A avaliação de modelos de PLN tem sido tradicionalmente orientada por métricas de desempenho, mas a literatura recente enfatiza que custo computacional, tempo de treino, consumo energético e reprodutibilidade também devem compor a decisão de adoção (TREVISIO *et al.*, 2023; SCHWARTZ *et al.*, 2020). Treviso *et al.* (2023) argumentam que a ampliação de escala em PLN tende a aumentar o consumo de dados, tempo, armazenamento e energia, motivando métodos eficientes especialmente em contextos de recursos limitados. Schwartz *et al.* (2020) cunharam o conceito de *Green AI*, propondo que a eficiência computacional seja reportada e valorizada na avaliação de modelos, não apenas a acurácia. Em uma instituição pública, essa dimensão é operacionalmente decisiva: um modelo que treina em segundos pode ser reexecutado frequentemente, auditado com facilidade e mantido sem infraestrutura dedicada, ao passo que um modelo que demanda dezenas de minutos exige *checkpoint*, controle de versão de pesos e justificativa robusta de ganho marginal (TREVISIO *et al.*, 2023).

3. MÉTODO

3.1 Delineamento geral

O estudo adota delineamento experimental aplicado, com base observacional retrospectiva de chamados de manutenção predial registrados no sistema GLPI institucional da UFSB, universidade multicampi com unidades em Itabuna, Ilhéus, Porto Seguro e Teixeira de Freitas (MORAIS; PAULA; REIS, 2023). A unidade de análise é o chamado individual de manutenção, representado por campos textuais concatenados e por uma categoria histórica registrada no sistema. O fluxo metodológico compõe-se de oito etapas sequenciais: (i) extração e consolidação da base; (ii) higienização textual; (iii) construção da matriz de atributos; (iv) treinamento e inferência multimodelo; (v) geração de predições *out-of-fold*; (vi) comparação preliminar com categoria histórica; (vii) análise estatística não paramétrica; e (viii) validação humana das divergências e amostras críticas. A Figura 1 apresenta esse fluxo como *pipeline* de governança preditiva.

[INSERIR AQUI: fig1_pipeline_governanca.png]

Figura do pipeline metodológico — gerar a partir do fluxo descrito ou utilizar diagrama existente no repositório.

Figura 1 Pipeline de governança preditiva: fluxo metodológico completo, da extração da base à retroalimentação por validação humana.

Fonte: Elaborado pelos autores (2026).

3.2 Corpus e variáveis

O corpus experimental é composto por 13.825 chamados de manutenção predial não vazios, organizados em 54 categorias históricas, extraídos do ambiente institucional da UFSB. Os campos textuais previstos no protocolo incluem título do chamado, descrição GLPI, título da ordem de serviço e descrição da ordem de serviço, concatenados em uma única representação textual para fins de classificação. A categoria histórica é utilizada como referência preliminar de comparação, mas a avaliação conclusiva depende da base validada por revisão humana. O idioma dos registros é português brasileiro, com presença significativa de jargões técnicos, nomes de ambientes, abreviações locais e descrições incompletas, características que impõem desafios específicos de pré-processamento e representação textual (SUNDARAM; ZEID, 2025).

A base é dinâmica: novos chamados continuam sendo sincronizados e classificados em turnos. Na consolidação desta auditoria (16/07/2026), o número de chamados elegíveis já havia crescido para 13.954, nas mesmas 54 categorias históricas. Os resultados da Seção 4 utilizam esse recorte mais recente; eventuais diferenças frente a valores publicados em versões preliminares deste texto refletem o crescimento da base, não uma mudança metodológica.

3.3 Pré-processamento textual

O pré-processamento textual foi documentado de modo reproduzível, uma vez que pequenas decisões sobre normalização podem alterar a matriz de atributos e, conseqüentemente, o desempenho dos modelos (SALTON; BUCKLEY, 1988). Para os classificadores clássicos, a representação principal é TF-IDF com *n-gramas* de uma e duas palavras e limite superior de 5.000 atributos para controle de dimensionalidade. Para o modelo neural LSTM, são utilizadas tokenizações específicas com vocabulário de 8.000 termos e comprimento máximo de sequência adequado à distribuição textual da base. Cabe ressaltar que a etapa de pré-processamento não elimina indiscriminadamente termos técnicos, códigos de ambientes, nomes de equipamentos ou expressões recorrentes da equipe, pois esses elementos possuem alto valor discriminativo em manutenção predial, onde palavras como *bomba*, *split*, *disjuntor*, *vazamento*, *infiltração* e *ar-condicionado* podem funcionar como âncoras semânticas relevantes para categorias específicas.

3.4 Modelos avaliados

O desenho experimental considera sete modelos materializados e uma extensão planejada. Os classificadores clássicos adotam representação TF-IDF e algoritmos de aprendizado supervisionado amplamente consolidados na literatura de classificação textual (JOACHIMS, 1998; PEDREGOSA *et al.*, 2011): Naive Bayes Multinomial, como *baseline* probabilístico; Regressão Logística, com calibração natural e boa interpretabilidade; LinearSVC calibrado, combinando margem linear e calibração de confiança via Platt (PLATT, 1999); SGD, como alternativa eficiente para matrizes esparsas de grande dimensão; Random Forest e Extra Trees, como representantes de métodos não lineares baseados em *ensemble* de árvores. A LSTM Bidirecional foi construída com camada de *embedding* de 8.000 termos e 128 dimensões, camada recorrente bidirecional de 64 unidades (GRAVES; SCHMIDHUBER, 2005), *dropout* de 0,5 e camada densa com ativação *softmax*, treinada com parada antecipada. A extensão com BERTimbau ou MiniLM *fine-tuned* deve ser tratada como etapa complementar, dependente de execução controlada, persistência de modelo e comparação estatística contra os classificadores já consolidados.

Um oitavo modelo, baseado em transformador pré-treinado em português com ajuste fino (BERTimbau, neuralmind/bert-base-portuguese-cased), foi incorporado como extensão contextual, com fallback automático para LSTM/RF quando as dependências de treinamento (torch/transformers) não estão disponíveis no ambiente de execução. Pelo custo computacional em CPU, o ajuste fino roda em fluxo de trabalho próprio, de baixa frequência, fora do ciclo padrão de 15 minutos. Até a data desta auditoria, o treinamento havia sido adiado automaticamente por avanço insuficiente da base validada (limiar de 100 novos casos conferidos ainda não atingido); seus resultados comparativos ainda não estão disponíveis e permanecem como trabalho em andamento, não como resultado reportado na Seção 4.

3.5 Desenho de avaliação

A avaliação foi realizada por predições fora da amostra em protocolo *out-of-fold* com *k-fold* estratificado, *seed* fixa e mesma partição para todos os modelos, desenho que reduz viés de comparação e permite testes pareados (SOKOLOVA; LAPALME, 2009). As métricas principais são acurácia, *macro-F1*, F1 ponderado, *balanced accuracy* e intervalo de confiança por *bootstrap* com 95% de confiança. A *macro-F1* e a *balanced accuracy* são essenciais face ao desbalanceamento entre categorias, dado que a acurácia isolada pode superestimar desempenho em classes majoritárias e mascarar falhas em categorias raras (SOKOLOVA; LAPALME, 2009). A correlação entre confiança e acerto é avaliada por Spearman; diferenças globais entre classificadores são avaliadas por Cochran Q e Friedman; comparações pareadas são avaliadas por McNemar (1947); e incerteza de acurácia é estimada por *bootstrap*. Quando múltiplas comparações são realizadas, aplica-se correção de Nemenyi no contexto de *ranks*.

3.6 Validação humana

A validação humana constitui a etapa que diferencia o presente estudo de uma simples comparação de classificadores contra histórico. A revisão registra, para cada caso auditado, a categoria histórica, a categoria sugerida por cada modelo, a confiança associada, a decisão humana e a categoria travada. A priorização recai sobre chamados em que há divergência entre modelos, alta confiança da IA contra histórico, baixa confiança generalizada, classes raras e pares de categorias com alta confusão recíproca. A decisão humana pode produzir quatro resultados: manter o histórico; aceitar a sugestão do modelo; definir terceira categoria; ou marcar o

caso como ambíguo ou taxonômico. Essa estrutura permite mensurar se a IA errou, se o histórico estava inconsistente ou se a própria taxonomia institucional necessita de revisão, em consonância com a perspectiva de que a verdade operacional deve ser construída progressivamente (ZHANG *et al.*, 2025).

3.7 Memória de decisão: veto e trava por chamado

À medida que a conferência humana avança, o protocolo incorpora uma memória de decisão por chamado, que evita o reprocessamento de casos já resolvidos e impede a repetição de erros já identificados. Quando a conferência confirma que uma categoria está correta, essa decisão é travada e reaproveitada diretamente nas rodadas seguintes de reclassificação, sem novo treinamento ou nova predição para aquele chamado. Quando a conferência identifica que uma categoria está incorreta, essa categoria passa a ser vetada especificamente para aquele chamado: os modelos do repositório de classificadores passam a escolher a melhor categoria alternativa fora do conjunto vetado, com a confiança renormalizada sobre as categorias remanescentes. Essa regra é aplicada de forma consistente na seleção de candidatos à reclassificação e no cálculo do ganho líquido, que passa a comparar o resultado da reclassificação contra a verdade validada quando ela está travada, e contra o histórico apenas quando ainda não há decisão humana. O objetivo metodológico da memória de decisão é impedir que o sistema corrija um erro apenas para reincidir nele em ciclos futuros, convertendo cada conferência manual em conhecimento persistente sobre o experimento, não em um evento isolado.

3.8 Camada de entropia de Shannon e divergência de Jensen-Shannon

Como dimensão complementar às métricas supervisionadas, o protocolo incorporou uma camada de análise informacional baseada em entropia de Shannon e divergência de Jensen-Shannon, calculada exclusivamente sobre os arquivos públicos e sanitizados do painel (sem identificador, título ou texto livre do chamado). Essa camada não substitui acurácia, calibração ou validação humana; responde a uma pergunta distinta, sobre onde modelos, categorias e chamados individuais concentram maior incerteza estrutural. No nível dos modelos, a entropia de Shannon sobre a distribuição de categorias previstas indica se um classificador dispersa suas predições por muitas classes ou as concentra excessivamente em poucas; a divergência de Jensen-Shannon mede a distância entre essa distribuição prevista e a distribuição histórica da base, funcionando como indicador de deslocamento distributivo. No nível das categorias, a entropia evidencia classes históricas cujas predições se espalham entre múltiplas categorias, sinalizando candidatas prioritárias a revisão taxonômica. No nível do chamado individual, a entropia de votos entre os modelos identifica registros em que há desacordo estrutural entre arquiteturas distintas, formando uma fila de auditoria orientada por ambiguidade, e não apenas por baixa confiança isolada de um único modelo.

3.9 Disponibilidade de dados e scripts

Os artefatos que sustentam os resultados relatados neste capítulo são gerados por scripts versionados no repositório público github.com/adinailson88/classificacao-chamados (branch `main`), independente do repositório operacional Malha IA. Os números citados nas Subseções 4.1 a 4.6 correspondem aos arquivos JSON publicados em `docs/dados/` (por exemplo, `estatistica.json`, `avaliacao_final.json`, `calibracao.json`, `reclass_resumo.json`, `shannon_resumo.json`, `jensen_shannon_modelos.json`), regenerados automaticamente por *workflows* do GitHub Actions a cada rodada do experimento e publicados também via GitHub Pages. Nenhum identificador pessoal, título ou texto livre de chamado é versionado nesses arquivos; a camada Shannon/Jensen-Shannon (Subseção 3.8) opera exclusivamente sobre agregados sanitizados. **Pendência explícita desta subseção:** consolidar, em rodada futura, a correspondência exata entre cada subseção de resultado e o script que a gera (por exemplo, `src/avaliacao_final.py`, `src/calibracao.py`, `src/analise_shannon.py`), hoje mapeada em `PLANO_ARTIGO_CAPITULO.md` mas ainda não transcrita para o corpo do artigo.

4. RESULTADOS

Esta seção apresenta dois conjuntos de resultados, deliberadamente segregados: a concordância com a categoria histórica (Subseção 4.1), que trata o registro do GLPI como referência preliminar e não como verdade absoluta; e o desempenho validado por conferência humana (Subseções 4.2 e 4.3), calculado exclusivamente sobre os chamados em que houve conferência dupla das colunas M (histórico) e N (IA). Na data de consolidação desta auditoria (16/07/2026), a base elegível continha 13.954 chamados e a conferência humana já cobria 4.737 chamados (33,9% da base), dos quais 4.681 com decisão travada e sem conflito. Ainda que

essa cobertura não configure amostra aleatória — a priorização recaiu sobre divergências e casos de menor confiança —, seu tamanho já permite leitura estatística mais robusta do que a amostra parcial de 305 casos (2,2% da base) reportada em versões anteriores deste protocolo.

4.1 Concordância com o histórico (base completa)

A comparação contra a categoria histórica, sobre a base completa ($n = 13.954$, com intervalo de confiança por bootstrap a 95%), mantém o LinearSVC calibrado na liderança, com acurácia de 0,7996 (IC95%: 0,7927–0,8063), seguido por Extra Trees (0,7859), Random Forest (0,7792), SGD (0,7745), Regressão Logística (0,7640) e Naive Bayes (0,6984). O teste de Cochran Q confirma diferença global entre os seis modelos ($Q = 1.448,755$; $gl = 5$; $p < 0,001$). O Kappa de Cohen entre cada modelo e o histórico acompanha o mesmo ordenamento (LinearSVC 0,7843; Extra Trees 0,7679; Random Forest 0,7604; SGD 0,7581; Regressão Logística 0,7473; Naive Bayes 0,6689), e o Kappa de Fleiss entre os próprios modelos (0,8068) indica concordância substancial entre arquiteturas distintas treinadas sobre a mesma base — evidência de que a hierarquia de desempenho não é artefato de uma única execução. A sétima fonte de classificação, a Etapa 1 oficial (executor LSTM/RF de produção), mantém concordância de 76,7% e confiança média de 71,7% no recorte publicado no painel, posicionando-se entre Random Forest e SGD nesta métrica.

Tabela 1 Concordância com a categoria histórica, base completa ($n = 13.954$)

Modelo	Acurácia	IC95% bootstrap	Kappa vs. histórico
LinearSVC calibrado	0,7996	0,7927 – 0,8063	0,7843
Extra Trees	0,7859	0,7789 – 0,7929	0,7679
Random Forest	0,7792	0,7722 – 0,7862	0,7604
SGD	0,7745	0,7678 – 0,7812	0,7581
Regressão Logística	0,7640	0,7570 – 0,7709	0,7473
Naive Bayes	0,6984	0,6909 – 0,7058	0,6689

Fonte: estatistica.json, gerado em 16/07/2026 ($n = 13.954$).

4.2 Ranking validado por conferência humana

A avaliação contra a verdade validada por conferência humana ($n = 4.681$; coluna M = conferência do histórico, coluna N = conferência da IA) muda a magnitude, mas não a ordem, da liderança observada em 4.1: todos os seis modelos atingem acerto validado entre 92% e 96%, patamar muito superior à concordância com o histórico. O LinearSVC calibrado permanece o melhor modelo isolado, com acerto validado de 0,9549 (IC95%: 0,9489–0,9603), seguido por SGD (0,9500), Random Forest (0,9477), Extra Trees (0,9470), Regressão Logística (0,9442) e Naive Bayes (0,9203). A diferença entre o primeiro e o segundo colocado é pequena em termos absolutos (0,49 ponto percentual), mas estatisticamente significativa (McNemar, $p = 0,0044$), sustentando a recomendação de uso do LinearSVC com calibração como IA de referência. Nenhum método de combinação testado — confiança calibrada máxima (0,9562), maioria ponderada com pesos aprendidos out-of-fold (0,9554) ou maioria simples (0,9547) — supera o LinearSVC isolado com significância estatística (McNemar $p \geq 0,05$ nos três casos), de modo que combinar modelos não se justifica operacionalmente diante do custo adicional de manter um comitê.

Tabela 2 Acerto validado por conferência humana dupla ($n = 4.681$)

Modelo	Acerto validado	IC95%
LinearSVC calibrado	0,9549	0,9489 – 0,9603
SGD	0,9500	0,9436 – 0,9562
Random Forest	0,9477	0,9413 – 0,9539
Extra Trees	0,9470	0,9406 – 0,9530
Regressão Logística	0,9442	0,9374 – 0,9509
Naive Bayes	0,9203	0,9122 – 0,9280

Fonte: avaliacao_final.json, gerado em 16/07/2026, conferência dupla M/N/P.

4.3 A classificação oficial frente ao histórico: matriz de confusão validada

Um resultado adicional, obtido diretamente da conferência dupla sobre a classificação oficial da Etapa 1 (coluna G, executor LSTM/RF), qualifica a tese de rótulos ruidosos apresentada na Introdução. Sobre 4.737 conferências, a categoria histórica (GLPI) validada atinge acerto de 0,9854, superior ao acerto validado da IA oficial (0,9508). A matriz de confusão IA×GLPI mostra 4.454 casos em que ambos estão corretos, 45 em que ambos estão incorretos, 186 em que a IA erra e o histórico está certo, e apenas 13 em que a IA corrige um histórico incorreto. Essa proporção — aproximadamente quatorze casos de erro da IA para cada caso de correção de histórico — indica que, nesta base e nesta amostra de conferência, o rótulo histórico do GLPI é, em geral, mais confiável do que a predição automática isolada. O resultado nuança, sem invalidar, a premissa metodológica do artigo: existe ruído real no histórico (58 dos 4.737 casos conferidos, 1,2%, têm categoria histórica incorreta), mas ele é proporcionalmente menor do que o risco de erro da própria IA nesta amostra. A implicação prática é que a IA deve ser tratada como instrumento de triagem e auditoria complementar ao histórico, não como substituto ou árbitro superior a ele.

Nota metodológica (23/07/2026): o campo do painel que sustentaria uma nova versão desta matriz (`calibracao.json`, `validacao_humana.matriz_ia_x_glpi`) apresenta, na consolidação mais recente, variação nula entre as quatro células — resultado do mesmo viés de seleção identificado e corrigido na Subseção 4.4 (a coluna N de conferência bruta raramente registra “Errado” na prática). Diferentemente da Subseção 4.4, este campo específico **ainda não foi corrigido**; os números de 16/07/2026 citados acima permanecem como único registro disponível desta matriz e **não devem ser tratados como reconfirmados** até uma nova rotina de cálculo (comparando a decisão travada M/N/P, não a marcação bruta de uma única coluna) ser implementada e reexecutada. Ver `docs/PLANO_PDF_ARTIGO_PAGES.md` para o registro técnico completo.

4.4 Confiança, calibração e faixas de decisão

A calibração bruta da Etapa 1 oficial mantém ECE histórico de 0,0536. Quando segmentada por faixa de confiança e cruzada com a validação humana, a faixa igual ou superior a 95% de confiança ($n = 4.739$; cerca de 34% da base) apresenta concordância de 99,35% com o histórico e, mais relevante, acerto validado de 99,73% sobre os 3.284 casos já conferidos nessa faixa — resultado que atinge e supera, nessa faixa específica, a meta de referência do experimento (confiança calibrada $\geq 95\%$ associada a acerto real $\geq 95\%$). Nas faixas inferiores, a degradação de desempenho acompanha a queda de confiança de forma consistente (90–95%: acerto validado 96,83%; 80–90%: 94,32%; 70–80%: 87,59%; 50–70%: 61,40%; inferior a 50%: 38,10%), o que corrobora a correlação positiva entre confiança bruta e acerto já observada na versão preliminar deste protocolo, mesmo sem calibração formal (Platt/isotônica) aplicada a essa camada. A leitura por executor confirma o desenho de triagem automática: o executor LSTM de alta confiança ($n = 4.739$) atinge 99,73% de acerto validado, enquanto o executor de baixa confiança ($n = 9.215$) atinge 84,30% ($n = 1.414$ validados) — diferença que justifica represar apenas os casos de baixa confiança para revisão manual.

Atualização de dados (23/07/2026): o parágrafo acima preserva os números de 16/07/2026 citados na versão anterior deste rascunho. Nesta data, ao revalidar a fonte viva (`docs/dados/calibracao.json`), foi corrigido um viés de seleção em `src/calibracao.py` que fazia o acerto validado por faixa sair artificialmente igual a 100% em toda faixa de confiança, inclusive abaixo de 50% (a coluna N de conferência bruta isolada raramente registra “Errado” no uso real; a correção passou a comparar a classificação do executor contra a categoria **decidida** pela memória M/N/P — a mesma verdade usada na Subseção 4.2 — em vez da marcação bruta de uma única coluna). A Tabela 3 mostra os números corrigidos, já sobre uma base de conferência bem maior (9.096 decisões travadas, ante 4.681 em 16/07):

Tabela 3 Acerto validado por faixa de confiança bruta, executor oficial (Etapa 1), pós-correção do viés de seleção ($n = 9.096$ decisões travadas)

Faixa	n total	Concord. histórico	n validados	Acerto validado
< 50%	3.972	42,35%	876	49,89%
50–70%	1.504	73,40%	741	83,94%
70–80%	972	87,45%	654	94,95%

Faixa	n total	Concord. histórico	n validados	Acerto validado
80–90%	1.499	87,99%	1.118	93,92%
90–95%	1.210	92,98%	1.009	91,48%
$\geq 95\%$	4.808	99,08%	4.698	96,79%

Fonte: `calibracao.json`, gerado em 23/07/2026 21:31 (America/Bahia), já com a correção de `src/calibracao.py` aplicada. ECE histórico nesta consolidação: 0,0598. A meta do experimento (confiança calibrada $\geq 95\%$ associada a acerto real $\geq 95\%$) fica muito próxima de ser atingida na faixa mais alta (96,79%), mas — como já registrado na versão anterior deste texto — a confiança utilizada aqui ainda é bruta (`softmax/decision_function`), não formalmente calibrada por Platt ou isotônica, e a amostra de conferência prioriza divergências, não é aleatória. Note-se também que a faixa 80–90% (93,92%) supera ligeiramente a faixa 90–95% (91,48%) — pequena inversão de monotonia plausível em dados reais com amostras desse tamanho, mas que merece acompanhamento nas próximas consolidações antes de ser tratada como padrão estável.

4.5 Reclassificação e ganho líquido

A reclassificação dos chamados já conferidos (execução de 30/06/2026, coluna O) produz resultados heterogêneos entre modelos, medidos contra a verdade validada quando travada e contra o histórico nos demais casos. O LinearSVC apresenta o maior ganho líquido absoluto (+30; 479 corrigidos e 449 prejudicados, sobre 29.794 reclassificações acumuladas, das quais 18.719 são reaproveitamento direto de decisão humana travada), seguido por Naive Bayes (+9) e Regressão Logística (+8). Em contraste, SGD (−92), Random Forest (−80) e Extra Trees (−40) apresentam ganho líquido negativo nesta rodada — a reclassificação piora mais casos do que corrige para esses três modelos. Esse resultado reforça a decisão metodológica de não aplicar reclassificação em massa de forma indiscriminada por modelo, tratando o ganho líquido, e não apenas a acurácia agregada, como critério de decisão operacional por classificador.

4.6 Diagnóstico de taxonomia e ambiguidade estrutural (Shannon/Jensen-Shannon)

A camada de entropia de Shannon, calculada sobre as oito fontes de classificação (Etapa 1 oficial e as sete IAs materializadas, incluindo o LSTM out-of-fold), aponta o LSTM como o modelo de maior diversidade nas categorias previstas, e o LinearSVC como o modelo cuja distribuição de predições mais se aproxima da distribuição histórica (menor divergência de Jensen-Shannon). No nível de chamado individual, 3.451 dos 13.954 registros (24,7%) apresentam alta entropia de votos entre os oito modelos, ou seja, desacordo estrutural relevante entre arquiteturas distintas — um critério de priorização de auditoria diferente e complementar à simples baixa confiança de um único modelo. No nível de categoria, a análise aponta um número relevante de ocorrências de alta ambiguidade nas predições (79, com suporte mínimo de 30 registros por categoria); a interpretação detalhada de quais categorias específicas concentram essa ambiguidade, e sua sobreposição com os pares de maior confusão recíproca já identificados na etapa de cruzamento de taxonomia (por exemplo, entre climatização e manutenção preventiva de ar-condicionado, ou entre estrutura predial, esquadrias e hidrossanitária), permanece como candidata a inspeção qualitativa dirigida. O que a camada Shannon oferece é a priorização estatística de onde essa inspeção deve começar, não a decisão de fusão ou desambiguação de categorias, que continua sendo humana.

4.7 Custo computacional

Nos recortes de comparação por lote (1.000 registros cada), o tempo de treino mantém-se na casa de segundos para os modelos lineares e probabilísticos mais simples (por exemplo, Naive Bayes $\sim 1,1$ s) e sobe para modelos com mais hiperparâmetros (Regressão Logística $\sim 8,7$ s neste recorte), enquanto o LSTM, por depender de épocas de treinamento em rede neural, permanece a opção de maior custo computacional entre as fontes de classificação avaliadas, exigindo minutos e infraestrutura de checkpoint; o oitavo modelo (transformador com ajuste fino) tende a ampliar ainda mais esse custo, o que motivou seu isolamento em fluxo de trabalho próprio, de baixa frequência (Subseção 3.4). Essa hierarquia de custo é consistente com a observada em versões anteriores deste protocolo e reforça o argumento operacional de que modelos lineares combinam o melhor desempenho validado (Subseção 4.2) com o menor custo de reexecução e auditoria.

4.8 Figuras

As figuras originalmente planejadas para este capítulo (Figura 1 — pipeline metodológico, Subseção 3.1; distribuição de confiança por desfecho; trade-off acurácia×custo; pares de maior confusão, Subseção 4.6) ainda não foram regeneradas a partir dos dados desta auditoria; os mesmos resultados são apresentados aqui em forma tabular e textual, com números conferidos diretamente nos arquivos publicados do painel. A geração das figuras finais depende da execução dos scripts de visualização (R ou Python) contra os JSON vigentes e fica registrada como pendência explícita, não como lacuna de conteúdo.

5. DISCUSSÃO

A comparação entre concordância histórica (Subseção 4.1) e desempenho validado (Subseção 4.2) revela um padrão que a literatura sobre rótulos ruidosos ajuda a interpretar, mas que a amostra validada desta pesquisa qualifica com maior precisão do que hipóteses genéricas permitiriam: a distância entre concordância com o histórico (~70–80%) e acerto validado (~92–96%) não decorre apenas de erro do histórico, mas também do fato de que boa parte das divergências entre IA e histórico corresponde a erro da própria IA, não do registro original. A matriz IA×GLPI (Subseção 4.3) mostra que, quando os dois discordam, o histórico está correto com frequência muito maior (186 casos) do que a IA corrige um erro genuíno do histórico (13 casos). Esse achado não invalida a premissa metodológica de que a categoria histórica não deve ser tratada como verdade absoluta — ainda existe uma taxa real, embora pequena (1,2% dos casos conferidos), de erro confirmado no registro original —, mas recomenda cautela contra a leitura oposta e igualmente equivocada, de que baixa concordância com o histórico implica automaticamente acerto da IA. A validação humana, portanto, cumpre função insubstituível: sem ela, seria impossível distinguir as duas situações apenas observando a taxa de concordância.

A manutenção da liderança do LinearSVC calibrado tanto na concordância histórica quanto no acerto validado (Subseções 4.1 e 4.2) reforça, com evidência agora validada e não apenas preliminar, a leitura já delineada na primeira versão deste protocolo: em textos curtos, técnicos e ruidosos como os chamados de manutenção predial, um classificador linear sobre representação TF-IDF pode superar arquiteturas neurais mais complexas, inclusive quando avaliado contra verdade humana, e ainda manter vantagem de custo computacional (Subseção 4.7). A ausência de ganho estatisticamente significativo de qualquer estratégia de combinação de modelos (Subseção 4.2) reforça a mesma leitura: neste domínio e neste estágio do experimento, investir engenharia em um único classificador linear bem calibrado tem retorno mais claro do que orquestrar um comitê de modelos heterogêneos.

O resultado da reclassificação (Subseção 4.5) introduz uma nuance operacional importante: o ganho líquido de corrigir chamados já classificados não é uniforme entre modelos, e para três dos seis classificadores avaliados (SGD, Random Forest e Extra Trees) a reclassificação nesta rodada piorou mais casos do que corrigiu. Isso sugere que decisões de reclassificação em produção devem ser tomadas por modelo, com base no ganho líquido medido, e não generalizadas a partir do desempenho médio de concordância ou acerto validado — um modelo pode ser competitivo na classificação inicial e, ainda assim, não ser um bom candidato a reclassificar decisões já tomadas.

A camada de entropia de Shannon e divergência de Jensen-Shannon (Subseção 4.6) não substitui as métricas supervisionadas ou a validação humana, mas amplia o repertório de governança do experimento ao separar três fenômenos que a acurácia isolada tende a confundir: erro de modelo, ambiguidade genuína da taxonomia institucional e heterogeneidade natural da distribuição de chamados. A identificação de 3.451 chamados (24,7% da base) com alto desacordo estrutural entre os oito modelos oferece um critério de priorização de auditoria distinto do simples corte por baixa confiança de um único classificador, e complementa a fila já construída a partir da conferência dupla M/N.

A meta de confiança calibrada igual ou superior a 95% associada a acerto real igual ou superior a 95% (Subseção 4.4), estabelecida como critério de sucesso deste protocolo, já é atingida na faixa alta de confiança da Etapa 1 oficial (99,73% de acerto validado sobre 3.284 casos conferidos), ainda que a confiança utilizada seja bruta (softmax/decision_function), não formalmente calibrada por Platt ou isotônica. Esse resultado é encorajador, mas deve ser lido com a mesma cautela metodológica aplicada ao restante do artigo: a amostra validada, embora já substancial (33,9% da base), prioriza divergências e casos de menor confiança na sua composição original, o que pode inflar artificialmente o acerto validado nas faixas de alta confiança, onde a

conferência tende a simplesmente confirmar o que já era esperado. A confirmação definitiva da meta depende da conclusão da conferência humana sobre uma amostra mais representativa da faixa alta, e não apenas dos casos originalmente priorizados.

As limitações do estudo permanecem análogas às já registradas, com dois ajustes relevantes em relação à versão anterior. Primeiro, a amostra validada deixou de ser uma amostra piloto de 305 casos (2,2% da base) e passou a cobrir 4.737 conferências (33,9% da base), o que aumenta substancialmente a robustez estatística das Subseções 4.2 a 4.4, ainda que sem garantia de representatividade aleatória. Segundo, os dois conflitos de conferência identificados em versões anteriores do protocolo (casos em que tanto a coluna M quanto a N foram marcadas como corretas, apesar de histórico e IA divergirem) foram resolvidos e não aparecem mais nos dados publicados (conflitos = 0 em `avaliacao_final.json`), embora isso não elimine a possibilidade de novos conflitos surgirem à medida que a conferência avança sobre casos ainda não revisados. Persistem como limitações a dependência de uma única instituição como caso empírico, a ausência de resultados comparativos do oitavo modelo (transformador com ajuste fino), cujo treinamento permanece adiado por critério automático de avanço insuficiente da base validada, e a intermitência observada na publicação automática do painel no GitHub Pages, discutida na auditoria técnica que acompanha este capítulo.

6. CONSIDERAÇÕES FINAIS

O presente capítulo atualizou o protocolo de classificação automática multimodelo de chamados de manutenção predial universitária em português brasileiro com os resultados acumulados até 16 de julho de 2026, incorporando uma oitava fonte de classificação (transformador com ajuste fino, ainda em treinamento adiado), uma camada de memória de decisão por veto e trava de categorias já conferidas, e uma camada de análise informacional baseada em entropia de Shannon e divergência de Jensen-Shannon. A contribuição central permanece metodológica: não apenas identificar o melhor classificador, mas estruturar um protocolo em que aprendizado de máquina, estatística não paramétrica, memória de decisão e auditoria humana qualificam progressivamente a base de dados e revelam inconsistências taxonômicas.

Diferentemente da versão preliminar deste texto, a conclusão atual já se apoia em validação humana substancial, e não apenas em concordância com o histórico. Sobre 4.681 chamados com decisão travada e sem conflito, o LinearSVC calibrado confirma-se como a melhor IA isolada, com acerto validado de 95,49% (IC95%: 94,89%–96,03%), à frente de SGD (95,00%), Random Forest (94,77%), Extra Trees (94,70%), Regressão Logística (94,42%) e Naive Bayes (92,03%); nenhuma estratégia de combinação de modelos supera essa IA isolada com significância estatística. A matriz de confusão IA×GLPI qualifica, sem invalidar, a premissa de rótulos ruidosos: o histórico administrativo, quando conferido, acerta mais do que a IA (98,54% contra 95,08%), mas ainda apresenta uma taxa real e não desprezível de erro confirmado (1,2% dos casos conferidos), o que justifica manter a arquitetura de validação humana como componente permanente do protocolo, não como etapa transitória a ser eliminada quando a IA atingir bom desempenho médio.

A meta original do experimento — confiança calibrada igual ou superior a 95% associada a acerto validado igual ou superior a 95% — já é observada na faixa de alta confiança da classificação oficial (99,73% de acerto validado), resultado que recomenda cautela otimista: é encorajador, mas ainda depende da conclusão da conferência humana sobre uma amostra mais representativa antes de ser tratado como meta cumprida para fins de liberação em produção sem revisão. Os próximos passos deste protocolo incluem a conclusão da conferência humana pendente (colunas M, N e P), a calibração formal por modelo (Platt/isotônica/temperatura condicionada a essa conferência, a decisão sobre retomar ou não o treinamento do oitavo modelo (transformador com ajuste fino), a revisão taxonômica dirigida pelos candidatos identificados na etapa de cruzamento de taxonomia e na entropia de Shannon, e a estabilização da publicação automática do painel, cuja intermitência técnica está documentada na auditoria que acompanha este capítulo. Com isso, o protocolo pretende seguir contribuindo tanto para a literatura de facility management e processamento de linguagem natural aplicado quanto para a melhoria concreta e continuamente auditável da gestão de manutenção predial em instituições públicas.

REFERÊNCIAS

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. ABNT NBR 5674: Manutenção de edificações: Requisitos para o sistema de gestão de manutenção. Rio de Janeiro: ABNT, 2012.

- BOUABDALLAOUI, Y.; LAFHAJ, Z.; YIM, P.; DUCOULOMBIER, L.; BENNADJI, B. Natural Language Processing Model for Managing Maintenance Requests in Buildings. *Buildings*, v. 10, n. 9, art. 160, 2020.
- GALKE, L.; SCHERP, A. Bag-of-words vs. graph vs. sequence in text classification: questioning the necessity of text-graphs and the surprising strength of a wide MLP. In: *ANNUAL MEETING OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS*, 60., 2022, Dublin. *Proceedings [...]*. Dublin: ACL, 2022. p. 4038–4051.
- GRAVES, A.; SCHMIDHUBER, J. Framewise phoneme classification with bidirectional LSTM and other neural network architectures. *Neural Networks*, v. 18, n. 5-6, p. 602–610, 2005.
- GUO, C.; PLEISS, G.; SUN, Y.; WEINBERGER, K. Q. On calibration of modern neural networks. In: *INTERNATIONAL CONFERENCE ON MACHINE LEARNING*, 34., 2017, Sydney. *Proceedings [...]*. Sydney: PMLR, 2017. p. 1321–1330.
- JOACHIMS, T. Text categorization with support vector machines: learning with many relevant features. In: *EUROPEAN CONFERENCE ON MACHINE LEARNING*, 10., 1998, Chemnitz. *Proceedings [...]*. Berlin: Springer, 1998. p. 137–142.
- KEJRIWAL, M.; SANTOS, H.; SHEN, K.; MULVEHILL, A. M.; MCGUINNESS, D. L. A noise audit of human-labeled benchmarks for machine commonsense reasoning. *Scientific Reports*, v. 14, art. 8609, 2024.
- LI, Y.; LIU, Y.; ZHANG, J.; CAO, L.; WANG, Q. Automated analysis and assignment of maintenance work orders using natural language processing. *Automation in Construction*, v. 165, art. 105501, 2024.
- LIU, Z.; BENGE, C.; JIANG, S. Ticket-BERT: labeling incident management tickets with language models. *arXiv:2307.00108*, 2023.
- MARTINS, R. F. B.; ESPEJO, M. M. S. B. Análise de custos de manutenção predial em uma universidade federal brasileira com uso do modelo de SES. *ABCustos*, São Leopoldo, v. 19, n. 1, 2024.
- MCNEMAR, Q. Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, v. 12, n. 2, p. 153–157, 1947.
- MOHAMMED, A. S.; AMOAH, C. Integration of technology in decision-making in university facilities management: a literature review. *Facilities*, v. 43, n. 13/14, p. 1018–1052, 2025.
- MORAIS, L. S. R. de; PAULA, H. M. de; REIS, R. P. A. Promoção da eficiência da manutenção predial em edificações públicas: abordagem baseada em registros de ordens de serviço. *Paranoá, Brasília*, v. 16, n. 34, p. 1–18, 2023.
- PAMPANA, A. K. et al. Data-driven analysis for facility management in higher education institution. *Buildings*, v. 12, art. 2094, 2022.
- PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.
- PLATT, J. C. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. In: SMOLA, A. J. et al. (Ed.). *Advances in Large Margin Classifiers*. Cambridge: MIT Press, 1999. p. 61–74.
- SALTON, G.; BUCKLEY, C. Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, v. 24, n. 5, p. 513–523, 1988.
- SCHWARTZ, R.; DODGE, J.; SMITH, N. A.; ETZIONI, O. Green AI. *Communications of the ACM*, v. 63, n. 12, p. 54–63, 2020.
- SOKOLOVA, M.; LAPALME, G. A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, v. 45, n. 4, p. 427–437, 2009.
- SUNDARAM, S.; ZEID, A. Technical Language Processing for Prognostics and Health Management: applying text similarity and topic modeling to maintenance work orders. *Journal of Intelligent Manufacturing*, v. 36, p. 1637–1657, 2025.

TREVISIO, M. et al. Efficient methods for Natural Language Processing: a survey. Transactions of the Association for Computational Linguistics, v. 11, p. 826–860, 2023.

ZHANG, H.; ZHANG, Y.; LI, J.; LIU, J.; JI, L. A survey on learning with noisy labels in Natural Language Processing: how to train models with label noise. Engineering Applications of Artificial Intelligence, v. 146, art. 110157, 2025.

APÊNDICES

Apêndice A — Dicionário de colunas da planilha experimental (A:M)

A aba experimental (CHAMADOS_ESQUELETO_REDUZIDO) segue o esquema fixo A:M, descrito em AGENTS.md do repositório:

Coluna	Campo
A	ID Chamado
B	TÍTULO
C	CATEGORIA COMPLETA (rótulo histórico)
D	DESCRIÇÃO GLPI
E	TÍTULO O.S.M.
F	DESCRIÇÃO O.S.M.
G	Classificação IA
H	Avaliação (%) — gravada como fração 0–1, formatada como %
I	Executor
J	Criticidade Atribuída por IA
K	Comparação — fórmula =SE(G="";"";G=C)
L	Classificado_Confiança_IA
M	CONFERÊNCIA (marcação humana; TRUE não é sobrescrito por nova classificação automática)

Apêndice B — Checklist de itens reportados

Adaptado do espírito do checklist tipo PRISMA-ScR do artigo-modelo de revisão (MCDM/TOPSIS/ODS/ESG) para relato de experimento de classificação supervisionada com validação humana. Cada item indica a subseção onde é reportado e o status na data de publicação; **não substitui a reconferência de números antes da submissão** — os status “Sim” abaixo atestam que o item é reportado em algum lugar do texto, não que o número citado já foi revalidado contra os JSONs vigentes.

Item	Subseção	Reportado?
Fonte de dados e sistema de origem declarados	3.1, 3.2	Sim (GLPI/UFSB)
Tamanho da amostra e período/corte de consolidação	3.2	Sim, mas com data de corte a reconferir
Critério de inclusão/exclusão de registros	3.2	Parcial — “chamados não vazios” declarado; demais critérios não detalhados
Pré-processamento textual	3.3	Sim
Modelos avaliados e hiperparâmetros principais	3.4	Sim (7 materializados + 1 em extensão)
Método de particionamento (out-of-fold, k-fold, seed)	3.5	Sim (out-of-fold, k-fold estratificado, seed fixa)

Item	Subseção	Reportado?
Métricas reportadas e justificativa	3.5	Sim (acurácia, macro-F1, balanced accuracy, IC95% bootstrap)
Testes estatísticos e correção para múltiplas comparações	3.5	Sim (Cochran Q, Friedman, McNemar, Nemenyi)
Critério de calibração de confiança (bruta vs. calibrada) e meta de desempenho	3.8, 4.4	Parcial — meta declarada ($\geq 95\%$ / $\geq 95\%$); calibração formal (Platt/isotônica) ainda não aplicada
Protocolo de validação humana	3.6	Sim
Cobertura da validação humana na data de publicação (n e % da base)	4 (abertura)	Sim, mas desatualizada — ver nota de revalidação de dados
Tratamento de conflitos de conferência	3.7	Sim (regra de veto/trava)
Reprodutibilidade (scripts e dados versionados)	3.9	Sim (repositório público, JSONs sanitizados)
Limitações declaradas	5, 6	Sim
Figuras/tabelas geradas a partir de dados verificáveis	4.8	Não — pendência explícita registrada

Apêndice C — Matriz de decisão M/N/P

Pendência explícita: apêndice ainda não preenchido. Deve tabular, para a amostra de conferência humana dupla, a relação entre coluna M (conferência do histórico), coluna N (conferência da IA) e coluna P (decisão final travada), com contagens por combinação de valores. Depende de extração direta da planilha experimental na data de fechamento da Seção 4 — não reaproveitar números de auditorias anteriores sem reconferência.