

CLASSIFICAÇÃO DE CHAMADOS DE MANUTENÇÃO PREDIAL COM APRENDIZADO DE MÁQUINA: DESEMPENHO E LIMITES DA AUTOMAÇÃO

Machine learning for building maintenance work-order classification: performance and the limits of automation

Adinailson Guimarães de Oliveira - adinailson.oliveira@cja.ufsb.edu.br

Fabício Berton Zanchi - fabricao.berton@ufsb.edu.br

Universidade Federal do Sul da Bahia (UFSB), Programa de Pós-Graduação em Biosistemas

RESUMO

A triagem de chamados de manutenção predial em instituições públicas depende da categoria registrada no sistema de atendimento, que condiciona o uso analítico da base. A literatura sobre classificação automática de chamados vem principalmente de outros idiomas e domínios e costuma comparar o modelo com o rótulo histórico, sem questioná-lo. Essa prática mistura erro do modelo com erro do próprio registro e não mede o risco de reescrever a base. Este artigo propõe e testa um protocolo de classificação sobre 13.972 chamados de manutenção predial universitária, em português brasileiro, em 41 categorias. As previsões vêm de validação cruzada agrupada pelo texto normalizado, a mesma unidade usada na inferência, de modo que um mesmo texto não entra ao mesmo tempo em treino e teste nem conta duas vezes como evidência. A referência de avaliação vem de auditoria administrativa sobre todo o corpus, que corrigiu a categoria de 4,25% dos registros. O melhor classificador, o LinearSVC, atinge 0,8253 de acurácia contra essa referência, à frente dos demais modelos comparados. Com calibração isotônica, esse mesmo modelo automatiza 68,90% do volume com 0,9464 de acurácia seletiva, perto da meta de 0,95, e encaminha o restante para revisão humana. A reclassificação automática da base, ao contrário, produz ganho líquido negativo nos sete modelos mesmo sob custos assimétricos, porque a divergência entre modelo e histórico prioriza a auditoria em vez de reescrever o registro. A contribuição deste artigo é esse protocolo, que une auditoria de rótulo, inferência que respeita a dependência entre textos, calibração, automação seletiva e uma medida explícita do risco de reclassificação.

Palavras-chave: manutenção predial; classificação de chamados; auditoria de rótulo; calibração e classificação seletiva; rótulos ruidosos.

ABSTRACT

Triage of building maintenance work orders in public institutions relies on the category recorded in the service-management system, which conditions the later analytical use of the database. Research on automatic classification comes mostly from other languages and domains and usually compares the model to the historical label without questioning it. This practice mixes model error with record error and leaves the risk of rewriting the database unmeasured. This paper proposes and tests a classification protocol over 13,972 university building maintenance work orders in Brazilian Portuguese, across 41 categories. Predictions come from cross-validation grouped by normalised text, the same unit used at inference, so that the same text never appears in both training and test at once nor counts twice as evidence. The evaluation reference comes from an administrative audit over the entire corpus, which corrected the category of 4.25% of records. The best classifier, LinearSVC, reaches 0.8253 accuracy against that reference, ahead of the other models compared. Under isotonic calibration, the same model automates 68.90% of the volume with 0.9464 selective accuracy, close to the 0.95 target, and routes the remainder to human review. Automatic reclassification of the base, by contrast, yields a negative net gain across the seven models even under asymmetric costs, because divergence between model and historical record prioritises the audit queue rather than rewriting the record. The contribution of this paper is precisely this protocol, which brings together label audit, inference that respects textual dependence, calibration, selective automation, and an explicit measure of reclassification risk.

Keywords: building maintenance; work-order classification; label audit; calibration and selective classification; noisy labels.

1. INTRODUÇÃO

A manutenção predial responde pela preservação do patrimônio edificado e pela continuidade das atividades finalísticas das instituições federais de ensino superior (IFES), ainda que opere sob restrição orçamentária

persistente (Martins; Espejo, 2024; Pampana *et al.*, 2022). Sob essa restrição, decidir onde intervir depende de evidência sobre o parque edificado, conforme a gestão sistematizada definida pela NBR 5674 (ABNT, 2012).

O sinal disponível para essa decisão é textual. Este artigo trata o campus universitário como um biossistema construído, definição operacional aqui proposta para a integração dinâmica entre infraestrutura física, atividade humana, sistemas tecnológicos e condicionantes ambientais, cuja governança depende da capacidade institucional de captar sinais e convertê-los em decisão. Essa definição apoia-se na perspectiva sistêmica de Capra (1997), na concepção de ecossistema de Odum (1996) e na ecologia urbana de Grimm *et al.* (2000), ainda que nenhum desses autores cunhe o termo. O artigo não mede a retroalimentação ecológica entre uso, falha e reparo (Subseção 5.4); seu objeto é o protocolo de classificação que organiza o sinal textual. Nas IFES, esse sinal assume a forma de registros de chamados de manutenção, armazenados em linguagem não estruturada, cuja interpretação individual impede o uso direto por mecanismos de decisão automatizada (Morais; Paula; Reis, 2023; Mohammed; Amoah, 2025). Convertê-los em dado estruturado e auditável é condição anterior a qualquer camada preditiva.

Três obstáculos condicionam essa conversão: a natureza textual curta e heterogênea dos registros, cujas abreviações locais e jargões de equipe dificultam a aplicação de modelos genéricos de processamento de linguagem natural (PLN) (Sundaram; Zeid, 2025); o desbalanceamento entre categorias, em que demandas recorrentes concentram grande parte da base e categorias raras dispõem de poucos exemplos para treinamento supervisionado (Li *et al.*, 2024); e a qualidade do próprio rótulo histórico, que pode resultar de interpretação rápida ou de taxonomia ainda não estabilizada, e por isso constitui evidência importante sem ser referência definitiva (Zhang *et al.*, 2025; Kejriwal *et al.*, 2024).

A literatura confirma a viabilidade técnica da tarefa, com acurácia de 0,83 sobre 15.623 ordens de serviço hospitalares (Li *et al.*, 2024) e 78% em requisições de edificação hospitalar (Bouabdallaoui *et al.*, 2020). Essas aplicações concentram-se, todavia, em bases de outros idiomas e em domínios industriais ou hospitalares, e avaliam o classificador contra o rótulo registrado, sem submetê-lo a auditoria. Restam duas lacunas: a escassez de corpora em português brasileiro na manutenção predial pública universitária, e a ausência de protocolo que trate a categoria histórica como objeto de auditoria e meça o risco de reescrevê-la.

A pergunta que orienta este artigo não é qual classificador mais concorda com a categoria histórica. É sob que condições a classificação automática produz dado estruturado confiável sem herdar as inconsistências do registro que lhe deu origem.

A resposta é um protocolo auditável, medido sobre 14.060 chamados reais de uma instituição federal de ensino superior. A contribuição não está na comparação entre algoritmos, aqui meio e não fim, mas na articulação de cinco elementos: auditoria administrativa de rótulo sobre o corpus integral, que separa a concordância com o histórico do acerto contra a referência revisada; inferência que respeita a dependência entre chamados de texto repetido, com o grupo textual como unidade na partição e nos testes; calibração dos escores de confiança; automação seletiva condicionada a esses escores, com encaminhamento do restante ao revisor; e avaliação do risco de reclassificação por função de utilidade explícita. Sete classificadores percorrem o protocolo sob as mesmas partições; o BERTimbau fica fora por custo computacional medido.

O objetivo geral é avaliar em que medida esse protocolo produz camada de dados estruturados apta a sustentar a governança da manutenção predial pública, consoante à integração físico-humano-tecnológico-ambiental do biossistema construído. Especificamente, o estudo busca auditar a categoria histórica sobre a totalidade do corpus, comparar sete classificadores sob o mesmo protocolo agrupado, calibrar os escores de confiança de modo a viabilizar automação seletiva e avaliar o risco de reclassificação automática da base sob função de utilidade explícita.

2. REFERENCIAL CONCEITUAL

2.1 Classificação automática de ordens de manutenção e de chamados

Ordens de manutenção documentam sintomas, locais, equipamentos e soluções em forma textual semiestruturada, o que lhes confere valor informacional elevado e uso habitualmente reduzido no planejamento (Pampana *et al.*, 2022; Moraes; Paula; Reis, 2023). Li *et al.* (2024) são a referência-âncora desta pesquisa por tratarem da automação de ordens de manutenção predial, ainda que em idioma e taxonomia distintos, e Sundaram e

Zeid (2025) acrescentam que chamados curtos e descrições incompletas inviabilizam modelos genéricos sem adaptação lexical ao corpus.

Na classificação de *tickets*, a evolução das representações lexicais aos modelos pré-treinados, como o Ticket-BERT, preprint no arXiv (Liu; Benge; Jiang, 2023), não se transfere sem cautela à manutenção predial, cujos sistemas e equipamentos não coincidem com categorias de incidentes digitais (Sundaram; Zeid, 2025). Em texto curto de vocabulário especializado, classificadores lineares sobre TF-IDF sustentam desempenho equivalente ao de redes neurais em múltiplos *benchmarks* (Galke; Scherp, 2022).

2.2 Desbalanceamento e rótulos ruidosos

Duas propriedades da base condicionam a leitura das métricas. O desbalanceamento entre categorias faz a acurácia agregada ser dominada pelas classes majoritárias e mascarar falhas nas raras, o que recomenda métricas de média por classe com o suporte declarado (Sokolova; Lapalme, 2009) e leva a classificação hierárquica de chamados a excluir rótulos de frequência muito baixa (Marcuzzo *et al.*, 2022). O ruído de rótulo decorre de ambiguidade semântica, sobreposição taxonômica ou erro de registro (Zhang *et al.*, 2025), e *benchmarks* rotulados por humanos contêm variabilidade relevante, o que questiona a prática de assumir referência única onde há julgamento subjetivo (Kejriwal *et al.*, 2024). A categoria histórica é, por conseguinte, tratada como registro administrativo sujeito a auditoria, e a referência de avaliação provém dessa auditoria de rótulo, e não do registro original tomado como definitivo.

2.3 Calibração e classificação seletiva

O escore de confiança de um classificador não é, por construção, uma probabilidade, e associá-lo à frequência de acerto exige calibração, seja por ajuste sigmoidal da margem (Platt, 1999), seja por regressão isotônica, necessidade que persiste mesmo em arquiteturas de alto desempenho (Guo *et al.*, 2017). É a calibração que torna operável a classificação seletiva, regime no qual o modelo decide apenas acima de um limiar de confiança e transfere os demais casos a outro decisor, cujo compromisso entre erro e rejeição foi formulado por Chow (1970) e é hoje reportado como par entre cobertura e risco (El-Yaniv; Wiener, 2010). Em fluxo humano-IA, é esse par que delimita quanto do volume pode ser decidido automaticamente e quanto deve ser encaminhado ao revisor humano.

2.4 Custo computacional e delimitação de escopo

A eficiência computacional deve ser reportada e valorizada na avaliação de modelos, não apenas a acurácia (Schwartz *et al.*, 2020; Treviso *et al.*, 2023). Em instituição pública o critério é decisório, pois um modelo que treina em segundos é reexecutado e auditado sem infraestrutura dedicada. É por esse critério que os modelos de linguagem de grande porte ficam fora desta comparação, embora dispensem ajuste supervisionado ao inferir a tarefa do próprio enunciado (Brown *et al.*, 2020). Eles exigem aceleradores dedicados ou serviços tarifados por uso. Deslocam as descrições dos chamados para fora do domínio da instituição. E variam entre versões do serviço, o que compromete a reprodutibilidade exigida pelo delineamento (Bender *et al.*, 2021). O protocolo integral não foi executado sobre essas arquiteturas nem sobre o BERTimbau, cujo custo medido é tratado na Subseção 4.5, de modo que nada se afirma sobre seu desempenho relativo.

3. MÉTODO

3.1 Delineamento, corpus e referência revisada

O estudo adota delineamento experimental aplicado sobre base observacional retrospectiva de chamados de manutenção predial do sistema GLPI de uma instituição federal de ensino superior pública multicampi (Morais; Paula; Reis, 2023). A unidade de análise é o chamado individual, representado pelo título e pela descrição do chamado e pelo título e pela descrição da ordem de serviço, aos quais se associa a categoria histórica registrada no sistema. O corpus congelado reúne 14.060 chamados de texto não vazio em 50 categorias históricas, cuja distribuição consta do Apêndice A, e corresponde a um corte único de extração sobre o qual os artefatos foram materializados e versionados. O idioma é o português brasileiro, com jargão técnico, abreviações locais e descrições incompletas (Sundaram; Zeid, 2025). O corte não preserva a data de abertura do chamado, restrição tratada na Subseção 5.3. A Figura 1 apresenta o fluxo metodológico como *pipeline* de governança preditiva, no qual a revisão humana precede o treinamento, pois dela sai o rótulo com que os modelos são treinados e contra o qual são avaliados.




Figura 1: Pipeline de governança preditiva, do fluxo de extração da base à retroalimentação por auditoria de rótulo.

A revisão humana é auditoria administrativa de rótulo, e não anotação independente. A pergunta submetida ao especialista é se a categoria já registrada é adequada ao chamado. Para cada registro, o avaliador examinou os quatro campos textuais e a categoria histórica, sem acesso a previsões ou níveis de confiança dos modelos. Confirmada a categoria, ela permanece como referência; rejeitada, o avaliador registra outra da mesma taxonomia. A revisão cobriu todo o corpus, com 13.462 manutenções da categoria histórica e 598 substituições, taxa de alteração de 4,25%. Manter a categoria é confirmação administrativa, não concordância entre avaliadores nem correção factual. Havendo uma única decisão por registro, não há segunda avaliação, cegamento nem adjudicação, e nenhuma medida de confiabilidade entre avaliadores é reportada; a ancoragem e as demais restrições constam da Subseção 5.3.

Uma análise de consistência interna complementa esse desenho sem substituir avaliação independente. O procedimento localiza os grupos de texto normalizado idêntico que receberam mais de uma categoria de referência e classifica cada um conforme as categorias em disputa pertençam ou não ao mesmo tipo de manutenção. Os grupos assim identificados sinalizam ambiguidade de contexto não textual ou inconsistência interna, origens que só o reexame caso a caso separaria. A contagem consta da Subseção 4.4.

3.2 Pré-processamento e representação

A normalização altera a matriz de atributos e, com ela, o desempenho dos modelos (Salton; Buckley, 1988). Os quatro campos são localizados por cabeçalho, despojados de espaços nas extremidades e concatenados por quebra de linha na ordem título do chamado, descrição do chamado, título da ordem de serviço e descrição da ordem de serviço. Campos vazios são descartados da concatenação, sem substituição por marcador. Para o agrupamento, cada campo é normalizado separadamente por decomposição Unicode com remoção de diacríticos, caixa baixa e colapso de espaços. O identificador do grupo é o resumo SHA-256 da serialização dos quatro campos normalizados mantidos separados, e não do texto concatenado, o que evita colidir registros que só coincidiriam após a junção.

A representação dos classificadores clássicos é TF-IDF com remoção de acentos, caixa baixa, n -gramas de uma e duas palavras, frequência documental mínima de uma ocorrência e limite superior de 30.000 atributos. A LSTM emprega tokenização própria, com vocabulário de 8.000 termos, marcador explícito para termo fora do vocabulário e comprimento máximo de 120 *tokens*, com preenchimento e truncamento à direita. Vetorizador, tokenizador e vocabulário são ajustados dentro de cada dobra, sobre a partição de treino. A etapa preserva termos técnicos, códigos de ambientes e nomes de equipamentos, pois palavras como *bomba*, *split* e *infiltração* são âncoras semânticas de categorias específicas.

3.3 Modelos e configuração experimental

Sete modelos em três famílias compõem a comparação principal, escolhidas pelas características do domínio: texto curto, vocabulário técnico e forte desbalanceamento. Nenhuma das três é descartada a priori: a

Tabela 1: Configuração experimental dos sete modelos, que compartilham partições, rótulo de treino e denominador ($n = 13.972$; 41 categorias).

Modelo	Representação	Hiperparâmetros essenciais	Balanceamento	Saída de confiança	Papel
Naive Bayes	TF-IDF	suavização $\alpha = 1$	nenhum	probabilidade máxima	<i>baseline</i> probabilístico
Regressão Logística	TF-IDF	até 1.000 iterações	pesos balanceados	probabilidade máxima	linear probabilístico
LinearSVC	TF-IDF	margem máxima, $C = 1$	pesos balanceados	<i>softmax</i> da margem	linear de margem máxima
SGD	TF-IDF	perda logarítmica	pesos balanceados	probabilidade máxima	linear incremental
Random Forest	TF-IDF	200 árvores	pesos balanceados	probabilidade máxima	<i>ensemble</i> agregado
Extra Trees	TF-IDF	200 árvores, cortes aleatórios	pesos balanceados	probabilidade máxima	<i>ensemble</i> aleatorizado
LSTM Bidirecional	tokenização própria	<i>embedding</i> de 128, 64 unidades, <i>dropout</i> 0,5, densa de 64, lote de 128	pesos balanceados	<i>softmax</i>	rede neural sequencial

comparação sob o mesmo protocolo permite decidir entre elas por evidência, não por preferência de projeto. Fronteiras lineares separam bem as classes sobre representação esparsa quando o vocabulário carrega poder discriminativo (Joachims, 1998; Salton; Buckley, 1988). Os *ensembles* de árvores capturam interações não lineares a custo maior, pagando por essa flexibilidade em tempo de treino. O Naive Bayes assume independência condicional entre atributos dada a classe, suposição violada quando termos técnicos co-ocorrem dentro de uma mesma categoria (Pedregosa *et al.*, 2011), mas serve de piso comparativo barato para as demais famílias. E a LSTM treina seus *embeddings* do zero (Graves; Schmidhuber, 2005), concentrando nessa camada cerca de 1,02 milhão de parâmetros, ordem de grandeza próxima dos 11.178 exemplos de cada partição de treino. A Tabela 1 resume representação, configuração e papel de cada modelo; os hiperparâmetros não declarados permanecem nos padrões da biblioteca e estão versionados com o ambiente de execução. Nenhum dos sete modelos passou por busca de hiperparâmetros: a comparação avalia as configurações da Tabela 1, sem representar o máximo desempenho de cada arquitetura.

Um oitavo modelo, o BERTimbau-Base (Devlin *et al.*, 2019; Souza; Nogueira; Lotufo, 2020), é experimento exploratório fora da comparação principal: foi ajustado sob protocolo distinto, com subamostragem estratificada e parada antecipada, sem predições *out-of-fold* sobre todo o corpus. A medição de custo que fundamenta a separação consta da Subseção 4.5, e nada se afirma, por ora, sobre seu desempenho relativo aos demais modelos.

3.4 Validação, calibração e inferência

A avaliação usa predições *out-of-fold* com **StratifiedGroupKFold**, cinco dobras, embaralhamento e semente fixa, estratificação pela referência revisada e agrupamento pelo hash do texto normalizado da Subseção 3.2, de modo que nenhum grupo atravessa a fronteira entre treino e teste. As partições são geradas uma única vez, versionadas e reutilizadas por todos os modelos e pela camada de regras, o que legitima os testes pareados (Sokolova; Lapalme, 2009), e foram preferidas a conjunto de teste fixo pela menor variância das estimativas em bases desbalanceadas (Kohavi, 1995). A separação é textual, e não cronológica: as métricas medem generalização para grupos de texto não vistos dentro do mesmo corte de extração, e não desempenho sobre chamados posteriores.

O agrupamento impõe custo de cobertura: uma categoria só entra na avaliação se tiver grupos textuais distintos em número suficiente para as cinco dobras. Nove das 50 categorias não satisfazem essa condição, quatro por aritmética e cinco por ausência efetiva em alguma dobra após a estratificação; somam 88 linhas, ou 0,63% da base congelada, e sua exclusão reduz o denominador das métricas de 14.060 para 13.972 registros

em 41 categorias; as nove excluídas, de menor frequência, constam da Tabela A3. As alternativas examinadas, com o efeito de cada convenção de denominador, constam da Subseção 4.1 e do material suplementar.

A unidade da inferência é o grupo textual, e não o chamado. Das 14.060 linhas, 4.586, ou 32,62%, compartilham texto normalizado com outra; a base congelada resolve-se em 9.786 grupos, 9.474 deles unitários, e 9.735 sobrevivem ao recorte das 13.972 linhas avaliadas. O mapa recalculado sobre o texto vivo, calculado após o congelamento da base, registra 9.734 grupos; a diferença de um grupo decorre de edição textual posterior ao congelamento e não altera o artefato canônico, cujos números são os únicos reportados neste artigo. Registros de texto idêntico recebem a mesma predição de qualquer classificador e não são evidências independentes; tratá-los como tal estreita artificialmente intervalos e valores de p (Cochran, 1977).

As métricas são assim definidas. A acurácia é a proporção de registros cuja predição coincide com a referência revisada, e o *macro-F1*, a média aritmética simples do F1 por categoria, que pondera igualmente classes de qualquer suporte (Sokolova; Lapalme, 2009). O erro de calibração esperado (ECE) é a média, ponderada pelo número de registros, do módulo da diferença entre acurácia e confiança média em dez faixas de largura igual, e o *escore de Brier*, na formulação binária de acerto ou erro, pune má calibração e baixa resolução. A cobertura é a fração de registros cuja confiança calibrada atinge o limiar, a acurácia seletiva restringe a acurácia a eles, e o complemento da cobertura é a taxa de encaminhamento humano. O ganho líquido é a diferença entre corrigidos e prejudicados onde a predição diverge do histórico, qualificado pela utilidade da Subseção 4.2.

A calibração e a escolha do limiar seguem desenho de dobra interna. Para cada dobra externa, uma dobra interna é escolhida deterministicamente entre as demais; o modelo é treinado nas três restantes e prediz a interna, e os pares de *escore* e acerto assim obtidos ajustam a regressão isotônica e fixam o limiar como o menor *escore* que atinge o alvo de acurácia. Calibrador e limiar são então aplicados aos *escores out-of-fold* da dobra externa, sobre a qual recai a avaliação. Transformações, tokenizadores, vocabulários, calibradores e limiares são, sem exceção, ajustados sem acesso à dobra externa.

A hipótese global de igualdade das taxas de acerto é apurada pela estatística Q de Cochran (Cochran, 1950), com a distribuição qui-quadrado tabelada substituída por referência empírica obtida por permutação do rótulo de modelo dentro de cada grupo, o que preserva a dependência interna (Good, 2005; Anderson; Ter Braak, 2003). Rejeitada a igualdade, os 21 pares são comparados por permutação pareada com troca de sinal da diferença de acertos por grupo, com correção sequencial de Holm-Bonferroni (Holm, 1979), e os intervalos das métricas e das diferenças vêm de *bootstrap* de conglomerados, que sorteia grupos com reposição e reconstrói a amostra com todos os registros de cada grupo sorteado (Efron, 1979; Efron; Tibshirani, 1993; Diccicio; Efron, 1996; Field; Welsh, 2007; Cameron; Gelbach; Miller, 2008). A divisão aleatória por linha permanece apenas como análise de sensibilidade, no material suplementar.

3.5 Reclassificação, utilidade e análises complementares

Cinco análises complementam a comparação principal, sobre as mesmas partições e sem alterar a referência revisada. A reclassificação da base histórica conta os registros em que a predição diverge da categoria histórica, arbitrados pela referência, e é qualificada pela utilidade sob custos assimétricos (Subseção 4.2). Uma camada explícita de regras de periodicidade atribui categoria preventiva quando o texto reúne termo de periodicidade e de equipamento. A camada informacional de entropia de Shannon e divergência de Jensen-Shannon (Shannon, 1948; Lin, 1991) é calculada sobre agregados e mede dispersão das predições, distância frente à distribuição histórica e desacordo entre modelos, este último usado para ordenar fila de auditoria, sem inferir desordem do sistema físico. Um teste de sensibilidade examina a cobertura sob três convenções de denominador.

A quinta análise é confirmatória. Votação majoritária, votação suave ponderada e stacking foram comparadas ao LinearSVC sobre os 13.972 registros cuja categoria histórica pertencia às 41 classes avaliadas, com previsões *cross-fitted* dos sete modelos-base, sem novo ajuste, em filas de igual capacidade. A capacidade da fila é definida, em cada dobra externa, pela fila natural de divergências do LinearSVC, sem limiar otimizado na avaliação externa. O parâmetro de suavização da votação ponderada foi escolhido só internamente, e cada metamodelo de stacking foi ajustado sem acesso à dobra externa avaliada.

3.6 Reprodutibilidade computacional

Tabela 2: Concordância com a categoria histórica, acurácia e macro-F1 contra a referência humana revisada, e custo de treino, por modelo ($n = 13.972$; 41 categorias). O intervalo é da acurácia, obtido por *bootstrap* de grupo textual com mil repetições sobre os 9.735 grupos congelados; o custo de treino é mediana de três execuções sobre a base completa.

Modelo	Concordância histórica	Acurácia	Macro-F1	Intervalo essencial (IC95% da acurácia)	Tempo de treino (s)
LinearSVC	0,7961	0,8253	0,6684	0,8115 – 0,8378	2,44
SGD	0,7781	0,8093	0,6669	0,7950 – 0,8227	2,28
Extra Trees	0,7844	0,8073	0,6362	0,7923 – 0,8211	26,69
Regressão Logística	0,7738	0,8050	0,6689	0,7907 – 0,8189	8,43
Random Forest	0,7747	0,7970	0,6152	0,7812 – 0,8111	22,62
LSTM	0,7017	0,7287	0,5240	0,7080 – 0,7480	83,44
Naive Bayes	0,6954	0,7088	0,2951	0,6860 – 0,7311	1,12

A rodada canônica foi executada em ambiente Linux de 64 bits, sobre executor hospedado de quatro processadores sem acelerador gráfico, com Python 3.11.15, NumPy 1.26.4, scikit-learn 1.5.2 e TensorFlow 2.17.0. A semente 42 foi aplicada ao embaralhamento das partições e aos componentes do scikit-learn que recebem `random_state`. A execução canônica da LSTM não fixou a semente global do TensorFlow. Partições, rótulos e protocolo são, portanto, reproduzíveis, mas os pesos e a trajetória de treinamento não o são de forma exata.

O treino da LSTM percorre no máximo quinze épocas, com separação interna de 10% para validação. A interrupção antecipada monitora a perda de validação, com paciência de três épocas e restauração dos pesos da melhor época, registrada no artefato de cada execução. Os tempos reportados na Subseção 4.1 estão em segundos e correspondem à mediana de três repetições de treino único sobre a base completa, não à soma das cinco dobras. Uma matriz de proveniência versionada associa cada número, tabela e figura ao script que o gerou, à entrada utilizada, ao denominador, à taxonomia, às partições e ao resumo criptográfico do corpus congelado.

4. RESULTADOS

Dois denominadores organizam a leitura desta seção. A base congelada contém 14.060 chamados, todos com referência humana, e é o número pertinente sempre que a frase tratar do corpus ou da cobertura da revisão. As métricas de desempenho, calibração e inferência são apuradas sobre as 13.972 linhas em 41 categorias que compõem as partições canônicas (Subseção 3.4; Tabela A3).

4.1 Desempenho, incerteza e custo

A comparação contra a categoria histórica, sobre as predições *out-of-fold* da rodada canônica ($n = 13.972$), mantém o LinearSVC à frente em acordo bruto, seguido por Extra Trees, SGD, Random Forest e Regressão Logística, com LSTM e Naive Bayes na última posição; o BERTimbau fica fora desse conjunto pelo motivo computacional detalhado na Subseção 4.5. A revisão humana estabeleceu categoria de referência para a totalidade dos 14.060 chamados da base congelada, e a avaliação contra essa referência incide sobre as 13.972 linhas das partições. Nela, o LinearSVC é o modelo de maior acurácia, com 0,8253 (IC95%: 0,8115–0,8378), seguido por SGD, Extra Trees, Regressão Logística e Random Forest, com LSTM e Naive Bayes bem atrás. A cobertura integral da revisão evita o viés decorrente de selecionar apenas uma subamostra para revisão, de modo que a acurácia relatada não constitui limite superior de amostra conferida; ela não elimina, porém, as ressalvas metodológicas detalhadas na Subseção 5.3.

Nenhum modelo vence em todos os critérios. As três melhores marcas de macro-F1 ficam a menos de três milésimos umas das outras, com Regressão Logística em 0,6689, LinearSVC em 0,6684 e SGD em 0,6669, e seus intervalos de confiança se sobrepõem integralmente, o que impede ordenar os três por essa métrica isoladamente. A leitura pertinente é que o LinearSVC lidera a acurácia sem pagar por isso em desempenho na cauda, ao contrário dos *ensembles* de árvores, que perdem cerca de três centésimos de macro-F1 na mesma faixa de acurácia. O SGD permanece competitivo nas duas métricas a um custo de treino semelhante ao do LinearSVC. A escolha operacional é, portanto, orientada por múltiplos critérios de avaliação, e deve pesar acurácia, macro-F1 e custo computacional em conjunto.

O custo de treino, medido no mesmo ambiente computacional para os sete modelos sobre a base completa, com mediana de três execuções, reforça a leitura orientada por múltiplos critérios. Os modelos lineares treinam em poucos segundos, de 1,12 s no Naive Bayes a 8,43 s na Regressão Logística, os *ensembles* de árvores exigem entre vinte e trinta segundos e a rede neural LSTM consome 83,44 segundos, cerca de 34 vezes o tempo do LinearSVC, para 9,7 pontos percentuais a menos de acurácia. Os tempos absolutos e as razões entre modelos descrevem o ambiente avaliado, um processador de quatro núcleos sem acelerador gráfico; a estabilidade relativa desses tempos em outras infraestruturas não foi testada. A Figura 2 cruza essas medições de custo com a acurácia e mostra o LinearSVC na posição mais favorável, com a maior acurácia a um custo de treino próximo do menor observado. O BERTimbau segue fora dessa leitura pelo mesmo motivo computacional (Subseção 4.5).




Figura 2: Trade-off entre acurácia e tempo de treino dos sete modelos comparados.

A comparação entre modelos exige tratar a dependência entre registros de texto idêntico como propriedade do desenho, e não como detalhe de implementação: as 13.972 linhas avaliadas distribuem-se por 9.735 grupos textuais, e 4.546 delas, ou 32,54%, pertencem a grupos com mais de um membro. O efeito de desenho, razão entre a variância da acurácia sob reamostragem de conglomerados e a variância binomial que a suposição de independência produziria (Cochran, 1977), fica entre 4,47 no LinearSVC e 8,83 no Naive Bayes, de modo que toda inferência desta subseção adota o grupo textual como unidade. O teste global rejeita a igualdade entre os sete modelos: a estatística Q de Cochran vale 2.661,04 sobre seis graus de liberdade, apurada contra distribuição empírica de duas mil permutações do rótulo de modelo dentro de cada grupo, com $p \leq 0,0005$. Só então os 21 pares foram comparados, por permutação pareada com troca de sinal da diferença de acertos por grupo e correção de Holm sobre a família: dezenove são significativos após a correção e dois não são, Extra Trees contra Regressão Logística e Extra Trees contra SGD, ambos com intervalo da diferença contendo o zero, o que é coerente com a sobreposição de macro-F1 relatada acima. Contra o segundo colocado, SGD, a vantagem do LinearSVC de 1,60 ponto percentual (IC95%: 0,0118–0,0204) corresponde a 533 grupos favoráveis contra 308, com 8.894 empatados: vantagem estatisticamente estabelecida e vantagem prática são coisas distintas, e nove de cada dez grupos não distinguem os dois modelos. A matriz completa dos 21 pares, com intervalos, grupos favoráveis e tamanho de efeito, consta do material suplementar.

O macro-F1 de 0,6684 do LinearSVC é média sobre as 41 categorias com suporte nas partições. Sob um cenário pessimista de sensibilidade, atribuindo F1 igual a zero às nove categorias ausentes das 50 da taxonomia, esse valor cai a 0,5481; não se trata de desempenho observado de um modelo treinado nas 50 categorias, pois nenhum classificador prevê categoria que não esteve em seu treino: a cobertura de linhas permanece alta, 99,37%, mas a de categorias cai a 82%. Agregado às 14 famílias do primeiro nível da taxonomia, o macro-F1 sobe a 0,6816, granularidade em que o LinearSVC assume também a liderança dessa métrica, antes com a Regressão Logística por três milésimos. A ordenação dos modelos é estável nas três convenções de denominador, à exceção dessa troca de posição no topo; os valores por modelo constam do material suplementar.

Tabela 3: Ganho líquido de reclassificação por modelo, contado apenas onde a predição diverge da categoria histórica e arbitrado pela referência humana revisada ($n = 13.972$). Neutros: registros em que a predição diverge da categoria histórica sem que predição ou histórico coincidam com a referência revisada.

Modelo	Divergências	Corrigidos	Prejudicados	Neutros	Ganho líquido
LinearSVC	2.849	475	2.321	53	−1.846
SGD	3.100	489	2.559	52	−2.070
Extra Trees	3.012	422	2.519	71	−2.097
Regressão Logística	3.161	492	2.621	48	−2.129
Random Forest	3.148	416	2.658	74	−2.242
LSTM	4.168	426	3.621	121	−3.195
Naive Bayes	4.256	309	3.783	164	−3.474

4.2 Auditoria do histórico e risco de reclassificação

A revisão humana manteve a categoria histórica em 95,75% dos casos da base congelada, taxa de alteração de 4,25% (Subseção 3.1), e não estimativa de prevalência de erro. Essa estabilidade da referência explica o resultado da reclassificação automática: como o histórico concorda com a revisão na quase totalidade dos casos, divergir dele costuma significar divergir também da referência.

O ganho líquido de reclassificação, contado apenas onde a predição diverge da categoria histórica e arbitrado pela referência revisada, é negativo nos sete modelos, de −1.846 no LinearSVC a −3.474 no Naive Bayes (Tabela 3). O melhor modelo produz 2.849 divergências, das quais apenas 475 representam correção contra 2.321 que degradariam o registro, razão que piora monotonicamente à medida que cai o desempenho do modelo. A reclassificação automática em massa não é, portanto, desaconselhada por cautela metodológica, mas por evidência de que degradaria a base em que fosse aplicada, e o ganho líquido, e não a acurácia agregada, é o critério adequado para essa decisão, a ser recalculado a cada atualização da base.

O ganho líquido simples pressupõe corrigir e estragar um registro valerem o mesmo, e revisar não custar nada. A qualificação decisória substitui essa hipótese pela função de utilidade $U = b \times \text{corrigidos} - c \times \text{prejudicados} - r \times \text{revisados}$, normalizada pelo benefício da correção em duas razões adimensionais: $\rho = c/b$, o custo do prejuízo em unidades de benefício, e $\lambda = r/b$, o custo da revisão humana na mesma unidade. Sob aplicação direta, a utilidade só seria positiva se ρ ficasse abaixo da razão de equilíbrio corrigidos/prejudicados, que vale 0,2047 no LinearSVC e cai a 0,0817 no Naive Bayes: a reclassificação exigiria estragar um registro por menos de um quinto do que vale corrigir outro, condição que a natureza do dano não sustenta, pois o registro corrompido propaga para a série temporal da categoria (Subseção 5.4). Em toda a faixa examinada, de $\rho = 0,25$ a $\rho = 4$, a utilidade é negativa nos sete modelos.

A mesma predição sustenta, entretanto, uma política de triagem: se a divergência apenas enfileira o chamado para revisão humana, sem reescrever o rótulo, não há prejudicados por construção, e o benefício é a fração da fila cujo histórico de fato estava errado. Essa fração soma corrigidos e neutros, pois nos dois casos a categoria histórica era inadequada: $(475 + 53) / 2.849 = 18,53\%$ no LinearSVC contra a taxa de alteração de 4,25% na base, enriquecimento de cerca de quatro vezes sobre a revisão aleatória. Essa precisão da fila de triagem não é a precisão estatística do classificador (Subseção 4.1). O limite de equilíbrio de λ coincide com essa precisão: a triagem paga enquanto revisar um chamado custar menos de 18,5% do que vale corrigir um registro. A consequência operacional é discutida na Subseção 5.2, e os valores por modelo constam do material suplementar.

4.3 Calibração e automação seletiva

A confiança bruta dos classificadores não é probabilidade e não sustenta decisão operacional sem tratamento: o erro de calibração esperado (ECE) do LinearSVC alcança 0,6925 sobre o escore bruto, porque a transformação da margem por função *softmax* produz valores que não correspondem a frequências de acerto. A calibração isotônica, ajustada em dobra interna, reduz esse valor a 0,0178 e o escore de Brier de 0,6052 para 0,1034, e melhora o ECE de cinco dos sete modelos (Tabela 4). Naive Bayes e LSTM foram as exceções, com aumento do ECE após a calibração, cuja causa não foi investigada.

Tabela 4: Calibração e automação seletiva dos sete modelos ($n = 13.972$). O ECE refere-se ao escore antes e depois da calibração isotônica; a cobertura e a acurácia seletiva correspondem ao alvo de 0,95.

Modelo	ECE bruto	ECE calibrado	Cobertura	Acurácia seletiva
LinearSVC	0,6925	0,0178	0,6890	0,9464
SGD	0,3046	0,0109	0,6162	0,9531
Extra Trees	0,0859	0,0108	0,6732	0,9502
Regressão Logística	0,2351	0,0189	0,6237	0,9415
Random Forest	0,0913	0,0145	0,6580	0,9495
LSTM	0,0158	0,0479	0,6545	0,9210
Naive Bayes	0,0144	0,0206	0,5518	0,9306

A calibração viabiliza a automação seletiva, em que o classificador decide sozinho acima de um limiar de confiança e encaminha o restante à revisão humana. Ao alvo de 0,95 de acurácia, o Extra Trees automatiza 67,32% dos chamados com acurácia seletiva de 0,9502, o SGD automatiza 61,62% com 0,9531 e o LinearSVC automatiza 68,90% com 0,9464, faixa que ilustra a mesma escolha por múltiplos critérios da Subseção 4.1 entre cobertura e acurácia seletiva. Parte das acurácias seletivas fica pouco abaixo do alvo, consequência esperada de escolher o limiar em dobra interna sem acesso ao conjunto de teste. Elevar o alvo a 0,99 reduz a cobertura à faixa de 31,94% a 47,04%, e o Naive Bayes só alcança o limiar em duas das cinco dobras, o que o desqualifica para esse regime.

A Figura 3 apresenta a curva de confiabilidade do Extra Trees calibrado, tornando visível a aderência entre confiança declarada e acerto observado ao longo das dez faixas.




Figura 3: Curva de confiabilidade do Extra Trees após calibração isotônica, com confiança média e acurácia observada por faixa.

4.4 Erros por categoria e implicações taxonômicas

O diagnóstico de dispersão entre as predições dos sete modelos mostra que diversidade de categorias previstas e aderência à distribuição histórica não caminham juntas neste corpus: o LSTM tem a maior entropia normalizada (0,8362) e o LinearSVC a menor divergência de Jensen-Shannon frente ao histórico (0,0055). No nível do chamado, os sete modelos são unânimes em 60,44% dos registros e discordam em três ou mais categorias em 16,35% deles, conjunto que caracteriza desacordo estrutural entre arquiteturas e prioriza auditoria complementar à baixa confiança de um único modelo. O Naive Bayes sintetiza o diagnóstico ao combinar a menor

cobertura de categorias, apenas 22 contra 39 a 41 dos demais modelos, com a menor entropia normalizada e a maior divergência frente ao histórico, o que explica seu macro-F1 de 0,2951 apesar de acurácia próxima de 0,71. O Naive Bayes é o único modelo sem reponderação de classes (Tabela 1), o que pode contribuir para sua degradação nas classes minoritárias, sem que todo o desempenho inferior lhe seja atribuível.

O desempenho também não é uniforme entre as 41 categorias avaliadas. A Figura 4 contrasta, entre as 33 categorias com suporte mínimo de trinta registros, as dez de maior e as dez de menor F1 do LinearSVC: nas melhores, o F1 varia de 0,9139 a 0,9972 sobre 6.271 chamados, quase todas de Manutenção Preventiva, de rotina programada e descrição padronizada; nas piores, cai à faixa de 0,2162 a 0,6288 sobre 2.403 chamados, de porte comparável, concentrando rótulos de fronteira aberta como Telhados preventivos, Reforma, Erro de chamado e Alvenaria, Pisos e Estrutura, que competem por vocabulário com categorias vizinhas. O padrão é sistemático, na linha do que Zhang *et al.* (2025) descrevem para rótulos ruidosos em processamento de linguagem natural, e não aleatório. O desempenho por categoria, com suporte, tipo e classe de volume, consta da Tabela A2.




Figura 4: F1 do LinearSVC e suporte, para as dez categorias de maior e de menor desempenho entre as 33 com suporte mínimo de 30 chamados.

Abaixo desse piso de suporte, três categorias chegam a F1 nulo ou próximo de nulo. Duas têm F1 zerado para o LinearSVC, Manutenção Preventiva > Hidráulica, com 27 registros, e Projetos e Reformas > Projeto, com 23, e uma terceira, Suprimentos / Apoio Técnico > Limpeza de equipamentos, ambiente e mobiliário, com 13 registros, registra F1 de 0,0909 (Tabela A2). Uma categoria com F1 nulo é inutilizável como insumo de série temporal por categoria, pois a predição sistematicamente errada desloca a contagem para outra classe.

A Figura 5 recorta a matriz de confusão sobre as oito categorias mais envolvidas em troca recíproca. A célula dominante registra 1.066 chamados de Instalação e reparo de equipamentos preditos como Alvenaria, Pisos e Estrutura, com 937 no sentido inverso, a maior fronteira do corpus, com 2.003 trocas somadas; seguem-se Alvenaria contra Esquadrias, com 1.097 trocas, e Alvenaria contra Hidráulica, com 940. Alvenaria, Pisos e Estrutura comparece nos cinco maiores pares e se comporta como categoria absorvente, para a qual convergem chamados sem sistema predial delimitado na descrição; a leitura assimétrica sugere absorção, não simples permuta. A fronteira entre climatização corretiva e preventiva não figura entre as maiores confusões, resultado coerente com a facilidade da tarefa de tipo reportada na Subseção 4.5. O ordenamento completo dos quinze pares de maior confusão recíproca consta do material suplementar.

A auditoria dos grupos de texto idêntico (Subseção 3.1) localiza ambiguidade no próprio dado, e não na predição: 17 grupos receberam mais de uma categoria de referência, afetando 85 linhas, ou 0,61% das linhas avaliadas, e em 14 deles, somando 74 linhas, as categorias em disputa pertencem a tipos distintos de manutenção, com o par mais frequente opondo Hidrossanitária > Hidráulica a Manutenção Preventiva > Reservatório, em 11 grupos e 65 linhas. Textos idênticos podem, portanto, corresponder a intervenções de naturezas diferentes, distinção irrecuperável por um classificador restrito aos quatro campos textuais deste estudo; a contagem sinaliza ambiguidade interna, mas não fixa teto quantitativo de desempenho, pois esse

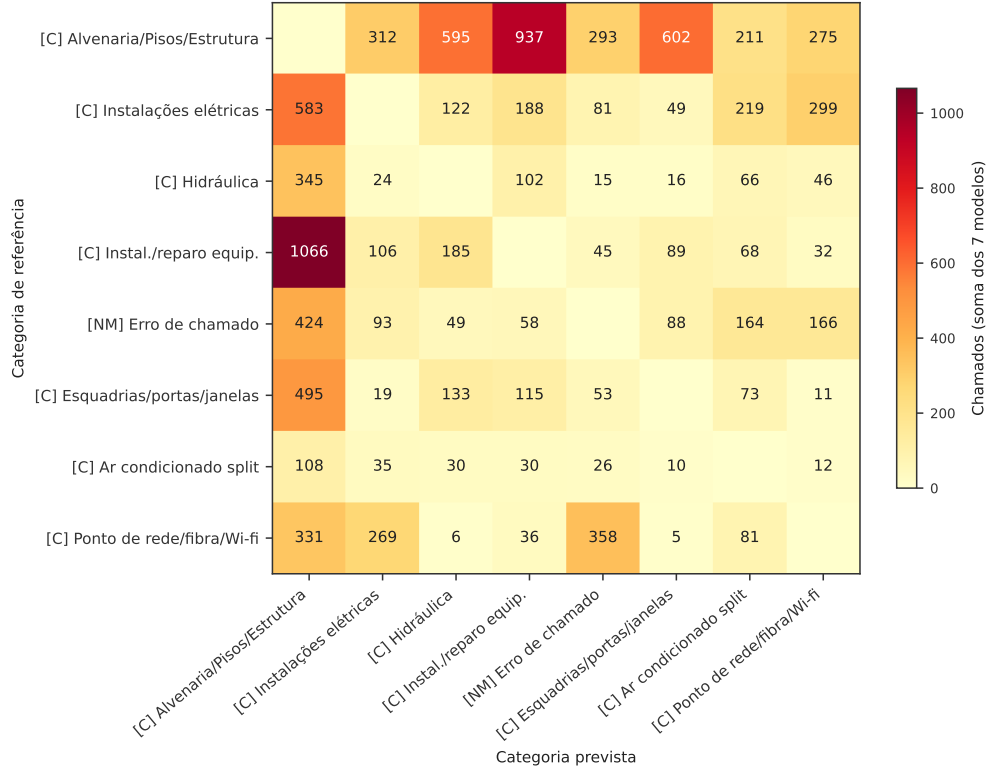


Figura 5: Recorte da matriz de confusão sobre as oito categorias mais envolvidas em troca recíproca, com contagens agregadas entre modelos. A diagonal, correspondente aos acertos, foi suprimida.

teto exigiria calcular a distribuição dos rótulos dentro de cada grupo, o que não foi feito.

Soma-se a esse quadro a duplicação taxonômica: a categoria Ar condicionado split existe simultaneamente sob Manutenção Preventiva, com 1.798 chamados, e sob Climatização, com 1.640, e o mesmo desdobramento ocorre com Ar condicionado central, Gerador, Nobreak, Elevador, Telhados, calhas, rufos e Sistemas de combate a incêndio. O critério que separa esses pares é a natureza preventiva ou corretiva da intervenção, que o texto frequentemente não explicita; parte do erro medido decorre de inferir do texto uma distinção nele ausente, e não de limitação do classificador. Daí uma recomendação anterior à escolha do modelo: revisar a taxonomia, unificando os pares que nomeiam o mesmo objeto e explicitando a natureza da manutenção no formulário de abertura, atua na origem do erro, não apenas em seu efeito, como a troca de classificador.

4.5 Análises complementares

O BERTimbau não integra a comparação principal por custo computacional, tendo o custo medido parcialmente (10,774 segundos por passo) e projetado para a dobra completa, resultando em 6,44 horas, valor que excede o teto de seis horas do ambiente disponível. Os 2.103 passos de treino de cada dobra projetam 6,29 horas só de treino, e a soma das cinco dobras projeta 32,2 horas, não cabendo nenhuma dobra completa, portanto, na infraestrutura do estudo. Tratando-se de extrapolação da taxa medida, e não de medição completa, nada se afirma sobre o desempenho do BERTimbau. Um experimento exploratório avaliou o transformador em lote de mil chamados (983 com referência humana); os valores (material suplementar) não são comparáveis, por não cobrir o corpus probabilisticamente e usar subamostragem estratificada com parada antecipada.

O treino do LSTM parou por interrupção antecipada após 11 épocas, com menor perda de validação na época 8 e maior acurácia de validação na época 10 (0,6722), padrão de saturação precoce consistente com *embeddings* treinados do zero serem insuficientes para um corpus deste porte (Subseção 3.3; Figura 6). A justificativa do particionamento agrupado é anterior a essa medição: a partição por linha permitiria ao mesmo texto ocupar treino e teste, e duas estimativas de sensibilidade indicam ganho espúrio entre 0,89 e 1,84 ponto

Tabela 5: Comparação confirmatória entre o LinearSVC e três combinações de modelos, em filas de igual capacidade ($n = 13.972$; 2.840 registros no agregado).

Método	Casos capturados	Diferença	Precisão	Recall
LinearSVC	523	referência	0,1842	0,8820
Votação majoritária	516	-7	0,1817	0,8702
Votação suave ponderada	503	-20	0,1771	0,8482
Stacking	512	-11	0,1803	0,8634

percentual sob esse desenho (material suplementar, protocolo declarado).




Figura 6: Curva de aprendizado do LSTM por época, perda e acurácia em treino e validação.

Dois recortes complementares qualificam a leitura agregada: a curva ABC global sobre o suporte das 41 categorias concentra 81,83% do volume em 12 categorias de classe A, e o macro-F1 do LinearSVC de 0,8207 refere-se à classe A dessa curva global, contra 0,5018 na classe C, localizando na cauda a distância entre acurácia e macro-F1 agregados. A Tabela A2 usa classificação distinta: a classe da curva ABC interna a cada tipo de manutenção. Projetada ao tipo de manutenção (três categorias, não a dicotomia usual entre preventivo e corretivo), a referência eleva o desempenho: o LinearSVC alcança 0,9443 de acurácia contra 0,8253 na tarefa de 41 categorias, com F1 de 0,9742 na preventiva e 0,9547 na corretiva, e toda a perda concentra-se no terceiro tipo, cujo F1 não ultrapassa 0,5330 em nenhum modelo. Nessa granularidade inverte-se a ordenação: o Extra Trees lidera a acurácia (0,9497) e o LinearSVC o macro-F1 (0,8180), por ir melhor na classe difícil — a escolha depende do nível de agregação e da métrica privilegiada. Há hierarquia de confiabilidade: a contagem por tipo é a leitura mais segura, a leitura por categoria só se sustenta nas classes de maior volume, e nas classes B e C o desempenho é insuficiente para uso automático (material suplementar).

A camada explícita de regras de periodicidade, que atribui categoria preventiva quando o texto reúne termo de periodicidade e de equipamento, dispara em 4.487 dos 13.972 registros e melhora o macro-F1 de apenas três dos sete modelos, com ganho concentrado no Naive Bayes (+0,0586) e perdas marginais em Extra Trees, Random Forest e LinearSVC. Como depende só do texto, a regra dispara no mesmo conjunto para os sete modelos; varia a predição substituída: no LinearSVC, os 4.487 disparos produzem 31 divergências, contra 219 no Naive Bayes, onde a regra acerta 201 vezes contra 9 do modelo. A leitura é que regras de domínio explícitas são redundantes diante de um classificador competente, que já as captura implicitamente do texto: o ganho do fluxo híbrido está no eixo humano-IA (Subseção 4.3), não no eixo regra-modelo.

Nos 13.972 registros modeláveis, 593 divergiam entre a categoria histórica e a referência revisada. Cada método foi comparado em fila de igual capacidade, e nenhuma combinação superou o LinearSVC (Tabela 5). O único ganho local, do stacking na terceira dobra, com 123 casos capturados contra 119, não se sustentou no agregado; o detalhamento por dobra e a proveniência constam do material suplementar (Tabela S16).

5. DISCUSSÃO

5.1 Adequação dos modelos e decisão por múltiplos critérios

O desempenho dos sete modelos (Tabela 2) não aponta vencedor absoluto. O LinearSVC lidera a acurácia, a Regressão Logística tem o macro-F1 pontual ligeiramente superior, e o SGD permanece próximo de ambos, com intervalos de confiança sobrepostos entre os três primeiros. A leitura operacional, portanto, segue os mesmos múltiplos critérios da Subseção 4.1, e a superioridade estatística do LinearSVC sobre o segundo colocado não basta, isoladamente, para declará-lo vencedor único.

O bom desempenho dos modelos lineares é compatível com a literatura sobre texto curto de vocabulário técnico, em que representações esparsas com fronteiras lineares sustentam desempenho competitivo (Joachims, 1998; Salton; Buckley, 1988; Galke; Scherp, 2022). Essa convergência é informativa por dois motivos. O corpus aqui analisado é institucional, em português brasileiro, e mantém a mesma regularidade observada em *benchmarks* de outra natureza. E a vantagem estatística do LinearSVC sobre o segundo colocado, embora estabelecida (Subseção 4.1), não se traduz em vantagem prática na maioria dos grupos textuais. Sob as configurações de referência adotadas (Tabela 1) e custo computacional comparável, a fronteira linear não é superada pelos *ensembles* nem pela LSTM treinada do zero neste corpus. Nada disso autoriza generalizar essa superioridade a outros domínios, corpora mais longos ou arquiteturas neurais e transformadoras mais profundas, não comparadas diretamente neste desenho.

O BERTimbau segue fora dessa comparação por condição de infraestrutura, não julgamento sobre desempenho (Subseção 4.5).

O custo de treino pesa na decisão institucional tanto quanto o acerto, pela mesma razão institucional da Subseção 2.4, condição que a literatura de eficiência recomenda reportar com a acurácia (Schwartz *et al.*, 2020; Treviso *et al.*, 2023). É esse critério, não só o desempenho isolado, que torna o LinearSVC e o SGD os candidatos mais favoráveis, por sustentar acurácia e macro-F1 competitivos a custo de treino mínimo, sem exigir infraestrutura fora do ambiente institucional (Subseção 4.1).

A comparação confirmatória com as três combinações (Subseção 4.5) reforça, neste corpus e capacidade, a escolha parcimoniosa já justificada, sem provar que *ensembles* sejam genericamente ineficazes nem afastar as limitações discutidas na Subseção 5.3.

5.2 Auditoria do histórico, reclassificação e fluxo humano-IA

A acurácia do LinearSVC contra a referência revisada (0,8253) supera sua concordância com o histórico (0,7961) em 2,92 pontos percentuais (Tabela 2). A diferença reflete a substituição da categoria histórica pela referência revisada no recorte avaliado. Das 598 alterações do corpus congelado, 593 ocorrem nos 13.972 registros modeláveis do experimento de ensemble e cinco ficam fora; esse recorte não coincide com as 13.972 linhas da comparação principal (Subseção 3.4), de modo que os 2,92 pontos percentuais não são atribuídos diretamente às 593 alterações. A revisão manteve a categoria histórica em 95,75% dos casos; os 4,25% restantes são taxa de alteração do rótulo sob a auditoria administrativa descrita na Subseção 3.1. É essa estabilidade da linha de base, não uma limitação estatística isolada, que explica por que a correção a partir da divergência fracassa.

O ganho líquido de reclassificação é negativo nos sete modelos (Tabela 3): o melhor corrige menos de um quinto das vezes em que diverge do histórico. O resultado diz respeito à tarefa, não a nuances entre modelos — a magnitude do prejuízo acompanha, na ordem inversa, o desempenho de cada classificador. Sob a função de utilidade (Subseção 4.2), a reclassificação em massa só compensaria se o custo de um registro prejudicado ficasse abaixo de um quinto do benefício de corrigir outro, hipótese que a assimetria do dano contradiz. Automação seletiva por confiança, entretanto, não equivale a reescrever a base: a mesma divergência que fracassa como correção em massa funciona como critério de priorização da fila de auditoria humana (Subseção 4.2), e a calibração isotônica torna esse regime operável, selecionando uma fração do volume no alvo de acurácia e encaminhando o restante ao revisor (Subseção 4.3); o desempenho desse regime sobre chamados futuros ainda não foi validado temporalmente (Subseção 5.3).

A ambiguidade taxonômica contribui para esse quadro: pares que nomeiam o mesmo objeto sob famílias distintas de natureza preventiva ou corretiva, e grupos de texto idêntico com referência divergente entre tipos de manutenção, mostram que parte do erro decorre da própria taxonomia, não apenas do classificador. Essa distinção segue irrecuperável ao classificador, como discutido na Subseção 4.4.

O diagnóstico de entropia de Shannon e divergência de Jensen-Shannon entre as previsões dos sete modelos (Subseção 4.4) amplia esse repertório de governança sem substituir as métricas supervisionadas: separa dispersão de predição, distância ao histórico e desacordo entre modelos, distinguindo erro do classificador de ambiguidade da taxonomia e de heterogeneidade da demanda; o desacordo estrutural entre arquiteturas passa a critério adicional para ordenar a auditoria, complementar à baixa confiança de um único modelo.

5.3 Limitações e alcance da evidência

A evidência tem alcance delimitado por características do desenho, que devem ser lidas em conjunto. Os dados provêm de uma única instituição federal de ensino superior, em português brasileiro e taxonomia institucional própria, o que exige validação externa antes de generalizar a outras instituições, idiomas ou taxonomias; essa transferência não foi testada. A referência humana resulta de auditoria administrativa por avaliador único, com a categoria histórica à vista, sem segunda avaliação, cegamento ou adjudicação, condição que impede estimar a prevalência de erro do rótulo histórico ou a reprodutibilidade da referência por outro especialista, restrição agravada pela ancoragem, constitutiva da auditoria de rótulo mas incompatível com anotação independente: a literatura registra variabilidade relevante entre anotadores nessa tarefa (Kejriwal *et al.*, 2024). Uma segunda avaliação sobre amostra estratificada, com adjudicação nos pares taxonômicos ambíguos, é a validação futura pertinente. As métricas cobrem 41 das 50 categorias da taxonomia, com as nove mais raras fora das partições por suporte insuficiente (Subseção 4.1), e os grupos de texto idêntico com referência divergente (Subseção 4.4) expõem inconsistência interna que não substitui avaliação independente. O LinearSVC foi selecionado com as mesmas previsões fora de dobra usadas para estimar seu desempenho (Subseção 4.1); a estimativa pode conservar otimismo dessa seleção, e a validação temporal futura deve avaliar também essa escolha.

O corpus congelado não preserva data de abertura por chamado, de modo que a validação cruzada agrupada mede generalização entre grupos textuais de um mesmo corte de extração, e não desempenho futuro sob deriva de vocabulário, taxonomia ou equipe de triagem; nenhuma métrica deste artigo é, portanto, prospectiva. A execução canônica da LSTM não fixou a semente global do TensorFlow, o que não compromete partições, rótulos ou protocolo, mas impede reproduzir exatamente pesos e trajetória de treinamento; o BERTimbau permanece exploratório, fora da comparação principal, por custo computacional medido.

5.4 Implicações para governança e continuidade da tese

A classificação auditável não é, em si, etapa preditiva, mas sim a camada de governança e estruturação dos dados que a antecede e a condiciona. Ela converte texto livre em categoria e confiança rastreáveis, condição sem a qual previsão de demanda por categoria, estimativa de custo de manutenção, leitura territorial e geo-processada do parque edificado, classificação de criticidade e métodos de decisão multicritério (MCDM) não têm base confiável sobre a qual operar. Nenhuma dessas etapas foi validada neste artigo, e sua incorporação permanece como trabalho futuro da tese, e não como extensão implícita dos resultados aqui reportados. A exigência é específica quando a camada classificada alimenta modelos de série temporal por categoria: um chamado mal classificado subtrai uma ocorrência de uma categoria e a acrescenta a outra, deslocando duas séries em sentidos opostos e propagando o erro à estimativa de demanda, de custo e ao ordenamento de prioridades que delas deriva, o que dá assimetria aos custos discutidos na Subseção 5.2.

O enquadramento do campus como biossistema construído (Seção 1) organiza essa continuidade como integração entre infraestrutura física, atividade humana, sistemas tecnológicos e condicionantes ambientais, e não como resultado empírico medido neste estudo: a contribuição empírica é o protocolo de classificação auditável, e o enquadramento situa por que essa camada de dados importa para a governança do biossistema, sem que o artigo meça retroalimentação ecológica ou desempenho ambiental. É esse enquadramento funcional, e não um achado sobre o sistema físico, que justifica tratar a auditoria de rótulo como etapa de governança e não como mero pré-processamento estatístico.

Este recorte reivindica contribuição para o ODS 12, consumo e produção responsáveis, pela rastreabilidade que o corpus com resumo criptográfico, a matriz de proveniência por artefato, as partições versionadas e a auditoria de rótulo com taxa declarada proporcionam, somada à eficiência computacional discutida nas Subseções 2.4 e 4.1. A dimensão de governança do ODS 9, indústria, inovação e infraestrutura, comparece pela capacidade institucional de decisão por evidência a partir de texto não estruturado. O ODS 11, cidades e comunidades sustentáveis, não é sustentado por este recorte, por ausência de dimensão territorial no corpus.

Toda aplicação futura sobre chamados novos permanece condicionada à inclusão de variável temporal na extração, à validação em período posterior ao corte avaliado, ao monitoramento de deriva de vocabulário e de taxonomia, à recalibração periódica dos limiares de confiança, ao retreinamento a cada mudança relevante da taxonomia e à manutenção da auditoria humana como instância final de decisão.

6. CONSIDERAÇÕES FINAIS

A contribuição central deste artigo é metodológica: um protocolo que separa a concordância com o rótulo histórico do acerto contra a referência humana revisada, mede as duas grandezas sob a mesma execução e usa partições agrupadas por texto que impedem a repetição de chamados entre treino e teste. Essa separação evita tratar o histórico como referência inquestionável e, ao mesmo tempo, impede concluir que toda divergência da classificação automática representa correção do registro original.

O achado central é duplo. Na avaliação sobre 13.972 chamados em 41 categorias, o LinearSVC alcança 0,8253 de acurácia (IC95%: 0,8115–0,8378) e lidera com significância estatística, mas sem vencedor absoluto quando acurácia, macro-F1 e custo são considerados em conjunto (Subseção 4.1). E a reclassificação automática da base histórica produz ganho líquido negativo nos sete modelos, resultado que se sustenta mesmo sob custos assimétricos (Subseção 4.2).

A implicação operacional é dupla. No corte avaliado, o LinearSVC constitui o principal candidato a piloto controlado com calibração isotônica e automação seletiva, sob as condições da Subseção 5.4, regime em que cerca de dois terços do volume poderiam ser decididos automaticamente com acurácia próxima de 0,95 e o restante encaminhado à revisão humana; e usar a divergência entre modelo e histórico não para reescrever a base, mas para priorizar a fila de auditoria, com enriquecimento de cerca de quatro vezes sobre a revisão aleatória.

As limitações mais consequentes são o avaliador único sem segunda avaliação independente, a ausência de validação temporal pela falta de data de abertura no corpus congelado, e o alcance restrito a uma única instituição, idioma e taxonomia (Subseção 5.3). Essas limitações delimitam o alcance dos resultados e orientam as validações futuras.

A continuidade da tese depende de reconstituir o corte preservando a data de abertura, o que viabiliza avaliação em períodos sucessivos, de incorporar segunda avaliação humana com adjudicação nos pares taxonômicos ambíguos, de testar a validação externa em outras instituições e de avançar, sob infraestrutura com acelerador gráfico, a execução *out-of-fold* integral do BERTimbau, hoje limitada a experimento exploratório. Feitas essas etapas, a camada classificada e auditável poderá sustentar modelos de previsão de demanda, de custo e de priorização multicritério de intervenções sobre o biosistema construído.

REFERÊNCIAS

- ANDERSON, M. J.; TER BRAAK, C. J. F. Permutation tests for multi-factorial analysis of variance. *Journal of Statistical Computation and Simulation*, v. 73, n. 2, p. 85–113, 2003. DOI: <https://doi.org/10.1080/00949650215733>.
- ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. *ABNT NBR 5674: Manutenção de edificações: Requisitos para o sistema de gestão de manutenção*. Rio de Janeiro: ABNT, 2012.
- BENDER, E. M.; GEBRU, T.; McMILLAN-MAJOR, A.; SHMITCHELL, S. On the dangers of stochastic parrots: can language models be too big? In: *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency (FAccT '21)*. New York: ACM, 2021. p. 610–623. DOI: <https://doi.org/10.1145/3442188.3445922>.
- BOUABDALLAOUI, Y.; LAFHAJ, Z.; YIM, P.; DUCOULOMBIER, L.; BENNADJI, B. Natural Language Processing Model for Managing Maintenance Requests in Buildings. *Buildings*, v. 10, n. 9, art. 160, 2020. DOI: <https://doi.org/10.3390/buildings10090160>.
- BROWN, T. B. et al. Language models are few-shot learners. In: *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*. Red Hook: Curran Associates, 2020. p. 1877–1901.
- CAMERON, A. C.; GELBACH, J. B.; MILLER, D. L. Bootstrap-based improvements for inference with clustered errors. *The Review of Economics and Statistics*, v. 90, n. 3, p. 414–427, 2008. DOI:

<https://doi.org/10.1162/rest.90.3.414>.

CAPRA, F. *A teia da vida: uma nova compreensão científica dos sistemas vivos*. São Paulo: Cultrix, 1997.

CHOW, C. K. On optimum recognition error and reject tradeoff. *IEEE Transactions on Information Theory*, v. 16, n. 1, p. 41–46, 1970. DOI: <https://doi.org/10.1109/tit.1970.1054406>.

COCHRAN, W. G. The comparison of percentages in matched samples. *Biometrika*, v. 37, n. 3-4, p. 256–266, 1950. DOI: <https://doi.org/10.2307/2332378>.

COCHRAN, W. G. *Sampling techniques*. 3. ed. New York: John Wiley & Sons, 1977.

DEVLIN, J.; CHANG, M.-W.; LEE, K.; TOUTANOVA, K. BERT: Pre-training of deep bidirectional transformers for language understanding. In: CONFERENCE OF THE NORTH AMERICAN CHAPTER OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS, 2019, Minneapolis. *Proceedings [...]*. Minneapolis: ACL, 2019. p. 4171–4186. DOI: <https://doi.org/10.18653/v1/N19-1423>.

DICICCIO, T. J.; EFRON, B. Bootstrap confidence intervals. *Statistical Science*, v. 11, n. 3, p. 189–228, 1996. DOI: <https://doi.org/10.1214/ss/1032280214>.

EFRON, B. Bootstrap methods: another look at the jackknife. *The Annals of Statistics*, v. 7, n. 1, p. 1–26, 1979. DOI: <https://doi.org/10.1214/aos/1176344552>.

EFRON, B.; TIBSHIRANI, R. J. *An introduction to the bootstrap*. New York: Chapman & Hall/CRC, 1993. DOI: <https://doi.org/10.1201/9780429246593>.

EL-YANIV, R.; WIENER, Y. On the foundations of noise-free selective classification. *Journal of Machine Learning Research*, v. 11, p. 1605–1641, 2010.

FIELD, C. A.; WELSH, A. H. Bootstrapping clustered data. *Journal of the Royal Statistical Society: Series B*, v. 69, n. 3, p. 369–390, 2007. DOI: <https://doi.org/10.1111/j.1467-9868.2007.00593.x>.

GALKE, L.; SCHERP, A. Bag-of-words vs. graph vs. sequence in text classification: questioning the necessity of text-graphs and the surprising strength of a wide MLP. In: ANNUAL MEETING OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS, 60., 2022, Dublin. *Proceedings [...]*. Dublin: ACL, 2022. p. 4038–4051. DOI: <https://doi.org/10.18653/v1/2022.acl-long.279>.

GOOD, P. *Permutation, parametric and bootstrap tests of hypotheses*. 3. ed. New York: Springer, 2005. DOI: <https://doi.org/10.1007/b138696>.

GRAVES, A.; SCHMIDHUBER, J. Framewise phoneme classification with bidirectional LSTM and other neural network architectures. *Neural Networks*, v. 18, n. 5-6, p. 602–610, 2005. DOI: <https://doi.org/10.1016/j.neunet.2005.06.042>.

GRIMM, N. B.; GROVE, J. M.; PICKETT, S. T. A.; REDMAN, C. L. Integrated approaches to long-term studies of urban ecological systems. *BioScience*, v. 50, n. 7, p. 571–584, 2000. DOI: [https://doi.org/10.1641/0006-3568\(2000\)050\[0571:IATLTO\]2.0.CO;2](https://doi.org/10.1641/0006-3568(2000)050[0571:IATLTO]2.0.CO;2).

GUO, C.; PLEISS, G.; SUN, Y.; WEINBERGER, K. Q. On calibration of modern neural networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 34., 2017, Sydney. *Proceedings [...]*. Sydney: PMLR, 2017. p. 1321–1330.

HOLM, S. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, v. 6, n. 2, p. 65–70, 1979.

JOACHIMS, T. Text categorization with support vector machines: learning with many relevant features. In: EUROPEAN CONFERENCE ON MACHINE LEARNING, 10., 1998, Chemnitz. *Proceedings [...]*. Berlin: Springer, 1998. p. 137–142. DOI: <https://doi.org/10.1007/BFb0026683>.

KEJRIWAL, M.; SANTOS, H.; SHEN, K.; MULVEHILL, A. M.; MCGUINNESS, D. L. A noise audit of human-labeled benchmarks for machine commonsense reasoning. *Scientific Reports*, v. 14, art. 8609, 2024. DOI: <https://doi.org/10.1038/s41598-024-58937-4>.

- KOHAVI, R. A study of cross-validation and bootstrap for accuracy estimation and model selection. In: INTERNATIONAL JOINT CONFERENCE ON ARTIFICIAL INTELLIGENCE, 14., 1995, Montreal. *Proceedings [...]*. San Francisco: Morgan Kaufmann, 1995. p. 1137–1143. DOI: <https://doi.org/10.5555/1643031.1643047>.
- LI, Y.; LIU, Y.; ZHANG, J.; CAO, L.; WANG, Q. Automated analysis and assignment of maintenance work orders using natural language processing. *Automation in Construction*, v. 165, art. 105501, 2024. DOI: <https://doi.org/10.1016/j.autcon.2024.105501>.
- LIN, J. Divergence measures based on the Shannon entropy. *IEEE Transactions on Information Theory*, v. 37, n. 1, p. 145–151, 1991. DOI: <https://doi.org/10.1109/18.61115>.
- LIU, Z.; BENGE, C.; JIANG, S. Ticket-BERT: labeling incident management tickets with language models. *Preprint*. arXiv:2307.00108, 2023. DOI: <https://doi.org/10.48550/arXiv.2307.00108>. Disponível em: <https://arxiv.org/abs/2307.00108>. Acesso em: 14 ago. 2026. Sem publicação revisada por pares localizada até a data de acesso.
- MARCUZZO, M.; ZANGARI, A.; SCHIAVINATO, M.; GIUDICE, L.; GASPARETTO, A.; ALBARELLI, A. A multi-level approach for hierarchical Ticket Classification. In: WORKSHOP ON NOISY USER-GENERATED TEXT, 8., 2022, Gyeongju. *Proceedings [...]*. Gyeongju: ACL, 2022. p. 201–214.
- MARTINS, R. F. B.; ESPEJO, M. M. S. B. Análise de custos de manutenção predial em uma universidade federal brasileira com uso do modelo de Suavização Exponencial Simples (SES). *ABCustos*, São Leopoldo, v. 19, n. 1, p. 79–98, 2024. DOI: <https://doi.org/10.47179/abcustos.v19i1.719>.
- MOHAMMED, A. S.; AMOAH, C. Integration of technology in decision-making in university facilities management: a literature review. *Facilities*, v. 43, n. 13/14, p. 1018–1052, 2025. DOI: <https://doi.org/10.1108/F-09-2024-0134>.
- MORAIS, L. S. R. de; PAULA, H. M. de; REIS, R. P. A. Promoção da eficiência da manutenção predial em edificações públicas: abordagem baseada em registros de ordens de serviço. *Paranoá*, Brasília, v. 16, n. 34, p. 1–27, 2023. DOI: <https://doi.org/10.18830/issn.1679-0944.n34.2023.08>.
- ODUM, E. P. *Fundamentos de ecologia*. 6. ed. Lisboa: Fundação Calouste Gulbenkian, 1996.
- PAMPANA, A. K. et al. Data-driven analysis for facility management in higher education institution. *Buildings*, v. 12, n. 12, art. 2094, 2022. DOI: <https://doi.org/10.3390/buildings12122094>.
- PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.
- PLATT, J. C. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. In: SMOLA, A. J. et al. (Ed.). *Advances in Large Margin Classifiers*. Cambridge: MIT Press, 1999. p. 61–74.
- SALTON, G.; BUCKLEY, C. Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, v. 24, n. 5, p. 513–523, 1988. DOI: [https://doi.org/10.1016/0306-4573\(88\)90021-0](https://doi.org/10.1016/0306-4573(88)90021-0).
- SCHWARTZ, R.; DODGE, J.; SMITH, N. A.; ETZIONI, O. Green AI. *Communications of the ACM*, v. 63, n. 12, p. 54–63, 2020. DOI: <https://doi.org/10.1145/3381831>.
- SHANNON, C. E. A mathematical theory of communication. *Bell System Technical Journal*, v. 27, n. 3, p. 379–423, jul. 1948. DOI: <https://doi.org/10.1002/j.1538-7305.1948.tb01338.x>; v. 27, n. 4, p. 623–656, out. 1948. DOI: <https://doi.org/10.1002/j.1538-7305.1948.tb00917.x>.
- SOKOLOVA, M.; LAPALME, G. A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, v. 45, n. 4, p. 427–437, 2009. DOI: <https://doi.org/10.1016/j.ipm.2009.03.002>.
- SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. BERTimbau: pretrained BERT models for Brazilian Portuguese. In: BRAZILIAN CONFERENCE ON INTELLIGENT SYSTEMS, 9., 2020, Rio Grande. *Proceedings [...]*. Cham: Springer, 2020. p. 403–417. DOI: https://doi.org/10.1007/978-3-030-61377-8_28.

SUNDARAM, S.; ZEID, A. Technical Language Processing for Prognostics and Health Management: applying text similarity and topic modeling to maintenance work orders. *Journal of Intelligent Manufacturing*, v. 36, n. 3, p. 1637–1657, 2025. DOI: <https://doi.org/10.1007/s10845-024-02323-4>.

TREVISIO, M. et al. Efficient methods for Natural Language Processing: a survey. *Transactions of the Association for Computational Linguistics*, v. 11, p. 826–860, 2023. DOI: https://doi.org/10.1162/tacl_a_00577.

ZHANG, H.; ZHANG, Y.; LI, J.; LIU, J.; JI, L. A survey on learning with noisy labels in Natural Language Processing: how to train models with label noise. *Engineering Applications of Artificial Intelligence*, v. 146, art. 110157, 2025. DOI: <https://doi.org/10.1016/j.engappai.2025.110157>.

APÊNDICE A — CATEGORIAS DO CORPUS E DAS PARTIÇÕES

A Tabela A1 apresenta as 50 categorias históricas presentes nos 14.060 chamados da base congelada, ordenadas por frequência decrescente e distribuídas em dois blocos paralelos para reduzir a extensão do apêndice. As Tabelas A2 e A3 decompõem o denominador das métricas: a primeira lista as 41 categorias que sustentaram suporte nas cinco dobras e compõem as 13.972 linhas avaliadas, e a segunda, as 9 que ficaram de fora. A Tabela A1 tabula a categoria histórica do GLPI; A2 e A3, a categoria de referência revisada. Diferenças entre elas podem decorrer da auditoria de rótulo (Subseção 3.1), não de erro de transcrição.

Tabela A1: Distribuição dos chamados por categoria histórica.

Categoria histórica	Quantidade	Categoria histórica	Quantidade
Manutenção Preventiva > Ar condicionado split	1.798	Manutenção Preventiva > Sistemas de combate a incêndio (extintores, hidrantes)	66
Climatização > Ar condicionado split	1.640	Estrutura Predial > Pintura	58
Estrutura Predial > Alvenaria / Pisos / Estrutura	1.302	Instalação de Acessórios e Mobiliário > Placas de identificação	54
Hidrossanitária > Hidráulica	1.282	Manutenção Preventiva > Telhados, calhas, rufos, etc.	44
Manutenção Preventiva > Gerador	1.215	TI / Dados / Rede > Coleta de dados	40
Estrutura Predial > Esquadrias, porta, portão e janelas	977	Elétrica > Gerador	38
Elétrica > Instalações elétricas	945	Hidrossanitária > Bomba	38
Elétrica > Iluminação	758	Climatização > Ar condicionado central	37
Manutenção Preventiva > Quadros Elétricos	578	Manutenção Preventiva > Esgoto	33
TI / Dados / Rede > Ponto de rede / fibra ótica / Wi-fi	404	Manutenção Preventiva > Hidráulica	33
Instalação de Acessórios e Mobiliário > Instalação/reparo de equipamentos (Suportes de TV, acessórios de banheiro e quadro branco)	290	Outros > Outros	33
Manutenção Preventiva > Reservatório	279	Segurança contra Incêndio > Sistemas de combate a incêndio (extintores, hidrantes)	29
Manutenção Preventiva > Vistoria em Instalações	247	Projetos e Reformas > Projeto	25
Outros > Erro de chamado	245	Equipamentos de Transporte > Elevador	22
Estrutura Predial > Infiltração	215	Elétrica > Subestação	18
Estrutura Predial > Telhados, calhas, rufos, etc.	207	Hidrossanitária > ETA / ETE	16
Manutenção Preventiva > Ar condicionado central	165	Suprimentos / Apoio Técnico > Limpeza de equipamentos, ambiente e mobiliário	14
Estrutura Predial > Forro	146	Manutenção Preventiva > Poços artesianos	13
Manutenção Preventiva > Iluminação	132	Manutenção Preventiva > Nobreak	10
Elétrica > Nobreak	128	Elétrica > Sistema Fotovoltaico (FV)	7
Área Externa e Ambiental > Manutenção área externa / meio ambiente / Poda de árvore / Roçagem	109	Área Externa e Ambiental > Drenagem	4
Posto de trabalho > Contratação de Posto de trabalho	102	Estrutura Predial > Instalações Especiais (gás, ar comprimido, etc.)	3
Manutenção Preventiva > Elevador	86	Manutenção Preventiva > Aplicação cupinicida	3
Suprimentos / Apoio Técnico > Materiais	85	Manutenção Preventiva > Bomba	3
Projetos e Reformas > Reforma	83	Suprimentos / Apoio Técnico > Transporte	1
Total geral	14.060		

Fonte: elaboração própria a partir do corpus analisado.

Na Tabela A2, o percentual é relativo ao volume do próprio tipo e o F1 corresponde ao LinearSVC. P, preventiva; C, corretiva; NM, não manutenção. Não manutenção agrupa as famílias que não descrevem serviço de manutenção predial: **Outros**, **Suprimentos / Apoio Técnico**, **Posto de trabalho** e **Projetos e Reformas**. **TI / Dados / Rede** permanece em manutenção corretiva por consistir predominantemente em reparo de infraestrutura.

Tabela A2: Categorias da referência revisada avaliadas na rodada, por tipo de manutenção e classe da curva ABC interna ao tipo (n = 13.972; 41 categorias).

Categoria de referência	Tipo	n	% do tipo	Classe	F1
Preventiva	P	4.902	100,00		
Manutenção Preventiva > Ar condicionado split	P	1.987	40,53	A	0,9972
Manutenção Preventiva > Gerador	P	1.208	24,64	A	0,9954
Manutenção Preventiva > Quadros Elétricos	P	578	11,79	A	0,9843
Manutenção Preventiva > Reservatório	P	318	6,49	A	0,9139
Manutenção Preventiva > Vistoria em Instalações	P	244	4,98	B	0,9419
Manutenção Preventiva > Ar condicionado central	P	168	3,43	B	0,9970
Manutenção Preventiva > Iluminação	P	132	2,69	B	0,9535
Manutenção Preventiva > Elevador	P	86	1,75	B	0,9655
Manutenção Preventiva > Sistemas de combate a incêndio (extintores, hidrantes)	P	66	1,35	C	0,8905
Manutenção Preventiva > Telhados, calhas, rufos, etc.	P	44	0,90	C	0,2162
Manutenção Preventiva > Esgoto	P	31	0,63	C	0,4286
Manutenção Preventiva > Hidráulica	P	27	0,55	C	0,0000
Manutenção Preventiva > Poços artesianos	P	13	0,27	C	1,0000
Corretiva	C	8.485	100,00		
Climatização > Ar condicionado split	C	1.448	17,07	A	0,9550
Hidrossanitária > Hidráulica	C	1.263	14,89	A	0,8651
Estrutura Predial > Alvenaria / Pisos / Estrutura	C	1.138	13,41	A	0,4610
Estrutura Predial > Esquadrias, porta, portão e janelas	C	1.003	11,82	A	0,8712
Elétrica > Instalações elétricas	C	909	10,71	A	0,7248
Elétrica > Iluminação	C	764	9,00	A	0,8901
TI / Dados / Rede > Ponto de rede / fibra ótica / Wi-fi	C	412	4,86	A	0,7173
Instalação de Acessórios e Mobiliário > Instalação/reparo de equipamentos (Suportes de TV, acessórios de banheiro e quadro branco)	C	405	4,77	B	0,4730
Estrutura Predial > Telhados, calhas, rufos, etc.	C	203	2,39	B	0,4962
Estrutura Predial > Infiltração	C	202	2,38	B	0,6493
Estrutura Predial > Forro	C	168	1,98	B	0,7746
Elétrica > Nobreak	C	150	1,77	B	0,7855
Área Externa e Ambiental > Manutenção área externa / meio ambiente / Poda de árvore / Roçagem	C	103	1,21	C	0,6288
Instalação de Acessórios e Mobiliário > Placas de identificação	C	69	0,81	C	0,6494
Estrutura Predial > Pintura	C	60	0,71	C	0,5890
Elétrica > Gerador	C	43	0,51	C	0,7723
Hidrossanitária > Bomba	C	43	0,51	C	0,7238
Climatização > Ar condicionado central	C	33	0,39	C	0,7324
Segurança contra Incêndio > Sistemas de combate a incêndio (extintores, hidrantes)	C	29	0,34	C	0,4815
Equipamentos de Transporte > Elevador	C	21	0,25	C	0,7692
Elétrica > Subestação	C	19	0,22	C	0,6061
Não manutenção	NM	585	100,00		
Outros > Erro de chamado	NM	258	44,10	A	0,3978
Posto de trabalho > Contratação de Posto de trabalho	NM	102	17,44	A	0,9561
Suprimentos / Apoio Técnico > Materiais	NM	96	16,41	A	0,4790
Projetos e Reformas > Reforma	NM	65	11,11	A	0,2407
Outros > Outros	NM	28	4,79	B	0,3404
Projetos e Reformas > Projeto	NM	23	3,93	B	0,0000
Suprimentos / Apoio Técnico > Limpeza de equipamentos, ambiente e mobiliário	NM	13	2,22	C	0,0909
Total avaliado		13.972			

As nove categorias restantes da taxonomia não sustentam suporte nas cinco dobras e ficam fora das partições, conforme o critério da Subseção 3.4. Somam 88 linhas, ou 0,63% da base congelada, e estão discriminadas na Tabela A3 para que a diferença entre os dois denominadores permaneça auditável.

Tabela A3: Categorias fora das partições canônicas.

Categoria de referência	Linhas	Motivo da exclusão
TI / Dados / Rede > Coleta de dados	40	ausente de ao menos uma dobra após a estratificação
Hidrossanitária > ETA / ETE	15	ausente de ao menos uma dobra após a estratificação
Manutenção Preventiva > Nobreak	9	ausente de ao menos uma dobra após a estratificação
Elétrica > Sistema Fotovoltaico (FV)	7	ausente de ao menos uma dobra após a estratificação
Estrutura Predial > Instalações Especiais (gás, ar comprimido, etc.)	5	ausente de ao menos uma dobra após a estratificação
Área Externa e Ambiental > Drenagem	4	suporte insuficiente para as cinco dobras
Manutenção Preventiva > Aplicação cupinicida	3	suporte insuficiente para as cinco dobras
Manutenção Preventiva > Bomba	3	suporte insuficiente para as cinco dobras
Suprimentos / Apoio Técnico > Transporte	2	suporte insuficiente para as cinco dobras
Total	88	

Fonte: elaboração própria a partir do corpus analisado.