

CLASSIFICAÇÃO MULTIMODELO DE CHAMADOS DE MANUTENÇÃO PREDIAL UNIVERSITÁRIA EM PORTUGUÊS BRASILEIRO SOB RÓTULOS HISTÓRICOS RUÍDOSOS

Multi-model classification of university building maintenance work orders in Brazilian Portuguese under noisy historical labels

Adinailson Guimarães de Oliveira - adinailson.oliveira@cja.ufsb.edu.br **Fabício Berton Zanchi** - fabricao.berton@ufsb.edu.br

Universidade Federal do Sul da Bahia (UFSB), Programa de Pós-Graduação em Biossistemas

RESUMO

A classificação automática de chamados de manutenção predial constitui recurso estratégico para qualificar a triagem operacional e ampliar a governança baseada em evidências em instituições públicas. Em bases históricas de sistemas informatizados de gestão de chamados, contudo, a categoria originalmente registrada não deve ser tratada como verdade absoluta, pois pode refletir decisões operacionais ruidosas, taxonomias sobrepostas, registros incompletos e interpretações heterogêneas entre equipes. Este artigo propõe um protocolo multimodelo para classificação de chamados reais de manutenção predial universitária em português brasileiro, extraídos do sistema institucional da Universidade Federal do Sul da Bahia. O experimento utiliza 13.965 chamados não vazios, organizados em 55 categorias históricas, e compara seis classificadores clássicos baseados em TF-IDF com uma rede neural LSTM bidirecional. O diferencial metodológico reside na distinção entre concordância com o histórico administrativo e acerto validado por revisão humana, tratando a categoria histórica como referência preliminar imperfeita. A distinção altera a leitura do desempenho, pois o acerto validado por conferência humana, apurado sobre 8.928 decisões, descreve apenas a amostra conferida e constitui limite superior por construção amostral. Os resultados indicam superioridade do LinearSVC tanto na concordância com o histórico (80,31%) quanto no acerto validado (95,24%), ao passo que o LSTM alcança 67,18% e 88,58%. A normalidade da concordância por turno é rejeitada para todos os modelos, o que justifica a bateria não paramétrica adotada. O custo computacional entra como dimensão de avaliação e evidencia que modelos lineares oferecem melhor relação entre desempenho e viabilidade operacional em cenários de texto curto, ruidoso e desbalanceado.

Palavras-chave: manutenção predial; classificação de chamados; processamento de linguagem natural; rótulos ruidosos; validação humana.

ABSTRACT

Automatic classification of building maintenance work orders is a strategic resource for qualifying operational triage and enhancing evidence-based governance in public institutions. However, in historical databases from computerized service management systems, the originally assigned category should not be treated as an unquestionable ground truth, since it may reflect noisy operational decisions, overlapping taxonomies, incomplete records, and heterogeneous interpretations across maintenance teams. This paper proposes a multi-model protocol for classifying real university building maintenance requests in Brazilian Portuguese, extracted from the GLPI system at the Federal University of Southern Bahia. The experiment uses 13,965 non-empty records organized into 55 historical categories and compares TF-IDF-based classical classifiers (Naïve Bayes, Logistic Regression, LinearSVC, SGD, Random Forest, and Extra Trees) and a bidirectional LSTM neural network. The Portuguese pre-trained transformer (BERTimbau) remains a planned extension, with neither completed training nor its own metric. The methodological contribution lies in distinguishing agreement with administrative history from human-validated accuracy, treating the historical category as an imperfect preliminary reference. This distinction proved decisive, since human-validated accuracy (8,928 decisions) describes only the reviewed sample and is an upper bound by sampling construction. Because the sample prioritizes divergences and critical cases rather than sampling at random, these results do not estimate performance over the full database (COCHRAN, 1977). Results indicate LinearSVC superiority both in agreement with history (80.31% accuracy, 95%CI: 79.63%–80.97%) and in human-validated accuracy (95.24%, 95%CI: 94.80%–95.68%), while LSTM achieved 67.18% agreement and 88.58% validated accuracy. Normality was rejected for all models, supporting non-parametric tests (Friedman, Cochran Q, McNemar, bootstrap). Computational cost is incorporated as an evaluation dimension, showing that linear models can offer a better balance between performance and operational feasibility in short, noisy, and imbalanced text.

Keywords: *building maintenance; work-order classification; natural language processing; noisy labels; human validation.*

1. INTRODUÇÃO

Um campus universitário pode ser descrito como um biossistema construído, isto é, a integração dinâmica entre infraestrutura física, atividade humana, sistemas tecnológicos e condicionantes ambientais, cuja persistência ao longo do tempo depende de mecanismos de retroalimentação contínua entre uso, falha e reparo (CAPRA, 1996; ODUM, 1971). A ecologia urbana descreve esse tipo de sistema como um organismo em troca permanente de matéria, energia e informação com seu entorno, cuja governança bem-sucedida depende da capacidade institucional de captar sinais operacionais e convertê-los em decisão (GRIMM *et al.*, 2008). Em instituições federais de ensino superior (IFES), esse sinal assume, na prática, a forma de registros textuais de chamados de manutenção predial, matéria-prima do *feedback* operacional do biossistema construído. Esses registros, no entanto, nascem aprisionados em linguagem não estruturada, fragmentária e sujeita a interpretação individual no momento do atendimento, o que impede seu uso direto por qualquer mecanismo de decisão automatizada (MORAIS; PAULA; REIS, 2023; MOHAMMED; AMOAH, 2025).

A exploração analítica dessas bases enfrenta ao menos três obstáculos estruturais, agravados pela restrição orçamentária que historicamente limita o custeio da manutenção predial em IFES a patamares inferiores a 2% do orçamento institucional (MARTINS; ESPEJO, 2024; PAMPANA *et al.*, 2022). O primeiro é a natureza textual curta, heterogênea e frequentemente incompleta dos registros. Chamados de manutenção predial são redigidos em linguagem técnica fragmentária, com abreviações locais e jargões de equipe que dificultam a aplicação direta de modelos genéricos de processamento de linguagem natural (PLN) (SUNDARAM; ZEID, 2025). O segundo é o desbalanceamento entre categorias. Demandas recorrentes de climatização, elétrica e hidrossanitária concentram grande parte da base, enquanto categorias raras dispõem de poucos exemplos para treinamento supervisionado (LI *et al.*, 2024). O terceiro, e o mais consequente do ponto de vista metodológico, é a qualidade do próprio rótulo histórico. A categoria registrada no momento do chamado pode resultar de interpretação rápida, conveniência operacional ou taxonomia ainda não estabilizada, de modo que o histórico administrativo constitui evidência importante, mas não verdade absoluta (ZHANG *et al.*, 2025; KEJRIWAL *et al.*, 2024).

A literatura recente sobre mineração textual de ordens de manutenção confirma a relevância de técnicas de PLN para transformar registros textuais em insumos de gestão. Li *et al.* (2024) demonstraram, em base hospitalar com 15.623 ordens de serviço, que a atribuição automática de equipes por PLN alcança acurácia de 0,83, reduzindo substancialmente a dependência de triagem manual. Sundaram e Zeid (2025) analisaram registros de *Maintenance Work Orders* sob a abordagem de *Technical Language Processing*, argumentando que textos técnicos de manutenção funcionam como *black holes* informacionais quando armazenam dados relevantes sem serem efetivamente utilizados na tomada de decisão. Bouabdallaoui *et al.* (2020), por sua vez, aplicaram modelos de PLN à classificação de requisições de manutenção em edificação hospitalar, reportando acurácia média de 78% com múltiplos métodos de representação textual. Contudo, a maior parte dessas aplicações concentra-se em bases em inglês ou chinês e em domínios industriais ou hospitalares, configurando lacuna relevante para corpora em português brasileiro no contexto da manutenção predial pública universitária.

Diante desse quadro, a pergunta que orienta este artigo não é qual classificador mais concorda com a categoria histórica. A questão é mais ampla e alinhada à função de governança que esses dados devem cumprir. Como extrair de texto ruidoso, de forma confiável e auditável, o dado estruturado capaz de alimentar um sistema de governança preditiva sem herdar acriticamente os erros do histórico que lhe deu origem? Rótulos ruidosos em PLN reduzem o desempenho de classificadores e ampliam o consumo de recursos computacionais necessários para tratá-los (ZHANG *et al.*, 2025). Soma-se a isso que *benchmarks* anotados por humanos carregam variabilidade relevante, o que torna questionável tratar qualquer rótulo, humano ou histórico, como verdade absoluta e não sujeita a julgamento (KEJRIWAL *et al.*, 2024). A classificação automática apresentada aqui constitui, portanto, a primeira camada de um protocolo maior, e não seu produto final. Cabe a essa camada produzir dado auditável o bastante para que divergências entre inteligência artificial e histórico administrativo sejam tratadas como evidência de revisão taxonômica, e não como ruído a descartar.

Com base em chamados reais da Universidade Federal do Sul da Bahia (UFSB), este artigo propõe uma comparação multimodelo de classificadores de texto aplicada a chamados de manutenção predial em português

brasileiro. A base experimental contém 13.965 chamados não vazios, distribuídos em 55 categorias históricas; os campos textuais considerados agregam título e descrição do chamado, além de informações associadas à ordem de serviço. O estudo compara modelos clássicos baseados em TF-IDF (Naive Bayes, Regressão Logística, LinearSVC, SGD, Random Forest e Extra Trees) com uma rede neural LSTM bidirecional. O BERTimbau é mantido como extensão planejada e não integra as comparações enquanto não houver treino concluído e métricas próprias rastreáveis. O objeto de avaliação, portanto, não é o classificador isolado, mas o protocolo de governança preditiva que articula aprendizado de máquina, auditoria estatística, custo computacional e validação humana. Essa formulação é consoante à manutenção baseada em evidências preconizada pela NBR 5674 (ABNT, 2012) e à integração físico-humano-tecnológico-ambiental que caracteriza um biosistema construído.

Cinco objetivos específicos orientam o trabalho. O primeiro é apresentar um protocolo de classificação automática que produza dado estruturado auditável a partir de texto livre. O segundo é distinguir a concordância com o rótulo histórico do acerto validado, evitando equiparar categoria histórica a *ground truth* incontestável. O terceiro é avaliar o desempenho por métricas globais e balanceadas, intervalos de confiança e testes estatísticos pareados adequados a dados não normais. O quarto é incorporar o custo computacional como dimensão de decisão operacional. O quinto é converter divergências entre inteligência artificial e histórico em evidência para revisão taxonômica e retroalimentação da base de treino.

2. REFERENCIAL CONCEITUAL

2.1 Processamento de linguagem natural em ordens de manutenção

Ordens de manutenção constituem registros operacionais com valor informacional elevado, porém usualmente subutilizado. Elas documentam sintomas, locais, equipamentos, procedimentos, materiais e soluções executadas, acumulando-se ao longo de anos em sistemas informatizados cuja forma textual e semiestruturada dificulta o uso direto em planejamento e alocação de recursos (PAMPANA *et al.*, 2022; MORAIS; PAULA; REIS, 2023). Li *et al.* (2024) propuseram estrutura baseada em PLN para análise e atribuição automática de ordens de manutenção hospitalar, utilizando 15.623 registros de hospital municipal em Xangai e reportando acurácia de 0,83 na tarefa de atribuição de trabalhadores, resultado que evidencia a possibilidade de automatizar processos antes dependentes de triagem manual em contextos prediais. Esse trabalho constitui referência-âncora para a presente pesquisa por tratar diretamente da automação de ordens de manutenção predial, embora em idioma, tipologia institucional e estrutura taxonômica distintos.

Sundaram e Zeid (2025), ao analisar registros textuais de *Maintenance Work Orders* sob a abordagem de *Technical Language Processing*, defenderam que textos técnicos de manutenção funcionam como repositórios informacionais subutilizados quando não integrados a processos decisórios. Essa perspectiva é especialmente pertinente à manutenção predial universitária, na qual chamados curtos, abreviações locais, nomes de ambientes e descrições incompletas dificultam o uso de modelos genéricos sem adaptação ao domínio. Bouabdallaoui *et al.* (2020) reportaram acurácia média de 78% na classificação de requisições de manutenção predial hospitalar utilizando múltiplos métodos de PLN, resultado que reforça a viabilidade da abordagem, mas também evidencia a necessidade de adaptação lexical e semântica ao corpus específico.

2.2 Classificação de tickets e evolução dos modelos

A classificação automática de *tickets* em ambientes de suporte técnico e ITSM evoluiu de representações vetoriais baseadas em frequência lexical para *embeddings* e modelos de linguagem pré-treinados. Liu, Bengue e Jiang (2023) propuseram o Ticket-BERT para rotulagem de *tickets* de incidentes, enfatizando desafios como atualização contínua de rótulos e necessidade de aprendizado ativo. Entretanto, a transferência direta de achados do ITSM para a manutenção predial deve ser cautelosa, pois a semântica do domínio envolve sistemas físicos, ambientes e equipamentos prediais que não coincidem com categorias de incidentes de *software* ou infraestrutura digital (SUNDARAM; ZEID, 2025).

Modelos lineares com TF-IDF continuam competitivos em tarefas de texto curto, especialmente quando o corpus é de porte médio, o vocabulário possui alta especificidade técnica e as classes são desbalanceadas (GALKE; SCHERP, 2022). Nesses cenários, modelos profundos podem não compensar seu custo computacional caso não disponham de volume suficiente, balanceamento adequado ou *embeddings* fortemente adaptados ao domínio. Galke e Scherp (2022), em revisão comparativa abrangente de métodos para classificação tex-

tual, demonstraram que classificadores baseados em *bag-of-words* com TF-IDF e SVM permanecem altamente competitivos frente a redes neurais em múltiplos *benchmarks*, sobretudo quando o corpus é reduzido ou o vocabulário é altamente especializado. Esse achado é particularmente relevante para o contexto institucional de manutenção predial, onde a base operacional raramente atinge escala compatível com as exigências de modelos de linguagem de grande porte.

2.3 Rótulos ruidosos e verdade operacional

O problema de rótulos ruidosos é central em aprendizado supervisionado aplicado a bases administrativas. Em classificação textual, ruído de rótulo pode decorrer de ambiguidade semântica, polissemia, insuficiência de contexto, sobreposição taxonômica, julgamento subjetivo ou erro humano de registro (ZHANG *et al.*, 2025). Conforme levantamento de Zhang *et al.* (2025), rótulos ruidosos em PLN afetam o desempenho dos modelos e podem ampliar o consumo de recursos, exigindo métodos robustos de tratamento de ruído. Kejriwal *et al.* (2024) reforçam que *benchmarks* rotulados por humanos podem conter variabilidade relevante, questionando a prática de assumir uma única verdade absoluta quando há julgamento subjetivo envolvido. No contexto do presente artigo, a categoria histórica do chamado é tratada como referência administrativa, não como verdade final, e a verdade operacional deve ser construída por validação humana com registro explícito da decisão tomada.

2.4 Custo computacional e eficiência em PLN

A avaliação de modelos de PLN tem sido tradicionalmente orientada por métricas de desempenho, mas a literatura recente enfatiza que custo computacional, tempo de treino, consumo energético e reprodutibilidade também devem compor a decisão de adoção (TREVISIO *et al.*, 2023; SCHWARTZ *et al.*, 2020). Treviso *et al.* (2023) argumentam que a ampliação de escala em PLN tende a aumentar o consumo de dados, tempo, armazenamento e energia, motivando métodos eficientes especialmente em contextos de recursos limitados. Schwartz *et al.* (2020) cunharam o conceito de *Green AI*, propondo que a eficiência computacional seja reportada e valorizada na avaliação de modelos, não apenas a acurácia. Em uma instituição pública, essa dimensão é operacionalmente decisiva. Um modelo que treina em segundos pode ser reexecutado frequentemente, auditado com facilidade e mantido sem infraestrutura dedicada, ao passo que um modelo que demanda dezenas de minutos exige *checkpoint*, controle de versão de pesos e justificativa robusta de ganho marginal (TREVISIO *et al.*, 2023).

3. MÉTODO

3.1 Delineamento geral

O estudo adota delineamento experimental aplicado, com base observacional retrospectiva de chamados de manutenção predial registrados no sistema GLPI institucional da UFSB, universidade multicampi com unidades em Itabuna, Ilhéus, Porto Seguro e Teixeira de Freitas (MORAIS; PAULA; REIS, 2023). A unidade de análise é o chamado individual de manutenção, representado por campos textuais concatenados e por uma categoria histórica registrada no sistema. O fluxo metodológico compõe-se de oito etapas sequenciais: (i) extração e consolidação da base; (ii) higienização textual; (iii) construção da matriz de atributos; (iv) treinamento e inferência multimodelo; (v) geração de predições *out-of-fold*; (vi) comparação preliminar com categoria histórica; (vii) análise estatística não paramétrica; e (viii) validação humana das divergências e amostras críticas. A Figura 1 apresenta esse fluxo como *pipeline* de governança preditiva.

3.2 Corpus e variáveis

O corpus experimental é composto por 13.965 chamados de manutenção predial não vazios, organizados em 55 categorias históricas, extraídos do ambiente institucional da UFSB. Os campos textuais previstos no protocolo incluem título do chamado, descrição GLPI, título da ordem de serviço e descrição da ordem de serviço, concatenados em uma única representação textual para fins de classificação. A categoria histórica é utilizada como referência preliminar de comparação, mas a avaliação conclusiva depende da base validada por revisão humana. O idioma dos registros é português brasileiro, com presença significativa de jargões técnicos, nomes de ambientes, abreviações locais e descrições incompletas, características que impõem desafios específicos de pré-processamento e representação textual (SUNDARAM; ZEID, 2025).




Figura 1: Pipeline de governança preditiva, do fluxo de extração da base à retroalimentação por validação humana.

A base é dinâmica, pois novos chamados continuam a ser incorporados e a taxonomia institucional pode ser revisada ao longo do tempo. Os resultados da Seção 4 referem-se ao corpus descrito acima.

3.3 Pré-processamento textual

O pré-processamento textual é documentado de modo reproduzível, uma vez que pequenas decisões sobre normalização podem alterar a matriz de atributos e, consequentemente, o desempenho dos modelos (SALTON; BUCKLEY, 1988). Para os classificadores clássicos, a representação principal é TF-IDF com n -gramas de uma e duas palavras e limite superior de 5.000 atributos para controle de dimensionalidade. Para o modelo neural LSTM, são utilizadas tokenizações específicas com vocabulário de 8.000 termos e comprimento máximo de sequência adequado à distribuição textual da base. Cabe ressaltar que a etapa de pré-processamento não elimina indiscriminadamente termos técnicos, códigos de ambientes, nomes de equipamentos ou expressões recorrentes da equipe, pois esses elementos possuem alto valor discriminativo em manutenção predial, onde palavras como *bomba*, *split*, *disjuntor*, *vazamento*, *infiltração* e *ar-condicionado* podem funcionar como âncoras semânticas relevantes para categorias específicas.

3.4 Modelos avaliados

O desenho experimental compara sete modelos, organizados em três famílias conceituais, cada uma escolhida por um motivo específico ligado às características do domínio, ou seja, texto curto, vocabulário técnico e forte desbalanceamento entre categorias (Subseção 3.2).

A família linear (LinearSVC, Regressão Logística e SGD) opera diretamente sobre a representação TF-IDF esparsa (Subseção 3.3). Em espaços de alta dimensionalidade, fronteiras lineares tendem a separar bem as classes quando o vocabulário carrega forte poder discriminativo (JOACHIMS, 1998; SALTON; BUCKLEY, 1988), como é o caso dos termos técnicos de manutenção predial, que funcionam como âncoras semânticas de categoria. A família de *ensembles* de árvores (Random Forest e Extra Trees) captura interações não lineares entre atributos, a um custo computacional maior. O **Naive Bayes Multinomial** entra como *baseline* probabilístico mais simples, útil para calibrar a expectativa de desempenho mínimo (JOACHIMS, 1998; PEDREGOSA *et al.*, 2011). A rede neural (LSTM Bidirecional) modela dependências sequenciais no texto, mas treina seus *embeddings* do zero, sem incorporar vetores pré-treinados em português (GRAVES; SCHMIDHUBER, 2005). A Subseção 3.4.1 discute por que essa escolha tende a penalizar o desempenho em corpora de porte médio como o deste estudo. Os sete modelos são avaliados na comparação *out-of-fold* (Subseção 4.1). Em paralelo, a classificação automática em produção opera com uma regra de contingência que aciona o Random Forest quando a base rotulada disponível é insuficiente para treinar a rede neural.

Um oitavo modelo, o transformador pré-treinado em português BERTimbau, permanece como extensão planejada. Seu ajuste fino depende do avanço da base validada e ainda não foi concluído, razão pela qual o

modelo não integra tabelas, rankings, testes inferenciais nem conclusões comparativas deste artigo.

3.4.1 Diferenças conceituais e operacionais entre os classificadores

Os sete modelos comparáveis cobrem quatro famílias com suposições distintas sobre os dados: um gerador probabilístico (Naive Bayes), discriminadores lineares (LinearSVC, Regressão Logística, SGD), *ensembles* não lineares baseados em árvores (Random Forest, Extra Trees) e uma rede neural sequencial (LSTM). Cada família responde de forma diferente a um corpus de texto curto, ruidoso e com forte desbalanceamento entre categorias (Subseção 3.2; Tabela S1), o que ajuda a explicar por que o desempenho não é uniforme entre elas nas Tabelas 1 e 2.

O **LinearSVC** otimiza uma fronteira de decisão linear por margem máxima sobre a representação TF-IDF esparsa de até 5.000 atributos (Subseção 3.3). Em espaços esparsos de alta dimensionalidade, classificadores lineares tendem a separar bem as classes quando o vocabulário carrega forte poder discriminativo (JOACHIMS, 1998; SALTON; BUCKLEY, 1988), como ocorre aqui, em que termos técnicos do domínio (*bomba*, *split*, *disjuntor*, *vazamento*, *infiltração*, *ar-condicionado*; Subseção 3.3) funcionam como âncoras semânticas de categoria. Essa combinação é consistente com o LinearSVC liderando tanto a concordância com o histórico (0,8031; Tabela 1) quanto o acerto validado (0,9524; Tabela 2).

O Naive Bayes assume independência condicional entre atributos dada a classe, suposição estrutural violada em texto de manutenção predial, onde termos técnicos co-ocorrem de forma sistemática dentro de uma mesma categoria. Essa divergência entre a suposição do modelo e a estrutura real dos dados explica de forma plausível a última posição do Naive Bayes, tanto na concordância com o histórico (0,6997; Tabela 1) quanto no acerto validado (0,8617; Tabela 2). Trata-se do comportamento esperado do modelo mais simples da comparação, e não de problema de implementação.

Random Forest e Extra Trees capturam interações não lineares entre atributos por meio da estrutura de árvores, mas em espaços esparsos de alta dimensionalidade como o TF-IDF tendem a ajustar-se demais às co-ocorrências mais frequentes, o que se reflete no desempenho intermediário de ambos nas Tabelas 1 e 2 (entre o LinearSVC e o Naive Bayes). O custo computacional dessa família é também o mais alto entre os modelos clássicos medidos. O treino por lote de 1.000 registros consome 19,45 s no Random Forest e 21,30 s no Extra Trees, entre 7,6 e 8,4 vezes o tempo do LinearSVC (2,55 s) e entre 17,1 e 18,7 vezes o do Naive Bayes (1,14 s) no mesmo lote (Tabela 7). Esse custo só se justificaria se revertido em ganho de acerto validado, o que não se confirma nos dados analisados (SCHWARTZ *et al.*, 2020; TREVISIO *et al.*, 2023).

A LSTM Bidirecional é projetada para modelar dependências sequenciais no texto, mas seus *embeddings* são inicializados aleatoriamente e treinados do zero, sem incorporação de vetores pré-treinados em português. A camada de *embedding* (8.000 termos $\times$ 128 dimensões) concentra sozinha cerca de 1,02 milhão de parâmetros, ordem de grandeza próxima do número de exemplos disponíveis por partição de treino, já que dos 13.965 chamados cerca de 11.172 compõem cada partição em $k=5$ *folds* (Subseção 3.5). Esse cenário é consistente com a hipótese de que modelos lineares igualam ou superam redes neurais em corpora de porte médio e ruidosos, quando não há *embeddings* pré-treinados disponíveis no idioma (GALKE; SCHERP, 2022). A Subseção 4.8 detalha a investigação da discrepância do *ablation* do LSTM, que confirma não se tratar de falha da arquitetura em si.

Na classificação automática em produção, distinta da comparação *out-of-fold* desta seção, a regra de continência opera no nível da base de treino, não por chamado individual. A LSTM só é treinada quando a base rotulada disponível atinge um mínimo de 200 exemplos. Abaixo desse limiar, um classificador Random Forest sobre TF-IDF substitui a rede neural para toda a base naquele momento. Um segundo critério, sem relação com essa troca de modelo, classifica a confiança de cada predição em três faixas (abaixo de 70%, entre 70% e 95%, acima de 95%), usadas para priorização de conferência humana e para as métricas de calibração da Subseção 4.4.

3.5 Desenho de avaliação

A avaliação se dá por predições fora da amostra em protocolo *out-of-fold* com *KFold* embaralhado, cinco partições, semente fixa e mesma partição determinística para todos os modelos. A partição não é estratificada, limitação do desenho implementado. O procedimento reduz viés de comparação e permite testes pareados (SOKOLOVA; LAPALME, 2009). São reportadas acurácia, *macro-F1*, *F1* ponderado, *balanced accuracy* e

intervalo de confiança a 95% por *bootstrap*, reamostragem com reposição que estima a distribuição de uma estatística sem pressupor sua forma paramétrica (EFRON, 1979; EFRON; TIBSHIRANI, 1993). DiCiccio e Efron (1996) revisam em detalhe os métodos de construção desse intervalo, percentil, BCa e *bootstrap-t*, e suas propriedades de cobertura.

A *macro-F1* e a *balanced accuracy* respondem ao desbalanceamento entre categorias, dado que a acurácia isolada pode superestimar o desempenho em classes majoritárias e mascarar falhas em categorias raras (SO-KOLOVA; LAPALME, 2009). A correlação entre confiança e acerto é avaliada por Spearman (SPEARMAN, 1904) e por correlação ponto-bisserial, apropriada quando uma das variáveis é binária (TATE, 1954). Diferenças globais entre os sete classificadores são apuradas por Cochran Q, teste não paramétrico para proporções pareadas em três ou mais condições (COCHRAN, 1950), e por Friedman, que dispensa o pressuposto de normalidade da ANOVA (FRIEDMAN, 1937). As comparações pareadas seguem o teste de McNemar (MC-NEMAR, 1947), e a incerteza de acurácia é estimada por *bootstrap* (EFRON, 1979), abordagem cuja aplicação a métricas de modelos preditivos permanece em refinamento (NOMA *et al.*, 2021).

Diante de múltiplas comparações, aplica-se o teste de Nemenyi sobre os postos médios (NEMENYI, 1963), conforme o protocolo consolidado por Demšar (2006) para comparação estatística de classificadores. Esse protocolo tem limitações já apontadas. Benavoli, Corani e Mangili (2016) demonstram que o teste de postos médios, base do Nemenyi, pode ser inconsistente, e recomendam testes pareados diretos como complemento. Por essa razão, reporta-se também o McNemar par a par (Subseção 4.9), em vez de depender apenas do Nemenyi. As comparações pareadas adicionais entre os sete modelos são corrigidas pelo método sequencial de Holm-Bonferroni, que controla a taxa de erro familiar sem o conservadorismo excessivo da correção de Bonferroni simples (HOLM, 1979).

Cabe justificar a escolha do *k-fold out-of-fold* em vez de um conjunto de teste fixo separado antes do treino. A literatura de avaliação de modelos indica que a validação cruzada produz estimativas de menor variância que um único *holdout*, sobretudo em bases pequenas ou desbalanceadas, por avaliar cada exemplo em algum *fold* em vez de descartar uma fração fixa dos dados do treino (KOHAVI, 1995). Esta base é desbalanceada por natureza, com várias das 55 categorias históricas apresentando suporte de dígito único.

A recomendação foi verificada empiricamente. Comparou-se o protocolo *k-fold* com um *holdout* fixo de 15% sobre os sete modelos comparáveis e a mesma base completa. A tentativa de estratificar esse *holdout* por categoria, prática padrão na maioria dos protocolos, falhou de imediato, pois a base contém categorias com um único exemplo. No *holdout* aleatório que a substituiu, várias categorias raras ficaram sem nenhum exemplo de teste, o que torna indefinida a métrica de desempenho dessas classes, problema que o *k-fold* evita por avaliar todo exemplo em algum *fold*. A acurácia global variou pouco entre os dois protocolos, mas a *macro-F1*, que pondera todas as categorias igualmente, piorou no *holdout* na maioria dos modelos. Constata-se, portanto, que o *holdout* fixo não melhora a estimativa de desempenho global nesta base e degrada sistematicamente a avaliação das categorias raras, padrão que a literatura antecipa para corpora pequenos e desbalanceados (KOHAVI, 1995).

A partição por linha, contudo, carrega uma limitação própria neste corpus. Chamados de manutenção repetem-se, e 32,67% das 13.965 linhas compartilham texto normalizado com outra linha, de modo que a base contém 9.714 grupos textuais distintos. Sob particionamento por linha, o mesmo texto pode cair em treino e em teste, o que superestima o desempenho. Para dimensionar esse efeito, os sete modelos foram reexecutados sob *GroupKFold* por hash de texto normalizado, protocolo que mantém todo grupo textual em uma única partição, e comparados com o *KFold* por linha sobre a mesma base e o mesmo alvo. O vazamento existe, mas é pequeno: a queda média de acurácia é de 0,58 ponto percentual e a máxima de 1,10, no Random Forest. O LinearSVC passa de 0,8031 para 0,7967. A ordenação dos modelos permanece a mesma sob os dois protocolos, com uma única exceção, a troca de posição entre SGD e Random Forest, justamente o par que o teste de McNemar corrigido por Holm-Bonferroni já apontava como estatisticamente indistinguível (Subseção 4.9). As Tabelas 1 e 2 reportam o protocolo por linha, por coerência com a materialização em produção, e o material suplementar traz a comparação completa entre os dois.

3.6 Validação humana

A validação humana constitui a etapa que diferencia o presente estudo de uma simples comparação de classificadores contra histórico. O processamento da base é organizado em **turnos**, blocos sequenciais de mil

chamados na ordem de registro, unidade em que a concordância é medida ao longo do corpus e que serve de bloco nos testes por postos da Subseção 4.9. O delineamento por blocos segue a recomendação de Demšar (2006) de comparar classificadores sobre partições múltiplas, e não sobre uma única medida agregada. A revisão registra, para cada caso auditado, a categoria histórica, a categoria sugerida por cada modelo, a confiança associada, a decisão humana e a categoria travada.

Duas unidades de análise convivem no protocolo e não devem ser confundidas. O **chamado** é o registro individual de manutenção, unidade das Tabelas 1, 2 e 5. A **conferência** é cada julgamento humano emitido sobre uma fonte de classificação de um chamado, de modo que um mesmo chamado gera mais de uma conferência quando o avaliador julga tanto a categoria histórica quanto a classificação automática. Daí decorrem os três denominadores usados na Seção 4: 9.534 chamados receberam ao menos uma conferência, 8.928 deles chegaram a decisão validada e os 606 restantes ficaram restritos, ao passo que o total de conferências emitidas sobre as duas fontes chega a 17.790, denominador da Tabela 3. A priorização recai sobre chamados em que há divergência entre modelos, alta confiança da IA contra histórico, baixa confiança generalizada, classes raras e pares de categorias com alta confusão recíproca. A decisão humana pode produzir quatro resultados, a saber, manter o histórico, aceitar a sugestão do modelo, definir terceira categoria ou marcar o caso como ambíguo ou taxonômico. Essa estrutura permite mensurar se a IA errou, se o histórico estava inconsistente ou se a própria taxonomia institucional necessita de revisão, em consonância com a perspectiva de que a verdade operacional deve ser construída progressivamente (ZHANG *et al.*, 2025).

3.7 Memória de decisão: veto e trava por chamado

À medida que a conferência humana avança, o protocolo incorpora uma memória de decisão por chamado, que evita o reprocessamento de casos já resolvidos e impede a repetição de erros já identificados. Quando a conferência confirma que uma categoria está correta, essa decisão é travada e reaproveitada diretamente nas rodadas seguintes de reclassificação, sem novo treinamento ou nova predição para aquele chamado. Quando a conferência identifica que uma categoria está incorreta, essa categoria passa a ser vetada especificamente para aquele chamado, e os modelos do repositório passam a escolher a melhor categoria alternativa fora do conjunto vetado, com a confiança renormalizada sobre as categorias remanescentes. Essa regra é aplicada de forma consistente na seleção de candidatos à reclassificação e no cálculo do ganho líquido, que passa a comparar o resultado da reclassificação contra a verdade validada quando ela está travada, e contra o histórico apenas quando ainda não há decisão humana. Essa memória é o mecanismo concreto de retroalimentação anunciado na Introdução: no biosistema construído, a conferência humana funciona como o sinal que corrige o próprio sistema de registro, e não apenas como aferição externa dele. O objetivo metodológico da memória de decisão é impedir que o sistema corrija um erro apenas para reincidir nele em ciclos futuros, convertendo cada conferência manual em conhecimento persistente sobre o experimento, não em um evento isolado.

3.8 Camada de entropia de Shannon e divergência de Jensen-Shannon

Como dimensão complementar às métricas supervisionadas, o protocolo incorporou uma camada de análise informacional baseada em entropia de Shannon e divergência de Jensen-Shannon (SHANNON, 1948; LIN, 1991), calculada exclusivamente sobre agregados públicos e sanitizados, sem identificador, título ou texto livre do chamado. Essa camada não substitui acurácia, calibração ou validação humana, pois responde a uma pergunta distinta, sobre onde modelos, categorias e chamados individuais concentram maior incerteza estrutural. A entropia opera aqui como medida da desordem informacional do biosistema construído, no sentido de Shannon (1948), e o que ela localiza não é erro de modelo, mas a região da taxonomia em que o próprio sistema de registro perdeu capacidade de discriminar. No nível dos modelos, a entropia de Shannon sobre a distribuição de categorias previstas indica se um classificador dispersa suas predições por muitas classes ou as concentra excessivamente em poucas; a divergência de Jensen-Shannon mede a distância entre essa distribuição prevista e a distribuição histórica da base, funcionando como indicador de deslocamento distributivo. No nível das categorias, a entropia evidenciar classes históricas cujas predições se espalham entre múltiplas categorias, sinalizando candidatas prioritárias a revisão taxonômica. No nível do chamado individual, a entropia de votos entre os modelos identifica registros em que há desacordo estrutural entre arquiteturas distintas, formando uma fila de auditoria orientada por ambiguidade, e não apenas por baixa confiança isolada de um único modelo.

3.9 Disponibilidade de dados

Os artefatos que sustentam os resultados relatados neste artigo são gerados por um processo automatizado e reproduzível, reexecutado a cada atualização do experimento. Os chamados analisados têm origem no sistema institucional GLPI da UFSB e não estão publicamente disponíveis, por restrição de privacidade institucional. As métricas derivadas e o código que produz cada figura, tabela e estatística deste artigo são de acesso público no repositório <https://github.com/adinailson88/classificacao-chamados>, que também descreve a estrutura completa dos dados e o material suplementar citado neste artigo. Nenhum identificador pessoal, título ou texto livre de chamado é armazenado nos agregados publicados, e a camada de entropia (Subseção 3.8) opera exclusivamente sobre esses agregados.

4. RESULTADOS

Esta seção apresenta dois conjuntos de resultados, deliberadamente segregados. O primeiro é a concordância com a categoria histórica (Subseção 4.1), que trata o registro do GLPI como referência preliminar, não como verdade absoluta. O segundo é o desempenho validado por conferência humana (Subseções 4.2 e 4.3), calculado exclusivamente sobre os chamados com decisão validada pela conferência humana. A base elegível contém 13.965 chamados. A conferência humana cobre 9.534 chamados (68,3% da base), dos quais 8.928 com decisão validada (63,9% da base) e 606 casos restritos, em que o avaliador eliminou as categorias conferidas sem indicar a correta. Entre os chamados conferidos, 168 registram conflito entre conferências.

Três achados resumem esta seção. Primeiro, os classificadores lineares (liderados pelo LinearSVC) superam tanto os *ensembles* de árvores quanto a rede neural LSTM em concordância e em acerto validado, com vantagem adicional de custo computacional (Subseções 4.1, 4.2 e 4.7). Segundo, a validação humana confirma que o próprio rótulo histórico contém ruído real, cerca de 1,8% dos casos conferidos, o que justifica metodologicamente todo o protocolo de conferência dupla (Subseção 4.3). Terceiro, a meta de calibração do estudo, que associa confiança igual ou superior a 95% a acerto real igual ou superior a 95%, é alcançada na faixa alta de confiança, com a ressalva de calibração discutida na Subseção 4.4.

4.1 Concordância com o histórico (base completa)

A comparação contra a categoria histórica, sobre a base completa ($n = 13.965$, com intervalo de confiança por bootstrap a 95%), mantém o LinearSVC na liderança, com acurácia de 0,8031 (IC95%: 0,7963–0,8097), seguido por Extra Trees (0,7894), Random Forest (0,7816), SGD (0,7767), Regressão Logística (0,7682), Naive Bayes (0,6997) e LSTM (0,6718). O teste de Cochran Q confirma diferença global entre os sete modelos avaliados ($Q = 2984,07$; $p < 0,001$). A comparação exclui o BERTimbau, cujo treino não foi concluído. O Kappa de Cohen (COHEN, 1960) entre cada modelo e o histórico reproduz a mesma ordenação, variando de 0,7881 (LinearSVC) a 0,6496 (LSTM), faixa que Landis e Koch (1977) classificam como concordância substancial. Cabe a ressalva de que o coeficiente é sensível à prevalência das categorias, o que recomenda lê-lo ao lado do acordo bruto (WONGPAKARAN *et al.*, 2013). A oitava fonte de classificação, a classificação automática em produção, mantém concordância de 78,61% e confiança média de 73,49%, posicionando-se entre Regressão Logística e SGD nesta métrica. A comparação direta com o LSTM *out-of-fold* da Tabela 1 não é apropriada porque essa fonte combina a rede neural com a regra de contingência do Random Forest (Subseção 3.4), em vez de um único modelo isolado.

Tabela 1 Concordância com a categoria histórica por modelo ($n = 13.965$).

Modelo	Acurácia	IC95%
LinearSVC	0,8031	0,7963 – 0,8097
Extra Trees	0,7894	0,7825 – 0,7961
Random Forest	0,7816	0,7749 – 0,7881
SGD	0,7767	0,7700 – 0,7835
Regressão Logística	0,7682	0,7613 – 0,7751
Naive Bayes	0,6997	0,6923 – 0,7071
LSTM (out-of-fold)	0,6718	0,6637 – 0,6796

A concordância com o histórico não é uniforme entre as 55 categorias. O desempenho por categoria, incluindo suporte, precisão, revocação e F1, está disponível no material suplementar. O desempenho concentra-se nas

classes de maior volume. As cinco categorias com maior F1 pertencem todas à Manutenção Preventiva, com destaque para Gerador ($F1 = 0,9908$; suporte = 1.211) e Quadros Elétricos ($F1 = 0,9869$; suporte = 576). No extremo oposto, as cinco categorias de menor F1 reúnem Sistema Fotovoltaico, Manutenção Preventiva sem subcategoria, Instalações Especiais, Transporte e Drenagem, todas com F1 inferior a 0,14. Essa leitura pede cautela, pois quatro dessas cinco categorias têm suporte igual ou inferior a sete registros, condição em que pequena variação absoluta altera fortemente a métrica.

4.2 Ranking validado por conferência humana

A avaliação contra a decisão validada pela conferência humana ($n = 9.070$ decisões) confirma a mesma liderança da Subseção 4.1. O LinearSVC permanece o melhor modelo isolado, com acerto validado de 0,9524 (IC95%: 0,9480–0,9568), seguido por SGD (0,9441), Regressão Logística (0,9404), Extra Trees (0,9312), Random Forest (0,9266), LSTM (0,8858) e Naive Bayes (0,8647). A diferença entre o primeiro e o segundo colocado é pequena em termos absolutos, de 0,83 ponto percentual, mas estatisticamente significativa (McNemar, $p < 0,001$). Foram avaliados também três *ensembles*, maioria ponderada (0,9494), confiança calibrada máxima (0,9483) e maioria simples (0,9467). Nenhum supera o LinearSVC isolado com significância, e o McNemar aponta $p < 0,05$ em favor do modelo isolado nos três casos. Não compensa combinar modelos nestes dados. A recomendação é usar o LinearSVC isolado, com calibração.

A seleção da amostra validada carrega viés estrutural, de modo que o número pontual de acerto validado acima constitui o limite superior de um intervalo, e não uma estimativa isenta de viés. A verdade validada usada neste cálculo só existe para um chamado quando o avaliador confirma pelo menos uma fonte como correta, seja o histórico, seja a classificação automática, seja a reclassificação. Dos 9.534 chamados conferidos, 606 (6,4%) caem no status restrito, em que o avaliador julgou todas as fontes erradas para aquele chamado sem indicar qual seria a categoria certa. Esses casos são excluídos do denominador de qualquer acerto validado por modelo, porque não existe categoria de referência contra a qual comparar a predição. Isso torna a amostra de 8.928 decisões, por construção, um subconjunto em que pelo menos uma fonte já estava correta, o que infla mecanicamente o acerto validado de qualquer modelo que tenda a concordar com o histórico ou com a classificação automática, independentemente da qualidade real do modelo nos casos mais difíceis, exatamente os que ficaram de fora.

Para tornar esse viés visível sem descartar a métrica, calculou-se um limite inferior de sensibilidade, correspondente ao acerto de cada modelo caso os 606 restritos entrassem no denominador contados como erro para todos os modelos. Trata-se do pior caso possível, pois a categoria certa desses chamados é desconhecida e nenhum modelo pode receber crédito neles. O intervalo entre limite inferior e superior substitui o número pontual como leitura honesta do acerto validado, com LinearSVC em 0,8919–0,9524 (amplitude 6,05 p.p.), SGD 0,8841–0,9441 (6,00 p.p.), Regressão Logística 0,8806–0,9404 (5,98 p.p.), Extra Trees 0,8720–0,9312 (5,92 p.p.), Random Forest 0,8677–0,9266 (5,89 p.p.), LSTM 0,8295–0,8858 (5,63 p.p.) e Naive Bayes 0,8097–0,8647 (5,50 p.p.). O achado metodologicamente mais importante desta análise de sensibilidade é que o ranking relativo entre os sete modelos não muda em nenhum ponto do intervalo. Mesmo no pior caso, o LinearSVC permanece à frente e o Naive Bayes atrás de todos. A conclusão qualitativa sobre qual modelo usar é, portanto, robusta ao viés identificado, ao passo que o valor absoluto do acerto validado exige essa ressalva sempre que for citado isoladamente.

Tabela 2 Acerto validado por modelo e limite inferior de sensibilidade ao viés de seleção ($n = 8.928$). O limite inferior conta os 606 casos restritos como erro de todos os modelos.

Modelo	Acerto validado	IC95%	Limite inferior
LinearSVC	0,9524	0,9480 – 0,9568	0,8919
SGD	0,9441	0,9396 – 0,9488	0,8841
Regressão Logística	0,9404	0,9357 – 0,9452	0,8806
Extra Trees	0,9312	0,9259 – 0,9365	0,8720
Random Forest	0,9266	0,9213 – 0,9319	0,8677
LSTM	0,8858	0,8795 – 0,8921	0,8295
Naive Bayes	0,8647	0,8578 – 0,8720	0,8097

4.3 A classificação automática frente ao histórico: matriz de confusão validada

Um resultado adicional, obtido comparando a categoria histórica e a classificação automática em produção contra a mesma decisão validada pela conferência humana, qualifica a tese de rótulos ruidosos apresentada na Introdução. O cruzamento abrange as 17.790 conferências em que ambas as fontes foram avaliadas. A categoria histórica coincide com a decisão em 98,17% dos casos (17.464 de 17.790), acima do acerto da classificação automática frente à mesma referência (92,80%; 16.510 de 17.790). A matriz de confusão (Tabela 3) mostra 16.510 casos em que ambas as fontes coincidem com a decisão, 326 em que nenhuma coincide, 954 em que o histórico acerta e a classificação automática erra, e nenhum caso em que a classificação automática corrige uma categoria histórica considerada incorreta. Essa ausência total tem explicação estrutural, discutida adiante.

O que o resultado sustenta com mais segurança é a outra metade da premissa. Existe ruído real no histórico, pois 326 das 17.790 conferências (1,83%) têm categoria histórica que não coincide com a decisão final. Esse ruído é proporcionalmente menor do que o risco de erro isolado da classificação automática na mesma amostra (954 conferências, 5,36%). A implicação prática permanece: a classificação automática deve ser tratada como instrumento de triagem e auditoria complementar ao histórico, não como substituto ou árbitro superior a ele.

Tabela 3 Matriz de confusão entre classificação automática e histórico, contra a decisão validada ($n = 17.790$ conferências).

	Histórico correto	Histórico incorreto
Classificação automática correta	16.510	0
Classificação automática incorreta	954	326

A ausência total de casos na célula “classificação automática correta / histórico incorreto” tem explicação estrutural. Quando a categoria decidida vem da confirmação da própria categoria histórica, a coluna “histórico incorreto” fica descartada para aquela linha por construção. A memória de decisão (Subseção 3.7) reforça esse efeito ao reaproveitar categorias já validadas, o que alinha a classificação automática às decisões confirmadas. A célula-zero mede, portanto, uma propriedade do desenho da conferência, e não a incapacidade de a classificação automática corrigir o histórico. Separar as duas coisas exigiria rastrear a origem de cada decisão validada, o que o desenho atual não permite.

4.4 Confiança, calibração e faixas de decisão

A classificação automática em produção mantém erro de calibração esperado (ECE) de 0,0549 sobre a confiança bruta. A unidade desta subseção é o chamado. O registro da classificação em produção é acumulativo, pois cada execução acrescenta uma linha por chamado sem substituir a anterior, e a leitura considera apenas a última classificação de cada chamado, de modo que os 13.965 chamados do corpus entram uma única vez e 8.895 deles têm conferência humana. Segmentada por faixa de confiança e cruzada com a decisão validada, a faixa igual ou superior a 95% concentra 5.061 chamados, 36,2% do corpus, com concordância de 98,70% frente ao histórico e acerto validado de 99,84% sobre os 4.894 chamados já decididos nessa faixa. O resultado cumpre a meta de referência do experimento, que associa confiança igual ou superior a 95% a acerto real igual ou superior a 95%. Cabe a ressalva de que a confiança empregada é bruta, sem calibração formal, de modo que a meta é atingida na métrica disponível, não em confiança calibrada em sentido estrito.

Nas faixas inferiores (Tabela 4), a degradação de desempenho acompanha a queda de confiança, do patamar de 99,17% na faixa de 90 a 95% até 55,05% abaixo de 50%. A progressão é monótona nas seis faixas, sem inversão entre faixas vizinhas, e corrobora a correlação positiva entre confiança bruta e acerto, quantificada por Spearman entre 0,46 e 0,64 conforme o modelo (Subseção 4.9), mesmo sem calibração formal aplicada a essa camada.

Tabela 4 Acerto validado por faixa de confiança. A unidade é o chamado, 13.965 no total, 8.895 com conferência humana.




Figura 2: Concordância com o histórico e acerto validado por faixa de confiança bruta da classificação automática.

Faixa	n total	Concord. histórico	n validados	Acerto validado
< 50%	3.673	43,42%	634	55,05%
50-70%	1.492	74,06%	632	91,77%
70-80%	912	83,99%	522	96,93%
80-90%	1.593	84,43%	1.126	98,67%
90-95%	1.234	94,98%	1.087	99,17%
>= 95%	5.061	98,70%	4.894	99,84%

A Figura 2 apresenta esses mesmos valores em forma gráfica, tornando visível o descolamento entre concordância com o histórico e acerto validado nas faixas inferiores de confiança.

4.5 Reclassificação e ganho líquido

A reclassificação dos chamados já conferidos produz resultados heterogêneos entre modelos, medidos contra a decisão validada quando ela existe e contra o histórico nos demais casos. O LSTM apresenta o maior ganho líquido absoluto (+100; 674 corrigidos e 574 prejudicados), seguido por Regressão Logística (+92) e LinearSVC (+73), e todos os sete modelos apresentam ganho líquido positivo (Tabela 5), embora o Extra Trees fique no limiar da neutralidade (+9). Esse resultado não autoriza aplicação indiscriminada, porque o ganho combina parcelas comparadas contra a decisão validada e contra o histórico, duas referências de naturezas distintas. Isso desaconselha a reclassificação em massa por modelo. O ganho líquido, e não apenas a acurácia agregada, é o critério operacional adequado para essa decisão, e deve ser recalculado a cada atualização da base.

Tabela 5 Ganho líquido de reclassificação por modelo.

Modelo	Corrigidos	Prejudicados	Ganho líquido
LSTM	674	574	+100
Regressão Logística	245	153	+92
LinearSVC	291	218	+73
Random Forest	234	186	+48
SGD	201	163	+38
Naive Bayes	158	132	+26
Extra Trees	237	228	+9

4.6 Diagnóstico de taxonomia e ambiguidade estrutural (Shannon/Jensen-Shannon)




Figura 3: Concordância com o histórico, confiança média e proporção de predições em alta confiança, para as dez categorias de maior e de menor concordância entre as 39 com suporte mínimo de 30 chamados.

O diagnóstico de Shannon abrange oito fontes comparáveis, a classificação automática em produção e os sete modelos avaliados. O BERTimbau foi excluído por não ter treino concluído. Duas leituras distintas emergem da Tabela 6. O LSTM apresenta a maior diversidade de categorias previstas, com entropia normalizada de 0,8213, ao passo que o LinearSVC exibe a menor divergência de Jensen-Shannon frente à distribuição histórica (0,0043). Dispersão de predições e aderência distributiva ao histórico, portanto, não caminham juntas, e o modelo de melhor acerto validado é justamente o de distribuição mais próxima da base. No nível de chamado individual, 3.268 dos 13.965 registros (23,4%) apresentam alta entropia de votos entre as oito fontes, ou seja, desacordo estrutural relevante entre arquiteturas distintas. Constitui critério de priorização de auditoria distinto e complementar à baixa confiança de um único modelo.

No nível de categoria, a análise aponta 77 ocorrências de alta ambiguidade nas predições, com suporte mínimo de 30 registros por categoria. A Figura 3 traduz esse diagnóstico em leitura direta, ao contrastar as dez categorias de maior e de menor concordância entre as 39 com suporte suficiente. O contraste é acentuado. Nas dez melhores, a concordância varia de 96,23% a 98,34%, com confiança média de 0,915 e 65,6% das predições emitidas acima do limiar de 95%. Nas dez piores, a concordância cai para a faixa de 14,47% a 67,83%, a confiança média recua para 0,463 e apenas 3,9% das predições atingem o limiar alto. Os dois grupos têm porte semelhante, 5.213 e 6.247 chamados, de modo que a diferença não decorre de escassez de exemplos.

O padrão que emerge é sistemático, não aleatório. Sete das dez categorias de maior concordância pertencem a Manutenção Preventiva, cujos chamados nascem de rotina programada e recebem descrição padronizada. As de menor concordância concentram rótulos de fronteira aberta, como Instalação e reparo de equipamentos (14,47%), Outros (26,47%) e Alvenaria, Pisos e Estrutura (34,28%), que competem por vocabulário com categorias vizinhas. A confiança acompanha a concordância nos dois extremos, o que reforça a correlação já reportada na Subseção 4.4 e indica que o classificador reconhece a própria incerteza nessas fronteiras. Trata-se, portanto, de ambiguidade estrutural da taxonomia, não apenas de erro do modelo, na linha do que Zhang *et al.* (2025) descrevem para rótulos ruidosos em processamento de linguagem natural.

A Figura 4 recorta a matriz de confusão sobre as oito categorias mais envolvidas em troca recíproca e mostra que os erros não se espalham pela taxonomia. A célula dominante registra 1.305 chamados de Climatização, Ar condicionado split, preditos como Manutenção Preventiva, Ar condicionado split. As duas categorias descrevem o mesmo equipamento e se distinguem apenas pela natureza da intervenção, corretiva ou programada, distinção que o texto do chamado raramente explicita. Outras concentrações seguem a mesma lógica de vizinhança semântica, com 815 chamados de Instalação e reparo de equipamentos preditos como Alvenaria, Pisos e Estrutura, e 707 no sentido inverso, entre Alvenaria e Esquadrias. A leitura da matriz é assimétrica em vários pares, o que sugere absorção de uma categoria por outra, e não simples permuta.

Esses dois recortes sustentam a mesma conclusão operacional. O desempenho agregado das Tabelas 1 e 2




Figura 4: Recorte da matriz de confusão sobre as oito categorias mais envolvidas em troca recíproca, com contagens agregadas entre modelos.




Figura 5: Quinze pares de categorias com maior confusão recíproca, agregados entre modelos. Os códigos do eixo vertical estão descritos no material suplementar.

esconde heterogeneidade relevante entre categorias, fenômeno que a *macro-F1* e a *balanced accuracy* foram adotadas para capturar (SOKOLOVA; LAPALME, 2009). Quando a queda de desempenho se concentra em fronteiras taxonômicas específicas, e não de modo difuso, a resposta adequada não é substituir o classificador, mas revisar a taxonomia. A interpretação qualitativa de cada par identificado, bem como a decisão de fundir ou redefinir categorias, permanece humana. O que a camada Shannon e essas duas figuras oferecem é a priorização estatística de onde essa inspeção deve começar. O Naive Bayes chama atenção por combinar a menor cobertura de categorias, apenas 17 contra 43 a 51 dos demais modelos, com entropia normalizada relativamente alta (0,8157). Trata-se de provável reflexo de concentração extrema em poucas categorias com dispersão residual entre elas, e também da maior divergência frente ao histórico observada na Tabela 6 (0,1024).

A Figura 5 mostra os quinze pares de categorias com maior confusão recíproca, dominados pela fronteira entre climatização corretiva e manutenção preventiva de ar condicionado, seguida pelas fronteiras internas de estrutura predial.




Figura 6: Trade-off entre acerto validado e tempo de treino, modelos clássicos.

Tabela 6 Entropia de Shannon e divergência de Jensen-Shannon por fonte de classificação.

Fonte	Categorias previstas	Entropia normalizada	JS vs. histórico
LSTM	51	0,8213	0,0427
Classificação automática	51	0,8089	0,0241
Regressão Logística	49	0,7906	0,0194
SGD	51	0,7806	0,0108
LinearSVC	50	0,7666	0,0043
Extra Trees	46	0,7217	0,0212
Random Forest	43	0,7279	0,0260
Naive Bayes	17	0,8157	0,1024

4.7 Custo computacional

Nos recortes de comparação por lote (1.000 registros cada), os seis modelos clássicos tiveram tempos de treino entre 1,14 s e 21,30 s. Não há medição comparável de custo para LSTM ou BERTimbau, portanto não é possível ordenar esses dois modelos frente aos demais. A tabela informa exclusivamente as medições disponíveis para os modelos clássicos.

Tabela 7 Custo computacional por lote de 1.000 registros. A acurácia refere-se ao lote, não à base completa.

Modelo	Tempo de treino (s)	Tempo de inferência (s)	Acurácia neste lote
Naive Bayes	1,14	0,07	0,539
LinearSVC	2,55	0,06	0,655
SGD	2,60	0,09	0,624
Regressão Logística	9,43	0,09	0,624
Random Forest	19,45	0,13	0,597
Extra Trees	21,30	0,14	0,610

A Figura 6 cruza essas medições de custo com o acerto validado da Tabela 2 e mostra que o LinearSVC ocupa a posição mais favorável, com o maior acerto validado a um custo de treino próximo do menor observado.

4.8 Comportamento do LSTM: curva de aprendizado e *ablation*

A Figura 7 mostra a curva real de aprendizado do LSTM sobre os 13.965 exemplos e 53 categorias. O treino parou por interrupção antecipada após 11 épocas, com menor perda de validação na época 8 e maior acurácia




Figura 7: Curva de aprendizado do LSTM por época, perda e acurácia em treino e validação.




Figura 8: *Ablation* do LSTM, quatro variantes de unidades recorrentes e *dropout*, avaliadas por *GroupKFold* contra a decisão validada.

de validação na época 10 (0,6722). O padrão indica saturação precoce, consistente com a hipótese de que *embeddings* treinados do zero são insuficientes para um corpus deste porte (Subseção 3.4.1).

O *ablation* de hiperparâmetros exige cuidado adicional de particionamento neste corpus. Chamados de manutenção repetem-se com frequência, e 46,72% das linhas validadas têm duplicata textual normalizada em outra parte da base. Uma partição aleatória por linha colocaria o mesmo texto em treino e teste, inflando o resultado. O *ablation* usa, por isso, *GroupKFold* por hash de texto normalizado, que mantém todo grupo textual em uma única partição. Sob esse protocolo, a configuração adotada em produção (64 unidades, *dropout* de 0,5) alcança 86,35% de acerto validado, e a partição aleatória equivalente produziria 87,68%, diferença de 1,33 ponto percentual que dimensiona o vazamento evitado.

As quatro variantes testadas separam-se por menos de 4 pontos percentuais entre a melhor e a pior (Figura 8), o que indica baixa sensibilidade do LSTM ao número de unidades recorrentes e à taxa de *dropout* nesta base. A limitação do modelo, portanto, não está no ajuste desses hiperparâmetros, mas na ausência de *embeddings* pré-treinados discutida na Subseção 3.4.1.

4.9 Robustez estatística: pressupostos e testes de sensibilidade

Antes de qualquer teste inferencial, foram verificados os pressupostos de robustez estatística usuais, a saber, outliers (TUKEY, 1977; HODGE; AUSTIN, 2004), homogeneidade de variância, normalidade, desbalanceamento entre categorias, colinearidade entre modelos, relação entre confiança e acerto e independência das observações, adaptando o protocolo de exploração de dados de Zuur, Ieno e Elphick (2010) da resposta contí-

nua da ecologia para a resposta categórica de classificação de chamados ($n = 13.965$). O teste de Shapiro-Wilk (SHAPIRO; WILK, 1965) foi escolhido por reunir o maior poder entre os testes de normalidade usuais nas comparações de Razali e Wah (2011) e de Ogunleye, Oyejola e Obisesan (2018). Ele rejeita a normalidade a 5% para os sete modelos sobre a concordância por turno, confirmando com números a justificativa não paramétrica já adotada na Subseção 3.5; a variância de confiança entre modelos também é fortemente heterogênea, reforçando essa escolha. O teste de Friedman (FRIEDMAN, 1937) confirma diferença global entre os modelos comparáveis, e o *post-hoc* de Nemenyi (NEMENYI, 1963) reproduz a mesma ordem das Tabelas 1 e 2, com poder estatístico menor que o McNemar par a par (MCNEMAR, 1947). Corrigido por Holm-Bonferroni (HOLM, 1979), o McNemar é significativo em praticamente todas as 21 comparações entre os sete modelos, e confirma que o LinearSVC é estatisticamente superior ao LSTM e ao Naive Bayes. A única exceção, sem significância, é o par SGD contra Random Forest. A verificação de colinearidade revela um efeito colateral relevante. Quatro dos sete modelos têm confiança altamente correlacionada entre si, com Fator de Inflação de Variância elevado (MARQUARDT, 1970), cujos limiares convencionais devem ser lidos com a cautela recomendada por O’Brien (2007), o que ajuda a explicar por que nenhum *ensemble* supera o LinearSVC isolado (Subseção 4.2), dado que modelos redundantes pouco acrescentam em informação independente a um comitê (DIETTERICH, 2000). A correlação entre confiança bruta e acerto é positiva e significativa em todos os sete modelos, com Spearman entre 0,46 e 0,64 e ponto-bisserial entre 0,43 e 0,66 ($p < 0,001$ em ambos; KORNROT, 2014), pré-requisito para a calibração discutida na Subseção 4.4 (GUO *et al.*, 2017; MINDERER *et al.*, 2021). A verificação completa dos oito pressupostos, item a item, com as tabelas de correlação, a verificação de autocorrelação serial (DURBIN; WATSON, 1950) e o Kappa de Fleiss (FLEISS, 1971) entre modelos, está disponível como Material Suplementar.

5. DISCUSSÃO

5.1 Concordância histórica frente ao acerto validado

A comparação entre concordância histórica (Subseção 4.1) e desempenho validado (Subseção 4.2) revela um descolamento sistemático entre as duas grandezas. O acerto validado do LinearSVC (95,24%) supera sua concordância com o histórico (80,31%) em 14,93 pontos percentuais, diferença que mede o quanto o rótulo administrativo subestima o classificador. Nenhuma dessas grandezas estima o desempenho da base completa, conforme a ressalva amostral detalhada na Subseção 5.3.

Um segundo mecanismo de viés, estrutural e mais específico, soma-se à não aleatoriedade da amostra. A regra de decisão da verdade validada (Subseção 3.7) exclui do denominador do acerto validado os chamados em que o avaliador julgou erradas todas as fontes conferidas, designados “restritos”. Dos 9.534 chamados conferidos, 606 (6,4%) estão nessa condição e ficam fora dos 8.928 usados na Subseção 4.2. Como esses casos não têm categoria de referência contra a qual comparar a predição de cada modelo, o acerto validado reportado como número pontual constitui um limite superior, pois mede o desempenho apenas onde pelo menos uma fonte já estava correta por construção.

A análise de sensibilidade recalcula um limite inferior, tratando os 606 restritos como erro de todos os modelos, e apura amplitude de 5,50 a 6,05 pontos percentuais conforme o modelo. A amplitude é relevante em termos absolutos, mas o *ranking* relativo entre os sete modelos permanece inalterado em qualquer ponto do intervalo. Duas implicações decorrem daí. A conclusão qualitativa sobre qual modelo priorizar é robusta a esse viés, ao passo que o valor pontual de acerto validado exige a ressalva do intervalo sempre que for citado isoladamente ou comparado a *benchmarks* externos. Esse mecanismo também explica a célula zerada da matriz de confusão (Subseção 4.3). Os casos em que o avaliador não confirma nenhuma fonte como correta, justamente onde a classificação automática teria mais chance de acertar sozinha, ficam fora da amostra decidida por construção.

A distinção entre concordância e acerto validado permanece metodologicamente necessária, e a matriz da Subseção 4.3 mostra por quê. Quando as duas fontes divergem da decisão final, o histórico está correto em 954 conferências, contra nenhuma em que a classificação automática corrige um erro genuíno do registro original, com a ressalva estrutural já discutida sobre a célula zerada. O achado preserva a premissa de que a categoria histórica não é verdade absoluta, já que persiste taxa real de erro confirmado no registro original, em 1,83% das conferências. Ao mesmo tempo, o resultado adverte contra a leitura oposta e igualmente equivocada, de que baixa concordância com o histórico implicaria acerto da classificação automática. Cabe destacar que a validação humana cumpre aqui função insubstituível, pois só ela distingue as duas situações,

que a taxa de concordância isolada confunde.

Na amostra conferida, o LinearSVC lidera tanto a concordância histórica quanto o acerto validado (Subseções 4.1 e 4.2). O resultado descreve esta base e esta amostra, sem estabelecer superioridade generalizável de classificadores lineares sobre arquiteturas neurais. A comparação de custo permanece restrita aos seis modelos clássicos da Tabela 7.

5.2 Reclassificação, ambiguidade taxonômica e calibração

O resultado da reclassificação (Subseção 4.5) introduz uma nuance operacional importante, pois o ganho líquido de corrigir chamados já classificados não é uniforme entre modelos. A amplitude vai de +9 no Extra Trees a +100 no LSTM, e a ordenação por ganho não reproduz a ordenação por acerto validado, o que mostra que classificar bem e recorrer bem são capacidades distintas. Decisões de reclassificação em produção devem ser tomadas por modelo e reavaliadas a cada atualização da base, com base no ganho líquido medido naquele momento, e não generalizadas a partir do desempenho médio de concordância ou acerto validado. Um modelo pode ser competitivo na classificação inicial e, ainda assim, não ser bom candidato a reclassificar decisões já tomadas.

A camada de entropia de Shannon e divergência de Jensen-Shannon (Subseção 4.6) não substitui as métricas supervisionadas ou a validação humana, mas amplia o repertório de governança do experimento ao separar três fenômenos que a acurácia isolada tende a confundir: o erro de modelo, a ambiguidade genuína da taxonomia institucional e a heterogeneidade natural da distribuição de chamados. A identificação de 3.268 chamados (23,4% da base) com alto desacordo estrutural entre as oito fontes comparáveis oferece um critério de priorização de auditoria distinto do simples corte por baixa confiança de um único classificador, e complementa a fila já construída a partir da conferência humana. A dispersão das predições e a aderência à distribuição histórica separam-se neste corpus, pois o LSTM lidera a diversidade de categorias previstas e o LinearSVC apresenta a menor divergência frente ao histórico (Subseção 4.6). Esse diagnóstico descreve o corpus analisado e não substitui acurácia ou validação humana.

A meta estabelecida como critério de sucesso do protocolo associa confiança calibrada igual ou superior a 95% a acerto real igual ou superior a 95% (Subseção 4.4). A faixa alta de confiança da classificação automática atinge 99,84% de acerto validado sobre 4.894 chamados conferidos, o que cumpre o critério na métrica disponível. Duas ressalvas qualificam essa leitura. A confiança utilizada é bruta (*softmax* ou *decision_function*), sem calibração formal por Platt ou isotônica (PLATT, 1999; GUO *et al.*, 2017), de modo que o requisito de confiança calibrada permanece pendente em sentido estrito. Além disso, a faixa concentra 36,2% dos chamados e é justamente aquela em que a conferência tende a confirmar o esperado.

O cumprimento da meta deve ser lido como propriedade do corpus analisado, não como garantia de operação. A amostra validada cobre 68,3% da base e sua composição privilegia divergências e casos de menor confiança, de modo que a fração ainda não conferida pode deslocar o resultado. Liberar a faixa alta para decisão automática exige concluir essa conferência e aplicar calibração formal por modelo.

5.3 Limitações

Os dados provêm de uma única instituição federal de ensino superior, com textos em português brasileiro e taxonomia institucional própria. Estender o desempenho relatado a outras instituições, taxonomias ou idiomas exige validação externa, ainda não realizada.

A amostra conferida por avaliadores humanos não é probabilística, porque prioriza divergências entre modelo e histórico e casos de maior criticidade. Os números de acerto validado descrevem, portanto, a amostra conferida, e não estimam por inferência o desempenho da base completa (COCHRAN, 1977). Uma regra de decisão adicional exclui do denominador os casos em que nenhuma fonte conferida foi confirmada como correta, 6,4% dos chamados conferidos. A análise de sensibilidade correspondente mostra amplitude de 5,50 a 6,05 pontos percentuais entre o cenário mais otimista e o mais conservador, sem alterar o ranking relativo entre os modelos.

As Tabelas 1 e 2 usam particionamento por linha, e não por grupo textual. A comparação da Subseção 3.5 mostra que isso superestima a acurácia em 0,58 ponto percentual em média, sem alterar a ordenação dos

modelos, exceto entre SGD e Random Forest, cuja diferença já não era significativa. Os valores absolutos devem ser lidos com essa margem.

Duas limitações dizem respeito aos modelos. O BERTimbau, único classificador contextual previsto no protocolo, não teve o ajuste fino concluído e ficou fora de todas as comparações. O LSTM treina seus *embeddings* do zero, sem vetores pré-treinados em português, condição que penaliza redes neurais em corpora de porte médio e ajuda a explicar seu desempenho inferior ao dos modelos lineares.

5.4 Contribuição para a governança preditiva da manutenção

A contribuição deste artigo não termina na categoria atribuída a cada chamado. Ao converter texto livre em categoria, criticidade e confiança auditáveis, o protocolo produz a camada de dados estruturados sobre a qual a gestão pública de manutenção predial pode operar de forma preditiva, e não apenas reativa. Previsão de demanda por categoria, priorização de intervenções segundo critérios de sustentabilidade e leitura territorial do parque edificado dependem, todas, de uma base classificada de modo confiável. Este artigo entrega essa fundação e demonstra que ela exige conferência humana para se sustentar.

6. CONSIDERAÇÕES FINAIS

A contribuição central deste artigo é metodológica. Em vez de apenas eleger o melhor classificador, o protocolo separa duas grandezas que a literatura de classificação de chamados costuma tratar como uma só, a concordância com o rótulo histórico e o acerto validado por conferência humana. Essa separação depende de uma camada de validação que registra a decisão do avaliador, veta categorias já rejeitadas e trava as confirmadas, convertendo cada conferência em conhecimento persistente. Foi ela que permitiu medir o desempenho contra uma referência construída, e não contra um rótulo administrativo aceito por conveniência.

O resultado prático confirma que a classificação automática serve à triagem e à auditoria, mas não dispensa a conferência humana. Sobre 8.928 chamados com decisão validada, o LinearSVC alcançou 95,24% de acerto validado (IC95%: 94,80%–95,68%), à frente dos demais seis modelos, e nenhum dos três *ensembles* avaliados o superou com significância estatística. A recomendação operacional é usar o LinearSVC isolado, escolha que o custo computacional reforça, já que os modelos lineares treinam em uma fração do tempo exigido pelos *ensembles* de árvores sem perder acerto. A confiança utilizada neste artigo é bruta, e liberar a faixa igual ou superior a 95% para decisão automática em produção exige calibração formal por modelo, por Platt ou por regressão isotônica (PLATT, 1999; GUO *et al.*, 2017). A matriz de confusão mostra por que a conferência continua necessária, pois o histórico administrativo também contém erros confirmados, em 1,83% das conferências. Esses valores descrevem a amostra conferida, com a ressalva de representatividade já registrada nas Limitações. As divergências entre modelos e histórico, por sua vez, deixaram de ser ruído descartado e passaram a alimentar a fila de revisão taxonômica, com 3.268 chamados sinalizados por alto desacordo estrutural entre as fontes.

Duas frentes dão continuidade ao trabalho. A primeira é a validação externa em outras instituições federais de ensino superior, para testar se o padrão observado se mantém sob taxonomias e volumes distintos, com o BERTimbau incorporado à comparação. A segunda é o uso desta camada classificada como entrada de modelos de previsão de demanda e de priorização multicritério de intervenções, lacuna já apontada na literatura de gestão de manutenção, que raramente incorpora dados operacionais de chamados. Nas duas direções, o protocolo aqui descrito funciona como pré-requisito, pois previsão e priorização só são confiáveis sobre uma base cuja classificação seja, ela própria, auditável.

REFERÊNCIAS

- ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. ABNT NBR 5674: Manutenção de edificações: Requisitos para o sistema de gestão de manutenção. Rio de Janeiro: ABNT, 2012.
- BENAVOLI, A.; CORANI, G.; MANGILI, F. Should we really use post-hoc tests based on mean-ranks? *Journal of Machine Learning Research*, v. 17, n. 5, p. 1–10, 2016.
- BOUABDALLAOUI, Y.; LAFHAJ, Z.; YIM, P.; DUCOULOMBIER, L.; BENNADJI, B. Natural Language Processing Model for Managing Maintenance Requests in Buildings. *Buildings*, v. 10, n. 9, art. 160, 2020.
- CAPRA, F. A teia da vida: uma nova compreensão científica dos sistemas vivos. São Paulo: Cultrix, 1996.

- CHAN, J. Y.-L.; LEOW, S. M. H.; BEA, K. T.; CHENG, W. K.; PHOONG, S. W.; HONG, Z.-W.; CHEN, Y.-L. Mitigating the multicollinearity problem and its machine learning approach: a review. *Mathematics*, v. 10, n. 8, art. 1283, 2022.
- COCHRAN, W. G. The comparison of percentages in matched samples. *Biometrika*, v. 37, n. 3-4, p. 256–266, 1950.
- COCHRAN, W. G. Sampling techniques. 3. ed. New York: John Wiley & Sons, 1977.
- COHEN, J. A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, v. 20, n. 1, p. 37–46, 1960.
- DEMŠAR, J. Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, v. 7, p. 1–30, 2006.
- DICICCIO, T. J.; EFRON, B. Bootstrap confidence intervals. *Statistical Science*, v. 11, n. 3, p. 189–228, 1996.
- DIETTERICH, T. G. Ensemble methods in machine learning. In: INTERNATIONAL WORKSHOP ON MULTIPLE CLASSIFIER SYSTEMS, 1., 2000, Cagliari. Proceedings [...]. Berlin: Springer, 2000. p. 1–15. (Lecture Notes in Computer Science, v. 1857).
- DURBIN, J.; WATSON, G. S. Testing for serial correlation in least squares regression, I. *Biometrika*, v. 37, n. 3-4, p. 409–428, 1950.
- EFRON, B. Bootstrap methods: another look at the jackknife. *The Annals of Statistics*, v. 7, n. 1, p. 1–26, 1979.
- EFRON, B.; TIBSHIRANI, R. J. An introduction to the bootstrap. New York: Chapman & Hall/CRC, 1993.
- FLEISS, J. L. Measuring nominal scale agreement among many raters. *Psychological Bulletin*, v. 76, n. 5, p. 378–382, 1971.
- FRIEDMAN, M. The use of ranks to avoid the assumption of normality implicit in the analysis of variance. *Journal of the American Statistical Association*, v. 32, n. 200, p. 675–701, 1937.
- GALKE, L.; SCHERP, A. Bag-of-words vs. graph vs. sequence in text classification: questioning the necessity of text-graphs and the surprising strength of a wide MLP. In: ANNUAL MEETING OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS, 60., 2022, Dublin. Proceedings [...]. Dublin: ACL, 2022. p. 4038–4051.
- GRAVES, A.; SCHMIDHUBER, J. Frameworkwise phoneme classification with bidirectional LSTM and other neural network architectures. *Neural Networks*, v. 18, n. 5-6, p. 602–610, 2005.
- GRIMM, N. B.; FAETH, S. H.; GOLUBIEWSKI, N. E.; REDMAN, C. L.; WU, J.; BAI, X.; BRIGGS, J. M. Global change and the ecology of cities. *Science*, v. 319, n. 5864, p. 756–760, 2008.
- GUO, C.; PLEISS, G.; SUN, Y.; WEINBERGER, K. Q. On calibration of modern neural networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 34., 2017, Sydney. Proceedings [...]. Sydney: PMLR, 2017. p. 1321–1330.
- HODGE, V. J.; AUSTIN, J. A survey of outlier detection methodologies. *Artificial Intelligence Review*, v. 22, n. 2, p. 85–126, 2004.
- HOLM, S. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, v. 6, n. 2, p. 65–70, 1979.
- JOACHIMS, T. Text categorization with support vector machines: learning with many relevant features. In: EUROPEAN CONFERENCE ON MACHINE LEARNING, 10., 1998, Chemnitz. Proceedings [...]. Berlin: Springer, 1998. p. 137–142.
- KEJRIWAL, M.; SANTOS, H.; SHEN, K.; MULVEHILL, A. M.; MCGUINNESS, D. L. A noise audit of human-labeled benchmarks for machine commonsense reasoning. *Scientific Reports*, v. 14, art. 8609, 2024.

- KOHAVI, R. A study of cross-validation and bootstrap for accuracy estimation and model selection. In: INTERNATIONAL JOINT CONFERENCE ON ARTIFICIAL INTELLIGENCE, 14., 1995, Montreal. Proceedings [...]. San Francisco: Morgan Kaufmann, 1995. p. 1137–1143.
- KORNBROT, D. Point biserial correlation. In: Wiley StatsRef: Statistics Reference Online. Chichester: Wiley, 2014.
- LANDIS, J. R.; KOCH, G. G. The measurement of observer agreement for categorical data. *Biometrics*, v. 33, n. 1, p. 159–174, 1977.
- LIMA, L. F. M.; MAROLDI, A. M.; SILVA, D. V. O. da; HAYASHI, C. R. M.; HAYASHI, M. C. P. I. Métricas científicas em estudos bibliométricos: detecção de outliers para dados univariados. *Em Questão*, Porto Alegre, v. 23, p. 254–273, 2017.
- LIN, J. Divergence measures based on the Shannon entropy. *IEEE Transactions on Information Theory*, v. 37, n. 1, p. 145–151, 1991. DOI: 10.1109/18.61115.
- LI, Y.; LIU, Y.; ZHANG, J.; CAO, L.; WANG, Q. Automated analysis and assignment of maintenance work orders using natural language processing. *Automation in Construction*, v. 165, art. 105501, 2024.
- LIU, Z.; BENGE, C.; JIANG, S. Ticket-BERT: labeling incident management tickets with language models. *arXiv:2307.00108*, 2023.
- MARQUARDT, D. W. Generalized inverses, ridge regression, biased linear estimation, and nonlinear estimation. *Technometrics*, v. 12, n. 3, p. 591–612, 1970.
- MARTINS, R. F. B.; ESPEJO, M. M. S. B. Análise de custos de manutenção predial em uma universidade federal brasileira com uso do modelo de SES. *ABCustos*, São Leopoldo, v. 19, n. 1, p. 79–98, 2024.
- MCNEMAR, Q. Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, v. 12, n. 2, p. 153–157, 1947.
- MINDERER, M.; DJOLONGA, J.; ROMIJNDERS, R.; HUBIS, F.; ZHAI, X.; HOULSBY, N.; TRAN, D.; LUCIC, M. Revisiting the calibration of modern neural networks. In: CONFERENCE ON NEURAL INFORMATION PROCESSING SYSTEMS, 35., 2021. *Advances in Neural Information Processing Systems*, v. 34, 2021.
- MOHAMMED, A. S.; AMOAH, C. Integration of technology in decision-making in university facilities management: a literature review. *Facilities*, v. 43, n. 13/14, p. 1018–1052, 2025.
- MORAIS, L. S. R. de; PAULA, H. M. de; REIS, R. P. A. Promoção da eficiência da manutenção predial em edificações públicas: abordagem baseada em registros de ordens de serviço. *Paranoá*, Brasília, v. 16, n. 34, p. 1–18, 2023. DOI: 10.18830/issn.1679-0944.n34.2023.08.
- NEMENYI, P. B. Distribution-free multiple comparisons. 1963. Tese (Doutorado em Estatística) — Princeton University, Princeton, 1963.
- NOMA, H.; SHINOZAKI, T.; IBA, K.; TERAMUKAI, S.; FURUKAWA, T. A. Confidence intervals of prediction accuracy measures for multivariable prediction models based on the bootstrap-based optimism correction methods. *Statistics in Medicine*, v. 40, n. 26, p. 5691–5701, 2021.
- O'BRIEN, R. M. A caution regarding rules of thumb for variance inflation factors. *Quality & Quantity*, v. 41, n. 5, p. 673–690, 2007.
- ODUM, H. T. *Environment, power, and society*. New York: Wiley-Interscience, 1971.
- OGUNLEYE, L. I.; OYEJOLA, B. A.; OBISESAN, K. O. Comparison of some common tests for normality. *International Journal of Probability and Statistics*, v. 7, n. 5, p. 130–137, 2018.
- PAMPANA, A. K. et al. Data-driven analysis for facility management in higher education institution. *Buildings*, v. 12, art. 2094, 2022.
- PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.

- PLATT, J. C. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. In: SMOLA, A. J. et al. (Ed.). *Advances in Large Margin Classifiers*. Cambridge: MIT Press, 1999. p. 61–74.
- RAZALI, N. M.; WAH, Y. B. Power comparisons of Shapiro-Wilk, Kolmogorov-Smirnov, Lilliefors and Anderson-Darling tests. *Journal of Statistical Modeling and Analytics*, v. 2, n. 1, p. 21–33, 2011.
- SALTON, G.; BUCKLEY, C. Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, v. 24, n. 5, p. 513–523, 1988.
- SCHWARTZ, R.; DODGE, J.; SMITH, N. A.; ETZIONI, O. Green AI. *Communications of the ACM*, v. 63, n. 12, p. 54–63, 2020.
- SHANNON, C. E. A mathematical theory of communication. *Bell System Technical Journal*, v. 27, n. 3, p. 379–423, jul. 1948; v. 27, n. 4, p. 623–656, out. 1948.
- SHAPIRO, S. S.; WILK, M. B. An analysis of variance test for normality (complete samples). *Biometrika*, v. 52, n. 3-4, p. 591–611, 1965.
- SOKOLOVA, M.; LAPALME, G. A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, v. 45, n. 4, p. 427–437, 2009.
- SPEARMAN, C. The proof and measurement of association between two things. *American Journal of Psychology*, v. 15, n. 1, p. 72–101, 1904.
- SUNDARAM, S.; ZEID, A. Technical Language Processing for Prognostics and Health Management: applying text similarity and topic modeling to maintenance work orders. *Journal of Intelligent Manufacturing*, v. 36, p. 1637–1657, 2025.
- TATE, R. F. Correlation between a discrete and a continuous variable. Point-biserial correlation. *The Annals of Mathematical Statistics*, v. 25, n. 3, p. 603–607, 1954.
- TREVISIO, M. et al. Efficient methods for Natural Language Processing: a survey. *Transactions of the Association for Computational Linguistics*, v. 11, p. 826–860, 2023.
- TUKEY, J. W. *Exploratory data analysis*. Reading: Addison-Wesley, 1977.
- WONGPAKARAN, N.; WONGPAKARAN, T.; WEDDING, D.; GWET, K. L. A comparison of Cohen’s Kappa and Gwet’s AC1 when calculating inter-rater reliability coefficients: a study conducted with personality disorder samples. *BMC Medical Research Methodology*, v. 13, art. 61, 2013.
- ZHANG, H.; ZHANG, Y.; LI, J.; LIU, J.; JI, L. A survey on learning with noisy labels in Natural Language Processing: how to train models with label noise. *Engineering Applications of Artificial Intelligence*, v. 146, art. 110157, 2025.
- ZUUR, A. F.; IENO, E. N.; ELPHICK, C. S. A protocol for data exploration to avoid common statistical problems. *Methods in Ecology and Evolution*, v. 1, n. 1, p. 3–14, 2010.