

CLASSIFICAÇÃO AUDITÁVEL DE CHAMADOS DE MANUTENÇÃO PREDIAL: FLUXO HUMANO-IA, CALIBRAÇÃO E RISCO DE RECLASSIFICAÇÃO

Auditable classification of building maintenance work orders: human-AI workflow, calibration, and reclassification risk

Adinailson Guimarães de Oliveira - adinailson.oliveira@cja.ufsb.edu.br **Fabício Berton Zanchi** - fabricao.berton@ufsb.edu.br

Universidade Federal do Sul da Bahia (UFSB), Programa de Pós-Graduação em Biosistemas

RESUMO

A triagem de chamados de manutenção predial em instituições públicas depende da categoria registrada no sistema de atendimento, cujo acerto condiciona todo uso analítico da base. A literatura sobre a classificação automática desses registros concentra-se em corpora de outros idiomas e domínios e avalia o classificador contra o rótulo histórico, o que impede distinguir erro do modelo de erro do registro e deixa por medir o risco de reescrever a base. Este artigo propõe e mede um protocolo auditável sobre 14.060 chamados de manutenção predial universitária em português brasileiro, com métricas nas 13.972 linhas das 41 categorias com suporte. As predições são obtidas fora da amostra sob validação cruzada agrupada pelo texto normalizado, unidade também adotada na inferência, de modo que registros de texto idêntico não atravessam a fronteira entre treino e teste nem contam como independentes. A referência de avaliação provém de auditoria administrativa de rótulo sobre a totalidade do corpus, que alterou a categoria histórica em 4,25% dos registros. O melhor dos sete classificadores alcança acurácia de 0,8253 contra essa referência, e a calibração isotônica viabiliza automação seletiva de cerca de dois terços do volume com acurácia de 0,95, encaminhando o restante ao revisor. A reclassificação automática da base produz ganho líquido negativo nos sete modelos, veredito que se mantém sob custos assimétricos e converte a divergência em critério de priorização da auditoria. A contribuição é o protocolo que articula governança de rótulo, inferência sob dependência textual, calibração, automação seletiva e avaliação explícita do risco de reclassificação.

Palavras-chave: manutenção predial; classificação de chamados; auditoria de rótulo; calibração e classificação seletiva; rótulos ruidosos.

ABSTRACT

Triage of building maintenance work orders in public institutions relies on the category recorded in the service-management system, whose accuracy conditions every later analytical use of the database. Research on the automatic classification of such records concentrates on corpora from other languages and domains and evaluates the classifier against the historical label, which prevents telling model error from record error and leaves the risk of rewriting the database unmeasured. This paper proposes and measures an auditable classification protocol over 14,060 university building maintenance work orders in Brazilian Portuguese, with metrics computed on the 13,972 records of the 41 categories with support. Predictions are obtained out of sample under cross-validation grouped by normalised text, the same unit adopted for inference, so that records sharing identical text neither cross the train-test boundary nor count as independent evidence. The evaluation reference comes from an administrative label audit over the entire corpus, which changed the historical category in 4.25% of records. The best of the seven classifiers compared reaches 0.8253 accuracy against that reference, and isotonic calibration enables selective automation of about two thirds of the volume at 0.95 accuracy, routing the remainder to human review. Automatic reclassification of the base yields a negative net gain across the seven models, a verdict that holds under asymmetric costs and turns divergence into a criterion for prioritising the audit queue. The contribution lies in the protocol that articulates label governance, inference under textual dependence, calibration, selective automation, and explicit assessment of reclassification risk.

Keywords: building maintenance; work-order classification; label audit; calibration and selective classification; noisy labels.

1. INTRODUÇÃO

A manutenção predial responde pela preservação do patrimônio edificado e pela continuidade das atividades finalísticas das instituições federais de ensino superior (IFES), ainda que disponha historicamente de menos de 2% do orçamento institucional (MARTINS; ESPEJO, 2024; PAMPANA *et al.*, 2022). Sob essa restrição,

decidir onde intervir depende de evidência sobre o parque edificado, conforme a gestão sistematizada definida pela NBR 5674 (ABNT, 2012).

O sinal disponível para essa decisão é textual. Um campus universitário constitui um biossistema construído, isto é, a integração dinâmica entre infraestrutura física, atividade humana, sistemas tecnológicos e condicionantes ambientais, cuja persistência depende de retroalimentação contínua entre uso, falha e reparo (CAPRA, 1996; ODUM, 1971), e sua governança repousa sobre a capacidade institucional de captar sinais operacionais e convertê-los em decisão (GRIMM *et al.*, 2008). Nas IFES, esse sinal assume a forma de registros de chamados de manutenção, armazenados em linguagem não estruturada, cuja interpretação individual impede o uso direto por mecanismos de decisão automatizada (MORAIS; PAULA; REIS, 2023; MOHAMMED; AMOAH, 2025). Convertê-los em dado estruturado e auditável é condição anterior a qualquer camada preditiva.

Três obstáculos condicionam essa conversão: a natureza textual curta e heterogênea dos registros, cujas abreviações locais e jargões de equipe dificultam a aplicação de modelos genéricos de processamento de linguagem natural (PLN) (SUNDARAM; ZEID, 2025); o desbalanceamento entre categorias, em que demandas recorrentes concentram grande parte da base e categorias raras dispõem de poucos exemplos para treinamento supervisionado (LI *et al.*, 2024); e a qualidade do próprio rótulo histórico, que pode resultar de interpretação rápida ou de taxonomia ainda não estabilizada, de modo a constituir evidência importante, mas não referência definitiva (ZHANG *et al.*, 2025; KEJRIWAL *et al.*, 2024).

A literatura confirma a viabilidade técnica da tarefa, com acurácia de 0,83 sobre 15.623 ordens de serviço hospitalares (LI *et al.*, 2024) e 78% em requisições de edificação hospitalar (BOUABDALLAOUI *et al.*, 2020). Essas aplicações concentram-se, todavia, em bases de outros idiomas e em domínios industriais ou hospitalares, e avaliam o classificador contra o rótulo registrado, sem submetê-lo a auditoria. Restam duas lacunas convergentes: a escassez de corpora em português brasileiro na manutenção predial pública universitária e a ausência de protocolo que trate a categoria histórica como objeto de auditoria e meça o risco de reescrevê-la.

A pergunta que orienta este artigo não é, portanto, qual classificador mais concorda com a categoria histórica, e sim sob que condições a classificação automática produz dado estruturado confiável sem herdar as inconsistências do registro que lhe deu origem.

A resposta é um protocolo auditável, medido sobre 14.060 chamados reais da Universidade Federal do Sul da Bahia (UFSB). A contribuição não está na comparação entre algoritmos, aqui meio e não fim, mas na articulação de cinco elementos: governança de rótulo por auditoria administrativa sobre o corpus integral, que separa a concordância com o histórico do acerto contra a referência revisada; inferência que respeita a dependência entre chamados de texto repetido, com o grupo textual como unidade na partição e nos testes; calibração dos escores de confiança; automação seletiva condicionada a esses escores, com encaminhamento do restante ao revisor; e avaliação do risco de reclassificação por função de utilidade explícita. Sete classificadores percorrem o protocolo sob as mesmas partições, e o BERTimbau fica fora por custo computacional medido.

O objetivo geral é avaliar em que medida esse protocolo produz camada de dados estruturados apta a sustentar a governança da manutenção predial pública, consoante à integração físico-humano-tecnológico-ambiental do biossistema construído.

2. REFERENCIAL CONCEITUAL

2.1 Classificação automática de ordens de manutenção e de chamados

Ordens de manutenção documentam sintomas, locais, equipamentos e soluções em forma textual semiestruturada, o que lhes confere valor informacional elevado e uso habitualmente reduzido no planejamento (PAMPANA *et al.*, 2022; MORAIS; PAULA; REIS, 2023). Li *et al.* (2024) são a referência-âncora desta pesquisa por tratarem da automação de ordens de manutenção predial, ainda que em idioma e taxonomia distintos, e Sundaram e Zeid (2025) acrescentam que chamados curtos e descrições incompletas inviabilizam modelos genéricos sem adaptação lexical ao corpus.

Na classificação de *tickets*, a evolução das representações lexicais aos modelos pré-treinados, como o TicketBERT (LIU; BENGGE; JIANG, 2023), não se transfere sem cautela à manutenção predial, cujos sistemas e equipamentos não coincidem com categorias de incidentes digitais (SUNDARAM; ZEID, 2025). Em texto

curto de vocabulário especializado, ademais, classificadores lineares sobre representações TF-IDF sustentam desempenho equivalente ao de redes neurais em múltiplos *benchmarks* (GALKE; SCHERP, 2022).

2.2 Desbalanceamento e rótulos ruidosos

Duas propriedades da base condicionam a leitura das métricas. O desbalanceamento entre categorias faz a acurácia agregada ser dominada pelas classes majoritárias e mascarar falhas nas raras, o que recomenda métricas de média por classe com o suporte declarado (SOKOLOVA; LAPALME, 2009) e leva a classificação hierárquica de chamados a excluir rótulos de frequência muito baixa (MARCUSOZZO *et al.*, 2022). O ruído de rótulo decorre de ambiguidade semântica, sobreposição taxonômica ou erro de registro (ZHANG *et al.*, 2025), e *benchmarks* rotulados por humanos contêm variabilidade relevante, o que questiona a prática de assumir referência única onde há julgamento subjetivo (KEJRIWAL *et al.*, 2024). A categoria histórica é tratada, por conseguinte, como registro administrativo sujeito a auditoria, e a referência de avaliação provém de auditoria de rótulo.

2.3 Calibração e classificação seletiva

O escore de confiança de um classificador não é, por construção, uma probabilidade, e associá-lo à frequência de acerto exige calibração por ajuste sigmoideal da margem (PLATT, 1999) ou por regressão isotônica, necessidade que persiste mesmo em arquiteturas de alto desempenho (GUO *et al.*, 2017). É a calibração que torna operável a classificação seletiva, regime no qual o modelo decide apenas acima de um limiar e transfere os demais casos a outro decisor, cujo compromisso entre erro e rejeição foi formulado por Chow (1970) e é hoje reportado como par entre cobertura e risco (EL-YANIV; WIENER, 2010). Em fluxo humano-IA, esse par delimita quanto do volume se decide automaticamente.

2.4 Custo computacional e delimitação de escopo

A eficiência computacional deve ser reportada e valorizada na avaliação de modelos, não apenas a acurácia (SCHWARTZ *et al.*, 2020; TREVISIO *et al.*, 2023). Em instituição pública o critério é decisório, pois um modelo que treina em segundos é reexecutado e auditado sem infraestrutura dedicada. É por ele que os modelos de linguagem de grande porte, embora dispensem ajuste supervisionado ao inferir a tarefa do próprio enunciado (BROWN *et al.*, 2020), ficam fora desta comparação: exigem aceleradores dedicados ou serviços tarifados por uso, deslocam as descrições dos chamados para fora do domínio da universidade e variam entre versões do serviço, o que compromete a reprodutibilidade exigida pelo delineamento (BENDER *et al.*, 2021). O protocolo integral não foi executado sobre essas arquiteturas nem sobre o BERTimbau, cujo custo medido é tratado na Subseção 4.5, de sorte que nada se afirma sobre seu desempenho relativo.

3. MÉTODO

3.1 Delineamento, corpus e referência revisada

O estudo adota delineamento experimental aplicado sobre base observacional retrospectiva de chamados de manutenção predial do sistema GLPI institucional da UFSB, universidade pública multicampi do sul da Bahia (MORAIS; PAULA; REIS, 2023). A unidade de análise é o chamado individual, representado pelo título e pela descrição do chamado e pelo título e pela descrição da ordem de serviço, aos quais se associa a categoria histórica registrada no sistema. O corpus congelado reúne 14.060 chamados de texto não vazio em 50 categorias históricas, cuja distribuição consta do Apêndice A, e corresponde a um corte único de extração sobre o qual os artefatos foram materializados e versionados. O idioma é o português brasileiro, com jargão técnico, abreviações locais e descrições incompletas (SUNDARAM; ZEID, 2025). O corte não preserva a data de abertura do chamado, restrição tratada na Subseção 5.3. A Figura 1 apresenta o fluxo metodológico como *pipeline* de governança preditiva, no qual a revisão humana precede o treinamento, pois dela sai o rótulo com que os modelos são treinados e contra o qual são avaliados.

A revisão humana é auditoria administrativa de rótulo, e não anotação independente: a pergunta submetida ao especialista é se a categoria já registrada é adequada ao chamado. Para cada registro, o avaliador examinou os quatro campos textuais e a categoria histórica, sem acesso a previsões ou níveis de confiança dos modelos; confirmada a categoria, ela permanece como referência, e rejeitada, o avaliador registra outra da mesma taxonomia. A revisão cobriu todo o corpus, com 13.462 manutenções da categoria histórica e 598




Figura 1: Pipeline de governança preditiva, do fluxo de extração da base à retroalimentação por auditoria de rótulo.

substituições, taxa de alteração de 4,25%. Manter a categoria é confirmação administrativa, e não concordância entre avaliadores nem correção factual. Havendo uma única decisão por registro, não há segunda avaliação, cegamento nem adjudicação, e nenhuma medida de confiabilidade entre avaliadores é reportada; a ancoragem e as demais restrições constam da Subseção 5.3.

Uma análise de consistência interna pode ser realizada sem segundo avaliador, mas não substitui avaliação independente nem permite estimar concordância interavaliadores. O procedimento localiza os grupos de texto normalizado idêntico que receberam mais de uma categoria de referência e classifica cada um conforme as categorias em disputa pertençam ou não ao mesmo tipo de manutenção; os grupos assim identificados sinalizam ambiguidade de contexto não textual ou inconsistência interna, origens que só o reexame caso a caso separaria. A contagem consta da Subseção 4.4.

3.2 Pré-processamento e representação

A normalização altera a matriz de atributos e, com ela, o desempenho dos modelos (SALTON; BUCKLEY, 1988), e por isso é descrita de modo verificável. Os quatro campos são localizados por cabeçalho, despojados de espaços nas extremidades e concatenados por quebra de linha na ordem título do chamado, descrição do chamado, título da ordem de serviço e descrição da ordem de serviço; campos vazios são descartados da concatenação, e não substituídos por marcador. Para o agrupamento, cada campo é normalizado separadamente por decomposição Unicode com remoção de diacríticos, caixa baixa e colapso de espaços, e o identificador do grupo é o resumo SHA-256 da serialização dos quatro campos normalizados mantidos separados, e não do texto concatenado, o que evita colidir registros que só coincidiriam após a junção.

A representação dos classificadores clássicos é TF-IDF com remoção de acentos, caixa baixa, *n-gramas* de uma e duas palavras, frequência documental mínima de uma ocorrência e limite superior de 30.000 atributos. A LSTM emprega tokenização própria, com vocabulário de 8.000 termos, marcador explícito para termo fora do vocabulário e comprimento máximo de 120 *tokens*, com preenchimento e truncamento à direita. Vetorizador, tokenizador e vocabulário são ajustados dentro de cada dobra, sobre a partição de treino. A etapa não elimina termos técnicos, códigos de ambientes ou nomes de equipamentos, pois palavras como *bomba*, *split* e *infiltração* são âncoras semânticas de categorias específicas.

3.3 Modelos e configuração experimental

Sete modelos em três famílias compõem a comparação principal, escolhidas pelas características do domínio: texto curto, vocabulário técnico e forte desbalanceamento. Fronteiras lineares separam bem as classes sobre representação esparsa quando o vocabulário carrega poder discriminativo (JOACHIMS, 1998; SALTON; BUCKLEY, 1988); os *ensembles* de árvores capturam interações não lineares a custo maior; o Naive Bayes assume independência condicional entre atributos dada a classe, suposição violada quando termos técnicos co-ocorrem dentro de uma mesma categoria (PEDREGOSA *et al.*, 2011); e a LSTM treina seus *embeddings*

do zero (GRAVES; SCHMIDHUBER, 2005), concentrando nessa camada cerca de 1,02 milhão de parâmetros, ordem de grandeza próxima dos 11.178 exemplos de cada partição de treino. A Tabela 1 resume representação, configuração e papel de cada modelo; os hiperparâmetros não declarados permanecem nos padrões da biblioteca e estão versionados no repositório, com o ambiente de execução.

Tabela 1 Configuração experimental dos sete modelos, que compartilham partições, rótulo de treino e denominador ($n = 13.972$; 41 categorias).

Modelo	Representação	Hiperparâmetros essenciais	Balanceamento	Saída de confiança	Papel
Naive Bayes	TF-IDF	suavização $\alpha = 1$	nenhum	probabilidade máxima	<i>baseline</i> probabilístico
Regressão Logística	TF-IDF	até 1.000 iterações	pesos balanceados	probabilidade máxima	linear probabilístico
LinearSVC	TF-IDF	margem máxima, $C = 1$	pesos balanceados	<i>softmax</i> da margem	linear de margem máxima
SGD	TF-IDF	perda logarítmica	pesos balanceados	probabilidade máxima	linear incremental
Random Forest	TF-IDF	200 árvores	pesos balanceados	probabilidade máxima	<i>ensemble</i> agregado
Extra Trees	TF-IDF	200 árvores, cortes aleatórios	pesos balanceados	probabilidade máxima	<i>ensemble</i> aleatorizado
LSTM Bidirecional	tokenização própria	<i>embedding</i> de 128, 64 unidades, <i>dropout</i> 0,5, densa de 64, lote de 128	pesos balanceados	<i>softmax</i>	rede neural sequencial

Um oitavo modelo, o BERTimbau-Base (DEVLIN *et al.*, 2019; SOUZA; NOGUEIRA; LOTUFO, 2020), é experimento exploratório fora da comparação principal: foi ajustado sob protocolo distinto, com subamostragem estratificada e parada antecipada, sem previsões *out-of-fold* sobre todo o corpus. A medição de custo que fundamenta a separação consta da Subseção 4.5; nada se afirma sobre seu desempenho relativo.

3.4 Validação, calibração e inferência

A avaliação usa previsões *out-of-fold* com **StratifiedGroupKFold**, cinco dobras, embaralhamento e semente fixa, estratificação pela referência revisada e agrupamento pelo hash do texto normalizado da Subseção 3.2, de modo que nenhum grupo atravessa a fronteira entre treino e teste. As partições são geradas uma única vez, versionadas e reutilizadas por todos os modelos e pela camada de regras, o que legitima os testes pareados (SOKOLOVA; LAPALME, 2009), e foram preferidas a conjunto de teste fixo pela menor variância das estimativas em bases desbalanceadas (KOHAVI, 1995). A separação é textual, e não cronológica: as métricas medem generalização para grupos de texto não vistos dentro do mesmo corte de extração, e não desempenho sobre chamados posteriores.

O agrupamento impõe custo de cobertura: uma categoria só entra na avaliação se tiver grupos textuais distintos em número suficiente para as cinco dobras. Nove das 50 categorias não satisfazem essa condição, quatro por aritmética e cinco por ausência efetiva em alguma dobra após a estratificação; somam 88 linhas, ou 0,63% da base congelada, e sua exclusão reduz o denominador das métricas de 14.060 para 13.972 registros em 41 categorias; as nove excluídas, de menor frequência, constam da Tabela A3. As alternativas examinadas, com o efeito de cada convenção de denominador, constam da Subseção 4.1 e do material suplementar.

A unidade da inferência é o grupo textual, e não o chamado. Das 14.060 linhas, 4.586, ou 32,62%, compartilham texto normalizado com outra; a base congelada resolve-se em 9.786 grupos, 9.474 deles unitários, e

9.735 sobrevivem ao recorte das 13.972 linhas avaliadas, ao passo que o mapa recalculado sobre o texto vivo registra 9.734, por edição posterior ao congelamento. Registros de texto idêntico recebem a mesma predição de qualquer classificador e não são evidências independentes; tratá-los como tal estreita artificialmente intervalos e valores de p (COCHRAN, 1977).

As métricas são assim definidas. A acurácia é a proporção de registros cuja predição coincide com a referência revisada, e o *macro*-F1, a média aritmética simples do F1 por categoria, que pondera igualmente classes de qualquer suporte (SOKOLOVA; LAPALME, 2009). O erro de calibração esperado (ECE) é a média, ponderada pelo número de registros, do módulo da diferença entre acurácia e confiança média em dez faixas de largura igual, e o *escore* de Brier, na formulação binária de acerto ou erro, pune má calibração e baixa resolução. A cobertura é a fração de registros cuja confiança calibrada atinge o limiar, a acurácia seletiva restringe a acurácia a eles, e o complemento da cobertura é a taxa de encaminhamento humano. O ganho líquido é a diferença entre corrigidos e prejudicados onde a predição diverge do histórico, qualificado pela utilidade da Subseção 4.2.

A calibração e a escolha do limiar seguem desenho de dobra interna. Para cada dobra externa, uma dobra interna é escolhida deterministicamente entre as demais; o modelo é treinado nas três restantes e prediz a interna, e os pares de *escore* e acerto assim obtidos ajustam a regressão isotônica e fixam o limiar como o menor *escore* que atinge o alvo de acurácia. Calibrador e limiar são então aplicados aos *escores out-of-fold* da dobra externa, sobre a qual recai a avaliação. Transformações, tokenizadores, vocabulários, calibradores e limiares são, sem exceção, ajustados sem acesso à dobra externa.

A hipótese global de igualdade das taxas de acerto é apurada pela estatística Q de Cochran (COCHRAN, 1950), com a distribuição qui-quadrado tabelada substituída por referência empírica obtida por permutação do rótulo de modelo dentro de cada grupo, o que preserva a dependência interna (GOOD, 2005; ANDERSON; TER BRAAK, 2003). Rejeitada a igualdade, os 21 pares são comparados por permutação pareada com troca de sinal da diferença de acertos por grupo, com correção sequencial de Holm-Bonferroni (HOLM, 1979), e os intervalos das métricas e das diferenças vêm de *bootstrap* de conglomerados, que sorteia grupos com reposição e reconstrói a amostra com todos os registros de cada grupo sorteado (EFRON, 1979; EFRON; TIBSHIRANI, 1993; DICICCIO; EFRON, 1996; FIELD; WELSH, 2007; CAMERON; GELBACH; MILLER, 2008). A divisão aleatória por linha permanece apenas como análise de sensibilidade, no material suplementar.

3.5 Reclassificação, utilidade e análises complementares

Quatro análises complementam a comparação principal, sobre as mesmas partições e os mesmos registros, sem alterar a referência revisada. A reclassificação da base histórica conta apenas os registros em que a predição diverge da categoria histórica, com a referência arbitrando cada divergência, e é qualificada pela utilidade sob custos assimétricos da Subseção 4.2. A camada explícita de regras de periodicidade, em módulo próprio e auditável, tem desenho e termos na Subseção 4.5. A camada informacional de entropia de Shannon e divergência de Jensen-Shannon (SHANNON, 1948; LIN, 1991) é calculada sobre agregados sanitizados e mede dispersão das predições, distância frente à distribuição histórica e desacordo entre modelos, este último usado para ordenar fila de auditoria; nada se afirma, a partir dela, sobre desordem do sistema físico. O teste de sensibilidade da cobertura sob três convenções de denominador consta da Subseção 4.1.

3.6 Reprodutibilidade, dados e aspectos institucionais

A rodada canônica foi executada em ambiente Linux de 64 bits, sobre executor hospedado de quatro processadores sem acelerador gráfico, com Python 3.11.15, NumPy 1.26.4, scikit-learn 1.5.2 e TensorFlow 2.17.0. A semente 42 foi aplicada ao embaralhamento das partições e aos componentes do scikit-learn que recebem `random_state`. A execução canônica da LSTM não fixou explicitamente a semente global do TensorFlow, de sorte que a reprodução exata dos pesos e da trajetória de treinamento não é garantida, embora partições, rótulos e protocolo o sejam. O treino percorre no máximo quinze épocas, com separação interna de 10% para validação, e é interrompido pelo monitoramento da perda de validação, com paciência de três épocas e restauração dos pesos da melhor época, registrada no artefato de cada execução. Os tempos da Subseção 4.1 são expressos em segundos, como mediana de três repetições de treino único sobre a base completa, e não como soma das cinco dobras. Matriz de proveniência versionada associa cada número, tabela e figura a script, entrada, denominador, taxonomia, partições e resumo criptográfico do corpus.

Os chamados analisados são registros administrativos da rotina de atendimento da instituição. A base de trabalho não é publicamente disponível, por restrição de privacidade institucional, e os campos textuais permanecem restritos ao ambiente do pesquisador. Os artefatos publicados são sanitizados na origem, pois nenhum identificador pessoal, identificador de chamado em texto claro, título ou descrição livre é gravado nos agregados versionados, e os mapas por registro usam o resumo SHA-256 do identificador, o que preserva a junção entre etapas sem expor o dado, em atenção ao princípio da necessidade previsto na Lei Geral de Proteção de Dados Pessoais (BRASIL, 2018).

O repositório não guarda documento de autorização institucional formal, de aprovação por comitê de ética ou de dispensa de apreciação ética, e nada é aqui afirmado a esse respeito; o acesso à base decorre da atuação do primeiro autor na gestão da manutenção predial da instituição, e a formalização documental é providência recomendada antes da submissão. As métricas derivadas e o código que produz cada figura, tabela e estatística são públicos em <https://github.com/adinailson88/classificacao-chamados>, que também descreve a estrutura dos dados e o material suplementar aqui citado.

4. RESULTADOS

Esta seção reporta o desempenho de sete modelos sob dois denominadores que não devem ser confundidos: a base congelada contém 14.060 chamados, todos com referência humana, número pertinente sempre que a frase tratar do corpus ou da cobertura da revisão, ao passo que as métricas de desempenho, calibração e inferência são apuradas sobre as 13.972 linhas em 41 categorias que compõem as partições canônicas (Subseção 3.4; Tabela A3).

Quatro achados organizam a seção. Os sete modelos foram avaliados de forma comparável sob o mesmo protocolo, mas apresentaram desempenhos distintos, sem vencedor absoluto ao considerar simultaneamente acurácia, macro-F1, custo e calibração: o LinearSVC lidera a acurácia, a Regressão Logística tem o macro-F1 pontual ligeiramente superior e o SGD permanece próximo dos dois, de modo que a escolha operacional depende de mais de um critério (Subseção 4.1). A reclassificação automática da base histórica produz ganho líquido negativo em todos os modelos, o que desautoriza a correção em massa e desloca o valor da divergência para a priorização da auditoria humana (Subseção 4.2). A calibração isotônica viabiliza automação seletiva de cerca de dois terços do volume com acurácia próxima de 0,95 (Subseção 4.3). E os erros que restam concentram-se em fronteiras taxonômicas específicas, e não se distribuem de modo difuso pela taxonomia (Subseção 4.4).

4.1 Desempenho, incerteza e custo

A comparação contra a categoria histórica, sobre as predições *out-of-fold* da rodada canônica ($n = 13.972$), mantém o LinearSVC à frente em acordo bruto, seguido por Extra Trees, SGD, Random Forest e Regressão Logística, com LSTM e Naive Bayes na última posição; o BERTimbau fica fora desse conjunto pelo motivo computacional detalhado na Subseção 4.5. A revisão humana estabeleceu categoria de referência para a totalidade dos 14.060 chamados da base congelada, e a avaliação contra essa referência incide sobre as 13.972 linhas das partições: o LinearSVC é o modelo de maior acurácia, com 0,8253 (IC95%: 0,8115–0,8378), seguido por SGD, Extra Trees, Regressão Logística e Random Forest, com LSTM e Naive Bayes bem atrás. A cobertura integral da revisão evita o viés decorrente de selecionar apenas uma subamostra para revisão, de modo que a acurácia relatada não constitui limite superior de amostra conferida; ela não elimina, porém, a ancoragem na categoria histórica, o avaliador único, a ausência de cegamento e a ausência de avaliação independente, ressalvas detalhadas na Subseção 5.3.

Não há vencedor absoluto entre os três primeiros colocados. O LinearSVC lidera a acurácia, mas as três melhores marcas de macro-F1 ficam a menos de três milésimos umas das outras, com Regressão Logística em 0,6689, LinearSVC em 0,6684 e SGD em 0,6669, e seus intervalos de confiança se sobrepõem integralmente: os três não devem ser ordenados por essa métrica isoladamente. A leitura pertinente é que o LinearSVC lidera a acurácia sem pagar por isso em desempenho na cauda, ao contrário dos *ensembles* de árvores, que perdem cerca de três centésimos de macro-F1 na mesma faixa de acurácia, e que o SGD permanece competitivo nas duas métricas a um custo de treino semelhante ao do LinearSVC. A escolha operacional é, portanto, multicritério, e deve pesar acurácia, macro-F1 e custo computacional conjuntamente, e não apenas a primeira.

Tabela 2 Concordância com a categoria histórica, acurácia e macro-F1 contra a referência humana revisada,

e custo de treino, por modelo ($n = 13.972$; 41 categorias). O intervalo é da acurácia, obtido por *bootstrap* de grupo textual com mil repetições sobre os 9.735 grupos congelados; o custo de treino é mediana de três execuções sobre a base completa.

Modelo	Concordância histórica	Acurácia	Macro-F1	Intervalo essencial (IC95% da acurácia)	Tempo de treino (s)
LinearSVC	0,7961	0,8253	0,6684	0,8115 – 0,8378	2,44
SGD	0,7781	0,8093	0,6669	0,7950 – 0,8227	2,28
Extra Trees	0,7844	0,8073	0,6362	0,7923 – 0,8211	26,69
Regressão Logística	0,7738	0,8050	0,6689	0,7907 – 0,8189	8,43
Random Forest	0,7747	0,7970	0,6152	0,7812 – 0,8111	22,62
LSTM	0,7017	0,7287	0,5240	0,7080 – 0,7480	83,44
Naive Bayes	0,6954	0,7088	0,2951	0,6860 – 0,7311	1,12

O custo de treino, medido no mesmo ambiente computacional para os sete modelos sobre a base completa, com mediana de três execuções, reforça a leitura multicritério: os modelos lineares treinam em poucos segundos, de 1,12 s no Naive Bayes a 8,43 s na Regressão Logística, os *ensembles* de árvores exigem entre vinte e trinta segundos e a rede neural LSTM consome 83,44 segundos, cerca de 34 vezes o tempo do LinearSVC, para 9,7 pontos percentuais a menos de acurácia. Os tempos absolutos e as razões entre modelos descrevem o ambiente avaliado, um processador de quatro núcleos sem acelerador gráfico; a estabilidade relativa desses tempos em outras infraestruturas não foi testada. A Figura 2 cruza essas medições de custo com a acurácia e mostra o LinearSVC na posição mais favorável, com a maior acurácia a um custo de treino próximo do menor observado. Contra o BERTimbau, o que se afirma é mais restrito: o custo medido de 6,44 horas por dobra inviabiliza a validação cruzada agrupada no ambiente do estudo (Subseção 4.5), sem que disso decorra juízo sobre seu desempenho.




Figura 2: Trade-off entre acurácia e tempo de treino, modelos clássicos.

A comparação entre modelos exige tratar a dependência entre registros de texto idêntico como propriedade do desenho, e não como detalhe de implementação: as 13.972 linhas avaliadas distribuem-se por 9.735 grupos

textuais, e 4.546 delas, ou 32,54%, pertencem a grupos com mais de um membro. O efeito de desenho, razão entre a variância da acurácia sob reamostragem de conglomerados e a variância binomial que a suposição de independência produziria (COCHRAN, 1977), fica entre 4,47 no LinearSVC e 8,83 no Naive Bayes, de modo que toda inferência desta subseção adota o grupo textual como unidade. O teste global rejeita a igualdade entre os sete modelos: a estatística Q de Cochran vale 2.661,04 sobre seis graus de liberdade, apurada contra distribuição empírica de duas mil permutações do rótulo de modelo dentro de cada grupo, com $p < 0,0005$. Só então os 21 pares foram comparados, por permutação pareada com troca de sinal da diferença de acertos por grupo e correção de Holm sobre a família: dezenove são significativos após a correção e dois não são, Extra Trees contra Regressão Logística e Extra Trees contra SGD, ambos com intervalo da diferença contendo o zero, o que é coerente com a sobreposição de macro-F1 relatada acima. Contra o segundo colocado, SGD, a vantagem do LinearSVC de 1,60 ponto percentual (IC95%: 0,0118–0,0204) corresponde a 533 grupos favoráveis contra 308, com 8.894 empatados: vantagem estatisticamente estabelecida e vantagem prática são coisas distintas, e nove de cada dez grupos não distinguem os dois modelos. A matriz completa dos 21 pares, com intervalos, grupos favoráveis e tamanho de efeito, consta do material suplementar.

O macro-F1 de 0,6684 do LinearSVC é média sobre as 41 categorias com suporte nas partições. Sob um cenário pessimista de sensibilidade, atribuindo F1 igual a zero às nove categorias ausentes das 50 da taxonomia, esse valor cai a 0,5481; não se trata de desempenho observado de um modelo treinado nas 50 categorias, pois nenhum classificador prevê categoria que não esteve em seu treino: a cobertura de linhas permanece alta, 99,37%, mas a de categorias cai a 82%. Agregado às 14 famílias do primeiro nível da taxonomia, o macro-F1 sobe a 0,6816, granularidade em que o LinearSVC assume também a liderança dessa métrica, antes com a Regressão Logística por três milésimos. A ordenação dos modelos é estável nas três convenções de denominador, à exceção dessa troca de posição no topo; os valores por modelo constam do material suplementar.

4.2 Auditoria do histórico e risco de reclassificação

A revisão humana manteve a categoria histórica em 13.462 dos 14.060 chamados da base congelada, ou 95,75% do corpus, e a substituiu em 598 registros, taxa de alteração do rótulo histórico de 4,25%, e não estimativa de prevalência de erro (Subseção 3.1). Essa estabilidade da referência explica o resultado da reclassificação automática: como o histórico já concorda com a revisão na quase totalidade dos casos, divergir dele significa, na maior parte das vezes, divergir também da referência.

O ganho líquido de reclassificação, contado apenas onde a predição diverge da categoria histórica e arbitrado pela referência revisada, é negativo nos sete modelos, de -1.846 no LinearSVC a -3.474 no Naive Bayes (Tabela 3). O melhor modelo produz 2.849 divergências, das quais apenas 475 representam correção contra 2.321 que degradariam o registro, razão que piora monotonicamente à medida que cai o desempenho do modelo. A reclassificação automática em massa não é, portanto, desaconselhada por cautela metodológica, mas por evidência de que degradaria a base em que fosse aplicada, e o ganho líquido, e não a acurácia agregada, é o critério adequado para essa decisão, a ser recalculado a cada atualização da base.

Tabela 3 Ganho líquido de reclassificação por modelo, contado apenas onde a predição diverge da categoria histórica e arbitrado pela referência humana revisada ($n = 13.972$).

Modelo	Divergências	Corrigidos	Prejudicados	Neutros	Ganho líquido
LinearSVC	2.849	475	2.321	53	-1.846
SGD	3.100	489	2.559	52	-2.070
Extra Trees	3.012	422	2.519	71	-2.097
Regressão Logística	3.161	492	2.621	48	-2.129
Random Forest	3.148	416	2.658	74	-2.242
LSTM	4.168	426	3.621	121	-3.195
Naive Bayes	4.256	309	3.783	164	-3.474

O ganho líquido simples pressupõe que corrigir um registro e estragar outro valham o mesmo, e que revisar não custe nada. A qualificação decisória substitui essa hipótese pela função de utilidade $U = b \times \text{corrigidos} - c \times$

prejudicados — $r \times$ revisados, normalizada pelo benefício da correção em duas razões adimensionais: $\rho = c/b$, o custo do prejuízo em unidades de benefício, e $\lambda = r/b$, o custo da revisão humana na mesma unidade. Sob aplicação direta, a utilidade só seria positiva se ρ ficasse abaixo da razão de equilíbrio corrigidos/prejudicados, que vale 0,2047 no LinearSVC e cai a 0,0817 no Naive Bayes: a reclassificação exigiria que estragar um registro custasse menos de um quinto do que vale corrigir outro, condição que a natureza do dano não sustenta, pois o registro corrompido propaga para a série temporal da categoria (Subseção 5.4). Em toda a faixa examinada, de $\rho = 0,25$ a $\rho = 4$, a utilidade é negativa nos sete modelos.

A mesma predição sustenta, entretanto, uma política de triagem: se a divergência apenas enfileira o chamado para revisão humana, sem reescrever o rótulo, não há prejudicados por construção, e o benefício é a fração da fila cujo histórico de fato estava errado, 18,53% no LinearSVC contra a taxa de alteração de 4,25% na base, enriquecimento de cerca de quatro vezes sobre a revisão aleatória. O limite de equilíbrio de λ coincide com essa precisão: a triagem paga enquanto revisar um chamado custar menos de 18,5% do que vale corrigir um registro. A consequência operacional é discutida na Subseção 5.2, e os valores por modelo constam do material suplementar.

4.3 Calibração e automação seletiva

A confiança bruta dos classificadores não é probabilidade e não sustenta decisão operacional sem tratamento: o erro de calibração esperado (ECE) do LinearSVC alcança 0,6925 sobre o escore bruto, porque a transformação da margem por função *softmax* produz valores que não correspondem a frequências de acerto. A calibração isotônica, ajustada em dobra interna, reduz esse valor a 0,0178 e o escore de Brier de 0,6052 para 0,1034, e melhora o ECE de cinco dos sete modelos. Naive Bayes e LSTM foram as exceções, com aumento do ECE após a calibração; o desenho não permite atribuir causalmente essa piora a um mecanismo específico.

A calibração viabiliza a automação seletiva, em que o classificador decide sozinho acima de um limiar de confiança e encaminha o restante à revisão humana. Ao alvo de 0,95 de acurácia, o Extra Trees automatiza 67,32% dos chamados com acurácia seletiva de 0,9502, o SGD automatiza 61,62% com 0,9531 e o LinearSVC automatiza 68,90% com 0,9464, faixa que ilustra a mesma escolha multicritério da Subseção 4.1 entre cobertura e acurácia seletiva. Parte das acurácias seletivas fica pouco abaixo do alvo, consequência esperada de escolher o limiar em dobra interna sem acesso ao conjunto de teste. Elevar o alvo a 0,99 reduz a cobertura à faixa de 31,94% a 47,04%, e o Naive Bayes só alcança o limiar em duas das cinco dobras, o que o desqualifica para esse regime.

Tabela 4 Calibração e automação seletiva dos quatro modelos mais competitivos em acurácia ($n = 13.972$). O ECE refere-se ao escore antes e depois da calibração isotônica; a cobertura e a acurácia seletiva correspondem ao alvo de 0,95. Random Forest é omitido desta versão reduzida; a tabela com os sete modelos, incluindo Naive Bayes e LSTM, cujo ECE aumenta após a calibração, consta do material suplementar (Tabela S16).

Modelo	ECE bruto	ECE calibrado	Cobertura	Acurácia seletiva
LinearSVC	0,6925	0,0178	0,6890	0,9464
SGD	0,3046	0,0109	0,6162	0,9531
Extra Trees	0,0859	0,0108	0,6732	0,9502
Regressão Logística	0,2351	0,0189	0,6237	0,9415

A Figura 3 apresenta a curva de confiabilidade do Extra Trees calibrado, tornando visível a aderência entre confiança declarada e acerto observado ao longo das dez faixas.




Figura 3: Curva de confiabilidade do Extra Trees após calibração isotônica, com confiança média e acurácia observada por faixa.

4.4 Erros por categoria e implicações taxonômicas

O diagnóstico de dispersão entre as previsões dos sete modelos mostra que diversidade de categorias previstas e aderência à distribuição histórica não caminham juntas neste corpus: o LSTM tem a maior entropia normalizada (0,8362) e o LinearSVC a menor divergência de Jensen-Shannon frente ao histórico (0,0055). No nível do chamado, os sete modelos são unânimes em 60,44% dos registros e discordam em três ou mais categorias em 16,35% deles, conjunto que caracteriza desacordo estrutural entre arquiteturas e prioriza auditoria complementar à baixa confiança de um único modelo. O Naive Bayes sintetiza o diagnóstico ao combinar a menor cobertura de categorias, apenas 22 contra 39 a 41 dos demais modelos, com a menor entropia normalizada e a maior divergência frente ao histórico, o que explica seu macro-F1 de 0,2951 apesar de acurácia próxima de 0,71.

O desempenho também não é uniforme entre as 41 categorias avaliadas. A Figura 4 contrasta, entre as 33 categorias com suporte mínimo de trinta registros, as dez de maior e as dez de menor F1 do LinearSVC: nas melhores, o F1 varia de 0,9139 a 0,9972 sobre 6.271 chamados, quase todas de Manutenção Preventiva, cujos chamados nascem de rotina programada e recebem descrição padronizada; nas piores, cai à faixa de 0,2162 a 0,6288 sobre 2.403 chamados, porte comparável em ordem de grandeza, concentrando rótulos de fronteira aberta como Telhados preventivos, Reforma, Erro de chamado e Alvenaria, Pisos e Estrutura, que competem por vocabulário com categorias vizinhas. O padrão é sistemático, na linha do que Zhang *et al.* (2025) descrevem para rótulos ruidosos em processamento de linguagem natural, e não aleatório. O desempenho por categoria, com suporte, tipo e classe de volume, consta da Tabela A2.

A Figura 5 recorta a matriz de confusão sobre as oito categorias mais envolvidas em troca recíproca. A célula dominante registra 1.066 chamados de Instalação e reparo de equipamentos preditos como Alvenaria, Pisos e Estrutura, com 937 no sentido inverso, a maior fronteira do corpus, com 2.003 trocas somadas; seguem-se Alvenaria contra Esquadrias, com 1.097 trocas, e Alvenaria contra Hidráulica, com 940. Alvenaria, Pisos e Estrutura comparece nos cinco maiores pares e se comporta como categoria absorvente, para a qual convergem chamados cuja descrição não delimita o sistema predial afetado; a leitura assimétrica de vários pares sugere absorção, e não simples permuta. A fronteira entre climatização corretiva e preventiva não figura entre




Figura 4: F1 do LinearSVC e suporte, para as dez categorias de maior e de menor desempenho entre as 33 com suporte mínimo de 30 chamados.

as maiores confusões, resultado coerente com a facilidade da tarefa de tipo reportada na Subseção 4.5. O ordenamento completo dos quinze pares de maior confusão recíproca consta do material suplementar.

A auditoria dos grupos de texto idêntico (Subseção 3.1) localiza ambiguidade no próprio dado, e não na predição: 17 grupos receberam mais de uma categoria de referência, afetando 85 linhas, ou 0,61% das linhas avaliadas, e em 14 deles, somando 74 linhas, as categorias em disputa pertencem a tipos distintos de manutenção, com o par mais frequente opondo Hidrossanitária > Hidráulica a Manutenção Preventiva > Reservatório, em 11 grupos e 65 linhas. Textos idênticos podem, portanto, corresponder a intervenções de naturezas diferentes, distinção irre recuperável por um classificador que utilize exclusivamente os quatro campos textuais empregados neste estudo; a contagem sinaliza ambiguidade interna, mas não fixa teto quantitativo de desempenho, pois esse teto exigiria calcular a distribuição dos rótulos dentro de cada grupo, o que não foi feito.

Soma-se a esse quadro a duplicação taxonômica: a categoria Ar condicionado split existe simultaneamente sob Manutenção Preventiva, com 1.798 chamados, e sob Climatização, com 1.640, e o mesmo desdobramento ocorre com Ar condicionado central, Gerador, Nobreak, Elevador, Telhados, calhas, rufos e Sistemas de combate a incêndio. O critério que separa esses pares é a natureza preventiva ou corretiva da intervenção, informação que o texto do chamado frequentemente não explicita, de modo que parte do erro medido decorre da exigência de inferir do texto uma distinção que nele não está registrada, e não de limitação do classificador. Depreende-se daí uma recomendação de governança anterior à escolha do modelo: revisar a taxonomia institucional, unificando os pares que nomeiam o mesmo objeto e explicitando o critério de natureza da manutenção no formulário de abertura do chamado, atua sobre a origem do erro, ao passo que a substituição do classificador atua apenas sobre seu efeito.




Figura 5: Recorte da matriz de confusão sobre as oito categorias mais envolvidas em troca recíproca, com contagens agregadas entre modelos.

4.5 Análises complementares

O BERTimbau não integra a comparação principal por motivo computacional medido no mesmo ambiente dos demais modelos: o ajuste fino custou 10,774 segundos por passo, e os 2.103 passos de cada dobra projetam 6,44 horas por dobra e 32,2 horas para as cinco, contra um teto de execução de seis horas, de modo que nem uma dobra completa cabe na infraestrutura do estudo. A limitação é de infraestrutura, e não do modelo; um experimento exploratório avaliou o transformador em lote de mil chamados, dos quais 983 com referência humana, e os valores constam do material suplementar, sem serem comparáveis às métricas desta seção, por não cobrirem o corpus de modo probabilístico e por empregarem subamostragem estratificada com parada antecipada.

O treino do LSTM parou por interrupção antecipada após 11 épocas, com menor perda de validação na época 8 e maior acurácia de validação na época 10 (0,6722), padrão de saturação precoce consistente com a hipótese de que *embeddings* treinados do zero são insuficientes para um corpus deste porte (Subseção 3.3; Figura 6). A justificativa do particionamento agrupado é anterior a essa medição e repousa na estrutura do corpus: a partição por linha permitiria ao mesmo texto ocupar treino e teste, e duas estimativas de sensibilidade indicam ganho espúrio entre 0,89 e 1,84 ponto percentual de acurácia sob esse desenho, valores que constam do material suplementar com o protocolo declarado.

Dois recortes complementares qualificam a leitura agregada sem alterá-la. A curva ABC sobre o suporte das 41 categorias concentra 81,83% do volume em 12 categorias de classe A, com macro-F1 do LinearSVC de 0,8207 nessa classe contra 0,5018 na classe C, o que localiza na cauda a distância entre acurácia e macro-F1




Figura 6: Curva de aprendizado do LSTM por época, perda e acurácia em treino e validação.

agregados. A projeção da referência e das predições para o nível de tipo de manutenção, em três categorias e não na dicotomia usual entre preventivo e corretivo, eleva o desempenho a outro patamar: o LinearSVC alcança 0,9443 de acurácia contra 0,8253 na tarefa de 41 categorias, com F1 de 0,9742 na preventiva e 0,9547 na corretiva, e toda a perda concentra-se no terceiro tipo, cujo F1 não ultrapassa 0,5330 em nenhum modelo. Cabe registrar a inversão de ordenação nessa granularidade: o Extra Trees lidera a acurácia, com 0,9497, e o LinearSVC lidera o macro-F1, com 0,8180, precisamente por ir melhor na classe difícil, o que faz a escolha do classificador depender tanto do nível de agregação da decisão quanto da métrica que ela privilegia. Depreende-se do conjunto dessas medições uma hierarquia de confiabilidade: a contagem por tipo de manutenção é a leitura mais segura, a leitura por categoria só se sustenta nas classes de maior volume de cada tipo, e nas classes B e C o desempenho medido não autoriza uso automático. O detalhamento por classe e por tipo consta do material suplementar.

A camada explícita de regras de periodicidade, que atribui categoria preventiva quando o texto reúne um termo de periodicidade e um termo de equipamento, dispara em 4.487 dos 13.972 registros e ainda assim melhora o macro-F1 de apenas três dos sete modelos, com ganho concentrado no Naive Bayes (+0,0586) e perdas marginais em Extra Trees, Random Forest e LinearSVC. Como a regra depende só do texto, ela dispara no mesmo conjunto para os sete modelos, e o que varia é a predição que substitui: no LinearSVC, os 4.487 disparos produzem apenas 31 divergências, contra 219 no Naive Bayes, no qual a regra acerta 201 vezes contra 9 do modelo. A leitura é que regras de domínio são redundantes diante de um classificador estatístico competente, que já captura implicitamente os sinais de periodicidade presentes no texto: o ganho do fluxo híbrido está no eixo humano-IA (Subseção 4.3), e não no eixo regra-modelo.

5. DISCUSSÃO

5.1 Concordância histórica, acerto contra a referência e custo do BERTimbau

A comparação entre concordância histórica e desempenho contra a referência humana revisada (Subseção 4.1) revela que as duas grandezas não são intercambiáveis. A acurácia do LinearSVC (82,53%) supera sua concordância com o histórico (79,61%) em 2,92 pontos percentuais. A diferença mede o efeito das 598 correções sobre a avaliação: ao substituir a categoria histórica pela categoria revisada, parte das divergências que seriam contabilizadas como erro do modelo passa a ser reconhecida como erro do registro administrativo.

Com a revisão estendida ao corpus integral, a diferença deixa de depender de qualquer recorte amostral e passa a ser propriedade medida da base. Em 598 dos 14.060 chamados, ou 4,25%, o avaliador rejeitou a categoria registrada e definiu outra. A grandeza é uma taxa de alteração do rótulo histórico sob auditoria administrativa, e não uma estimativa da prevalência de erro do registro: ela mede quantas categorias um especialista único decidiu trocar tendo o rótulo à vista, o que é compatível com a hipótese de rótulos ruidosos da literatura (KEJRIWAL *et al.*, 2024; ZHANG *et al.*, 2025) sem quantificá-la. O valor é específico deste corpus e desta taxonomia, e sua transposição a outras instituições exige nova revisão. A taxa é baixa por duas causas que a Subseção 3.1 discrimina sem que o desenho permita separá-las, o rótulo produzido sob

verificação de equipe técnica e a ancoragem do procedimento de auditoria; seja qual for a proporção entre elas, o que os modelos acompanham não é um rótulo ingênuo, e é essa estabilidade da linha de base que torna negativo o ganho de reclassificação discutido na Subseção 5.2.

O BERTimbau não integra essa comparação por motivo computacional medido (Subseção 4.5), e nada se afirma aqui sobre sua qualidade relativa, pois rankings produzidos sob protocolos distintos não sustentam comparação direta.

5.2 Reclassificação, ambiguidade taxonômica e calibração

O resultado da reclassificação (Subseção 4.2) contraria a expectativa que motivou o estudo e tem consequência operacional direta. O ganho líquido de corrigir chamados já classificados é negativo em todos os sete modelos, e a magnitude do prejuízo acompanha, na ordem inversa, o desempenho de cada um. Não se trata de nuance entre modelos, e sim de veredito sobre a tarefa: nenhum classificador aqui avaliado é candidato a reclassificar a base histórica em massa. A explicação é aritmética antes de ser metodológica, pois, estreito o espaço de alteração da referência (Subseção 5.1), qualquer divergência sistemática entre modelo e histórico tende a cair fora dele, e o melhor modelo diverge 2.849 vezes para acertar 475, cerca de um acerto para cada cinco prejuízos. O resultado depende de a referência cobrir todo o corpus, pois arbitrar parte das divergências pelo próprio histórico premiaria o modelo por concordar com o rótulo que se pretendia auditar. O veredito tampouco é artefato de contabilidade: sob a função de utilidade da Subseção 4.2, a reclassificação direta só compensaria se estragar um registro custasse menos de um quinto do que vale corrigir outro, hipótese que a assimetria do dano contradiz, e é a inversa, a de que o prejuízo custa tanto ou mais que a correção, que descreve o caso da manutenção predial.

Disso não decorre que a classificação automática seja inútil neste domínio, e sim que seu uso defensável é seletivo. Sobre chamados novos não há rótulo prévio correto a ser degradado, o que retira o risco medido na Subseção 4.2, mas não transporta para o futuro a acurácia aqui reportada: ela foi estimada entre grupos textuais de um mesmo corte de extração, e não ao longo do tempo (Subseção 5.3), de modo que o uso prospectivo é recomendação condicional. Sobre a base histórica, dois encaminhamentos se sustentam. O primeiro é a automação condicionada à confiança da Subseção 4.3, que preserva o registro nas faixas em que o modelo não tem vantagem demonstrável sobre ele. O segundo inverte o papel da divergência: em vez de autorizar a reescrita, ela prioriza a fila de auditoria humana, e nessa função a mesma predição que perde por larga margem sustenta enriquecimento de cerca de quatro vezes sobre a revisão aleatória. A predição que não substitui o revisor pode dirigi-lo, e essa é a leitura operacional que o resultado negativo autoriza.

A camada de entropia de Shannon e divergência de Jensen-Shannon (Subseção 4.4) não substitui as métricas supervisionadas ou a revisão humana, mas amplia o repertório de governança ao separar três fenômenos que a acurácia isolada tende a confundir: o erro de modelo, a ambiguidade genuína da taxonomia institucional e a heterogeneidade natural da distribuição de chamados.

A calibração transforma essa leitura em procedimento operável (Subseção 4.3). Escores brutos não são probabilidade, e o ajuste isotônico em dobra interna (PLATT, 1999; GUO *et al.*, 2017) é o que permite associar confiança alta a acerto alto sem depender de faixas cuja escala não tem interpretação probabilística, condição do regime seletivo discutido acima.

Uma ressalva qualifica a leitura: o calibrador é ajustado sobre escores de um modelo treinado em três dobras e aplicado a escores de um modelo treinado em quatro, troca deliberada entre ausência de vazamento e casamento exato de distribuição.

5.3 Limitações

Os dados provêm de uma única instituição federal de ensino superior, com textos em português brasileiro e taxonomia institucional própria. Estender o desempenho relatado a outras instituições, taxonomias ou idiomas exige validação externa.

A revisão humana cobre o corpus integral, o que afasta o viés de seleção que limitaria a leitura caso apenas parte dos chamados tivesse sido revista, mas seu desenho impõe três restrições que precisam ser lidas em conjunto. A primeira é o avaliador único: não houve segunda avaliação independente nem cega, nenhuma

medida de concordância entre avaliadores foi apurada e a reprodutibilidade da referência por outro especialista permanece não testada. A literatura registra variabilidade relevante entre anotadores em tarefas dessa natureza, de modo que a referência aqui utilizada não deve ser tratada como isenta de erro. A segunda é a ancoragem: o revisor decidiu com a categoria histórica à vista, condição constitutiva da auditoria de rótulo e incompatível com anotação independente, de sorte que a taxa de confirmação de 95,75% expressa conjuntamente a estabilidade do registro e o efeito do procedimento, sem que este desenho permita atribuir peso a cada parcela. A terceira é consequência das duas anteriores: a taxa de alteração de 4,25% não autoriza estimar a prevalência de categorias históricas incorretas na base, e nenhuma afirmação desse tipo é feita neste artigo. Uma segunda avaliação sobre amostra estratificada, com registro de divergências e adjudicação por terceiro revisor, é a validação futura pertinente, sobretudo nos pares taxonômicos ambíguos.

A taxonomia institucional apresenta pares de categorias que nomeiam o mesmo objeto sob famílias distintas, e a divergência interna medida na Subseção 4.4 confirma o problema no próprio dado. Nesses pares, a atribuição depende de um critério de natureza da intervenção que o texto do chamado nem sempre permite inferir, o que impõe teto ao desempenho alcançável por um classificador que utilize exclusivamente os quatro campos textuais empregados neste estudo.

As métricas valem para as 41 categorias com suporte nas cinco dobras, e não para a taxonomia inteira. As nove categorias excluídas são justamente as mais raras, e o efeito é quantificado na Subseção 4.1: sobre as 50 categorias, o *macro-F1* do melhor modelo cai de 0,6684 a 0,5481. A cobertura de linhas permanece alta, 99,37%, mas a de categorias é de 82%, e nenhuma afirmação deste artigo se estende às nove ausentes. A Tabela A3 torna a diferença auditável, e nenhuma das alternativas examinadas, cujo efeito consta da mesma subseção e do material suplementar, elimina a restrição.

Uma restrição adicional decorre do congelamento: as partições são fixadas por um mapa versionado de grupos textuais, o que garante reprodutibilidade mas dissocia o experimento do crescimento da base operacional, e dois registros tiveram o texto editado depois, o que basta para explicar diferenças de última casa decimal em execuções futuras.

A limitação mais consequente para o uso prospectivo é a ausência de validação temporal. O corpus congelado não dispõe de data de abertura por chamado, restrição verificada sobre o contrato de colunas da base e sobre os artefatos da rodada canônica, de modo que treino, calibração e teste não puderam ser separados em períodos sucessivos. Segue-se que a validação cruzada agrupada estima generalização entre grupos textuais de um mesmo corte de extração, e não desempenho futuro sob deriva temporal: nenhum número deste artigo prevê o comportamento do classificador sobre chamados posteriores, e toda recomendação de uso prospectivo é condicional.

Os mecanismos que essa lacuna deixa por medir operam na direção do desempenho reportado. A deriva de vocabulário desloca a matriz de atributos à medida que entram equipamentos, edificações e jargões ausentes do treino; cada fusão, criação ou renomeação de categoria, providência recomendada na Subseção 4.4, altera o próprio espaço de saída, incluído aí o caso extremo da categoria nova, para a qual não há exemplo e não pode haver predição; mudanças no formulário de abertura e na composição da equipe de triagem alteram a distribuição do texto de entrada e do rótulo administrativo que lhe corresponde. Implantação defensável pressupõe, por conseguinte, monitoramento da acurácia sobre amostra auditada, recalibração periódica dos escores, dado que o limiar da Subseção 4.3 é solidário à distribuição de confiança observada, e retreinamento a cada mudança de taxonomia. A avaliação em períodos sucessivos depende de extração que preserve a data de abertura e constitui validação futura prioritária, anterior a qualquer decisão de automação em regime.

Quanto às arquiteturas, o BERTimbau não foi avaliado sob este protocolo, por limitação de infraestrutura, e a execução *out-of-fold* integral com aceleração gráfica permanece como trabalho futuro; a LSTM, por sua vez, treina *embeddings* do zero, sem vetores pré-treinados em português, condição que limita a comparação entre arquiteturas neurais.

5.4 Contribuição para a governança preditiva da manutenção

Ao converter texto livre em categoria e confiança auditáveis, o protocolo produz a camada de dados estruturados sobre a qual a gestão pública de manutenção predial pode operar de forma preditiva, e não apenas reativa. Previsão de demanda por categoria, priorização de intervenções segundo critérios de sustentabilidade

e leitura territorial do parque edificado dependem, todas, de uma base classificada de modo confiável, e a medição aqui reportada mostra que essa confiabilidade exige revisão humana.

A exigência tem razão específica quando a camada classificada alimenta modelos de série temporal por categoria. Um chamado atribuído à categoria incorreta subtrai uma ocorrência da série de uma categoria e a acrescenta à de outra, deslocando duas séries em sentidos opostos, e o efeito propaga-se à estimativa de demanda e de custo e ao ordenamento de prioridades que dela deriva, de sorte que o erro de classificação se converte em erro de alocação de recurso. É essa a razão pela qual o acerto contra a referência revisada opera como requisito de engenharia da camada preditiva, e não apenas como métrica de comparação entre modelos, e também a que dá assimetria aos custos da Subseção 4.2: corromper um registro correto custa mais do que vale recuperar um incorreto.

O recorte da Subseção 4.5 indica em que ordem essa camada pode ser incorporada a indicadores institucionais. A razão entre manutenção preventiva e corretiva, que expressa a maturidade da gestão do parque edificado, é a leitura de menor erro medido e dispensa revisão caso a caso, desde que o erro seja reafetado periodicamente sobre amostra auditada, uma vez que o valor medido vale para o corte avaliado; já os indicadores desagregados por categoria exigem restrição às classes de maior volume dentro de cada tipo, sob pena de atribuir a frações residuais do corpus uma precisão que a medição não sustenta. A hierarquia converte o diagnóstico de desempenho em critério de publicação de indicador, e não apenas em ressalva metodológica.

6. CONSIDERAÇÕES FINAIS

A contribuição central deste artigo é metodológica. O protocolo separa a concordância com o rótulo histórico do acerto contra a referência humana revisada e mede as duas grandezas sobre a mesma execução, com partições agrupadas por texto que impedem a repetição de chamados entre treino e teste. Essa separação evita tratar o histórico como referência inquestionável e, ao mesmo tempo, impede concluir que toda divergência da classificação automática representa correção do registro original.

Na avaliação sobre 13.972 chamados em 41 categorias, o LinearSVC alcança 82,53% de acurácia (IC95%: 81,15%–83,78%) e supera os demais modelos com significância estatística, ao custo de treino de 2,44 s sobre a base inteira. A recomendação operacional é usá-lo com calibração isotônica e automação condicionada à confiança, regime em que cerca de dois terços do volume podem ser decididos automaticamente com acurácia próxima de 0,95 e o terço restante encaminhado à revisão humana. A recomendação é condicional quanto a chamados futuros, pois o corpus congelado, desprovido de data de abertura, não permitiu separar treino, calibração e teste no tempo: estender o regime seletivo à operação corrente pressupõe monitoramento do desempenho e recalibração periódica.

O achado que mais altera a orientação prática é negativo. A reclassificação automática da base histórica produz prejuízo líquido em todos os sete modelos, porque a revisão manteve a categoria registrada em 95,75% dos casos e o espaço de alteração é estreito demais para compensar os erros introduzidos. O veredito não depende da hipótese de custos iguais: sob função de utilidade explícita, a reescrita só compensaria se estragar um registro valesse menos de um quinto do que vale corrigir outro. A mesma divergência que não autoriza a reescrita presta-se, porém, à priorização da auditoria humana, com enriquecimento de cerca de quatro vezes sobre a revisão aleatória. Também é negativo, e igualmente útil, o resultado da camada explícita de regras de periodicidade: ela é redundante diante de um classificador estatístico competente, que já captura esses sinais a partir do texto.

A finalização metodológica exige reconhecer o que os dados não respondem. A referência provém de auditoria administrativa conduzida por avaliador único, com a categoria histórica à vista e sem segunda avaliação independente, de modo que o estudo não estima a prevalência de erro do rótulo histórico nem a reprodutibilidade da referência por outro especialista, e o desempenho medido não cobre as nove categorias mais raras da taxonomia. Tampouco há validação temporal, pela ausência de data de abertura no corpus congelado, de sorte que a estabilidade do desempenho sob deriva de vocabulário e sob alteração da taxonomia permanece por medir. A próxima etapa deve incorporar segunda avaliação, com adjudicação de divergências nos pares ambíguos, submeter a própria taxonomia a revisão e reconstituir o corte com a data de abertura preservada, o que viabiliza avaliação em períodos sucessivos. Em paralelo, a validação externa em outras instituições e a execução *out-of-fold* integral do BERTimbau, viável em infraestrutura com acelerador gráfico, poderão testar a estabilidade dos resultados sob taxonomias e volumes distintos. A camada classificada poderá então

alimentar modelos de previsão de demanda e de priorização multicritério de intervenções sobre uma base cuja incerteza e origem das decisões permanecem auditáveis.

REFERÊNCIAS

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. ABNT NBR 5674: Manutenção de edificações: Requisitos para o sistema de gestão de manutenção. Rio de Janeiro: ABNT, 2012.

ANDERSON, M. J.; TER BRAAK, C. J. F. Permutation tests for multi-factorial analysis of variance. *Journal of Statistical Computation and Simulation*, v. 73, n. 2, p. 85–113, 2003.

BENDER, E. M.; GEBRU, T.; McMILLAN-MAJOR, A.; SHMITCHELL, S. On the dangers of stochastic parrots: can language models be too big? In: *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency (FAccT '21)*. New York: ACM, 2021. p. 610–623.

BOUABDALLAOUI, Y.; LAFHAJ, Z.; YIM, P.; DUCOULOMBIER, L.; BENNADJI, B. Natural Language Processing Model for Managing Maintenance Requests in Buildings. *Buildings*, v. 10, n. 9, art. 160, 2020.

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Brasília: Presidência da República, 2018.

BROWN, T. B.; MANN, B.; RYDER, N.; SUBBIAH, M.; KAPLAN, J.; DHARIWAL, P.; NEELAKANTAN, A. et al. Language models are few-shot learners. In: *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*. Red Hook: Curran Associates, 2020. p. 1877–1901.

CAMERON, A. C.; GELBACH, J. B.; MILLER, D. L. Bootstrap-based improvements for inference with clustered errors. *The Review of Economics and Statistics*, v. 90, n. 3, p. 414–427, 2008.

CAPRA, F. A teia da vida: uma nova compreensão científica dos sistemas vivos. São Paulo: Cultrix, 1996.

CHOW, C. K. On optimum recognition error and reject tradeoff. *IEEE Transactions on Information Theory*, v. 16, n. 1, p. 41–46, 1970.

COCHRAN, W. G. The comparison of percentages in matched samples. *Biometrika*, v. 37, n. 3-4, p. 256–266, 1950.

COCHRAN, W. G. *Sampling techniques*. 3. ed. New York: John Wiley & Sons, 1977.

COHEN, J. A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, v. 20, n. 1, p. 37–46, 1960.

DEVLIN, J.; CHANG, M.-W.; LEE, K.; TOUTANOVA, K. BERT: Pre-training of deep bidirectional transformers for language understanding. In: *CONFERENCE OF THE NORTH AMERICAN CHAPTER OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS*, 2019, Minneapolis. *Proceedings [...]*. Minneapolis: ACL, 2019. p. 4171–4186.

DICICCIO, T. J.; EFRON, B. Bootstrap confidence intervals. *Statistical Science*, v. 11, n. 3, p. 189–228, 1996.

EFRON, B. Bootstrap methods: another look at the jackknife. *The Annals of Statistics*, v. 7, n. 1, p. 1–26, 1979.

EFRON, B.; TIBSHIRANI, R. J. *An introduction to the bootstrap*. New York: Chapman & Hall/CRC, 1993.

EL-YANIV, R.; WIENER, Y. On the foundations of noise-free selective classification. *Journal of Machine Learning Research*, v. 11, p. 1605–1641, 2010.

FIELD, C. A.; WELSH, A. H. Bootstrapping clustered data. *Journal of the Royal Statistical Society: Series B*, v. 69, n. 3, p. 369–390, 2007.

GALKE, L.; SCHERP, A. Bag-of-words vs. graph vs. sequence in text classification: questioning the necessity of text-graphs and the surprising strength of a wide MLP. In: *ANNUAL MEETING OF THE ASSOCIATION*

- FOR COMPUTATIONAL LINGUISTICS, 60., 2022, Dublin. Proceedings [...]. Dublin: ACL, 2022. p. 4038–4051.
- GOOD, P. Permutation, parametric and bootstrap tests of hypotheses. 3. ed. New York: Springer, 2005.
- GRAVES, A.; SCHMIDHUBER, J. Framewise phoneme classification with bidirectional LSTM and other neural network architectures. *Neural Networks*, v. 18, n. 5-6, p. 602–610, 2005.
- GRIMM, N. B.; FAETH, S. H.; GOLUBIEWSKI, N. E.; REDMAN, C. L.; WU, J.; BAI, X.; BRIGGS, J. M. Global change and the ecology of cities. *Science*, v. 319, n. 5864, p. 756–760, 2008.
- GUO, C.; PLEISS, G.; SUN, Y.; WEINBERGER, K. Q. On calibration of modern neural networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 34., 2017, Sydney. Proceedings [...]. Sydney: PMLR, 2017. p. 1321–1330.
- HOLM, S. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, v. 6, n. 2, p. 65–70, 1979.
- JOACHIMS, T. Text categorization with support vector machines: learning with many relevant features. In: EUROPEAN CONFERENCE ON MACHINE LEARNING, 10., 1998, Chemnitz. Proceedings [...]. Berlin: Springer, 1998. p. 137–142.
- KEJRIWAL, M.; SANTOS, H.; SHEN, K.; MULVEHILL, A. M.; MCGUINNESS, D. L. A noise audit of human-labeled benchmarks for machine commonsense reasoning. *Scientific Reports*, v. 14, art. 8609, 2024.
- KOHAVI, R. A study of cross-validation and bootstrap for accuracy estimation and model selection. In: INTERNATIONAL JOINT CONFERENCE ON ARTIFICIAL INTELLIGENCE, 14., 1995, Montreal. Proceedings [...]. San Francisco: Morgan Kaufmann, 1995. p. 1137–1143.
- LANDIS, J. R.; KOCH, G. G. The measurement of observer agreement for categorical data. *Biometrics*, v. 33, n. 1, p. 159–174, 1977.
- LIN, J. Divergence measures based on the Shannon entropy. *IEEE Transactions on Information Theory*, v. 37, n. 1, p. 145–151, 1991. DOI: 10.1109/18.61115.
- LI, Y.; LIU, Y.; ZHANG, J.; CAO, L.; WANG, Q. Automated analysis and assignment of maintenance work orders using natural language processing. *Automation in Construction*, v. 165, art. 105501, 2024.
- LIU, Z.; BENGE, C.; JIANG, S. Ticket-BERT: labeling incident management tickets with language models. arXiv:2307.00108, 2023.
- MARCUZZO, M.; ZANGARI, A.; GIUDICE, L.; GASPARETTO, A.; SCHIAVINATO, M.; ALBARELLI, A. A multi-level approach for hierarchical Ticket Classification. In: PROCEEDINGS OF THE 8TH WORKSHOP ON NOISY USER-GENERATED TEXT (W-NUT 2022), 2022. Anais [...]. Association for Computational Linguistics, 2022. p. 201–214.
- MARTINS, R. F. B.; ESPEJO, M. M. S. B. Análise de custos de manutenção predial em uma universidade federal brasileira com uso do modelo de SES. *ABCustos*, São Leopoldo, v. 19, n. 1, p. 79–98, 2024.
- MCNEMAR, Q. Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, v. 12, n. 2, p. 153–157, 1947.
- MOHAMMED, A. S.; AMOAH, C. Integration of technology in decision-making in university facilities management: a literature review. *Facilities*, v. 43, n. 13/14, p. 1018–1052, 2025.
- MORAIS, L. S. R. de; PAULA, H. M. de; REIS, R. P. A. Promoção da eficiência da manutenção predial em edificações públicas: abordagem baseada em registros de ordens de serviço. *Paranoá*, Brasília, v. 16, n. 34, p. 1–18, 2023. DOI: 10.18830/issn.1679-0944.n34.2023.08.
- ODUM, H. T. Environment, power, and society. New York: Wiley-Interscience, 1971.
- PAMPANA, A. K. et al. Data-driven analysis for facility management in higher education institution. *Buildings*, v. 12, art. 2094, 2022.

- PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.
- PLATT, J. C. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. In: SMOLA, A. J. et al. (Ed.). *Advances in Large Margin Classifiers*. Cambridge: MIT Press, 1999. p. 61–74.
- SALTON, G.; BUCKLEY, C. Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, v. 24, n. 5, p. 513–523, 1988.
- SCHWARTZ, R.; DODGE, J.; SMITH, N. A.; ETZIONI, O. Green AI. *Communications of the ACM*, v. 63, n. 12, p. 54–63, 2020.
- SHANNON, C. E. A mathematical theory of communication. *Bell System Technical Journal*, v. 27, n. 3, p. 379–423, jul. 1948; v. 27, n. 4, p. 623–656, out. 1948.
- SOKOLOVA, M.; LAPALME, G. A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, v. 45, n. 4, p. 427–437, 2009.
- SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. BERTimbau: pretrained BERT models for Brazilian Portuguese. In: *BRAZILIAN CONFERENCE ON INTELLIGENT SYSTEMS*, 9., 2020. *Proceedings [...]*. Cham: Springer, 2020. p. 403–417. DOI: 10.1007/978-3-030-61377-8_28.
- SUNDARAM, S.; ZEID, A. Technical Language Processing for Prognostics and Health Management: applying text similarity and topic modeling to maintenance work orders. *Journal of Intelligent Manufacturing*, v. 36, p. 1637–1657, 2025.
- TREVISIO, M. et al. Efficient methods for Natural Language Processing: a survey. *Transactions of the Association for Computational Linguistics*, v. 11, p. 826–860, 2023.
- WONGPAKARAN, N.; WONGPAKARAN, T.; WEDDING, D.; GWET, K. L. A comparison of Cohen’s Kappa and Gwet’s AC1 when calculating inter-rater reliability coefficients: a study conducted with personality disorder samples. *BMC Medical Research Methodology*, v. 13, art. 61, 2013.
- ZHANG, H.; ZHANG, Y.; LI, J.; LIU, J.; JI, L. A survey on learning with noisy labels in Natural Language Processing: how to train models with label noise. *Engineering Applications of Artificial Intelligence*, v. 146, art. 110157, 2025.

APÊNDICE A — CATEGORIAS DO CORPUS E DAS PARTIÇÕES

A Tabela A1 apresenta as 50 categorias históricas presentes nos 14.060 chamados da base congelada, ordenadas por frequência decrescente e distribuídas em dois blocos paralelos para reduzir a extensão do apêndice. As Tabelas A2 e A3 decompõem o denominador das métricas: a primeira lista as 41 categorias que sustentaram suporte nas cinco dobras e compõem as 13.972 linhas avaliadas, e a segunda, as 9 que ficaram de fora.

Tabela A1 Distribuição dos chamados por categoria histórica.

Categoria histórica	Quantidade	Categoria histórica	Quantidade
Manutenção Preventiva > Ar condicionado split	1.798	Manutenção Preventiva > Sistemas de combate a incêndio (extintores, hidrantes)	66
Climatização > Ar condicionado split	1.640	Estrutura Predial > Pintura	58
Estrutura Predial > Alvenaria / Pisos / Estrutura	1.302	Instalação de Acessórios e Mobiliário > Placas de identificação	54
Hidrossanitária > Hidráulica	1.282	Manutenção Preventiva > Telhados, calhas, rufos, etc.	44
Manutenção Preventiva > Gerador	1.215	TI / Dados / Rede > Coleta de dados	40
Estrutura Predial > Esquadrias, porta, portão e janelas	977	Elétrica > Gerador	38
Elétrica > Instalações elétricas	945	Hidrossanitária > Bomba	38
Elétrica > Iluminação	758	Climatização > Ar condicionado central	37
Manutenção Preventiva > Quadros Elétricos	578	Manutenção Preventiva > Esgoto	33
TI / Dados / Rede > Ponto de rede / fibra ótica / Wi-fi	404	Manutenção Preventiva > Hidráulica	33
Instalação de Acessórios e Mobiliário > Instalação/reparo de equipamentos (Suportes de TV, acessórios de banheiro e quadro branco)	290	Outros > Outros	33
Manutenção Preventiva > Reservatório	279	Segurança contra Incêndio > Sistemas de combate a incêndio (extintores, hidrantes)	29
Manutenção Preventiva > Vistoria em Instalações	247	Projetos e Reformas > Projeto	25
Outros > Erro de chamado	245	Equipamentos de Transporte > Elevador	22
Estrutura Predial > Infiltração	215	Elétrica > Subestação	18
Estrutura Predial > Telhados, calhas, rufos, etc.	207	Hidrossanitária > ETA / ETE	16
Manutenção Preventiva > Ar condicionado central	165	Suprimentos / Apoio Técnico > Limpeza de equipamentos, ambiente e mobiliário	14
Estrutura Predial > Forro	146	Manutenção Preventiva > Poços artesianos	13
Manutenção Preventiva > Iluminação	132	Manutenção Preventiva > Nobreak	10
Elétrica > Nobreak	128	Elétrica > Sistema Fotovoltaico (FV)	7
Área Externa e Ambiental > Manutenção área externa / meio ambiente / Poda de árvore / Roçagem	109	Área Externa e Ambiental > Drenagem	4
Posto de trabalho > Contratação de Posto de trabalho	102	Estrutura Predial > Instalações Especiais (gás, ar comprimido, etc.)	3
Manutenção Preventiva > Elevador	86	Manutenção Preventiva > Aplicação cupinizada	3
Suprimentos / Apoio Técnico > Materiais	85	Manutenção Preventiva > Bomba	3
Projetos e Reformas > Reforma	83	Suprimentos / Apoio Técnico > Transporte	1
Total geral	14.060		

Fonte: elaboração própria a partir do corpus analisado.

Tabela A2 Categorias da referência revisada avaliadas na rodada, por tipo de manutenção e classe da curva ABC interna ao tipo (n = 13.972; 41 categorias). O percentual é relativo ao volume do próprio tipo e o F1 corresponde ao LinearSVC. P, preventiva; C, corretiva; NM, não manutenção. Enquadram-se em não manutenção as famílias que não descrevem serviço de manutenção predial, a saber, Outros, Suprimentos / Apoio Técnico, Posto de trabalho e Projetos e Reformas. A família TI / Dados / Rede permanece em manutenção corretiva por consistir predominantemente em reparo de infraestrutura predial.

Categoria de referência	Tipo	n	% do tipo	Classe	F1
Preventiva	P	4.902	100,00		
Manutenção Preventiva > Ar condicionado split	P	1.987	40,53	A	0,9972
Manutenção Preventiva > Gerador	P	1.208	24,64	A	0,9954
Manutenção Preventiva > Quadros Elétricos	P	578	11,79	A	0,9843
Manutenção Preventiva > Reservatório	P	318	6,49	A	0,9139
Manutenção Preventiva > Vistoria em Instalações	P	244	4,98	B	0,9419
Manutenção Preventiva > Ar condicionado central	P	168	3,43	B	0,9970
Manutenção Preventiva > Iluminação	P	132	2,69	B	0,9535
Manutenção Preventiva > Elevador	P	86	1,75	B	0,9655
Manutenção Preventiva > Sistemas de combate a incêndio (extintores, hidrantes)	P	66	1,35	C	0,8905
Manutenção Preventiva > Telhados, calhas, rufos, etc.	P	44	0,90	C	0,2162
Manutenção Preventiva > Esgoto	P	31	0,63	C	0,4286
Manutenção Preventiva > Hidráulica	P	27	0,55	C	0,0000
Manutenção Preventiva > Poços artesianos	P	13	0,27	C	1,0000
Corretiva	C	8.485	100,00		
Climatização > Ar condicionado split	C	1.448	17,07	A	0,9550
Hidrossanitária > Hidráulica	C	1.263	14,89	A	0,8651
Estrutura Predial > Alvenaria / Pisos / Estrutura	C	1.138	13,41	A	0,4610
Estrutura Predial > Esquadrias, porta, portão e janelas	C	1.003	11,82	A	0,8712
Elétrica > Instalações elétricas	C	909	10,71	A	0,7248
Elétrica > Iluminação	C	764	9,00	A	0,8901
TI / Dados / Rede > Ponto de rede / fibra ótica / Wi-fi	C	412	4,86	A	0,7173
Instalação de Acessórios e Mobiliário > Instalação/reparo de equipamentos (Suportes de TV, acessórios de banheiro e quadro branco)	C	405	4,77	B	0,4730
Estrutura Predial > Telhados, calhas, rufos, etc.	C	203	2,39	B	0,4962
Estrutura Predial > Infiltração	C	202	2,38	B	0,6493
Estrutura Predial > Forro	C	168	1,98	B	0,7746
Elétrica > Nobreak	C	150	1,77	B	0,7855
Área Externa e Ambiental > Manutenção área externa / meio ambiente / Poda de árvore / Roçagem	C	103	1,21	C	0,6288
Instalação de Acessórios e Mobiliário > Placas de identificação	C	69	0,81	C	0,6494
Estrutura Predial > Pintura	C	60	0,71	C	0,5890
Elétrica > Gerador	C	43	0,51	C	0,7723
Hidrossanitária > Bomba	C	43	0,51	C	0,7238
Climatização > Ar condicionado central	C	33	0,39	C	0,7324
Segurança contra Incêndio > Sistemas de combate a incêndio (extintores, hidrantes)	C	29	0,34	C	0,4815
Equipamentos de Transporte > Elevador	C	21	0,25	C	0,7692
Elétrica > Subestação	C	19	0,22	C	0,6061
Não manutenção	NM	585	100,00		
Outros > Erro de chamado	NM	258	44,10	A	0,3978
Posto de trabalho > Contratação de Posto de trabalho	NM	102	17,44	A	0,9561
Suprimentos / Apoio Técnico > Materiais	NM	96	16,41	A	0,4790
Projetos e Reformas > Reforma	NM	65	11,11	A	0,2407
Outros > Outros	NM	28	4,79	B	0,3404
Projetos e Reformas > Projeto	NM	23	3,93	B	0,0000
Suprimentos / Apoio Técnico > Limpeza de equipamentos, ambiente e mobiliário	NM	13	2,22	C	0,0909
Total avaliado		13.972			

As nove categorias restantes da taxonomia não sustentam suporte nas cinco dobras e ficam fora das partições, conforme o critério da Subseção 3.4. Somam 88 linhas, ou 0,63% da base congelada, e estão discriminadas na Tabela A3 para que a diferença entre os dois denominadores permaneça auditável.

Tabela A3 Categorias fora das partições canônicas.

Categoria de referência	Linhas	Motivo da exclusão
TI / Dados / Rede > Coleta de dados	40	ausente de ao menos uma dobra após a estratificação
Hidrossanitária > ETA / ETE	15	ausente de ao menos uma dobra após a estratificação
Manutenção Preventiva > Nobreak	9	ausente de ao menos uma dobra após a estratificação
Elétrica > Sistema Fotovoltaico (FV)	7	ausente de ao menos uma dobra após a estratificação
Estrutura Predial > Instalações Especiais (gás, ar comprimido, etc.)	5	ausente de ao menos uma dobra após a estratificação
Área Externa e Ambiental > Drenagem	4	suporte insuficiente para as cinco dobras
Manutenção Preventiva > Aplicação cupinicida	3	suporte insuficiente para as cinco dobras
Manutenção Preventiva > Bomba	3	suporte insuficiente para as cinco dobras
Suprimentos / Apoio Técnico > Transporte	2	suporte insuficiente para as cinco dobras
Total	88	

Fonte: elaboração própria a partir do corpus analisado.