

Sumário

CLASSIFICAÇÃO AUTOMÁTICA MULTIMODELO DE CHAMADOS DE MANUTENÇÃO PREDIAL UNIVERSITÁRIA EM PORTUGUÊS BRASILEIRO: PROTOCOLO DE GOVERNANÇA PREDITIVA COM VALIDAÇÃO HUMANA SOB RÓTULOS HISTÓRICOS RUIDOSOS

Multi-model automatic classification of university building maintenance work orders in Brazilian Portuguese: a predictive governance protocol with human validation under noisy historical labels

Adinailson Guimarães de Oliveira

Universidade Federal do Sul da Bahia (UFSB), Programa de Pós-Graduação em Biossistemas

E-mail: adinailson.oliveira@cja.ufsb.edu.br

RESUMO

A classificação automática de chamados de manutenção predial constitui recurso estratégico para a qualificação da triagem operacional e para a ampliação da governança baseada em evidências em instituições públicas. Contudo, em bases históricas de sistemas informatizados de gestão de chamados, a categoria originalmente registrada não deve ser tratada como verdade absoluta, uma vez que pode refletir decisões operacionais ruidosas, taxonomias sobrepostas, registros incompletos e interpretações heterogêneas entre equipes de atendimento. O presente artigo propõe um protocolo multimodelo para classificação de chamados reais de manutenção predial universitária em português brasileiro, extraídos do sistema GLPI da Universidade Federal do Sul da Bahia. O experimento utiliza 13.965 chamados não vazios, organizados em 55 categorias históricas, e compara classificadores clássicos baseados em TF-IDF (Naive Bayes, Regressão Logística, LinearSVC calibrado, SGD, Random Forest e Extra Trees), rede neural LSTM bidirecional e um transformador pré-treinado em português (BERTimbau, com ajuste fino), já com resultado comparativo disponível nesta consolidação. O diferencial metodológico reside na distinção entre concordância com o histórico administrativo e acerto validado por revisão humana, tratando a categoria histórica como referência preliminar imperfeita — distinção que se mostrou decisiva: o acerto validado por conferência humana (9.096 decisões travadas) revelou-se mais conservador do que a concordância com o histórico sugeria, à medida que a amostra de conferência cresceu e deixou de se concentrar apenas em casos de fácil confirmação. Resultados indicam superioridade do LinearSVC calibrado tanto na concordância com o histórico (acurácia de 80,34%, IC95%: 79,69%–80,97%) quanto no acerto validado (79,89%, IC95%: 78,99%–80,73%), enquanto o LSTM apresentou concordância de 68,47% e acerto validado de 74,71%. A normalidade da concordância por turno foi rejeitada para todos os modelos, justificando testes não paramétricos (Friedman, Cochran Q, McNemar, bootstrap). O custo computacional é incorporado como dimensão de avaliação, evidenciando que modelos lineares podem oferecer melhor relação entre desempenho e viabilidade operacional em cenários de texto curto, ruidoso e desbalanceado.

Palavras-chave: manutenção predial; classificação de chamados; processamento de linguagem natural; rótulos ruidosos; validação humana; governança preditiva.

ABSTRACT

Automatic classification of building maintenance work orders is a strategic resource for qualifying operational triage and enhancing evidence-based governance in public institutions. However, in historical databases from computerized service management systems, the originally assigned category should not be treated as an unquestionable ground truth, since it may reflect noisy operational decisions, overlapping taxonomies, incomplete records, and heterogeneous interpretations across maintenance teams. This paper proposes a multi-model protocol for classifying real university building maintenance requests in Brazilian Portuguese, extracted from the GLPI system at the Federal University of Southern Bahia. The experiment uses 13,965 non-empty records organized into 55 historical categories and compares TF-IDF-based classical classifiers (Naive Bayes, Logistic Regression, calibrated LinearSVC, SGD, Random Forest, and Extra Trees), a bidirectional LSTM neural network, and a Portuguese pre-trained transformer (BERTimbau, fine-tuned), already with comparative results in this consolidation. The methodological contribution lies in distinguishing agreement with administrative history from human-validated accuracy — a distinction that proved decisive: human-validated

accuracy (9,096 locked decisions) turned out more conservative than agreement with history suggested, as the validation sample grew and stopped concentrating on easily confirmed cases. Results indicate calibrated LinearSVC superiority both in agreement with history (80.34% accuracy, 95%CI: 79.69%–80.97%) and in human-validated accuracy (79.89%, 95%CI: 78.99%–80.73%), while LSTM achieved 68.47% agreement and 74.71% validated accuracy. Normality was rejected for all models, supporting non-parametric tests (Friedman, Cochran Q, McNemar, bootstrap). Computational cost is incorporated as an evaluation dimension.

Keywords: building maintenance; work-order classification; natural language processing; noisy labels; human validation; predictive governance.

1. INTRODUÇÃO

A manutenção predial em instituições federais de ensino superior (IFES) envolve decisões recorrentes de triagem, categorização, priorização e alocação de equipes, agravadas pela dispersão territorial, pela diversidade de sistemas prediais e pela restrição orçamentária que historicamente limita o custeio dessas atividades a patamares inferiores a 2% do orçamento institucional (MARTINS; ESPEJO, 2024; PAMPANA *et al.*, 2022). Sistemas informatizados de registro de chamados, como plataformas GLPI e ambientes de *helpdesk*, tornaram-se, nesse contexto, não apenas instrumentos de solicitação, mas bases de conhecimento institucional sobre falhas, recorrências e padrões de uso, cujo potencial analítico permanece amplamente subutilizado (MORAIS; PAULA; REIS, 2023; MOHAMMED; AMOAH, 2025).

A exploração analítica dessas bases é limitada por ao menos três fatores estruturais. O primeiro reside na natureza textual curta, heterogênea e frequentemente incompleta dos registros, uma vez que chamados de manutenção predial são redigidos em linguagem técnica fragmentária, com abreviações locais e jargões de equipe que dificultam a aplicação direta de modelos genéricos de processamento de linguagem natural (PLN) (SUNDARAM; ZEID, 2025). O segundo fator é o desbalanceamento entre categorias, dado que demandas recorrentes de climatização, elétrica e hidrossanitária tendem a concentrar grande parte da base, ao passo que categorias raras dispõem de poucos exemplos para treinamento supervisionado (LI *et al.*, 2024). O terceiro fator, possivelmente o mais crítico do ponto de vista metodológico, é a qualidade dos rótulos históricos, pois a categoria registrada no momento do chamado pode resultar de interpretação rápida, classificação por conveniência operacional ou taxonomia ainda não estabilizada, de modo que o histórico administrativo constitui evidência importante, porém não verdade absoluta (ZHANG *et al.*, 2025; KEJRIWAL *et al.*, 2024).

A literatura recente sobre mineração textual de ordens de manutenção confirma a relevância de técnicas de PLN para transformar registros textuais em insumos de gestão. Li *et al.* (2024) demonstraram, em base hospitalar com 15.623 ordens de serviço, que a atribuição automática de equipes por PLN alcança acurácia de 0,83, reduzindo substancialmente a dependência de triagem manual. Sundaram e Zeid (2025) analisaram registros de *Maintenance Work Orders* sob a abordagem de *Technical Language Processing*, argumentando que textos técnicos de manutenção funcionam como *black holes* informacionais quando armazenam dados relevantes sem serem efetivamente utilizados na tomada de decisão. Bouabdallaoui *et al.* (2020), por sua vez, aplicaram modelos de PLN à classificação de requisições de manutenção em edificação hospitalar, reportando acurácia média de 78% com múltiplos métodos de representação textual. Contudo, a maior parte dessas aplicações concentra-se em bases em inglês ou chinês e em domínios industriais ou hospitalares, configurando lacuna relevante para corpora em português brasileiro no contexto da manutenção predial pública universitária.

O presente artigo parte de uma tese metodológica específica: em bases reais de chamados de manutenção, a avaliação de modelos não deve ser reduzida à pergunta sobre qual classificador mais concorda com a categoria histórica. Conforme Zhang *et al.* (2025), rótulos ruidosos em PLN afetam o desempenho dos classificadores e podem ampliar o consumo de recursos computacionais, exigindo métodos robustos de tratamento de ruído. Kejriwal *et al.* (2024) reforçam que *benchmarks* rotulados por humanos podem conter variabilidade relevante, questionando a prática de assumir uma única verdade absoluta quando há julgamento subjetivo envolvido. Dessa forma, a pergunta central deve ser mais ampla: em que medida os modelos reproduzem o histórico, em que medida auxiliam na identificação de inconsistências desse histórico e de que maneira a revisão humana pode converter divergências entre inteligência artificial e registro administrativo em melhoria progressiva da taxonomia institucional.

Com base em chamados reais da Universidade Federal do Sul da Bahia (UFSB), propõe-se uma comparação multimodelo de classificadores de texto aplicados a chamados de manutenção predial em português brasi-

leiro. A base experimental contém 13.965 chamados não vazios (na consolidação vigente de 23/07/2026), distribuídos em 55 categorias históricas, e os campos textuais considerados agregam informações do título e da descrição do chamado, além de informações associadas à ordem de serviço. O estudo compara modelos clássicos baseados em TF-IDF (Naive Bayes, Regressão Logística, LinearSVC, SGD, Random Forest e Extra Trees) com abordagem neural LSTM bidirecional e um transformador pré-treinado em português (BERTimbau, com ajuste fino), já com resultado comparativo disponível nesta consolidação. O objeto de avaliação, portanto, não é apenas o classificador isolado, mas o protocolo de governança preditiva que articula aprendizado de máquina, auditoria estatística, custo computacional e validação humana, em consonância com a perspectiva de manutenção baseada em evidências preconizada pela NBR 5674 (ABNT, 2012).

Os objetivos específicos do estudo são: (i) apresentar um protocolo de comparação multimodelo para classificação de chamados reais de manutenção predial universitária em português brasileiro; (ii) distinguir concordância com rótulo histórico de acerto validado, evitando equiparar categoria histórica a *ground truth* incontestável; (iii) avaliar desempenho por métricas globais, métricas balanceadas, intervalos de confiança e testes estatísticos pareados adequados a dados não normais; (iv) incorporar custo computacional como dimensão de decisão operacional; e (v) transformar divergências entre IA e histórico em evidências para revisão taxonômica e retroalimentação da base de treino.

2. REFERENCIAL CONCEITUAL

2.1 Processamento de linguagem natural em ordens de manutenção

Ordens de manutenção constituem registros operacionais com valor informacional elevado, porém usualmente subutilizado. Elas documentam sintomas, locais, equipamentos, procedimentos, materiais e soluções executadas, acumulando-se ao longo de anos em sistemas informatizados cuja forma textual e semiestruturada dificulta o uso direto em planejamento e alocação de recursos (PAMPANA *et al.*, 2022; MORAIS; PAULA; REIS, 2023). Li *et al.* (2024) propuseram estrutura baseada em PLN para análise e atribuição automática de ordens de manutenção hospitalar, utilizando 15.623 registros de hospital municipal em Xangai e reportando acurácia de 0,83 na tarefa de atribuição de trabalhadores, resultado que evidencia a possibilidade de automatizar processos antes dependentes de triagem manual em contextos prediais. Esse trabalho constitui referência-âncora para a presente pesquisa por tratar diretamente da automação de ordens de manutenção predial, embora em idioma, tipologia institucional e estrutura taxonômica distintos.

Sundaram e Zeid (2025), ao analisar registros textuais de *Maintenance Work Orders* sob a abordagem de *Technical Language Processing*, defenderam que textos técnicos de manutenção funcionam como repositórios informacionais subutilizados quando não integrados a processos decisórios. Essa perspectiva é especialmente pertinente à manutenção predial universitária, na qual chamados curtos, abreviações locais, nomes de ambientes e descrições incompletas dificultam o uso de modelos genéricos sem adaptação ao domínio. Bouabdallaoui *et al.* (2020) reportaram acurácia média de 78% na classificação de requisições de manutenção predial hospitalar utilizando múltiplos métodos de PLN, resultado que reforça a viabilidade da abordagem, mas também evidencia a necessidade de adaptação lexical e semântica ao corpus específico.

2.2 Classificação de tickets e evolução dos modelos

A classificação automática de *tickets* em ambientes de suporte técnico e ITSM evoluiu de representações vetoriais baseadas em frequência lexical para *embeddings* e modelos de linguagem pré-treinados. Liu, Bengue e Jiang (2023) propuseram o Ticket-BERT para rotulagem de *tickets* de incidentes, enfatizando desafios como atualização contínua de rótulos e necessidade de aprendizado ativo. Entretanto, a transferência direta de achados do ITSM para a manutenção predial deve ser cautelosa, pois a semântica do domínio envolve sistemas físicos, ambientes e equipamentos prediais que não coincidem com categorias de incidentes de *software* ou infraestrutura digital (SUNDARAM; ZEID, 2025).

Modelos lineares com TF-IDF continuam competitivos em tarefas de texto curto, especialmente quando o corpus é de porte médio, o vocabulário possui alta especificidade técnica e as classes são desbalanceadas (GALKE; SCHERP, 2022). Nesses cenários, modelos profundos podem não compensar seu custo computacional caso não disponham de volume suficiente, balanceamento adequado ou *embeddings* fortemente adaptados ao domínio. Galke e Scherp (2022), em revisão comparativa abrangente de métodos para classificação textual, demonstraram que classificadores baseados em *bag-of-words* com TF-IDF e SVM permanecem altamente

competitivos frente a redes neurais em múltiplos *benchmarks*, sobretudo quando o corpus é reduzido ou o vocabulário é altamente especializado. Esse achado é particularmente relevante para o contexto institucional de manutenção predial, onde a base operacional raramente atinge escala compatível com as exigências de modelos de linguagem de grande porte.

2.3 Rótulos ruidosos e verdade operacional

O problema de rótulos ruidosos é central em aprendizado supervisionado aplicado a bases administrativas. Em classificação textual, ruído de rótulo pode decorrer de ambiguidade semântica, polissemia, insuficiência de contexto, sobreposição taxonômica, julgamento subjetivo ou erro humano de registro (ZHANG *et al.*, 2025). Conforme levantamento de Zhang *et al.* (2025), rótulos ruidosos em PLN afetam o desempenho dos modelos e podem ampliar o consumo de recursos, exigindo métodos robustos de tratamento de ruído. Kejriwal *et al.* (2024) reforçam que *benchmarks* rotulados por humanos podem conter variabilidade relevante, questionando a prática de assumir uma única verdade absoluta quando há julgamento subjetivo envolvido. No contexto do presente artigo, a categoria histórica do chamado é tratada como referência administrativa, não como verdade final, e a verdade operacional deve ser construída por validação humana com registro explícito da decisão tomada.

2.4 Custo computacional e eficiência em PLN

A avaliação de modelos de PLN tem sido tradicionalmente orientada por métricas de desempenho, mas a literatura recente enfatiza que custo computacional, tempo de treino, consumo energético e reprodutibilidade também devem compor a decisão de adoção (TREVISIO *et al.*, 2023; SCHWARTZ *et al.*, 2020). Treviso *et al.* (2023) argumentam que a ampliação de escala em PLN tende a aumentar o consumo de dados, tempo, armazenamento e energia, motivando métodos eficientes especialmente em contextos de recursos limitados. Schwartz *et al.* (2020) cunharam o conceito de *Green AI*, propondo que a eficiência computacional seja reportada e valorizada na avaliação de modelos, não apenas a acurácia. Em uma instituição pública, essa dimensão é operacionalmente decisiva: um modelo que treina em segundos pode ser reexecutado frequentemente, auditado com facilidade e mantido sem infraestrutura dedicada, ao passo que um modelo que demanda dezenas de minutos exige *checkpoint*, controle de versão de pesos e justificativa robusta de ganho marginal (TREVISIO *et al.*, 2023).

3. MÉTODO

3.1 Delineamento geral

O estudo adota delineamento experimental aplicado, com base observacional retrospectiva de chamados de manutenção predial registrados no sistema GLPI institucional da UFSB, universidade multicampi com unidades em Itabuna, Ilhéus, Porto Seguro e Teixeira de Freitas (MORAIS; PAULA; REIS, 2023). A unidade de análise é o chamado individual de manutenção, representado por campos textuais concatenados e por uma categoria histórica registrada no sistema. O fluxo metodológico compõe-se de oito etapas sequenciais: (i) extração e consolidação da base; (ii) higienização textual; (iii) construção da matriz de atributos; (iv) treinamento e inferência multimodelo; (v) geração de predições *out-of-fold*; (vi) comparação preliminar com categoria histórica; (vii) análise estatística não paramétrica; e (viii) validação humana das divergências e amostras críticas. A Figura 1 apresenta esse fluxo como *pipeline* de governança preditiva.

Figura 1 Pipeline de governança preditiva: fluxo metodológico completo, da extração da base à retroalimentação por validação humana.

Fonte: elaborado pelos autores (2026), gerado a partir da descrição desta subseção (04_artigo/figuras/fig1_pipeline_gove

3.2 Corpus e variáveis

O corpus experimental é composto por 13.825 chamados de manutenção predial não vazios, organizados em 54 categorias históricas, extraídos do ambiente institucional da UFSB. Os campos textuais previstos no protocolo incluem título do chamado, descrição GLPI, título da ordem de serviço e descrição da ordem de serviço, concatenados em uma única representação textual para fins de classificação. A categoria histórica é utilizada como referência preliminar de comparação, mas a avaliação conclusiva depende da base validada por revisão humana. O idioma dos registros é português brasileiro, com presença significativa de jargões técnicos, nomes

Figura 1 - Pipeline de governanca preditiva: fluxo metodologico completo




Figura 1: Figura 1 — Pipeline de governança preditiva: fluxo metodológico completo, da extração da base à retroalimentação por validação humana.

de ambientes, abreviações locais e descrições incompletas, características que impõem desafios específicos de pré-processamento e representação textual (SUNDARAM; ZEID, 2025).

A base é dinâmica: novos chamados continuam sendo sincronizados e classificados em turnos. Na consolidação vigente (23/07/2026), o número de chamados elegíveis já cresceu para 13.965, em 55 categorias históricas (uma categoria adicional frente à contagem original de 54, em função de uma migração de nomenclatura registrada na auditoria técnica que acompanha este capítulo). Os resultados da Seção 4 utilizam esse recorte mais recente; eventuais diferenças frente a valores publicados em versões preliminares deste texto refletem o crescimento da base e a ampliação da conferência humana, não uma mudança metodológica dos scripts de análise (confirmado por conferência do histórico de commits dos scripts que produzem `avaliacao_final.json` e `estatistica.json`).

3.3 Pré-processamento textual

O pré-processamento textual foi documentado de modo reproduzível, uma vez que pequenas decisões sobre normalização podem alterar a matriz de atributos e, conseqüentemente, o desempenho dos modelos (SALTON; BUCKLEY, 1988). Para os classificadores clássicos, a representação principal é TF-IDF com *n-gramas* de uma e duas palavras e limite superior de 5.000 atributos para controle de dimensionalidade. Para o modelo neural LSTM, são utilizadas tokenizações específicas com vocabulário de 8.000 termos e comprimento máximo de sequência adequado à distribuição textual da base. Cabe ressaltar que a etapa de pré-processamento não elimina indiscriminadamente termos técnicos, códigos de ambientes, nomes de equipamentos ou expressões recorrentes da equipe, pois esses elementos possuem alto valor discriminativo em manutenção predial, onde palavras como *bomba*, *split*, *disjuntor*, *vazamento*, *infiltração* e *ar-condicionado* podem funcionar como âncoras semânticas relevantes para categorias específicas.

3.4 Modelos avaliados

O desenho experimental considera oito modelos, todos já materializados nesta consolidação. Os classificadores clássicos adotam representação TF-IDF e algoritmos de aprendizado supervisionado amplamente consolidados na literatura de classificação textual (JOACHIMS, 1998; PEDREGOSA *et al.*, 2011): Naive Bayes Multinomial, como *baseline* probabilístico; Regressão Logística, com calibração natural e boa interpretabilidade; LinearSVC calibrado, combinando margem linear e calibração de confiança via Platt (PLATT, 1999); SGD, como alternativa eficiente para matrizes esparsas de grande dimensão; Random Forest e Extra Trees, como representantes de métodos não lineares baseados em *ensemble* de árvores. A LSTM Bidirecional foi construída com camada de *embedding* de 8.000 termos e 128 dimensões, camada recorrente bidirecional de 64 unidades (GRAVES; SCHMIDHUBER, 2005), *dropout* de 0,5 e camada densa com ativação *softmax*, treinada com parada antecipada, avaliada tanto na comparação *out-of-fold* (Subseção 4.1) quanto na Etapa 1 oficial de produção, com *fallback* de Random Forest.

O oitavo modelo, um transformador pré-treinado em português com ajuste fino (BERTimbau,

neuralmind/bert-base-portuguese-cased), foi incorporado como extensão contextual, com *fallback* automático para LSTM/RF quando as dependências de treinamento (torch/transformers) não estão disponíveis no ambiente de execução. Pelo custo computacional em CPU, o ajuste fino roda em fluxo de trabalho próprio, de baixa frequência, fora do ciclo padrão de 15 minutos, e é condicionado a um limiar mínimo de avanço da base validada (100 novos casos conferidos) antes de cada novo treinamento. Nesta consolidação (23/07/2026), esse limiar já foi atingido e o modelo tem resultado comparativo disponível e reportado na Seção 4 (68,06% de concordância com o histórico, 73,79% de acerto validado) — diferentemente de versões anteriores deste protocolo, em que o treinamento permanecia adiado e o modelo era tratado como trabalho em andamento.

3.5 Desenho de avaliação

A avaliação foi realizada por predições fora da amostra em protocolo *out-of-fold* com *k-fold* estratificado, *seed* fixa e mesma partição para todos os modelos, desenho que reduz viés de comparação e permite testes pareados (SOKOLOVA; LAPALME, 2009). As métricas principais são acurácia, *macro-F1*, *F1* ponderado, *balanced accuracy* e intervalo de confiança por *bootstrap* com 95% de confiança. A *macro-F1* e a *balanced accuracy* são essenciais face ao desbalanceamento entre categorias, dado que a acurácia isolada pode superestimar desempenho em classes majoritárias e mascarar falhas em categorias raras (SOKOLOVA; LAPALME, 2009). A correlação entre confiança e acerto é avaliada por Spearman; diferenças globais entre classificadores são avaliadas por Cochran Q e Friedman; comparações pareadas são avaliadas por McNemar (1947); e incerteza de acurácia é estimada por *bootstrap*. Quando múltiplas comparações são realizadas, aplica-se correção de Nemenyi no contexto de *ranks*.

3.6 Validação humana

A validação humana constitui a etapa que diferencia o presente estudo de uma simples comparação de classificadores contra histórico. A revisão registra, para cada caso auditado, a categoria histórica, a categoria sugerida por cada modelo, a confiança associada, a decisão humana e a categoria travada. A priorização recai sobre chamados em que há divergência entre modelos, alta confiança da IA contra histórico, baixa confiança generalizada, classes raras e pares de categorias com alta confusão recíproca. A decisão humana pode produzir quatro resultados: manter o histórico; aceitar a sugestão do modelo; definir terceira categoria; ou marcar o caso como ambíguo ou taxonômico. Essa estrutura permite mensurar se a IA errou, se o histórico estava inconsistente ou se a própria taxonomia institucional necessita de revisão, em consonância com a perspectiva de que a verdade operacional deve ser construída progressivamente (ZHANG *et al.*, 2025).

3.7 Memória de decisão: veto e trava por chamado

À medida que a conferência humana avança, o protocolo incorpora uma memória de decisão por chamado, que evita o reprocessamento de casos já resolvidos e impede a repetição de erros já identificados. Quando a conferência confirma que uma categoria está correta, essa decisão é travada e reaproveitada diretamente nas rodadas seguintes de reclassificação, sem novo treinamento ou nova predição para aquele chamado. Quando a conferência identifica que uma categoria está incorreta, essa categoria passa a ser vetada especificamente para aquele chamado: os modelos do repositório de classificadores passam a escolher a melhor categoria alternativa fora do conjunto vetado, com a confiança renormalizada sobre as categorias remanescentes. Essa regra é aplicada de forma consistente na seleção de candidatos à reclassificação e no cálculo do ganho líquido, que passa a comparar o resultado da reclassificação contra a verdade validada quando ela está travada, e contra o histórico apenas quando ainda não há decisão humana. O objetivo metodológico da memória de decisão é impedir que o sistema corrija um erro apenas para reincidir nele em ciclos futuros, convertendo cada conferência manual em conhecimento persistente sobre o experimento, não em um evento isolado.

3.8 Camada de entropia de Shannon e divergência de Jensen-Shannon

Como dimensão complementar às métricas supervisionadas, o protocolo incorporou uma camada de análise informacional baseada em entropia de Shannon e divergência de Jensen-Shannon, calculada exclusivamente sobre os arquivos públicos e sanitizados do painel (sem identificador, título ou texto livre do chamado). Essa camada não substitui acurácia, calibração ou validação humana; responde a uma pergunta distinta, sobre onde modelos, categorias e chamados individuais concentram maior incerteza estrutural. No nível dos modelos, a entropia de Shannon sobre a distribuição de categorias previstas indica se um classificador

dispersa suas predições por muitas classes ou as concentra excessivamente em poucas; a divergência de Jensen-Shannon mede a distância entre essa distribuição prevista e a distribuição histórica da base, funcionando como indicador de deslocamento distributivo. No nível das categorias, a entropia evidencia classes históricas cujas predições se espalham entre múltiplas categorias, sinalizando candidatas prioritárias a revisão taxonômica. No nível do chamado individual, a entropia de votos entre os modelos identifica registros em que há desacordo estrutural entre arquiteturas distintas, formando uma fila de auditoria orientada por ambiguidade, e não apenas por baixa confiança isolada de um único modelo.

3.9 Disponibilidade de dados e scripts

Os artefatos que sustentam os resultados relatados neste capítulo são gerados por scripts versionados no repositório público github.com/adinailson88/classificacao-chamados (branch `main`), independente do repositório operacional Malha IA. Os números citados nas Subseções 4.1 a 4.6 correspondem aos arquivos JSON publicados em `docs/dados/` (por exemplo, `estatistica.json`, `avaliacao_final.json`, `calibracao.json`, `reclass_resumo.json`, `shannon_resumo.json`, `jensen_shannon_modelos.json`), regenerados automaticamente por *workflows* do GitHub Actions a cada rodada do experimento e publicados também via GitHub Pages. Nenhum identificador pessoal, título ou texto livre de chamado é versionado nesses arquivos; a camada Shannon/Jensen-Shannon (Subseção 3.8) opera exclusivamente sobre agregados sanitizados. **Pen-dência explícita desta subseção:** consolidar, em rodada futura, a correspondência exata entre cada subseção de resultado e o script que a gera (por exemplo, `src/avaliacao_final.py`, `src/calibracao.py`, `src/analise_shannon.py`), hoje mapeada em `PLANO_ARTIGO_CAPITULO.md` mas ainda não transcrita para o corpo do artigo.

4. RESULTADOS

Esta seção apresenta dois conjuntos de resultados, deliberadamente segregados: a concordância com a categoria histórica (Subseção 4.1), que trata o registro do GLPI como referência preliminar e não como verdade absoluta; e o desempenho validado por conferência humana (Subseções 4.2 e 4.3), calculado exclusivamente sobre os chamados com decisão travada pela memória M/N/P. Na consolidação vigente (23/07/2026), a base elegível contém 13.965 chamados e a conferência humana já cobre 9.534 chamados (68,3% da base), dos quais 9.096 com decisão travada e sem conflito (65,1% da base) e 438 casos restritos (categoria eliminada, ainda sem decisão travada). Esse crescimento — de 4.737 conferências (33,9% da base) em 16/07/2026 para 9.534 (68,3%) nesta consolidação — quase dobra a cobertura em relação à versão anterior deste protocolo e, como discutido na Subseção 4.2 e na Seção 5, revela um padrão de desempenho sensivelmente mais conservador do que a amostra menor sugeria.

4.1 Concordância com o histórico (base completa)

A comparação contra a categoria histórica, sobre a base completa ($n = 13.965$, com intervalo de confiança por bootstrap a 95%), mantém o LinearSVC calibrado na liderança, com acurácia de 0,8034 (IC95%: 0,7969–0,8097), seguido por Extra Trees (0,7898), Random Forest (0,7798), SGD (0,7784), Regressão Logística (0,7691), Naive Bayes (0,6990), LSTM (0,6847) e o transformador pré-treinado BERTimbau, já com resultado disponível nesta consolidação (0,6806). O teste de Cochran Q confirma diferença global entre os oito modelos ($Q = 3.494,146$; $gl = 7$; $p < 0,001$). O Kappa de Cohen entre cada modelo e o histórico acompanha ordenamento muito próximo (LinearSVC 0,7884; Extra Trees 0,7721; SGD 0,7623; Random Forest 0,7611; Regressão Logística 0,7527; Naive Bayes 0,6697; LSTM 0,6633; BERTimbau 0,6590), e o Kappa de Fleiss entre os oito modelos (0,7538) indica concordância substancial entre arquiteturas distintas treinadas sobre a mesma base, ainda que um pouco menor do que a observada entre os seis classificadores clássicos isolados na consolidação de 16/07/2026 (0,8068) — resultado esperado ao acrescentar duas arquiteturas (LSTM, BERTimbau) cujo padrão de erro diverge mais dos modelos lineares e de *ensemble* de árvores. A nona fonte de classificação, a Etapa 1 oficial (executor LSTM/RF de produção, coluna G da planilha), mantém concordância de 77,65% e confiança média de 71,67% nesta consolidação, posicionando-se entre SGD e Regressão Logística nesta métrica — não é diretamente comparável ao LSTM *out-of-fold* da Tabela 1, pois combina LSTM com *fallback* de Random Forest conforme a regra de produção (Subseção 3.4), não um único modelo isolado.

Tabela 1 Concordância com a categoria histórica, base completa ($n = 13.965$)

Modelo	Acurácia	IC95% bootstrap	Kappa vs. histórico
LinearSVC calibrado	0,8034	0,7969 – 0,8097	0,7884
Extra Trees	0,7898	0,7828 – 0,7964	0,7721
Random Forest	0,7798	0,7729 – 0,7864	0,7611
SGD	0,7784	0,7719 – 0,7851	0,7623
Regressão Logística	0,7691	0,7624 – 0,7757	0,7527
Naive Bayes	0,6990	0,6914 – 0,7064	0,6697
LSTM (out-of-fold)	0,6847	0,6769 – 0,6923	0,6633
Transformer (BERTimbau)	0,6806	0,6730 – 0,6881	0,6590

Fonte: `estatistica.json`, gerado em 23/07/2026 20:45 (n = 13.965).

4.2 Ranking validado por conferência humana

A avaliação contra a verdade validada pela memória de decisão M/N/P (n = 9.096 decisões travadas) confirma a mesma liderança da Subseção 4.1, mas em patamar bem mais conservador do que o reportado na consolidação de 16/07/2026: o LinearSVC calibrado permanece o melhor modelo isolado, com acerto validado de 0,7989 (IC95%: 0,7899–0,8073), seguido por SGD (0,7909), Regressão Logística (0,7859), Extra Trees (0,7762), Random Forest (0,7689), LSTM (0,7471), o transformador BERTimbau (0,7379) e Naive Bayes (0,7114). A diferença entre o primeiro e o segundo colocado é pequena em termos absolutos (0,8 ponto percentual), mas estatisticamente significativa (McNemar, $p \sim 0,000002$), sustentando a recomendação de uso do LinearSVC calibrado como IA de referência. Nenhum método de combinação testado supera o LinearSVC isolado: maioria ponderada com pesos aprendidos *out-of-fold* (0,7944), maioria simples (0,7930) e confiança calibrada máxima (0,7930) ficam todos **abaixo** do LinearSVC (0,7989), com a diferença estatisticamente significativa a favor do LinearSVC isolado nos três casos (McNemar $p = 0,0008$; $p < 0,0001$; $p < 0,0001$, respectivamente). Combinar modelos, portanto, não se justifica operacionalmente diante do custo adicional de manter um comitê.

Tabela 2 Acerto validado contra a verdade decidida M/N/P (n = 9.096)

Modelo	Acerto validado	IC95%
LinearSVC calibrado	0,7989	0,7899 – 0,8073
SGD	0,7909	0,7819 – 0,7994
Regressão Logística	0,7859	0,7768 – 0,7947
Extra Trees	0,7762	0,7667 – 0,7847
Random Forest	0,7689	0,7598 – 0,7777
LSTM	0,7471	0,7375 – 0,7556
Transformer (BERTimbau)	0,7379	0,7287 – 0,7471
Naive Bayes	0,7114	0,7016 – 0,7208

Fonte: `avaliacao_final.json`, gerado em 23/07/2026 04:58, contra a categoria decidida pela memória M/N/P (`decisao_validada.verdade_validada`).

Nota metodológica sobre a mudança de patamar (92–96% em 16/07/2026 → 71–80% nesta consolidação): o código de `avaliacao_final.py` que produz esta tabela **não foi alterado** entre 16/07 e 23/07/2026 (confirmado por `git log`) — a queda não decorre de mudança de metodologia, mas do crescimento da amostra validada (4.681 → 9.096 decisões, quase o dobro). A leitura mais provável, retomada na Seção 5, é que a amostra menor de 16/07 estava mais concentrada em casos já fáceis de confirmar como corretos, e a ampliação da cobertura revelou uma taxa de acerto real mais baixa e mais representativa da base como um todo. Isso reforça, e não enfraquece, a premissa metodológica central deste artigo: avaliar modelos apenas contra amostras pequenas de validação humana pode superestimar o desempenho real.

4.3 A classificação oficial frente ao histórico: matriz de confusão validada

Um resultado adicional, obtido comparando a categoria histórica e a classificação da IA oficial (coluna G, executor LSTM/RF) contra a mesma verdade decidida pela memória M/N/P, qualifica a tese de rótulos ruidosos apresentada na Introdução. Sobre as 9.096 decisões travadas desta consolidação, a categoria histórica (GLPI) coincide com a decisão em 96,49% dos casos (8.777 de 9.096), acima do acerto da IA oficial frente à mesma verdade (90,15%; 8.200 de 9.096) — repetindo, em magnitude renovada, o padrão já observado em 16/07/2026 (98,54% contra 95,08%, sobre uma amostra bem menor). A matriz de confusão IA×histórico mostra 8.200 casos em que ambos coincidem com a decisão, 319 em que nenhum dos dois coincide, 577 em que o histórico acerta e a IA erra, e **nenhum** caso, nesta consolidação, em que a IA corrige uma categoria histórica que a decisão considerou incorreta. Diferentemente da observação anterior (13 casos de correção da IA sobre 4.737 conferências), a ausência total dessa célula nesta base maior tem explicação estrutural discutida abaixo, não deve ser lida automaticamente como “a IA nunca corrige o histórico”. O que o resultado sustenta com mais segurança é a outra metade da premissa: existe ruído real no histórico — 319 dos 9.096 casos conferidos (3,51%, quase o triplo da proporção observada em 16/07/2026) têm categoria histórica que não coincide com a decisão final —, mas esse ruído é proporcionalmente menor do que o risco de erro isolado da IA nesta mesma amostra (577 casos, 6,34%). A implicação prática permanece: a IA deve ser tratada como instrumento de triagem e auditoria complementar ao histórico, não como substituto ou árbitro superior a ele.

Tabela 4 Matriz de confusão IA×histórico contra a verdade decidida (M/N/P) (n = 9.096)

	Histórico correto	Histórico incorreto
IA correta	8.200	0
IA incorreta	577	319

Fonte: `calibracao.json`, gerado em 23/07/2026 21:53. Leitura: 8.200 casos em que ambos (IA e histórico) coincidem com a categoria decidida; 319 em que nenhum dos dois coincide; 577 em que o histórico acerta e a IA erra; e **zero** casos em que a IA acerta e o histórico erra. A ausência total de casos na célula “IA correta / histórico incorreto” chama atenção e tem explicação estrutural, não é necessariamente evidência de que a IA nunca corrige o histórico: quando a categoria decidida vem de confirmação da própria categoria histórica (fonte `conferencia_glpi`), a célula “histórico incorreto” fica automaticamente descartada para aquela linha; a memória de decisão (Subseção 3.7) também reaproveita categorias já travadas em rodadas anteriores, o que tende a alinhar a classificação vigente da IA (coluna G no momento do snapshot) com decisões já confirmadas. Antes de tratar essa célula-zero como achado substantivo (ex.: “a IA nunca corrige o histórico”), recomenda-se auditoria dirigida da fonte de decisão (fonte `decisao`) por linha — não realizada nesta rodada.

4.4 Confiança, calibração e faixas de decisão

A calibração bruta da Etapa 1 oficial mantém ECE histórico de 0,0598 nesta consolidação. Quando segmentada por faixa de confiança e cruzada com a verdade decidida pela memória M/N/P — não mais com a marcação bruta de uma única coluna de conferência, correção aplicada em `src/calibracao.py` nesta rodada (ver observação metodológica adiante) —, a faixa igual ou superior a 95% de confiança (n = 4.808; 34,4% da base) apresenta concordância de 99,08% com o histórico e, mais relevante, acerto validado de 96,79% sobre os 4.698 casos já com decisão travada nessa faixa — resultado que fica muito próximo da meta de referência do experimento (confiança calibrada $\geq 95\%$ associada a acerto real $\geq 95\%$), embora não a atinja com folga. Nas faixas inferiores, a degradação de desempenho acompanha a queda de confiança de forma consistente (90–95%: acerto validado 91,48%; 80–90%: 93,92%; 70–80%: 94,95%; 50–70%: 83,94%; inferior a 50%: 49,89%), o que corrobora a correlação positiva entre confiança bruta e acerto — quantificada nesta consolidação por Spearman entre 0,45 e 0,56 conforme o modelo (Subseção 4.1, `estatistica.json`) —, mesmo sem calibração formal (Platt/isotônica) aplicada a essa camada. A faixa 80–90% (93,92%) supera ligeiramente a faixa 90–95% (91,48%) — pequena inversão de monotonia plausível em dados reais com amostras desse tamanho, mas que merece acompanhamento nas próximas consolidações antes de ser tratada como padrão estável.

Tabela 3 Acerto validado por faixa de confiança bruta, executor oficial (Etapa 1), contra a verdade decidida M/N/P (n = 9.096 decisões travadas)

Faixa	n total	Concord. histórico	n validados	Acerto validado
< 50%	3.972	42,35%	876	49,89%
50–70%	1.504	73,40%	741	83,94%
70–80%	972	87,45%	654	94,95%
80–90%	1.499	87,99%	1.118	93,92%
90–95%	1.210	92,98%	1.009	91,48%
>= 95%	4.808	99,08%	4.698	96,79%

Fonte: `calibracao.json`, gerado em 23/07/2026 21:53. A amostra de conferência prioriza divergências e casos de menor confiança na composição original, não é aleatória — a leitura acima deve ser tomada como piso/teto conforme o desenho da conferência, não como taxa de acerto sobre amostra representativa.

Nota metodológica: até 22/07/2026, esta tabela comparava a classificação do executor apenas contra a marcação bruta da coluna N (CONFERÊNCIA IA) isolada, o que produzia acerto validado artificialmente igual a 100% em toda faixa de confiança, inclusive abaixo de 50% — a coluna N, no uso real, quase nunca recebe marcação “Errado” (o erro da IA costuma ficar registrado via M, sem tocar N). Corrigido em `src/calibracao.py` no commit 21258deb (23/07/2026): a comparação passou a usar a categoria decidida pela memória M/N/P (`decisao_validada.verdade_validada`), a mesma verdade da Subseção 4.2, eliminando o viés de seleção. Teste de regressão em `tests/test_calibracao.py`.

4.5 Reclassificação e ganho líquido

A reclassificação dos chamados já conferidos (execução de 30/06/2026, coluna O) produz resultados heterogêneos entre modelos, medidos contra a verdade validada quando travada e contra o histórico nos demais casos. O LinearSVC apresenta o maior ganho líquido absoluto (+30; 479 corrigidos e 449 prejudicados, sobre 29.794 reclassificações acumuladas, das quais 18.719 são reaproveitamento direto de decisão humana travada), seguido por Naive Bayes (+9) e Regressão Logística (+8). Em contraste, SGD (−92), Random Forest (−80) e Extra Trees (−40) apresentam ganho líquido negativo nesta rodada — a reclassificação piora mais casos do que corrige para esses três modelos. Esse resultado reforça a decisão metodológica de não aplicar reclassificação em massa de forma indiscriminada por modelo, tratando o ganho líquido, e não apenas a acurácia agregada, como critério de decisão operacional por classificador.

Atualização de dados (23/07/2026): o parágrafo acima preserva os números da execução de 30/06/2026. A Tabela 5 mostra o recorte mais recente (`reclass_resumo.json`, execução de 23/07/2026), já incluindo o LSTM (ausente da comparação anterior):

Tabela 5 Ganho líquido de reclassificação por modelo (execução de 23/07/2026)

Modelo	Total reclassificado	Corrigidos	Prejudicados	Ganho líquido	Reuso de decisão humana
LSTM	13.418	628	539	+89	8.805
LinearSVC	13.451	278	209	+69	8.856
Regressão Logística	13.332	235	144	+91	8.727
SGD	13.379	186	157	+29	8.771
Random Forest	18.049	209	184	+25	13.387
Naive Bayes	13.226	125	132	−7	8.623
Extra Trees	13.310	202	204	−2	8.713

Fonte: `reclass_resumo.json`, gerado em 23/07/2026 21:31 (modelos executados em 23/07/2026 07:55–07:56). Nesta consolidação, apenas Extra Trees e Naive Bayes mantêm ganho líquido negativo (a versão de 30/06 também apontava SGD e Random Forest como negativos; ambos passaram a positivo). **Observação de qualidade de dado, não corrigida nesta rodada:** o total reclassificado do Random Forest (18.049)

destoa dos demais modelos (~13.200–13.450), apesar de a execução ter ocorrido no mesmo dia e com poucos minutos de diferença dos demais — não foi investigada a causa; não interpretar o ganho líquido do Random Forest como diretamente comparável aos demais até essa discrepância ser explicada.

4.6 Diagnóstico de taxonomia e ambiguidade estrutural (Shannon/Jensen-Shannon)

A camada de entropia de Shannon, calculada sobre as oito fontes de classificação (Etapa 1 oficial e as sete IAs materializadas, incluindo o LSTM out-of-fold), aponta o LSTM como o modelo de maior diversidade nas categorias previstas, e o LinearSVC como o modelo cuja distribuição de predições mais se aproxima da distribuição histórica (menor divergência de Jensen-Shannon). No nível de chamado individual, 3.451 dos 13.954 registros (24,7%) apresentam alta entropia de votos entre os oito modelos, ou seja, desacordo estrutural relevante entre arquiteturas distintas — um critério de priorização de auditoria diferente e complementar à simples baixa confiança de um único modelo. No nível de categoria, a análise aponta um número relevante de ocorrências de alta ambiguidade nas predições (79, com suporte mínimo de 30 registros por categoria); a interpretação detalhada de quais categorias específicas concentram essa ambiguidade, e sua sobreposição com os pares de maior confusão recíproca já identificados na etapa de cruzamento de taxonomia (por exemplo, entre climatização e manutenção preventiva de ar-condicionado, ou entre estrutura predial, esquadrias e hidrossanitária), permanece como candidata a inspeção qualitativa dirigida. O que a camada Shannon oferece é a priorização estatística de onde essa inspeção deve começar, não a decisão de fusão ou desambiguação de categorias, que continua sendo humana.

Atualização de dados (23/07/2026): o parágrafo acima preserva a leitura da versão anterior deste rascunho, que atribuía ao LSTM a maior diversidade e ao LinearSVC a menor divergência frente ao histórico. Na consolidação mais recente (`shannon_modelos.json`, `shannon_resumo.json`), **a Etapa 1 oficial assume as duas posições** — maior entropia de previsões e menor divergência de Jensen-Shannon —, com LSTM e o transformador (BERTimbau) muito próximos em terceiro e segundo lugar de diversidade:

Tabela 6 Entropia de Shannon e divergência de Jensen-Shannon por fonte de classificação (23/07/2026)

Fonte	Categorias previstas	Entropia (nats)	Entropia normalizada	JS vs. histórico
Etapa 1 oficial	53	4,6758	0,8163	0,0286
Transformer (BERTimbau)	51	4,6288	0,8160	0,0872
LSTM	52	4,6201	0,8105	0,0847
Regressão Logística	52	4,4490	0,7805	0,0716
SGD	53	4,4363	0,7745	0,0639
LinearSVC	53	4,3356	0,7569	0,0575
Extra Trees	47	3,9955	0,7193	0,0761
Random Forest	47	3,9574	0,7124	0,0804
Naive Bayes	19	3,3340	0,7848	0,1755

Fonte: `shannon_modelos.json` e `jensen_shannon_modelos.json`, gerados em 23/07/2026 (workflow `dashboard.yml`, via `src/analise_shannon.py`). No nível de categoria, a mais recente `shannon_resumo.json` aponta 91 ocorrências de alta ambiguidade nas predições (ante 79 na versão anterior) e 3.378 chamados (ante 3.451) com alta entropia de votos entre modelos — números próximos, sem mudança de leitura qualitativa. Naive Bayes chama atenção por combinar a menor cobertura de categorias (19, ante 47–53 dos demais) com entropia normalizada relativamente alta (0,7848) — provável reflexo de concentração extrema em poucas categorias com alguma dispersão residual, não investigado em detalhe nesta rodada.

4.7 Custo computacional

Nos recortes de comparação por lote (1.000 registros cada), o tempo de treino mantém-se na casa de segundos para os modelos lineares e probabilísticos mais simples (por exemplo, Naive Bayes ~ 1,1 s) e sobe para modelos com mais hiperparâmetros (Regressão Logística ~ 8,7 s neste recorte), enquanto o LSTM, por depender de

épocas de treinamento em rede neural, permanece a opção de maior custo computacional entre as fontes de classificação avaliadas, exigindo minutos e infraestrutura de checkpoint; o oitavo modelo (transformador com ajuste fino) tende a ampliar ainda mais esse custo, o que motivou seu isolamento em fluxo de trabalho próprio, de baixa frequência (Subseção 3.4). Essa hierarquia de custo é consistente com a observada em versões anteriores deste protocolo e reforça o argumento operacional de que modelos lineares combinam o melhor desempenho validado (Subseção 4.2) com o menor custo de reexecução e auditoria.

Tabela 7 Custo computacional por lote de 1.000 registros

Modelo	Tempo de treino (s)	Tempo de inferência (s)	Acurácia neste lote
Naive Bayes	1,14	0,07	0,539
LinearSVC	2,55	0,06	0,655
SGD	2,60	0,09	0,624
Regressão Logística	9,43	0,09	0,624
Random Forest	19,45	0,13	0,597
Extra Trees	21,30	0,14	0,610

Fonte: `comparacao_modelos.json`, execução mais recente por modelo em 18/07/2026 03:30 — não reexecutado em 23/07/2026; único registro de custo computacional disponível no painel para os modelos clássicos. LSTM e o transformador (BERTimbau) não constam deste arquivo; seu custo mais alto é descrito qualitativamente no parágrafo acima (dependência de épocas de treinamento em rede neural), não medido nesta mesma tabela. A acurácia reportada aqui é sobre um lote de 1.000 registros (não a base completa) e serve só para contextualizar o trade-off custo×desempenho desta subseção — não usar como substituto das Tabelas 1 e 2.

4.8 Figuras

Atualização de dados (23/07/2026): das quatro figuras originalmente planejadas para este capítulo, três foram geradas nesta rodada a partir dos JSONs vigentes do painel (script `matplotlib`, ver `04_artigo/figuras/`). A quarta permanece pendente por um motivo de qualidade de dado, não de esforço de geração.

Figura 2 Confiança bruta × concordância com o histórico × acerto validado, por faixa de confiança (executor oficial, Etapa 1). Mesmos números da Tabela 3 (Subseção 4.4), em forma gráfica.

Fonte: `calibracao.json`, gerado em 23/07/2026 21:53.

Figura 3 Trade-off entre acerto validado (conferência humana, 23/07/2026) e custo computacional (tempo de treino, lote de 1.000 registros, 18/07/2026), modelos clássicos. LSTM e o transformador (BERTimbau) não constam desta figura por não terem registro de tempo de treino no mesmo arquivo (Tabela 7, Subseção 4.7); seu custo mais alto é descrito qualitativamente no texto.

Fonte: `comparacao_modelos.json` (custo) e `avaliacao_final.json` (acerto validado).

Figura 4 (pares de maior confusão entre categorias) — pendência explícita, motivo novo: ao preparar esta figura, foi descoberta corrupção de acentuação (mojibake — caracteres substitutos no lugar de vogais acentuadas, por exemplo em “Instalação” e “Climatização”) nos nomes de categoria de três arquivos-fonte (`estatistica.json`, campo `top_confusoes`; `cruzamento_taxonomia.json`; `confusao_historico_ia.json`). Rastreamento parcial (não confirmado por leitura direta da planilha): `src/analise_estatistica.py` lê os nomes de categoria das abas `CLASSIF__<modelo>` (não da aba principal nem de `registros.json`, que estão limpos), o que restringe a suspeita a essas abas de trabalho específicas ou a como esse script as lê. Publicar essa figura com texto corrompido seria pior do que não publicá-la — fica como **Informação insuficiente para verificar** até investigação com acesso à planilha real, registrada como novo achado em `PLANO_ARTIGO_CAPITULO.md`, separado do bug de calibração corrigido nesta mesma rodada (Subseções 4.3 e 4.4).

5. DISCUSSÃO

Figura 2 - Confiança bruta x concordância x acerto validado, por faixa (executor oficial, Etapa 1 - 23/07/2026)




Figura 2: Figura 2 — Confiança bruta × concordância com o histórico × acerto validado, por faixa de confiança (executor oficial, Etapa 1, 23/07/2026).

A comparação entre concordância histórica (Subseção 4.1) e desempenho validado (Subseção 4.2) revela um padrão que mudou de magnitude ao longo da elaboração deste capítulo e que, por isso, merece registro explícito antes de qualquer outra leitura: na consolidação de 16/07/2026, sobre 4.681 decisões travadas, o acerto validado (92–96%) superava com folga a concordância com o histórico (70–80%); na consolidação vigente (23/07/2026), sobre 9.096 decisões — quase o dobro —, os dois patamares se aproximaram (concordância 68–80%, acerto validado 71–80%), com o LinearSVC calibrado praticamente empatado entre as duas métricas (80,34% concordância, 79,89% acerto validado). Como já registrado na Subseção 4.2, essa aproximação não decorre de mudança nos scripts de avaliação (confirmado por conferência do histórico de commits), e sim do crescimento da amostra de conferência: a leitura mais provável é que a amostra menor de 16/07 concentrava casos mais fáceis de confirmar como corretos, e a ampliação revelou uma taxa de acerto real mais baixa e mais representativa da base como um todo. Esse é, em si, um achado metodológico relevante para a literatura de validação humana em PLN aplicado: amostras de conferência pequenas, mesmo quando maiores do que o convencional na área (a versão original deste protocolo já superava a amostra piloto de 305 casos), podem superestimar sistematicamente o desempenho real de um classificador se a priorização de casos a conferir não for depois compensada por uma amostra final ampla o bastante para diluir esse viés inicial.

Ainda assim, a distinção entre concordância e acerto validado continua metodologicamente necessária, e a matriz IA×histórico (Subseção 4.3) mostra por quê: quando os dois discordam da decisão final, o histórico está correto com frequência muito maior (577 casos) do que a IA corrige um erro genuíno do histórico (0 casos nesta consolidação — com a ressalva estrutural já registrada na Subseção 4.3 sobre essa célula específica). Esse achado não invalida a premissa metodológica de que a categoria histórica não deve ser tratada como verdade absoluta — ainda existe uma taxa real de erro confirmado no registro original (3,51% dos casos conferidos nesta consolidação, quase o triplo do 1,2% observado em 16/07/2026, o que por si só recomenda cautela contra tratar mesmo esse número como estabilizado) —, mas recomenda cautela contra a leitura oposta e igualmente equivocada, de que baixa concordância com o histórico implica automaticamente acerto da IA. A validação humana, portanto, cumpre função insubstituível: sem ela, seria impossível distinguir as duas situações apenas observando a taxa de concordância — e, como o achado acima demonstra, seria impossível




Figura 3: Figura 3 — Trade-off entre acerto validado e custo computacional (tempo de treino), modelos clássicos.

também saber se uma amostra de validação já é grande o bastante para ser tratada como representativa.

A manutenção da liderança do LinearSVC calibrado tanto na concordância histórica quanto no acerto validado (Subseções 4.1 e 4.2) reforça, com evidência agora validada e não apenas preliminar, a leitura já delineada na primeira versão deste protocolo: em textos curtos, técnicos e ruidosos como os chamados de manutenção predial, um classificador linear sobre representação TF-IDF pode superar arquiteturas neurais mais complexas, inclusive quando avaliado contra verdade humana, e ainda manter vantagem de custo computacional (Subseção 4.7). A ausência de ganho estatisticamente significativo de qualquer estratégia de combinação de modelos (Subseção 4.2) reforça a mesma leitura: neste domínio e neste estágio do experimento, investir engenharia em um único classificador linear bem calibrado tem retorno mais claro do que orquestrar um comitê de modelos heterogêneos.

O resultado da reclassificação (Subseção 4.5) introduz uma nuance operacional importante: o ganho líquido de corrigir chamados já classificados não é uniforme entre modelos nem estável ao longo do tempo. Na execução de 30/06/2026, três dos seis classificadores clássicos avaliados (SGD, Random Forest e Extra Trees) tinham ganho líquido negativo; na execução de 23/07/2026, com o LSTM incluído na comparação, apenas Extra Trees e Naive Bayes permanecem negativos — SGD e Random Forest passaram a positivo. Essa oscilação, por si só, reforça o argumento: decisões de reclassificação em produção devem ser tomadas por modelo e reavaliadas a cada rodada, com base no ganho líquido medido naquele momento, e não generalizadas a partir do desempenho médio de concordância ou acerto validado, nem tratadas como um veredito permanente sobre determinado classificador — um modelo pode ser competitivo na classificação inicial e, ainda assim, não ser um bom candidato a reclassificar decisões já tomadas em todas as rodadas.

A camada de entropia de Shannon e divergência de Jensen-Shannon (Subseção 4.6) não substitui as métricas supervisionadas ou a validação humana, mas amplia o repertório de governança do experimento ao separar três fenômenos que a acurácia isolada tende a confundir: erro de modelo, ambiguidade genuína da taxonomia institucional e heterogeneidade natural da distribuição de chamados. A identificação de 3.378 chamados (24,2% da base) com alto desacordo estrutural entre as nove fontes de classificação (Etapa 1 oficial e as oito IAs materializadas) oferece um critério de priorização de auditoria distinto do simples corte por baixa confiança de um único classificador, e complementa a fila já construída a partir da conferência M/N/P. O achado de que a Etapa 1 oficial, não o LSTM isolado, lidera tanto a diversidade de predições quanto a menor divergência frente ao histórico (Subseção 4.6) é consistente com sua natureza híbrida (LSTM com *fallback* de Random Forest): a combinação tende a produzir uma distribuição de categorias mais rica do que qualquer modelo isolado, sem se afastar tanto do padrão histórico quanto arquiteturas mais recentes (LSTM *out-of-fold*, BERTimbau).

A meta de confiança calibrada igual ou superior a 95% associada a acerto real igual ou superior a 95% (Subseção 4.4), estabelecida como critério de sucesso deste protocolo, fica próxima de ser atingida, mas não é mais alcançada com folga como sugeria a consolidação anterior: a faixa alta de confiança da Etapa 1 oficial chega a 96,79% de acerto validado sobre 4.698 casos conferidos (ante 99,73% sobre 3.284 casos em 16/07/2026), ainda que a confiança utilizada seja bruta (softmax/decision_function), não formalmente calibrada por Platt ou isotônica. Essa queda de 99,73% para 96,79% na própria faixa de mais alta confiança, à medida que a conferência quase dobrou de tamanho, é o mesmo padrão discutido acima para o acerto validado geral, e reforça a mesma cautela: a amostra validada, embora agora cubra 68,3% da base (ante 33,9% em 16/07/2026), ainda prioriza divergências e casos de menor confiança na sua composição original, o que pode ter inflado artificialmente o acerto validado nas faixas de alta confiança das consolidações anteriores, onde a conferência tendia a simplesmente confirmar o que já era esperado. A confirmação definitiva da meta depende da conclusão da conferência humana sobre a fração ainda não conferida da base (31,7%), e a trajetória observada entre 16/07 e 23/07/2026 recomenda que a leitura de “meta já atingida” só seja aceita quando essa conferência estiver substancialmente mais completa, não a cada consolidação intermediária.

As limitações do estudo foram atualizadas em relação à versão anterior, com quatro ajustes relevantes. Primeiro, a amostra validada deixou de ser uma amostra piloto de 305 casos (2,2% da base) e passou a cobrir 9.534 conferências (68,3% da base, 9.096 decisões travadas sem conflito), o que aumenta substancialmente a robustez estatística das Subseções 4.2 a 4.4 — mas, como discutido acima, essa mesma ampliação já revelou que a robustez estatística de uma amostra intermediária não garante estabilidade da magnitude do resultado, apenas de sua direção geral (a ordem entre modelos manteve-se; o patamar de acerto, não). Segundo,

os conflitos de conferência identificados em versões anteriores do protocolo (casos em que duas colunas de conferência confirmam categorias diferentes) permanecem em zero nos dados publicados (`conflitos = 0` em `avaliacao_final.json`), o que não elimina a possibilidade de novos conflitos surgirem à medida que a conferência avança sobre os 31,7% da base ainda sem decisão travada. Terceiro, o oitavo modelo (transformador BERTimbau com ajuste fino), que na versão anterior deste protocolo ainda não tinha resultado comparativo, passou a ter: seu desempenho (68,06% de concordância, 73,79% de acerto validado) o posiciona entre os últimos colocados do ranking, próximo ao LSTM, não superando os classificadores lineares clássicos nesta base — resultado que, mesmo preliminar, já qualifica a expectativa inicial de que um transformador pré-treinado traria ganho automático de desempenho neste domínio de texto curto e técnico. Quarto, foi identificada nesta rodada uma corrupção de acentuação (mojibake) nos nomes de categoria de três arquivos-fonte usados para análises de confusão entre categorias (Subseção 4.8), que impediu a geração da quarta figura planejada e permanece sem causa-raiz confirmada — registrada como pendência técnica em `PLANO_ARTIGO_CAPITULO.md`, não como resultado do experimento em si. Persistem como limitações a dependência de uma única instituição como caso empírico e a intermitência observada na publicação automática do painel no GitHub Pages, discutida na auditoria técnica que acompanha este capítulo.

6. CONSIDERAÇÕES FINAIS

O presente capítulo atualizou o protocolo de classificação automática multimodelo de chamados de manutenção predial universitária em português brasileiro com os resultados acumulados até 23 de julho de 2026, incorporando uma oitava fonte de classificação já com resultado comparativo (transformador BERTimbau com ajuste fino), uma camada de memória de decisão por veto e trava de categorias já conferidas, e uma camada de análise informacional baseada em entropia de Shannon e divergência de Jensen-Shannon. A contribuição central permanece metodológica: não apenas identificar o melhor classificador, mas estruturar um protocolo em que aprendizado de máquina, estatística não paramétrica, memória de decisão e auditoria humana qualificam progressivamente a base de dados e revelam inconsistências taxonômicas — e, como esta rodada demonstrou, também revelam e corrigem inconsistências no próprio pipeline de avaliação (Subseções 4.3 e 4.4).

Diferentemente da versão preliminar deste texto, a conclusão atual se apoia em validação humana substancial e, pela primeira vez, ampla o bastante para revisar a magnitude dos resultados publicados anteriormente. Sobre 9.096 chamados com decisão travada e sem conflito, o LinearSVC calibrado confirma-se como a melhor IA isolada, com acerto validado de 79,89% (IC95%: 78,99%–80,73%), à frente de SGD (79,09%), Regressão Logística (78,59%), Extra Trees (77,62%), Random Forest (76,89%), LSTM (74,71%), o transformador BERTimbau (73,79%) e Naive Bayes (71,14%); nenhuma estratégia de combinação de modelos supera essa IA isolada com significância estatística. Esse patamar é substancialmente mais conservador do que os 92–96% reportados na consolidação de 16/07/2026 sobre uma amostra bem menor (4.681 decisões) — queda que, como discutido na Seção 5, reflete o crescimento da própria amostra de validação, não uma piora do classificador nem mudança de metodologia de cálculo. A matriz de confusão IA×histórico qualifica, sem invalidar, a premissa de rótulos ruidosos: o histórico administrativo, quando conferido, acerta mais do que a IA (96,49% contra 90,15%), mas apresenta uma taxa real e crescente de erro confirmado (3,51% dos casos conferidos, ante 1,2% em 16/07/2026), o que justifica manter a arquitetura de validação humana como componente permanente do protocolo, não como etapa transitória a ser eliminada quando a IA atingir bom desempenho médio.

A meta original do experimento — confiança calibrada igual ou superior a 95% associada a acerto validado igual ou superior a 95% — fica próxima de ser atingida na faixa de alta confiança da classificação oficial (96,79% de acerto validado, ante 99,73% na consolidação anterior sobre amostra menor), resultado que recomenda cautela redobrada em relação à já registrada na versão anterior deste texto: a trajetória entre 16/07 e 23/07/2026 mostrou que mesmo a leitura “meta atingida” pode reverter quando a amostra de conferência cresce, o que reforça — e não apenas repete — a recomendação de não tratar a meta como cumprida para fins de liberação em produção sem revisão antes da conclusão da conferência humana sobre uma fração bem mais representativa da base. Os próximos passos deste protocolo incluem a conclusão da conferência humana pendente (31,7% da base ainda sem decisão travada), a calibração formal por modelo (Platt/isotônica/temperatura) condicionada a essa conferência, a análise comparativa mais aprofundada do desempenho do transformador BERTimbau frente aos classificadores lineares (por ora inferior, resultado

que qualifica a expectativa inicial sobre ganho automático de arquiteturas pré-treinadas neste domínio), a investigação da discrepância de escala identificada na reclassificação do Random Forest (Subseção 4.5) e da corrupção de acentuação identificada nos arquivos-fonte de análise de confusão entre categorias (Subseção 4.8), a revisão taxonômica dirigida pelos candidatos identificados na etapa de cruzamento de taxonomia e na entropia de Shannon, e a estabilização da publicação automática do painel, cuja intermitência técnica está documentada na auditoria que acompanha este capítulo. Com isso, o protocolo pretende seguir contribuindo tanto para a literatura de *facility management* e processamento de linguagem natural aplicado quanto para a melhoria concreta e continuamente auditável da gestão de manutenção predial em instituições públicas — inclusive como exemplo de que a própria prática de reconferir dados vivos antes de publicar, defendida ao longo deste capítulo, é capaz de encontrar e corrigir falhas no pipeline de avaliação, não apenas nos rótulos históricos que motivaram o estudo.

REFERÊNCIAS

- ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. ABNT NBR 5674: Manutenção de edificações: Requisitos para o sistema de gestão de manutenção. Rio de Janeiro: ABNT, 2012.
- BOUABDALLAOUI, Y.; LAFHAJ, Z.; YIM, P.; DUCOULOMBIER, L.; BENNADJI, B. Natural Language Processing Model for Managing Maintenance Requests in Buildings. *Buildings*, v. 10, n. 9, art. 160, 2020.
- GALKE, L.; SCHERP, A. Bag-of-words vs. graph vs. sequence in text classification: questioning the necessity of text-graphs and the surprising strength of a wide MLP. In: ANNUAL MEETING OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS, 60., 2022, Dublin. Proceedings [...]. Dublin: ACL, 2022. p. 4038–4051.
- GRAVES, A.; SCHMIDHUBER, J. Framewise phoneme classification with bidirectional LSTM and other neural network architectures. *Neural Networks*, v. 18, n. 5-6, p. 602–610, 2005.
- GUO, C.; PLEISS, G.; SUN, Y.; WEINBERGER, K. Q. On calibration of modern neural networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 34., 2017, Sydney. Proceedings [...]. Sydney: PMLR, 2017. p. 1321–1330.
- JOACHIMS, T. Text categorization with support vector machines: learning with many relevant features. In: EUROPEAN CONFERENCE ON MACHINE LEARNING, 10., 1998, Chemnitz. Proceedings [...]. Berlin: Springer, 1998. p. 137–142.
- KEJRIWAL, M.; SANTOS, H.; SHEN, K.; MULVEHILL, A. M.; MCGUINNESS, D. L. A noise audit of human-labeled benchmarks for machine commonsense reasoning. *Scientific Reports*, v. 14, art. 8609, 2024.
- LI, Y.; LIU, Y.; ZHANG, J.; CAO, L.; WANG, Q. Automated analysis and assignment of maintenance work orders using natural language processing. *Automation in Construction*, v. 165, art. 105501, 2024.
- LIU, Z.; BENGE, C.; JIANG, S. Ticket-BERT: labeling incident management tickets with language models. arXiv:2307.00108, 2023.
- MARTINS, R. F. B.; ESPEJO, M. M. S. B. Análise de custos de manutenção predial em uma universidade federal brasileira com uso do modelo de SES. *ABCustos*, São Leopoldo, v. 19, n. 1, 2024.
- MCNEMAR, Q. Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, v. 12, n. 2, p. 153–157, 1947.
- MOHAMMED, A. S.; AMOAH, C. Integration of technology in decision-making in university facilities management: a literature review. *Facilities*, v. 43, n. 13/14, p. 1018–1052, 2025.
- MORAIS, L. S. R. de; PAULA, H. M. de; REIS, R. P. A. Promoção da eficiência da manutenção predial em edificações públicas: abordagem baseada em registros de ordens de serviço. *Paranoá*, Brasília, v. 16, n. 34, p. 1–18, 2023.
- PAMPANA, A. K. et al. Data-driven analysis for facility management in higher education institution. *Buildings*, v. 12, art. 2094, 2022.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.

PLATT, J. C. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. In: SMOLA, A. J. et al. (Ed.). *Advances in Large Margin Classifiers*. Cambridge: MIT Press, 1999. p. 61–74.

SALTON, G.; BUCKLEY, C. Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, v. 24, n. 5, p. 513–523, 1988.

SCHWARTZ, R.; DODGE, J.; SMITH, N. A.; ETZIONI, O. Green AI. *Communications of the ACM*, v. 63, n. 12, p. 54–63, 2020.

SOKOLOVA, M.; LAPALME, G. A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, v. 45, n. 4, p. 427–437, 2009.

SUNDARAM, S.; ZEID, A. Technical Language Processing for Prognostics and Health Management: applying text similarity and topic modeling to maintenance work orders. *Journal of Intelligent Manufacturing*, v. 36, p. 1637–1657, 2025.

TREVISIO, M. et al. Efficient methods for Natural Language Processing: a survey. *Transactions of the Association for Computational Linguistics*, v. 11, p. 826–860, 2023.

ZHANG, H.; ZHANG, Y.; LI, J.; LIU, J.; JI, L. A survey on learning with noisy labels in Natural Language Processing: how to train models with label noise. *Engineering Applications of Artificial Intelligence*, v. 146, art. 110157, 2025.

APÊNDICES

Apêndice A — Dicionário de colunas da planilha experimental (A:M)

A aba experimental (CHAMADOS_ESQUELETO_REDUZIDO) segue o esquema fixo A:M, descrito em `AGENTS.md` do repositório:

Coluna	Campo
A	ID Chamado
B	TÍTULO
C	CATEGORIA COMPLETA (rótulo histórico)
D	DESCRIÇÃO GLPI
E	TÍTULO O.S.M.
F	DESCRIÇÃO O.S.M.
G	Classificação IA
H	Avaliação (%) — gravada como fração 0–1, formatada como %
I	Executor
J	Criticidade Atribuída por IA
K	Comparação — fórmula <code>=SE(G="";"";G=C)</code>
L	Classificado_Confiança_IA
M	CONFERÊNCIA (marcação humana; TRUE não é sobrescrito por nova classificação automática)

Apêndice B — Checklist de itens reportados

Adaptado do espírito do checklist tipo PRISMA-ScR do artigo-modelo de revisão (MCDM/TOPSIS/ODS/ESG) para relato de experimento de classificação supervisionada com validação humana. Cada item indica a subseção onde é reportado e o status na data de publicação; **não substitui a reconferência de números antes da submissão** — os status “Sim” abaixo atestam que o item é reportado em algum lugar do texto, não que o número citado já foi revalidado contra os JSONs vigentes.

Item	Subseção	Reportado?
Fonte de dados e sistema de origem declarados	3.1, 3.2	Sim (GLPI/UFSB)
Tamanho da amostra e período/corte de consolidação	3.2	Sim, mas com data de corte a reconferir
Critério de inclusão/exclusão de registros	3.2	Parcial — “chamados não vazios” declarado; demais critérios não detalhados
Pré-processamento textual	3.3	Sim
Modelos avaliados e hiperparâmetros principais	3.4	Sim (7 materializados + 1 em extensão)
Método de particionamento (out-of-fold, k-fold, seed)	3.5	Sim (out-of-fold, k-fold estratificado, seed fixa)
Métricas reportadas e justificativa	3.5	Sim (acurácia, macro-F1, balanced accuracy, IC95% bootstrap)
Testes estatísticos e correção para múltiplas comparações	3.5	Sim (Cochran Q, Friedman, McNemar, Nemenyi)
Critério de calibração de confiança (bruta vs. calibrada) e meta de desempenho	3.8, 4.4	Parcial — meta declarada ($\geq 95\%$); calibração formal (Platt/isotônica) ainda não aplicada
Protocolo de validação humana	3.6	Sim
Cobertura da validação humana na data de publicação (n e % da base)	4 (abertura)	Sim, mas desatualizada — ver nota de revalidação de dados
Tratamento de conflitos de conferência	3.7	Sim (regra de veto/trava)
Reprodutibilidade (scripts e dados versionados)	3.9	Sim (repositório público, JSONs sanitizados)
Limitações declaradas	5, 6	Sim
Figuras/tabelas geradas a partir de dados verificáveis	4.8	Não — pendência explícita registrada

Apêndice C — Matriz de decisão M/N/P

Contagens agregadas disponíveis nos JSONs públicos do painel (23/07/2026):

Métrica	n
Chamados com ao menos uma conferência (M, N ou P)	9.534
Decisões travadas (categoria decidida sem conflito)	9.096
Casos restritos (categoria eliminada, sem decisão travada)	438
Conflitos (M e N confirmam categorias diferentes)	0
Conferências da coluna N (CONFERÊNCIA IA) preenchidas	9.096
Conferências da coluna M (CONFERÊNCIA GLPI) preenchidas	9.534
Conferências da coluna P (CONFERÊNCIA IA - 2) preenchidas	0

Fonte: `auditoria_conferencias.json` e `calibracao.json`, gerados em 23/07/2026. A coluna P (reclassificação conferida) está zerada nesta consolidação — nenhuma reclassificação foi conferida via essa coluna especificamente até esta data.

Pendência explícita: o cruzamento fino de 3 vias (contagem por combinação exata de valores de $M \times N \times P$ — ex.: quantos casos têm $M=\text{Correto}$ e $N=\text{Errado}$ simultaneamente) **não está disponível em nenhum**

JSON público atual e exige extração direta da planilha experimental (**Informação insuficiente para verificar** com os dados hoje publicados). O que se aproxima disso é a matriz 2×2 IA $\times$ histórico da Tabela 4 (Subseção 4.3), que cruza acerto da IA e do histórico contra a verdade decidida — não é o mesmo cruzamento $M \times N \times P$ bruto, mas cobre a mesma pergunta de fundo (quando IA e histórico concordam ou divergem da decisão final).