

CLASSIFICAÇÃO AUTOMÁTICA MULTIMODELO DE CHAMADOS DE MANUTENÇÃO PREDIAL UNIVERSITÁRIA EM PORTUGUÊS BRASILEIRO COM VALIDAÇÃO HUMANA

Multi-model automatic classification of university building maintenance work orders in Brazilian Portuguese with human validation

Adinailson Guimarães de Oliveira - adinailson.oliveira@cja.ufsb.edu.br **Fabício Berton Zanchi** - fabricao.berton@ufsb.edu.br

Universidade Federal do Sul da Bahia (UFSB), Programa de Pós-Graduação em Biosistemas

RESUMO

A classificação automática de chamados de manutenção predial constitui recurso estratégico para qualificar a triagem operacional e ampliar a governança baseada em evidências em instituições públicas. Em bases históricas de sistemas informatizados de gestão de chamados, contudo, a categoria originalmente registrada não deve ser tratada como verdade absoluta, pois pode refletir decisões operacionais ruidosas, taxonomias sobrepostas, registros incompletos e interpretações heterogêneas entre equipes. Este artigo propõe um protocolo multimodelo para classificação de chamados reais de manutenção predial universitária em português brasileiro, extraídos do sistema institucional da Universidade Federal do Sul da Bahia. O experimento utiliza 14.060 chamados não vazios, organizados em 50 categorias históricas. A comparação principal avalia seis classificadores clássicos baseados em TF-IDF e uma rede neural LSTM bidirecional por previsões *out-of-fold* sob validação cruzada agrupada por texto, o que impede que chamados de texto idêntico atravessem treino e teste. O BERTimbau, transformador pré-treinado em português, fica fora da comparação por custo medido, uma vez que o ajuste fino projeta 6,44 horas por dobra em processador sem acelerador gráfico. O diferencial metodológico reside na distinção entre concordância com o histórico administrativo e acerto contra a referência humana final, que cobre a totalidade do corpus e é apurada sobre as 13.972 linhas de 41 categorias com suporte nas cinco dobras. O LinearSVC lidera as duas leituras, com acordo bruto de 79,61% frente ao histórico e acurácia de 82,53% frente à referência humana. O achado central contraria a expectativa que motivou o estudo: o ganho líquido de reclassificação da base histórica é negativo em todos os sete modelos, de -1.846 no melhor deles a -3.474 no pior, porque a referência humana confirma a categoria histórica em 95,75% dos registros e divergir do histórico significa, quase sempre, divergir também da referência. Uma camada explícita de regras de periodicidade, avaliada nas mesmas partições, mostra-se redundante e melhora o F1 macro de apenas três dos sete modelos. O custo computacional permanece dimensão relevante da decisão e favorece modelos lineares em cenários de texto curto, ruidoso e desbalanceado: o LinearSVC treina em 2,44 s, contra 83,44 s da rede recorrente no mesmo ambiente. O recorte do desempenho por volume de categoria e por natureza da intervenção demonstra que o F1 macro de 0,6684 resulta da composição da métrica, pois o mesmo modelo alcança 0,8207 nas 12 categorias que concentram 81,83% do volume, e que a distinção entre manutenção preventiva e corretiva é obtida com F1 de 0,9742 e 0,9547, respectivamente.

Palavras-chave: manutenção predial; classificação de chamados; processamento de linguagem natural; rótulos ruidosos; validação humana.

ABSTRACT

Automatic classification of building maintenance work orders is a strategic resource for improving operational triage and evidence-based governance in public institutions. However, the originally assigned category in historical service-management databases should not be treated as unquestionable ground truth because it may reflect noisy operational decisions, overlapping taxonomies, incomplete records, and heterogeneous interpretations. This paper proposes a multi-model protocol for classifying real university building maintenance requests in Brazilian Portuguese from the Federal University of Southern Bahia. The experiment uses 14,060 non-empty records organized into 50 historical categories. The main comparison evaluates six TF-IDF-based classical classifiers and a bidirectional LSTM through out-of-fold predictions under text-grouped cross-validation, which prevents work orders sharing identical text from crossing the train-test boundary. BERTimbau, a Portuguese pre-trained transformer, is excluded from the main comparison on measured cost grounds, as fine-tuning projects 6.44 hours per fold on a processor without graphics acceleration. The methodological contribution is the distinction between agreement with the administrative history and accuracy against the final human reference,

which covers the entire corpus and is computed over 13,972 records in the 41 categories with support across all five folds. LinearSVC leads both readings, with 79.61% raw agreement against the history and 82.53% accuracy against the human reference. The central finding contradicts the expectation that motivated the study: the net gain from reclassifying the historical base is negative for all seven models, from $-1,846$ in the best to $-3,474$ in the worst, because the human reference confirms the historical category in 95.75% of records, so departing from the history almost always means departing from the reference as well. An explicit periodicity rule layer, evaluated on the same partitions, proves redundant and improves macro F1 for only three of the seven models. Computational cost remains a relevant decision dimension and favors linear models in short, noisy, and imbalanced text settings: LinearSVC trains in 2.44 s, against 83.44 s for the recurrent network in the same environment. Breaking performance down by category volume and by the nature of the intervention shows that the macro F1 of 0.6684 stems from how the metric is composed, since the same model reaches 0.8207 on the 12 categories that concentrate 81.83% of the volume, and that preventive maintenance is told apart from corrective maintenance with F1 of 0.9742 and 0.9547, respectively.

Keywords: building maintenance; work-order classification; natural language processing; noisy labels; human validation.

1. INTRODUÇÃO

Um campus universitário pode ser descrito como um biossistema construído, isto é, a integração dinâmica entre infraestrutura física, atividade humana, sistemas tecnológicos e condicionantes ambientais, cuja persistência ao longo do tempo depende de mecanismos de retroalimentação contínua entre uso, falha e reparo (CAPRA, 1996; ODUM, 1971). A ecologia urbana descreve esse tipo de sistema como um organismo em troca permanente de matéria, energia e informação com seu entorno, cuja governança bem-sucedida depende da capacidade institucional de captar sinais operacionais e convertê-los em decisão (GRIMM *et al.*, 2008). Em instituições federais de ensino superior (IFES), esse sinal assume, na prática, a forma de registros textuais de chamados de manutenção predial, matéria-prima do *feedback* operacional do biossistema construído. Esses registros, no entanto, nascem aprisionados em linguagem não estruturada, fragmentária e sujeita a interpretação individual no momento do atendimento, o que impede seu uso direto por qualquer mecanismo de decisão automatizada (MORAIS; PAULA; REIS, 2023; MOHAMMED; AMOAH, 2025).

A exploração analítica dessas bases enfrenta três obstáculos estruturais, agravados pela restrição orçamentária que historicamente limita o custeio da manutenção predial em IFES a patamares inferiores a 2% do orçamento institucional (MARTINS; ESPEJO, 2024; PAMPANA *et al.*, 2022). O primeiro é a natureza textual curta e heterogênea dos registros, redigidos em linguagem técnica fragmentária, com abreviações locais e jargões de equipe que dificultam a aplicação direta de modelos genéricos de processamento de linguagem natural (PLN) (SUNDARAM; ZEID, 2025). O segundo é o desbalanceamento entre categorias, dado que demandas recorrentes de climatização, elétrica e hidrossanitária concentram grande parte da base, ao passo que categorias raras dispõem de poucos exemplos para treinamento supervisionado (LI *et al.*, 2024). O terceiro, e o mais consequente do ponto de vista metodológico, é a qualidade do próprio rótulo histórico, que pode resultar de interpretação rápida, conveniência operacional ou taxonomia ainda não estabilizada, de modo a constituir evidência importante, mas não verdade absoluta (ZHANG *et al.*, 2025; KEJRIWAL *et al.*, 2024).

A literatura recente confirma a relevância do PLN para converter esses registros em insumo de gestão. Li *et al.* (2024) demonstraram, em base hospitalar com 15.623 ordens de serviço, que a atribuição automática de equipes alcança acurácia de 0,83; Bouabdallaoui *et al.* (2020) reportaram acurácia média de 78% na classificação de requisições em edificação hospitalar; e Sundaram e Zeid (2025), sob a abordagem de *Technical Language Processing*, argumentam que textos técnicos de manutenção funcionam como *black holes* informacionais quando armazenam dados relevantes sem serem utilizados na decisão. A maior parte dessas aplicações concentra-se, contudo, em bases em inglês ou chinês e em domínios industriais ou hospitalares, o que configura lacuna para corpora em português brasileiro no contexto da manutenção predial pública universitária.

Diante desse quadro, a pergunta que orienta este artigo não é qual classificador mais concorda com a categoria histórica, e sim como extrair de texto ruidoso, de forma confiável e auditável, o dado estruturado capaz de alimentar um sistema de governança preditiva sem herdar acriticamente os erros do histórico que lhe deu origem. A formulação importa porque rótulos ruidosos reduzem o desempenho de classificadores (ZHANG *et al.*, 2025) e porque *benchmarks* anotados por humanos carregam variabilidade relevante, o que torna

questionável tratar qualquer rótulo, humano ou histórico, como verdade não sujeita a julgamento (KEJRIWAL *et al.*, 2024). Cabe à camada de classificação automática, por conseguinte, produzir dado auditável o bastante para que divergências entre modelo e histórico sejam tratadas como evidência de revisão taxonômica, e não como ruído a descartar.

Com base em chamados reais da Universidade Federal do Sul da Bahia (UFSB), este artigo propõe uma comparação multimodelo de classificadores de texto aplicada a chamados de manutenção predial em português brasileiro. A base experimental contém 14.060 chamados não vazios em 50 categorias históricas, e os campos textuais agregam título e descrição do chamado, além de informações da ordem de serviço. O estudo compara modelos clássicos baseados em TF-IDF com uma rede neural LSTM bidirecional; o BERTimbau é ajustado, mas fica fora da comparação principal por custo medido. O objeto de avaliação, portanto, não é o classificador isolado, mas o protocolo de governança que articula aprendizado de máquina, auditoria estatística, custo computacional e revisão humana, formulação consoante à manutenção baseada em evidências preconizada pela NBR 5674 (ABNT, 2012) e à integração físico-humano-tecnológico-ambiental que caracteriza um biosistema construído.

Quatro objetivos específicos orientam o trabalho: apresentar um protocolo de classificação que produza dado estruturado auditável a partir de texto livre; distinguir a concordância com o rótulo histórico do acerto contra a referência humana final; avaliar o desempenho por métricas balanceadas, intervalos de confiança e testes pareados adequados a dados não normais, incorporando o custo computacional como dimensão de decisão; e determinar, por medição e não por presunção, se a classificação automática é capaz de corrigir retroativamente a base histórica.

2. REFERENCIAL CONCEITUAL

2.1 Processamento de linguagem natural em ordens de manutenção

Ordens de manutenção constituem registros operacionais de valor informacional elevado e uso habitualmente reduzido. Documentam sintomas, locais, equipamentos, procedimentos e soluções executadas, acumulando-se por anos em sistemas cuja forma textual e semiestruturada dificulta o emprego direto em planejamento e alocação de recursos (PAMPANA *et al.*, 2022; MORAIS; PAULA; REIS, 2023). Li *et al.* (2024) constituem a referência-âncora desta pesquisa por tratarem diretamente da automação de ordens de manutenção predial, ainda que em idioma, tipologia institucional e estrutura taxonômica distintos. Sundaram e Zeid (2025) acrescentam perspectiva pertinente à manutenção predial universitária, na qual chamados curtos, abreviações locais e descrições incompletas inviabilizam o uso de modelos genéricos sem adaptação ao domínio, tese que os 78% de acurácia média reportados por Bouabdallaoui *et al.* (2020) sustentam ao mesmo tempo em que evidenciam a necessidade dessa adaptação lexical e semântica ao corpus específico.

2.2 Classificação de tickets e evolução dos modelos

A classificação automática de *tickets* em ambientes de suporte técnico e ITSM evoluiu de representações vetoriais baseadas em frequência lexical para *embeddings* e modelos de linguagem pré-treinados. Liu, Bengue e Jiang (2023) propuseram o Ticket-BERT para rotulagem de *tickets* de incidentes, enfatizando desafios como atualização contínua de rótulos e necessidade de aprendizado ativo. Entretanto, a transferência direta de achados do ITSM para a manutenção predial deve ser cautelosa, pois a semântica do domínio envolve sistemas físicos, ambientes e equipamentos prediais que não coincidem com categorias de incidentes de *software* ou infraestrutura digital (SUNDARAM; ZEID, 2025).

Modelos lineares com TF-IDF permanecem competitivos em tarefas de texto curto, sobretudo quando o corpus é de porte médio, o vocabulário possui alta especificidade técnica e as classes são desbalanceadas. Galke e Scherp (2022), em revisão comparativa de métodos para classificação textual, demonstraram que classificadores baseados em *bag-of-words* com TF-IDF e SVM sustentam desempenho equivalente ao de redes neurais em múltiplos *benchmarks* quando o corpus é reduzido ou o vocabulário é especializado. O achado é particularmente pertinente à manutenção predial institucional, cuja base operacional raramente atinge escala compatível com as exigências de modelos de linguagem de grande porte.

2.3 Rótulos ruidosos e verdade operacional

O ruído de rótulo é problema central do aprendizado supervisionado sobre bases administrativas e, em

classificação textual, decorre de ambiguidade semântica, polissemia, insuficiência de contexto, sobreposição taxonômica ou erro de registro (ZHANG *et al.*, 2025). Kejriwal *et al.* (2024) acrescentam que *benchmarks* rotulados por humanos contêm variabilidade relevante, o que questiona a prática de assumir verdade única onde há julgamento subjetivo. Neste artigo, por conseguinte, a categoria histórica é tratada como referência administrativa, e não como verdade final, e a referência operacional é construída por revisão humana com registro explícito da decisão.

2.4 Custo computacional e eficiência em PLN

A avaliação de modelos de PLN tem sido tradicionalmente orientada por métricas de desempenho, mas a literatura recente enfatiza que custo computacional, tempo de treino, consumo energético e reprodutibilidade também devem compor a decisão de adoção (TREVISIO *et al.*, 2023; SCHWARTZ *et al.*, 2020). Treviso *et al.* (2023) argumentam que a ampliação de escala em PLN tende a aumentar o consumo de dados, tempo, armazenamento e energia, motivando métodos eficientes especialmente em contextos de recursos limitados. Schwartz *et al.* (2020) cunharam o conceito de *Green AI*, propondo que a eficiência computacional seja reportada e valorizada na avaliação de modelos, não apenas a acurácia. Em uma instituição pública, essa dimensão é operacionalmente decisiva. Um modelo que treina em segundos pode ser reexecutado frequentemente, auditado com facilidade e mantido sem infraestrutura dedicada, ao passo que um modelo que demanda dezenas de minutos exige *checkpoint*, controle de versão de pesos e justificativa robusta de ganho marginal (TREVISIO *et al.*, 2023).

Os modelos de linguagem de grande porte não integram esta comparação. Operam sobre representações contextuais em arquitetura de transformador (VASWANI *et al.*, 2017), dispõem de bilhões de parâmetros contra os aproximadamente 110 milhões do BERTimbau (SOUZA; NOGUEIRA; LOTUFO, 2020) e dispensam ajuste supervisionado, pois inferem a tarefa de instruções e de poucos exemplos no próprio enunciado (BROWN *et al.*, 2020), do que decorre a expectativa de maior acurácia em chamados de redação atípica. Sua adoção esbarra, contudo, em três restrições diante do critério de eficiência aqui adotado: a execução exige aceleradores dedicados ou serviços tarifados por uso, incompatíveis com a reexecução frequente que o fluxo institucional pressupõe; o processamento por terceiros desloca as descrições dos chamados para fora do domínio da universidade; e a variabilidade das respostas entre versões do serviço compromete a reprodutibilidade exigida pelo delineamento (BENDER *et al.*, 2021). Tendo em vista que a tarefa é fechada e institucionalmente delimitada, condição na qual classificadores baseados em *bag-of-words* permanecem competitivos (GALKE; SCHERP, 2022), a avaliação desses modelos fica indicada como desdobramento futuro.

3. MÉTODO

3.1 Delineamento geral

O estudo adota delineamento experimental aplicado, com base observacional retrospectiva de chamados de manutenção predial registrados no sistema GLPI institucional da UFSB, universidade multicampi com unidades em Itabuna, Ilhéus, Porto Seguro e Teixeira de Freitas (MORAIS; PAULA; REIS, 2023). A unidade de análise é o chamado individual de manutenção, representado por campos textuais concatenados e por uma categoria histórica registrada no sistema. O fluxo metodológico compõe-se de oito etapas sequenciais: (i) extração e consolidação da base; (ii) higienização textual; (iii) construção da matriz de atributos; (iv) treinamento e inferência multimodelo; (v) geração de predições *out-of-fold*; (vi) comparação preliminar com categoria histórica; (vii) análise estatística não paramétrica; e (viii) validação humana das divergências e amostras críticas. A Figura 1 apresenta esse fluxo como *pipeline* de governança preditiva.

3.2 Corpus e variáveis

O corpus experimental é composto por 14.060 chamados de manutenção predial não vazios, organizados em 50 categorias históricas, extraídos do ambiente institucional da UFSB. Os campos textuais previstos no protocolo incluem título do chamado, descrição GLPI, título da ordem de serviço e descrição da ordem de serviço, concatenados em uma única representação textual para fins de classificação. A categoria histórica é utilizada como referência preliminar de comparação, mas a avaliação conclusiva depende da base validada por revisão humana. O idioma dos registros é português brasileiro, com presença significativa de jargões técnicos, nomes de ambientes, abreviações locais e descrições incompletas, características que impõem desafios específicos de pré-processamento e representação textual (SUNDARAM; ZEID, 2025).




Figura 1: Pipeline de governança preditiva, do fluxo de extração da base à retroalimentação por validação humana.

A base é dinâmica, pois a planilha de trabalho é alimentada continuamente pelo sistema de atendimento e novos chamados são incorporados a cada sincronização. Por essa razão, todos os resultados da Seção 4 referem-se a um corte por data de abertura, que compreende os chamados registrados até 1º de agosto de 2026 e totaliza 14.060 registros elegíveis. Os artefatos que sustentam cada número, incluindo previsões por modelo e matrizes de confusão, foram materializados sobre esse mesmo corte e estão versionados no repositório indicado na Subseção 3.8, de modo que a reprodução não depende do estado corrente do sistema institucional. A distribuição completa dos chamados entre as 50 categorias históricas é apresentada no Apêndice A.

3.3 Pré-processamento textual

O pré-processamento textual é documentado de modo reprodutível, uma vez que pequenas decisões sobre normalização podem alterar a matriz de atributos e, conseqüentemente, o desempenho dos modelos (SALTON; BUCKLEY, 1988). Para os classificadores clássicos, a representação principal é TF-IDF com n -gramas de uma e duas palavras e limite superior de 30.000 atributos para controle de dimensionalidade. Para o modelo neural LSTM, são utilizadas tokenizações específicas com vocabulário de 8.000 termos e comprimento máximo de 120 tokens por sequência. O vetorizador, o tokenizador e o vocabulário são ajustados dentro de cada dobra, sobre a partição de treino, de modo que nenhuma estatística do conjunto de teste participa da representação. Cabe ressaltar que a etapa de pré-processamento não elimina indiscriminadamente termos técnicos, códigos de ambientes, nomes de equipamentos ou expressões recorrentes da equipe, pois esses elementos possuem alto valor discriminativo em manutenção predial, onde palavras como *bomba*, *split*, *disjuntor*, *vazamento*, *infiltração* e *ar-condicionado* podem funcionar como âncoras semânticas relevantes para categorias específicas.

3.4 Modelos avaliados

O desenho experimental compara sete modelos, organizados em três famílias conceituais, cada uma escolhida por um motivo específico ligado às características do domínio, ou seja, texto curto, vocabulário técnico e forte desbalanceamento entre categorias (Subseção 3.2).

A família linear (LinearSVC, Regressão Logística e SGD) opera diretamente sobre a representação TF-IDF esparsa (Subseção 3.3). Em espaços de alta dimensionalidade, fronteiras lineares tendem a separar bem as classes quando o vocabulário carrega forte poder discriminativo (JOACHIMS, 1998; SALTON; BUCKLEY, 1988), como é o caso dos termos técnicos de manutenção predial, que funcionam como âncoras semânticas de categoria. A família de *ensembles* de árvores (Random Forest e Extra Trees) captura interações não lineares entre atributos, a um custo computacional maior. O **Naive Bayes Multinomial** entra como *baseline* probabilístico mais simples, útil para calibrar a expectativa de desempenho mínimo (JOACHIMS, 1998; PEDREGOSA *et al.*, 2011). A rede neural (LSTM Bidirecional) modela dependências sequenciais no texto, mas treina seus *embeddings* do zero, sem incorporar vetores pré-treinados em português (GRAVES; SCHMIDHUBER, 2005). A Subseção 3.4.1 discute por que essa escolha tende a penalizar o desempenho

em corpora de porte médio como o deste estudo. Os sete modelos são avaliados na comparação *out-of-fold* (Subseção 4.1). Em paralelo, a classificação automática em produção opera com uma regra de contingência que aciona o Random Forest quando a base rotulada disponível é insuficiente para treinar a rede neural.

Um oitavo modelo, o BERTimbau-Base, incorpora representações contextuais pré-treinadas em português brasileiro e é ajustado para as 50 categorias do corpus (DEVLIN *et al.*, 2019; SOUZA; NOGUEIRA; LOTUFO, 2020). O treino foi concluído em modo automático, com subamostragem estratificada e parada antecipada por restrição computacional. Como o modelo não possui predições *out-of-fold* materializadas sobre toda a base, ele não é inserido artificialmente no ranking integral dos sete modelos. Sua viabilidade computacional é examinada na Subseção 4.3.

3.4.1 Diferenças conceituais e operacionais entre os classificadores

Os sete modelos comparáveis cobrem quatro famílias com suposições distintas sobre os dados: um gerador probabilístico (Naive Bayes), discriminadores lineares (LinearSVC, Regressão Logística, SGD), *ensembles* não lineares baseados em árvores (Random Forest, Extra Trees) e uma rede neural sequencial (LSTM). Cada família responde de forma diferente a um corpus de texto curto, ruidoso e com forte desbalanceamento entre categorias (Subseção 3.2; Tabela A2), o que ajuda a explicar por que o desempenho não é uniforme entre elas nas Tabelas 1 e 2.

Os discriminadores lineares otimizam fronteiras de decisão sobre a representação TF-IDF esparsa de até 30.000 atributos (Subseção 3.3), e é essa a família favorecida pelo corpus. Em espaços esparsos de alta dimensionalidade, classificadores lineares separam bem as classes quando o vocabulário carrega forte poder discriminativo (JOACHIMS, 1998; SALTON; BUCKLEY, 1988), condição satisfeita aqui, em que termos técnicos do domínio funcionam como âncoras semânticas de categoria. Verifica-se, em consonância com essa expectativa, que o LinearSVC lidera tanto a concordância com o histórico quanto a acurácia contra a referência humana.

O Naive Bayes, na outra extremidade, assume independência condicional entre atributos dada a classe, suposição estrutural violada em texto de manutenção predial, no qual termos técnicos co-ocorrem de modo sistemático dentro de uma mesma categoria. A divergência entre a suposição do modelo e a estrutura real dos dados explica sua última posição nas duas leituras, e o colapso é ainda mais nítido no F1 macro, de 0,2951, porque o modelo restringe as predições a 22 das 41 categorias. Trata-se do comportamento esperado do modelo mais simples da comparação, e não de problema de implementação.

Random Forest e Extra Trees capturam interações não lineares por meio da estrutura de árvores, mas em espaços esparsos tendem a ajustar-se demais às co-ocorrências frequentes, o que se reflete no desempenho intermediário de ambos. O custo computacional dessa família é também o mais alto entre os modelos clássicos medidos, entre 9,3 e 10,9 vezes o tempo de treino do LinearSVC (Tabela 5), e só se justificaria se revertido em ganho de acurácia, o que não se confirma nos dados analisados (SCHWARTZ *et al.*, 2020; TREVISIO *et al.*, 2023).

A LSTM bidirecional é projetada para modelar dependências sequenciais no texto, mas seus *embeddings* são inicializados aleatoriamente e treinados do zero, sem incorporação de vetores pré-treinados em português. A camada de *embedding* concentra sozinha cerca de 1,02 milhão de parâmetros, ordem de grandeza próxima do número de exemplos disponíveis por partição de treino, já que dos 13.972 chamados cerca de 11.178 compõem cada partição em cinco dobras. Esse cenário é consoante à hipótese de que modelos lineares igualam ou superam redes neurais em corpora de porte médio e ruidosos, quando não há *embeddings* pré-treinados disponíveis no idioma (GALKE; SCHERP, 2022), e a curva de aprendizado da Subseção 4.8 mostra saturação precoce, e não instabilidade de treino.

3.5 Desenho de avaliação

A avaliação se dá por predições fora da amostra em protocolo *out-of-fold* com `StratifiedGroupKFold`, cinco dobras e semente fixa, estratificado pela referência humana e agrupado pelo hash do texto normalizado. As partições são geradas uma única vez, versionadas e reutilizadas por todos os modelos e pela camada de regras, o que reduz o viés de comparação e legitima os testes pareados (SOKOLOVA; LAPALME, 2009). A validação cruzada foi preferida a um conjunto de teste fixo porque produz estimativas de menor variância em bases desbalanceadas, ao avaliar cada exemplo em alguma dobra em vez de descartar uma fração constante do

treino (KOHAVI, 1995), condição pertinente a um corpus em que várias categorias apresentam suporte de dígito único.

São reportadas acurácia, *macro-F1*, *balanced accuracy* e intervalo de confiança a 95% por *bootstrap*, reamostragem com reposição que estima a distribuição de uma estatística sem pressupor sua forma paramétrica (EFRON, 1979; EFRON; TIBSHIRANI, 1993; DICICCIO; EFRON, 1996). A *macro-F1* e a *balanced accuracy* respondem ao desbalanceamento entre categorias, dado que a acurácia isolada superestima o desempenho nas classes majoritárias e mascara falhas nas raras (SOKOLOVA; LAPALME, 2009). A correlação entre confiança e acerto é avaliada por Spearman (SPEARMAN, 1904) e por correlação ponto-bisserial, apropriada quando uma das variáveis é binária (TATE, 1954).

A inferência segue ordem declarada. Diferenças globais entre os sete classificadores são apuradas por Cochran Q, teste não paramétrico para proporções pareadas em três ou mais condições (COCHRAN, 1950), e somente se o teste global rejeitar a igualdade procede-se às comparações pareadas por McNemar (MCNEMAR, 1947), corrigidas pelo método sequencial de Holm-Bonferroni, que controla a taxa de erro familiar sem o conservadorismo da correção de Bonferroni simples (HOLM, 1979). O protocolo de Demšar (2006) para comparação de classificadores recomenda o *post-hoc* de Nemenyi sobre postos médios (NEMENYI, 1963), mas Benavoli, Corani e Mangili (2016) demonstram que o teste de postos médios pode ser inconsistente e recomendam testes pareados diretos, razão pela qual a inferência principal repousa no McNemar. A estimação da incerteza por *bootstrap* em métricas de modelos preditivos permanece em refinamento (NOMA *et al.*, 2021), o que recomenda ler os intervalos ao lado dos testes pareados, e não em substituição a eles.

A partição por linha, contudo, carrega uma limitação própria neste corpus, e é ela que determina o protocolo adotado. Chamados de manutenção repetem-se: 4.586 das 14.060 linhas, ou 32,62%, compartilham texto normalizado com outra linha, e a base congelada resolve-se em 9.786 grupos textuais, dos quais 9.474 são unitários. Desses grupos, 9.735 sobrevivem ao recorte das 13.972 linhas avaliadas, e é essa a contagem empregada como unidade de reamostragem na Subseção 4.9. Sob particionamento por linha, o mesmo texto pode cair em treino e em teste, o que superestima o desempenho. Toda a avaliação principal usa, por isso, **StratifiedGroupKFold** com cinco dobras e semente fixa, estratificado pela referência humana e agrupado pelo hash do texto normalizado, de modo que nenhum grupo textual atravessa a fronteira entre treino e teste. As partições são geradas uma única vez, versionadas e reutilizadas por todos os modelos e pela camada de regras, o que torna as comparações pareadas legítimas. A divisão aleatória por linha permanece apenas como análise de sensibilidade, cujo protocolo próprio e cujos resultados constam do material suplementar (Subseção 4.8).

O agrupamento impõe um custo de cobertura que precisa ser declarado. Uma categoria só entra na avaliação se dispuser de grupos textuais distintos em número suficiente para figurar nas cinco dobras. Nove das 50 categorias não satisfazem essa condição, quatro por aritmética, tendo menos grupos distintos que dobras, e cinco por ausência efetiva em alguma dobra após a estratificação. Elas somam 88 linhas, e sua exclusão reduz o denominador das métricas de 14.060 para 13.972 registros em 41 categorias. Excluir rótulos de baixa frequência é prática corrente na classificação hierárquica de chamados (MARCUIZZO *et al.*, 2022), ainda que o limiar daqueles autores seja de cem ocorrências e o critério aqui adotado seja o suporte por dobra. A Tabela A3 discrimina as categorias excluídas, de modo que a diferença entre os dois denominadores permaneça auditável.

O BERTimbau seria submetido ao mesmo protocolo, e a decisão de mantê-lo fora da comparação principal apoia-se em medição de custo, não em preferência editorial. O procedimento e o resultado dessa medição constam da Subseção 4.3.

3.6 Revisão humana e referência final

A revisão humana constitui a etapa que diferencia o presente estudo de uma simples comparação de classificadores contra histórico. O desenho é de auditoria de rótulo, e não de anotação do zero: a pergunta submetida ao especialista é se a categoria registrada é adequada ao chamado. Para cada registro, o avaliador examinou o título e a descrição do chamado, o título e a descrição da ordem de serviço, quando existentes, e a categoria histórica. Previsões e níveis de confiança dos modelos não estavam visíveis durante a revisão.

Ver a categoria histórica é constitutivo dessa tarefa, e não contaminação do julgamento: corrigir um rótulo

pressupõe conhecê-lo. Cabe registrar, porém, que a categoria histórica não é atribuição isolada. Ela resulta do registro pelo demandante seguido de verificação por equipe técnica, de modo que o rótulo auditado já incorpora uma conferência anterior, o que ajuda a explicar a alta taxa de confirmação reportada adiante.

Quando a categoria histórica é confirmada, ela constitui a referência; quando é rejeitada, o avaliador registra a categoria correta. A categoria resultante desse processo constitui a referência humana final utilizada na avaliação dos modelos. A revisão cobriu a totalidade do corpus: os 14.060 chamados receberam veredito, sendo 13.462 por confirmação da categoria histórica e 598 por registro de categoria distinta, ou 4,25% do corpus. Não restaram chamados sem referência, o que elimina o viés de seleção que condicionaria uma amostra conferida.

A revisão foi conduzida por um único especialista, e a confiabilidade entre avaliadores não foi medida, limitação declarada na Subseção 5.3. Uma estimativa do ruído do próprio rótulo está, contudo, disponível sem segundo avaliador: 17 grupos de texto idêntico receberam referência divergente, afetando 85 linhas, ou 0,60% da base congelada. Esse valor estabelece um piso de erro irreduzível para qualquer modelo, em consonância com a perspectiva de que a verdade operacional deve ser construída progressivamente (ZHANG *et al.*, 2025).

3.7 Camada de entropia de Shannon e divergência de Jensen-Shannon

Como dimensão complementar às métricas supervisionadas, o protocolo incorporou uma camada de análise informacional baseada em entropia de Shannon e divergência de Jensen-Shannon (SHANNON, 1948; LIN, 1991), calculada exclusivamente sobre agregados públicos e sanitizados, sem identificador, título ou texto livre do chamado. Essa camada não substitui acurácia, calibração ou validação humana, pois responde a uma pergunta distinta, sobre onde modelos, categorias e chamados individuais concentram maior incerteza estrutural. A entropia opera aqui como medida da desordem informacional do bioecossistema construído, no sentido de Shannon (1948), e o que ela localiza não é erro de modelo, mas a região da taxonomia em que o próprio sistema de registro perdeu capacidade de discriminar. No nível dos modelos, a entropia de Shannon sobre a distribuição de categorias previstas indica se um classificador dispersa suas predições por muitas classes ou as concentra excessivamente em poucas; a divergência de Jensen-Shannon mede a distância entre essa distribuição prevista e a distribuição histórica da base, funcionando como indicador de deslocamento distributivo. No nível das categorias, a entropia evidencia classes históricas cujas predições se espalham entre múltiplas categorias, sinalizando candidatas prioritárias a revisão taxonômica. No nível do chamado individual, a entropia de votos entre os modelos identifica registros em que há desacordo estrutural entre arquiteturas distintas, formando uma fila de auditoria orientada por ambiguidade, e não apenas por baixa confiança isolada de um único modelo.

3.8 Disponibilidade de dados

Os artefatos que sustentam os resultados relatados neste artigo são gerados por um processo automatizado e reproduzível, reexecutado a cada atualização do experimento. Os chamados analisados têm origem no sistema institucional GLPI da UFSB e não estão publicamente disponíveis, por restrição de privacidade institucional. As métricas derivadas e o código que produz cada figura, tabela e estatística deste artigo são de acesso público no repositório <https://github.com/adinailson88/classificacao-chamados>, que também descreve a estrutura completa dos dados e o material suplementar citado neste artigo. Nenhum identificador pessoal, título ou texto livre de chamado é armazenado nos agregados publicados, e a camada de entropia (Subseção 3.7) opera exclusivamente sobre esses agregados.

4. RESULTADOS

Esta seção apresenta dois conjuntos de resultados deliberadamente segregados. O primeiro é a concordância dos sete modelos com a categoria histórica (Subseção 4.1), em que o registro administrativo é referência preliminar, não verdade absoluta. O segundo é o desempenho desses mesmos modelos contra a referência humana final (Subseção 4.2).

Dois denominadores convivem no texto e não devem ser confundidos. A base congelada contém 14.060 chamados, todos com referência humana, e é o número pertinente sempre que a frase trata do corpus ou da cobertura da revisão. As métricas, contudo, são apuradas sobre 13.972 linhas em 41 categorias: nove categorias, somando 88 linhas, não sustentam suporte nas cinco dobras e ficaram fora das partições, conforme o critério da Subseção 3.5 e o detalhamento da Tabela A3. Excluir rótulos de baixa frequência tem precedente

na classificação hierárquica de chamados (MARCUIZZO *et al.*, 2022), com a ressalva de que o limiar daqueles autores é de cem ocorrências e o critério aqui é o suporte por dobra.

Quatro achados resumem a seção. Primeiro, o LinearSVC lidera tanto a concordância histórica quanto a acurácia contra a referência humana, e mantém vantagem de custo. Segundo, o ganho líquido de reclassificação é negativo em todos os modelos, o que desautoriza a correção automática da base histórica em massa. Terceiro, a camada explícita de regras de periodicidade é redundante diante de um classificador competente. Quarto, a calibração viabiliza automação seletiva de cerca de dois terços do volume com acurácia próxima de 0,95, encaminhando o restante à revisão humana.

4.1 Concordância com a categoria histórica

A comparação contra a categoria histórica, sobre as predições *out-of-fold* da rodada canônica ($n = 13.972$), mantém o LinearSVC na liderança, com acordo bruto de 0,7961, seguido por Extra Trees (0,7844), SGD (0,7781), Random Forest (0,7747), Regressão Logística (0,7738), LSTM (0,7017) e Naive Bayes (0,6954). A comparação exclui o BERTimbau, que não possui predições *out-of-fold* sobre as 13.972 linhas pelo motivo computacional exposto na Subseção 4.3. O Kappa de Cohen (COHEN, 1960) entre cada modelo e o histórico reproduz ordenação semelhante, variando de 0,7807 (LinearSVC) a 0,6653 (Naive Bayes), faixa que Landis e Koch (1977) classificam como concordância substancial. As duas medidas divergem em uma única troca de posição, entre Random Forest e Regressão Logística, decorrente da sensibilidade do coeficiente à prevalência das categorias, o que recomenda lê-lo ao lado do acordo bruto (WONGPAKARAN *et al.*, 2013).

O coeficiente é aplicável aqui porque modelo e categoria histórica constituem fontes independentes de classificação. O mesmo não valeria entre a referência humana e a categoria histórica, uma vez que o revisor teve acesso ao rótulo administrativo ao decidir, o que viola o pressuposto de independência e inflaria o coeficiente pela adjudicação.

Tabela 1 Concordância com a categoria histórica por modelo ($n = 13.972$).

Modelo	Acordo bruto	Kappa de Cohen
LinearSVC	0,7961	0,7807
Extra Trees	0,7844	0,7665
SGD	0,7781	0,7618
Random Forest	0,7747	0,7559
Regressão Logística	0,7738	0,7574
LSTM	0,7017	0,6809
Naive Bayes	0,6954	0,6653

O desempenho não é uniforme entre as 41 categorias avaliadas e concentra-se nas classes de maior volume. As categorias de maior F1 pertencem todas à Manutenção Preventiva, com destaque para Ar condicionado split ($F1 = 0,9972$; suporte = 1.987), Gerador (0,9954; 1.208) e Quadros Elétricos (0,9843; 578). No extremo oposto, Manutenção Preventiva sem subcategoria hidráulica e Projeto não alcançam acerto algum, e Limpeza de equipamentos, Telhados preventivos e Reforma ficam abaixo de 0,25. Essa leitura pede cautela, pois essas categorias têm suporte entre 13 e 65 registros, condição em que pequena variação absoluta altera fortemente a métrica. O desempenho por categoria, com suporte, tipo e classe de volume, consta da Tabela A2.

4.2 Acerto contra a referência humana final

A conferência humana estabeleceu categoria de referência para a totalidade dos 14.060 chamados da base congelada, e a avaliação incide sobre os 13.972 que compõem as partições canônicas. O LinearSVC é o melhor modelo em acurácia, com 0,8253 (IC95%: 0,8115–0,8378), seguido por SGD (0,8093), Extra Trees (0,8073), Regressão Logística (0,8050), Random Forest (0,7970), LSTM (0,7287) e Naive Bayes (0,7088). A vantagem sobre o SGD, segundo colocado, é de 1,60 ponto percentual e permanece significativa após correção de Holm, com 536 acertos exclusivos do LinearSVC contra 312 do SGD.

A cobertura integral da conferência elimina o viés de seleção que condicionava as versões anteriores desta métrica. Não há chamado sem categoria de referência, de modo que a acurácia relatada deixa de constituir

limite superior de amostra conferida. A ressalva remanescente é de outra natureza: a categoria de referência resulta de julgamento humano sobre uma taxonomia que apresenta pares sobrepostos, discutidos na Subseção 4.6.

A leitura por acurácia deve ser acompanhada do F1 macro, que pondera igualmente todas as categorias e revela comportamento distinto entre os modelos. As três melhores marcas de F1 macro ficam a menos de três milésimos umas das outras, com Regressão Logística em 0,6689, LinearSVC em 0,6684 e SGD em 0,6669, e seus intervalos de confiança se sobrepõem integralmente. Os três modelos não devem ser ordenados por essa métrica. A leitura pertinente é outra: o LinearSVC lidera a acurácia sem pagar por isso em desempenho na cauda, ao contrário dos *ensembles* de árvores, que perdem cerca de três centésimos de F1 macro na mesma faixa de acurácia. No extremo oposto, o Naive Bayes combina acurácia de 0,7088 com F1 macro de 0,2951, o que caracteriza um classificador que acerta as categorias frequentes e falha de modo sistemático nas demais.

Tabela 2 Acurácia e F1 macro por modelo contra a referência humana final ($n = 13.972$; 41 categorias). As duas métricas são a estimativa observada na amostra inteira; os intervalos vêm de *bootstrap* de grupo textual, com mil repetições sobre os 9.735 grupos congelados. A média das reamostragens é grandeza distinta da estimativa observada e não ocupa estas colunas: para o LinearSVC, por exemplo, a média do F1 macro é 0,6664, contra os 0,6684 observados. O F1 macro pondera igualmente todas as categorias, independentemente do suporte.

Modelo	Acurácia	IC95%	F1 macro	IC95%
LinearSVC	0,8253	0,8115 – 0,8378	0,6684	0,6526 – 0,6804
SGD	0,8093	0,7950 – 0,8227	0,6669	0,6510 – 0,6788
Extra Trees	0,8073	0,7923 – 0,8211	0,6362	0,6177 – 0,6498
Regressão Logística	0,8050	0,7907 – 0,8189	0,6689	0,6534 – 0,6812
Random Forest	0,7970	0,7812 – 0,8111	0,6152	0,5971 – 0,6288
LSTM	0,7287	0,7080 – 0,7480	0,5240	0,5107 – 0,5343
Naive Bayes	0,7088	0,6860 – 0,7311	0,2951	0,2887 – 0,3099

4.3 Viabilidade computacional do BERTimbau

O BERTimbau não integra a comparação principal, e o motivo é computacional. O ajuste fino foi cronometrado no mesmo ambiente dos demais modelos, um executor de quatro processadores sem acelerador gráfico, e custou 10,774 segundos por passo, com variação de 0,12 segundo entre o passo mais rápido e o mais lento. São 2.103 passos por dobra, o que projeta 6,44 horas para uma única dobra e 32,2 horas para as cinco. O teto de execução disponível é de seis horas, de modo que nem uma dobra completa cabe na infraestrutura do estudo.

A limitação é de infraestrutura, não do modelo. O BERTimbau não foi avaliado sob o protocolo agrupado desta rodada e, por conseguinte, nada se afirma aqui sobre seu desempenho relativo. Uma comparação integral exigiria aceleração por unidade de processamento gráfico, recurso indisponível no ambiente em que o estudo foi conduzido, e permanece como trabalho futuro.

Um experimento exploratório anterior avaliou o transformador junto aos demais modelos em um lote de mil chamados, dos quais 983 possuíam referência humana. Seus valores constam do material suplementar (Tabela S6), preservados como registro. Eles não são comparáveis aos da Tabela 1 nem aos da Tabela 2: o lote corresponde aos primeiros registros elegíveis, não é probabilístico, não cobre o corpus e o ajuste do transformador empregou subamostragem estratificada com parada antecipada. Rankings produzidos sob protocolos distintos não sustentam comparação direta.

4.4 Calibração e automação seletiva por confiança

A confiança bruta dos classificadores não é probabilidade e não pode sustentar decisão operacional sem tratamento. O erro de calibração esperado (ECE) do LinearSVC alcança 0,6925 sobre o escore bruto, porque a transformação da margem por função *softmax* produz valores que não correspondem a frequências de acerto.

A calibração isotônica, ajustada em dobra interna de calibração, reduz esse valor a 0,0178, e o escore de Brier cai de 0,6052 para 0,1034. O SGD segue o mesmo padrão, de 0,3046 para 0,0109.

O procedimento reduz o ECE de cinco dos sete modelos. O Naive Bayes e o LSTM constituem exceção e pioram levemente, de 0,0144 para 0,0206 e de 0,0158 para 0,0479, o que é consequência esperada de ajustar um calibrador sobre amostra menor quando a confiança original já era adequada. O melhor resultado calibrado pertence ao Extra Trees, com ECE de 0,0108.

A calibração viabiliza a automação seletiva, em que o classificador decide sozinho acima de um limiar de confiança e encaminha o restante à revisão humana. Ao alvo de 0,95 de acurácia, o Extra Trees automatiza 67,32% dos chamados com acurácia seletiva de 0,9502 e encaminha 32,68% ao revisor; o LinearSVC automatiza 68,90% com 0,9464. Elevar o alvo a 0,99 reduz a cobertura à faixa de 31,94% a 47,04%, e o Naive Bayes só alcança o limiar em duas das cinco dobras, o que o desqualifica para esse regime.

Parte das acurácias seletivas fica pouco abaixo do alvo, como os 0,9464 do LinearSVC contra a meta de 0,95. Não se trata de defeito, e sim da consequência esperada de escolher o limiar em dobra interna e aplicá-lo a dados nunca vistos. Um procedimento que atingisse o alvo exatamente em todas as dobras seria indício de que o limiar teve acesso ao conjunto de teste.

Tabela 3 Calibração e automação seletiva por modelo (n = 13.972). O ECE e o Brier referem-se ao escore antes e depois da calibração isotônica; a cobertura e a acurácia seletiva correspondem ao alvo de 0,95.

Modelo	ECE bruto	ECE calibrado	Brier calibrado	Cobertura	Acurácia seletiva
Extra Trees	0,0859	0,0108	0,1057	0,6732	0,9502
SGD	0,3046	0,0109	0,1124	0,6162	0,9531
Random Forest	0,0913	0,0145	0,1082	0,6580	0,9495
LinearSVC	0,6925	0,0178	0,1034	0,6890	0,9464
Regressão Logística	0,2351	0,0189	0,1173	0,6237	0,9415
Naive Bayes	0,0144	0,0206	0,1280	0,5518	0,9306
LSTM	0,0158	0,0479	0,1221	0,6545	0,9210

A Figura 2 apresenta a curva de confiabilidade do Extra Trees calibrado, tornando visível a aderência entre confiança declarada e acerto observado ao longo das dez faixas.




Figura 2: Curva de confiabilidade do Extra Trees após calibração isotônica, com confiança média e acurácia observada por faixa.

4.5 Reclassificação e ganho líquido

A hipótese operacional que motiva esta subseção é a de que um classificador competente possa corrigir a base histórica em massa. A medição a refuta. O ganho líquido de reclassificação é negativo em todos os sete modelos, variando de -1.846 no LinearSVC a -3.474 no Naive Bayes (Tabela 4). O procedimento é direto: conta-se apenas onde a predição diverge da categoria histórica, e a referência humana arbitra cada divergência, de modo que corrigido é o caso em que o modelo acerta e o histórico erra, e prejudicado o caso inverso.

O melhor modelo produz 2.849 divergências, das quais apenas 475 representam correção efetiva contra 2.321 que degradariam o registro. A razão é de aproximadamente um acerto para cada cinco prejuízos, e piora monotonicamente à medida que cai o desempenho do modelo: o Naive Bayes diverge 4.256 vezes para acertar 309.

A explicação não está em falha de cálculo, e sim na qualidade da base. A conferência humana confirmou a categoria histórica em 13.462 dos 14.060 chamados, ou 95,75% do corpus, e substituiu o rótulo em 598 registros. Uma base que já está correta em mais de nove décimos dos casos oferece pouca margem de correção e muita margem de dano: divergir do histórico significa, na maior parte das vezes, divergir também da referência. O teto teórico de correção corresponde aos 4,25% de registros efetivamente incorretos, e nenhum modelo se aproxima dele sem produzir um volume de alterações indevidas várias vezes maior.

O resultado inverte a orientação operacional. A reclassificação automática em massa não é desaconselhada por cautela metodológica, mas por evidência de que degradaria a base em que fosse aplicada. O uso defensável da classificação automática neste corpus é prospectivo, sobre chamados novos, ou seletivo, restrito à faixa de alta confiança tratada na Subseção 4.4 e sujeito a revisão humana no restante. O ganho líquido, e não a acurácia agregada, é o critério adequado para essa decisão, e deve ser recalculado a cada atualização da base.

Tabela 4 Ganho líquido de reclassificação por modelo, contado apenas onde a predição diverge da categoria histórica e arbitrado pela referência humana final ($n = 13.972$).

Modelo	Divergências	Corrigidos	Prejudicados	Neutros	Ganho líquido
LinearSVC	2.849	475	2.321	53	−1.846
SGD	3.100	489	2.559	52	−2.070
Extra Trees	3.012	422	2.519	71	−2.097
Regressão	3.161	492	2.621	48	−2.129
Logística					
Random Forest	3.148	416	2.658	74	−2.242
LSTM	4.168	426	3.621	121	−3.195
Naive Bayes	4.256	309	3.783	164	−3.474

4.6 Diagnóstico de taxonomia e ambiguidade estrutural (Shannon/Jensen-Shannon)

O diagnóstico de Shannon abrange os sete modelos com predições *out-of-fold* sobre a totalidade das linhas avaliadas. O BERTimbau fica de fora pelo motivo exposto na Subseção 4.3. Duas leituras distintas emergem da dispersão das predições. O LSTM apresenta a maior diversidade previstas, com entropia normalizada de 0,8362, ao passo que o LinearSVC exibe a menor divergência de Jensen-Shannon frente à distribuição histórica (0,0055). Dispersão de predições e aderência distributiva ao histórico, portanto, não caminham juntas, e o modelo de melhor acurácia é justamente o de distribuição mais próxima da base.

No nível de chamado individual, os sete modelos são unânimes em 8.444 dos 13.972 registros, ou 60,44%. No extremo oposto, 2.285 registros, ou 16,35%, distribuem os votos por três ou mais categorias distintas, o que caracteriza desacordo estrutural entre arquiteturas: a divergência deixa de ser a escolha entre duas alternativas e passa a indicar ausência de sinal textual suficiente para delimitar a categoria. Esse subconjunto constitui critério de priorização de auditoria distinto e complementar à baixa confiança de um único modelo, já que decorre de discordância entre indutores e não da incerteza declarada por um deles.

No nível de categoria, o contraste é acentuado entre as 33 categorias com suporte mínimo de trinta registros. A Figura 3 contrasta as dez de maior e as dez de menor F1 do LinearSVC. Nas dez melhores, o F1 varia de 0,9139 a 0,9972 e o conjunto reúne 6.271 chamados; nas dez piores, cai para a faixa de 0,2162 a 0,6288 sobre 2.403 chamados. Os dois grupos têm porte comparável em ordem de grandeza, de modo que a diferença não decorre de escassez de exemplos.




Figura 3: F1 do LinearSVC e suporte, para as dez categorias de maior e de menor desempenho entre as 33 com suporte mínimo de 30 chamados.

O padrão que emerge é sistemático, não aleatório. Oito das dez categorias de maior desempenho pertencem a Manutenção Preventiva, cujos chamados nascem de rotina programada e recebem descrição padronizada. As de menor desempenho concentram rótulos de fronteira aberta, como Telhados preventivos (0,2162), Reforma (0,2407), Erro de chamado (0,3978) e Alvenaria, Pisos e Estrutura (0,4610), que competem por vocabulário com categorias vizinhas. Trata-se, portanto, de ambiguidade estrutural da taxonomia, não apenas de erro do modelo, na linha do que Zhang *et al.* (2025) descrevem para rótulos ruidosos em processamento de linguagem natural.

A Figura 4 recorta a matriz de confusão sobre as oito categorias mais envolvidas em troca recíproca e mostra que os erros não se espalham pela taxonomia. A célula dominante registra 1.066 chamados de Instalação e reparo de equipamentos preditos como Alvenaria, Pisos e Estrutura, com 937 no sentido inverso, o que faz desse par a maior fronteira do corpus, com 2.003 trocas somadas. Seguem-se Alvenaria contra Esquadrias, com 1.097 trocas, e Alvenaria contra Hidráulica, com 940. Alvenaria, Pisos e Estrutura comparece nos cinco maiores pares e se comporta como categoria absorvente, para a qual convergem chamados cuja descrição não delimita o sistema predial afetado. A leitura da matriz é assimétrica em vários pares, o que sugere absorção de uma categoria por outra, e não simples permuta.

Convém registrar que a fronteira entre climatização corretiva e preventiva, dominante sob o protocolo anterior, deixa de figurar entre as maiores confusões. Os dois rótulos descrevem o mesmo equipamento e se distinguem pela natureza da intervenção; treinados contra a referência humana revisada, os modelos passam a separá-los de modo consistente. A ambiguidade que resta é a de escopo entre sistemas prediais, não a de natureza do serviço, resultado coerente com a facilidade da tarefa de tipo reportada na Subseção 4.11.

Esses recortes sustentam a mesma conclusão operacional. O desempenho agregado das Tabelas 1 e 2 esconde heterogeneidade relevante entre categorias, fenômeno que a *macro-F1* e a *balanced accuracy* foram adotadas para capturar (SOKOLOVA; LAPALME, 2009). Quando a queda de desempenho se concentra em fronteiras taxonômicas específicas, e não de modo difuso, a resposta adequada não é substituir o classificador, mas revisar a taxonomia, decisão que permanece humana e para a qual a camada de Shannon oferece apenas a priorização estatística. O Naive Bayes sintetiza o diagnóstico ao combinar a menor cobertura de categorias, apenas 22 contra 39 a 41 dos demais modelos, com a menor entropia normalizada e a maior divergência frente ao histórico: concentra o corpus em pouco mais de metade da taxonomia e reproduz mal a distribuição real, o que explica seu F1 macro de 0,2951 apesar de acurácia próxima de 0,71. A Figura 5 mostra os quinze pares de maior confusão recíproca, dominados pelas fronteiras internas de estrutura predial.




Figura 4: Recorte da matriz de confusão sobre as oito categorias mais envolvidas em troca recíproca, com contagens agregadas entre modelos.




Figura 5: Quinze pares de categorias com maior confusão recíproca, agregados entre modelos. Os códigos do eixo vertical estão descritos no material suplementar.

4.7 Custo computacional

O custo de treino e de inferência foi medido para os sete modelos sobre a base completa, no mesmo ambiente computacional (processador de quatro núcleos, sem acelerador gráfico), com mediana de três execuções por modelo. O desenho é o de treino único sobre a base inteira, e não a soma das cinco dobras da validação cruzada, de modo que os valores medem o custo de colocar cada modelo em operação. Os tempos absolutos variam conforme a máquina, mas as razões entre modelos permanecem estáveis e constituem o dado relevante para a decisão de adoção.

Os modelos lineares treinam em poucos segundos, de 1,12 s no Naive Bayes a 8,43 s na Regressão Logística. Os *ensembles* de árvores exigem entre vinte e trinta segundos, e a rede neural LSTM consome 83,44 s, cerca de 34 vezes o tempo do LinearSVC e 74,6 vezes o do Naive Bayes, que é o extremo mais rápido. A faixa entre a execução mais rápida e a mais lenta é estreita em todos os modelos, com exceção do LSTM, o que permite distinguir diferença real de ruído do executor.

O BERTimbau situa-se em outra ordem de grandeza e por isso não figura na tabela: seu ajuste fino projeta 6,44 horas por dobra, conforme a Subseção 4.3, contra segundos para os demais. A comparação direta seria imprópria, uma vez que os tempos da tabela referem-se a treino único sobre a base inteira e o do transformador, a uma dobra da validação cruzada.

Tabela 5 Custo computacional por modelo sobre a base completa ($n = 13.972$), mediana de três execuções em processador de quatro núcleos.

Modelo	Tempo de treino (s)	Faixa	Tempo de inferência (s)
Naive Bayes	1,12	1,12 – 1,12	0,89
SGD	2,28	2,27 – 2,28	0,93
LinearSVC	2,44	2,41 – 2,46	0,89
Regressão Logística	8,43	8,43 – 8,46	0,92
Random Forest	22,62	22,62 – 22,66	1,34
Extra Trees	26,69	26,63 – 26,72	1,46
LSTM	83,44	70,38 – 83,63	4,89

A Figura 6 cruza essas medições de custo com a acurácia da Tabela 2 e mostra que o LinearSVC ocupa a posição mais favorável, com a maior acurácia a um custo de treino próximo do menor observado. O argumento de eficiência da Subseção 2.4 se sustenta em duas frentes. Contra o LSTM, a comparação é direta e desfavorável ao modelo neural, que custa 34 vezes mais para perder 9,7 pontos percentuais de acurácia. Contra o BERTimbau, o que se afirma é mais restrito: o custo medido inviabiliza a validação cruzada agrupada no ambiente do estudo, sem que disso decorra juízo sobre seu desempenho.

4.8 Comportamento do LSTM e justificativa do protocolo agrupado

A Figura 7 mostra a curva de aprendizado do LSTM. O treino parou por interrupção antecipada após 11 épocas, com menor perda de validação na época 8 e maior acurácia de validação na época 10 (0,6722). O padrão indica saturação precoce, consistente com a hipótese de que *embeddings* treinados do zero são insuficientes para um corpus deste porte (Subseção 3.4.1). A curva provém de um treino único sobre a base inteira, com validação interna de 10%, e descreve a dinâmica de convergência da arquitetura, não o desempenho reportado na Tabela 2, que é a união das predições *out-of-fold* das cinco dobras.

A justificativa do particionamento agrupado é anterior a qualquer medição de desempenho e repousa na estrutura do corpus: 32,62% das linhas compartilham texto normalizado com outra linha (Subseção 3.5), de modo que a partição por linha permitiria ao mesmo texto ocupar treino e teste. Duas estimativas da magnitude do efeito foram produzidas em execuções anteriores ao congelamento da base, ambas indicando ganho espúrio entre 0,89 e 1,84 ponto percentual de acurácia. Elas constam do material suplementar com o respectivo protocolo declarado e não são comparáveis às Tabelas 1 e 2, porque foram apuradas sobre outra base, outro denominador e outro rótulo de treino. O estudo de sensibilidade a unidades recorrentes e *dropout*, conduzido no mesmo protocolo anterior, também consta do suplemento: as quatro variantes separam-se por




Figura 6: Trade-off entre acurácia e tempo de treino, modelos clássicos.




Figura 7: Curva de aprendizado do LSTM por época, perda e acurácia em treino e validação.

menos de quatro pontos percentuais entre a melhor e a pior, o que indica baixa sensibilidade do LSTM a esses hiperparâmetros nesta base.

4.9 Robustez estatística: pressupostos e testes de sensibilidade

Antes de qualquer teste inferencial, foram verificados os pressupostos de robustez estatística usuais, a saber, outliers (TUKEY, 1977; HODGE; AUSTIN, 2004), homogeneidade de variância, normalidade, desbalanceamento entre categorias, colinearidade entre modelos, relação entre confiança e acerto e independência das observações, adaptando o protocolo de exploração de dados de Zuur, Ieno e Elphick (2010) da resposta contínua da ecologia para a resposta categórica de classificação de chamados ($n = 13.972$). O teste de Shapiro-Wilk (SHAPIRO; WILK, 1965) foi escolhido por reunir o maior poder entre os testes de normalidade usuais nas comparações de Razali e Wah (2011) e de Ogunleye, Oyejola e Obisesan (2018). Aplicado à distribuição de confiança de cada modelo, sobre subamostra de cinco mil observações com semente fixa, ele rejeita a normalidade a 5% para os sete modelos, confirmando com números a justificativa não paramétrica já adotada na Subseção 3.5. A variância de confiança entre modelos também é fortemente heterogênea, com Levene de 4.216,75 e p praticamente nulo, o que reforça essa escolha.

A independência das observações merece tratamento próprio, porque é o pressuposto que este corpus viola de modo mais evidente. Registros que compartilham texto idêntico não são independentes, e tratá-los como tal estreitaria artificialmente qualquer intervalo. Os intervalos da Tabela 2 vêm, por isso, de *bootstrap* de conglomerados, com mil reamostragens dos 9.735 grupos textuais congelados que compõem as 13.972 linhas avaliadas, com semente fixa, e não de reamostragem por linha.

A contagem de grupos merece uma nota, porque o texto reporta duas: 9.786 na base congelada de 14.060 chamados e 9.735 no recorte de 13.972 linhas. São a mesma partição textual sob denominadores distintos, e a diferença de 51 corresponde aos grupos que saem junto com as 88 linhas fora das partições. O mapa de partições registra 9.734 porque recalcula o agrupamento sobre o texto corrente, e dois chamados tiveram a descrição editada depois do congelamento, um deles passando a coincidir com um grupo já existente. A unidade reproduzível é a congelada, e é ela que sustenta os intervalos aqui reportados.

A ordem dos testes é declarada porque importa. O Cochran Q (COCHRAN, 1950) foi aplicado primeiro à hipótese global de que os sete modelos têm a mesma taxa de acerto, e a rejeita com $Q = 2661,04$ sobre seis graus de liberdade e p praticamente nulo. Só então as comparações pareadas foram conduzidas por McNemar (MCNEMAR, 1947) sobre os 21 pares, com correção de Holm-Bonferroni (HOLM, 1979) aplicada a essa família. Sem o teste global, 21 comparações constituiriam pesca de significância.

Dos 21 pares, 19 são significativos após a correção e 2 não são: Extra Trees contra Regressão Logística e Extra Trees contra SGD, ambos com p ajustado de 0,819. Esses dois pares devem ser lidos como empate dentro do poder do teste, e não como ordenação, o que é coerente com a sobreposição dos intervalos de F1 macro apontada na Subseção 4.2. O LinearSVC supera todos os demais com significância.

A verificação de colinearidade revela um efeito colateral pertinente à decisão de arquitetura. Quatro dos sete modelos apresentam confiança altamente correlacionada entre si, com Fator de Inflação de Variância entre 20,78 e 29,98 (MARQUARDT, 1970), muito acima do limiar convencional de dez, que deve ainda assim ser lido com a cautela recomendada por O'Brien (2007). São o Extra Trees, o Random Forest, a Regressão Logística e o SGD; os três restantes ficam abaixo de 4,3. Modelos redundantes pouco acrescentam em informação independente a um comitê (DIETTERICH, 2000), o que desaconselha combiná-los em *ensemble*. A correlação entre confiança bruta e acerto, por sua vez, é positiva e significativa nos sete modelos, com Spearman entre 0,4809 e 0,6160 e ponto-bisserial entre 0,4500 e 0,6560 ($p < 0,001$ em ambos; KORNROT, 2014), pré-requisito para a calibração discutida na Subseção 4.4 (GUO *et al.*, 2017; MINDERER *et al.*, 2021). A verificação completa dos pressupostos, item a item, com as estatísticas de normalidade, variância, colinearidade e correlação por modelo, consta do material suplementar e é apurada sobre as mesmas predições que sustentam as Tabelas 1 a 5.

4.10 Análise de erro por categoria e matriz de confusão

A avaliação por acurácia global descreve o desempenho médio, mas oculta a distribuição do acerto entre categorias. Esta subseção examina a matriz de confusão de cada modelo contra a categoria de referência revisada, apurada sobre os 13.972 chamados avaliados. As predições não extrapolam a taxonomia de treino, de modo que referência e predições percorrem o mesmo conjunto de 41 categorias.

O contraste entre acurácia e F1 macro é o primeiro achado. Os sete modelos apresentam acurácia entre 0,7088 e 0,8253, faixa de 12 pontos percentuais, ao passo que o F1 macro varia de 0,2951 a 0,6689, faixa de 37 pontos. A dispersão muito maior na segunda métrica indica que os modelos se diferenciam sobretudo no tratamento das categorias de baixa frequência. O Naive Bayes ilustra o caso extremo, pois combina acurácia de 0,7088 com F1 macro de 0,2951, o que corresponde a um classificador que resolve as categorias volumosas e colapsa nas demais. O SGD e a Regressão Logística, embora percam em acurácia para o LinearSVC, alcançam F1 macro equivalente, o que sugere fronteira de decisão mais distribuída entre classes.

A leitura dos pares de maior confusão revela que parte substancial do erro não é aleatória, mas concentrada em fronteiras específicas da taxonomia. No LinearSVC, o par de maior volume ocorre entre **Estrutura Predial > Alvenaria / Pisos / Estrutura e Instalação de Acessórios e Mobiliário > Instalação/reparo de equipamentos**, com 174 casos em um sentido e 107 no sentido inverso. A assimetria indica absorção parcial da segunda categoria pela primeira, e não apenas fronteira mal definida. Seguem-se **Alvenaria** contra **Esquadrias, porta, portão e janelas**, com 106 casos e 31 no inverso, e **Alvenaria**

contra Hidrossanitária > Hidráulica, com 68 e 34. O desequilíbrio é sistemático e reforça a leitura de que Alvenaria opera como categoria de destino para chamados cuja descrição não delimita o sistema predial afetado.

Observa-se ainda a categoria Outros > Erro de chamado entre os pares de maior volume, com 56 casos recebidos de TI / Dados / Rede > Ponto de rede / fibra ótica / Wi-fi e 45 no sentido inverso. Trata-se de categoria residual, cuja atribuição depende de juízo sobre a pertinência do próprio chamado, e não de sua natureza técnica, o que a torna estruturalmente difícil para qualquer modelo baseado em texto.

Soma-se a esse quadro a duplicação taxonômica. A categoria Ar condicionado split existe simultaneamente sob Manutenção Preventiva, com 1.798 chamados, e sob Climatização, com 1.640, e o mesmo desdobramento ocorre com Ar condicionado central, Gerador, Nobreak, Elevador, Telhados, calhas, rufos e Sistemas de combate a incêndio. O critério que separa esses pares é a natureza preventiva ou corretiva da intervenção, informação que o texto do chamado frequentemente não explicita, de modo que uma fração do erro medido não decorre de limitação do classificador, mas da exigência de inferir do texto uma distinção que nele não está registrada. A cauda de categorias raras impõe restrição análoga: das 50 categorias históricas, 14 reúnem menos de trinta chamados e 6 reúnem menos de dez, suporte em que um único acerto desloca o F1 em dezenas de pontos percentuais.

Depreende-se do conjunto dessas observações uma recomendação de governança anterior à escolha do modelo. Antes de perseguir ganho de acurácia por meio de arquiteturas mais custosas, convém revisar a taxonomia institucional, unificando os pares que nomeiam o mesmo objeto e explicitando o critério de natureza da manutenção no formulário de abertura do chamado. Essa intervenção atua sobre a origem do erro, enquanto a substituição do classificador atua apenas sobre seu efeito.

4.11 Desempenho por volume de categoria e por natureza da manutenção

O F1 macro atribui o mesmo peso a uma categoria de dois chamados e a outra de dois mil, o que torna a métrica agregada pouco informativa quando a distribuição de volume é acentuadamente desigual. Aplicou-se, por conseguinte, uma curva ABC sobre o suporte das 41 categorias avaliadas. A classe A reúne o menor conjunto de categorias que acumula ao menos 80% do volume, a classe B corresponde ao intervalo entre 80% e 95%, e a classe C abrange o restante. A partição resultante concentra 11.433 chamados, equivalentes a 81,83% do total, em apenas 12 categorias; a classe B reúne outras 12 categorias e 1.912 chamados; a classe C reúne 17 categorias e 627 chamados, ou 4,49% do total.

O F1 macro recalculado dentro de cada classe demonstra que a distância entre acurácia e F1 macro decorre da composição da métrica, e não de falha generalizada do classificador. O LinearSVC alcança 0,8207 na classe A e 0,5018 na classe C, de modo que o valor agregado de 0,6684 constitui média entre dois regimes distintos de desempenho. A ordenação dos modelos permanece estável nas três classes, o que indica que o recorte não altera a comparação entre arquiteturas, apenas a interpretação de sua magnitude. Constata-se ainda que o Naive Bayes é o único modelo cujo colapso alcança a classe B, com 0,2527, ao passo que os demais preservam desempenho superior a 0,63 nas duas primeiras classes. Os valores por modelo e classe constam do material suplementar.

O segundo recorte separa os chamados pela natureza da intervenção. Adotou-se classificação em três tipos, e não a dicotomia usual entre preventivo e corretivo, porque a taxonomia institucional abriga famílias que não descrevem serviço de manutenção. Encontram-se nessa condição o registro indevido de chamado, a contratação de posto de trabalho, o fornecimento de materiais e a execução de reformas. Essas famílias somam 585 chamados, correspondentes a 4,19% das linhas avaliadas, e sua atribuição indiscriminada à manutenção corretiva elevaria o denominador desta em cerca de 7% relativos, com efeito direto sobre qualquer razão calculada entre as duas naturezas. Sob o critério adotado, a manutenção preventiva responde por 4.902 chamados (35,09%) e a corretiva por 8.485 (60,73%).

A projeção da referência revisada e das predições para o nível de tipo eleva o desempenho a outro patamar. O LinearSVC alcança 0,9443 de acurácia nessa granularidade, contra 0,8253 na tarefa de 41 categorias, com F1 de 0,9742 na manutenção preventiva e de 0,9547 na corretiva. A distinção entre preventivo e corretivo, apontada na Subseção 4.10 como origem taxonômica de parte do erro por categoria, resolve-se com folga quando lida no nível em que a decisão de gestão efetivamente ocorre.

Toda a perda de desempenho observada nessa projeção concentra-se no terceiro tipo, cujo F1 não ultrapassa 0,5330 em nenhum dos sete modelos e recua a 0,2684 no Naive Bayes, resultado coerente com a natureza dessas categorias, cuja atribuição depende de juízo administrativo sobre a pertinência do próprio chamado e não de sua descrição técnica. Cabe registrar a inversão de ordenação entre as duas métricas nessa granularidade: o Extra Trees lidera a acurácia, com 0,9497, ao passo que o LinearSVC lidera o F1 macro, com 0,8180, precisamente por ir melhor na classe difícil. Reportar apenas a acurácia ocultaria a diferença, e depreende-se que a escolha do classificador depende tanto do nível de agregação em que a decisão será tomada quanto da métrica que ela privilegia.

A curva ABC recalculada dentro de cada tipo delimita o conjunto mínimo de categorias que sustenta cada leitura. Na manutenção preventiva, quatro categorias concentram 83,46% do volume do tipo, e nelas o LinearSVC alcança F1 macro de 0,9727. Na corretiva são necessárias sete categorias para cobrir 81,76% do tipo, com 0,7835, valor sensivelmente inferior e compatível com a ambiguidade de fronteira descrita na subseção anterior. No conjunto de não manutenção, as quatro categorias que cobrem 89,06% do tipo alcançam apenas 0,5184, o que confirma a dificuldade como propriedade do tipo, e não da cauda de baixa frequência. O detalhamento por classe e por tipo consta do material suplementar.

Depreende-se do conjunto dessas medições uma hierarquia de confiabilidade que orienta a incorporação da classificação automática a indicadores institucionais de infraestrutura. A contagem por tipo de manutenção constitui a leitura mais segura, com erro agregado inferior a 2% na classe preventiva, e prescinde de revisão caso a caso. A leitura por categoria mostra-se confiável apenas nas categorias de classe A do respectivo tipo, condição satisfeita por quatro categorias preventivas e sete corretivas, que reúnem 11.028 chamados e estão discriminadas na Tabela A2. Nas classes B e C, e em toda a família de não manutenção, o desempenho medido não autoriza uso automático. Recomenda-se, nesses casos, o encaminhamento a revisão humana ou a agregação em rubrica única, procedimento que preserva a totalidade do volume sem atribuir às frações menores uma precisão que a medição não sustenta.

4.12 Camada explícita de regras de periodicidade

O desenho do estudo previa medir, e não presumir, o valor de uma camada de regras de domínio sobre a predição estatística. A regra implementada atribui categoria preventiva quando o chamado reúne, no mesmo texto, um termo de periodicidade e um termo de equipamento, e abstém-se nos demais casos. São 19 termos de periodicidade e 31 de equipamento. A avaliação usa as mesmas partições e os mesmos registros da comparação principal, e em nenhuma configuração a referência humana é alterada.

A regra dispara em 4.487 dos 13.972 registros, quase um terço do corpus, e ainda assim melhora o F1 macro de apenas três dos sete modelos. O ganho concentra-se onde o classificador é fraco: o Naive Bayes sobe 0,0586 no F1 macro, ao passo que Extra Trees e Random Forest perdem 0,0038 cada, e o LinearSVC perde 0,0017. Nos chamados de referência preventiva a acurácia sobe em todos os modelos, mas o efeito é de segunda ordem fora do Naive Bayes, entre 0,0020 e 0,0060.

O número que explica o padrão é o de conflitos. Como a regra depende apenas do texto, ela dispara no mesmo conjunto de registros para os sete modelos; o que varia é a predição que ela substitui. No LinearSVC, os 4.487 disparos produzem apenas 31 divergências, nas quais a regra acerta 11 vezes e o modelo, 13. No Naive Bayes, os mesmos disparos produzem 219 divergências, com a regra acertando 201 contra 9 do modelo.

A leitura correta, portanto, não é que regras de domínio funcionam, e sim que elas são redundantes diante de um classificador estatístico competente. Os modelos já capturam implicitamente os sinais de periodicidade presentes no texto, e a camada explícita apenas repete o que eles fazem, com o custo adicional de manter uma tabela de termos. Trata-se de resultado negativo, contrário à expectativa que motivou o teste, e com implicação de desenho: o ganho do fluxo híbrido está no eixo humano-IA, tratado na Subseção 4.4, e não no eixo regra-modelo.

5. DISCUSSÃO

5.1 Concordância histórica, acerto contra a referência e custo do BERTimbau

A comparação entre concordância histórica (Subseção 4.1) e desempenho contra a referência humana (Subseção 4.2) revela que as duas grandezas não são intercambiáveis. A acurácia do LinearSVC (82,53%) supera

sua concordância com o histórico (79,61%) em 2,92 pontos percentuais. A diferença mede o efeito das 598 correções sobre a avaliação: ao substituir a categoria histórica pela categoria revisada, parte das divergências que seriam contabilizadas como erro do modelo passa a ser reconhecida como erro do registro administrativo.

Com a revisão estendida ao corpus integral, a diferença deixa de depender de qualquer recorte amostral e passa a ser propriedade medida da base. Em 598 dos 14.060 chamados, ou 4,25%, o avaliador rejeitou a categoria registrada e definiu outra, o que confirma nos dados a hipótese de rótulos ruidosos sustentada pela literatura (KEJRIWAL *et al.*, 2024; ZHANG *et al.*, 2025). A estimativa é específica deste corpus e desta taxonomia, e sua transposição a outras instituições exige nova revisão.

Convém observar que 4,25% é uma taxa de erro baixa para um rótulo administrativo, e isso decorre do modo como ele é produzido: a categoria não é atribuição isolada do demandante, mas resultado de registro seguido de verificação por equipe técnica. O que os modelos acompanham, portanto, não é um rótulo ingênuo, e essa qualidade da linha de base é o que torna negativo o ganho de reclassificação discutido na Subseção 5.2.

O BERTimbau não integra essa comparação, e a razão é computacional, não de desempenho. O ajuste fino custa 6,44 horas por dobra em processador sem acelerador gráfico, contra um teto de seis horas por execução, de modo que nem uma dobra completa cabe na infraestrutura disponível (Subseção 4.3). Nada se afirma aqui sobre sua qualidade relativa: o modelo não foi avaliado sob este protocolo, e rankings produzidos sob protocolos distintos não sustentam comparação direta. A execução *out-of-fold* integral com aceleração por unidade de processamento gráfico permanece como trabalho futuro.

5.2 Reclassificação, ambiguidade taxonômica e calibração

O resultado da reclassificação (Subseção 4.5) contraria a expectativa que motivou o estudo e tem consequência operacional direta. O ganho líquido de corrigir chamados já classificados é negativo em todos os sete modelos, e a magnitude do prejuízo acompanha, na ordem inversa, o desempenho de cada um. Não se trata de nuance entre modelos, e sim de veredito sobre a tarefa: nenhum classificador aqui avaliado é candidato a reclassificar a base histórica em massa.

A explicação é aritmética antes de ser metodológica. Com a categoria histórica correta em 95,75% dos registros, o espaço de correção disponível é de 4,25%, e qualquer divergência sistemática entre modelo e histórico tende a cair fora dele. O melhor modelo diverge 2.849 vezes para acertar 475: aproximadamente um acerto para cada cinco prejuízos. Convém explicitar por que versões anteriores desta análise chegaram a sinal oposto. Contabilizar o ganho contra a decisão revisada onde ela existe e contra o próprio histórico onde não existe mistura duas referências de naturezas distintas e infla o resultado, porque na segunda parcela o modelo é premiado por concordar com o rótulo que se pretendia auditar. Com referência humana disponível para todo o corpus, a comparação passa a ser única e o sinal se inverte.

Disso não decorre que a classificação automática seja inútil neste domínio, e sim que seu uso defensável é prospectivo e seletivo. Sobre chamados novos, não há rótulo prévio correto a ser degradado. Sobre a base histórica, o encaminhamento adequado é a automação condicionada à confiança da Subseção 4.4, que preserva o registro nas faixas em que o modelo não tem vantagem demonstrável sobre ele.

A camada de entropia de Shannon e divergência de Jensen-Shannon (Subseção 4.6) não substitui as métricas supervisionadas ou a revisão humana, mas amplia o repertório de governança ao separar três fenômenos que a acurácia isolada tende a confundir: o erro de modelo, a ambiguidade genuína da taxonomia institucional e a heterogeneidade natural da distribuição de chamados. Os sete modelos são unânimes em 60,44% dos registros, e os 2.285 chamados em que os votos se espalham por três ou mais categorias, ou 16,35%, oferecem critério de priorização de auditoria distinto do simples corte por baixa confiança de um único classificador. A dispersão das predições e a aderência à distribuição histórica separam-se neste corpus, pois o LSTM lidera a diversidade de categorias previstas e o LinearSVC apresenta a menor divergência frente ao histórico.

A calibração transforma essa leitura em procedimento operável (Subseção 4.4). A confiança bruta não é probabilidade, e o caso do LinearSVC é extremo: seu erro de calibração esperado de 0,6925 cai a 0,0178 após ajuste isotônico em dobra interna (PLATT, 1999; GUO *et al.*, 2017). Com escores calibrados, o alvo de 0,95 de acurácia é atingido automatizando cerca de dois terços do volume e encaminhando o terço restante à revisão humana. Essa é a forma defensável de cumprir o critério de sucesso do protocolo, que associa

confiança alta a acerto alto, sem depender de faixas de confiança bruta cuja escala não tem interpretação probabilística.

Duas ressalvas qualificam a leitura. A cobertura reportada é média entre as cinco dobras e varia entre elas, e parte das acurácias seletivas fica poucos milésimos abaixo do alvo, consequência esperada de escolher o limiar sem acesso ao conjunto de teste. Ademais, o calibrador é ajustado sobre escores de um modelo treinado em três dobras e aplicado a escores de um modelo treinado em quatro, troca deliberada entre ausência de vazamento e casamento exato de distribuição.

5.3 Limitações

Os dados provêm de uma única instituição federal de ensino superior, com textos em português brasileiro e taxonomia institucional própria. Estender o desempenho relatado a outras instituições, taxonomias ou idiomas exige validação externa.

A conferência humana cobre o corpus integral, o que afasta o viés de seleção que limitaria a leitura caso apenas parte dos chamados tivesse sido revista. Permanece, contudo, a limitação de que a categoria de referência é produto de julgamento humano realizado por um único avaliador, sem medida de concordância entre revisores independentes. A literatura registra variabilidade relevante entre anotadores em tarefas dessa natureza, de modo que a referência aqui utilizada não deve ser tratada como isenta de erro.

A taxonomia institucional apresenta pares de categorias que nomeiam o mesmo objeto sob famílias distintas, discutidos na Subseção 4.6. Nesses pares, a atribuição depende de um critério de natureza da manutenção que o texto do chamado nem sempre permite inferir, o que impõe teto ao desempenho alcançável por qualquer classificador. A validação confirma a necessidade de governança sobre os rótulos, mas não autoriza estimar, com o desenho atual, a prevalência de categorias históricas incorretas.

As métricas valem para as 41 categorias com suporte nas cinco dobras, e não para a taxonomia inteira. As nove categorias excluídas são justamente as mais raras, de modo que o F1 macro reportado é, em alguma medida, otimista em relação ao que se obteria sobre a taxonomia completa. A Tabela A3 torna a diferença auditável, mas não a elimina.

Uma restrição adicional decorre do congelamento. As partições são fixadas por um mapa versionado de grupos textuais, e não recalculadas a cada execução, o que garante reprodutibilidade mas dissocia o experimento do crescimento da base operacional. Três registros tiveram o texto editado após o congelamento, o que basta para explicar diferenças de última casa decimal em execuções futuras.

O BERTimbau não foi avaliado sob este protocolo, e a limitação é de infraestrutura. Nada se afirma sobre seu desempenho relativo, e a execução *out-of-fold* integral com aceleração por unidade de processamento gráfico permanece como trabalho futuro. A LSTM, por sua vez, treina *embeddings* do zero, sem vetores pré-treinados em português, condição que limita a comparação entre arquiteturas neurais.

5.4 Contribuição para a governança preditiva da manutenção

A contribuição deste artigo não termina na categoria atribuída a cada chamado. Ao converter texto livre em categoria, criticidade e confiança auditáveis, o protocolo produz a camada de dados estruturados sobre a qual a gestão pública de manutenção predial pode operar de forma preditiva, e não apenas reativa. Previsão de demanda por categoria, priorização de intervenções segundo critérios de sustentabilidade e leitura territorial do parque edificado dependem, todas, de uma base classificada de modo confiável. Este artigo entrega essa fundação e demonstra que ela exige conferência humana para se sustentar.

A exigência de confiabilidade tem razão específica quando a camada classificada alimenta modelos de série temporal por categoria. Um chamado atribuído à categoria incorreta não produz apenas um erro de rótulo: subtrai uma ocorrência da série de uma categoria e a acrescenta à série de outra, deslocando duas séries em sentidos opostos. O efeito propaga-se à estimativa de demanda e de custo por categoria e, em seguida, ao ordenamento de prioridades que dela deriva, de modo que o erro de classificação se converte em erro de alocação de recurso. Sob essa perspectiva, o acerto validado deixa de ser métrica de comparação entre modelos e passa a operar como requisito de engenharia da camada preditiva, o que justifica o esforço de conferência integral aqui descrito.

O recorte apresentado na Subseção 4.11 indica, ademais, em que ordem essa camada pode ser incorporada a indicadores institucionais de sustentabilidade e de desempenho da infraestrutura. A razão entre manutenção preventiva e corretiva, que expressa a maturidade da gestão do parque edificado e alimenta metas de conservação patrimonial e de uso eficiente de recursos, é justamente a leitura de menor erro medido, razão pela qual pode ser publicada sem revisão caso a caso. Já os indicadores desagregados por categoria exigem restrição às classes de maior volume dentro de cada tipo, sob pena de atribuir a frações residuais do corpus uma precisão que a medição não sustenta. Essa hierarquia converte o diagnóstico de desempenho em critério operacional de publicação de indicador, e não apenas em ressalva metodológica.

6. CONSIDERAÇÕES FINAIS

A contribuição central deste artigo é metodológica. O protocolo separa a concordância com o rótulo histórico do acerto contra a referência humana final e mede as duas grandezas sobre a mesma execução, com partições agrupadas por texto que impedem a repetição de chamados entre treino e teste. Essa separação evita tratar o histórico como verdade automática e, ao mesmo tempo, impede concluir que toda divergência da classificação automática representa correção do registro original.

Na avaliação sobre 13.972 chamados em 41 categorias, o LinearSVC alcança 82,53% de acurácia (IC95%: 81,15%–83,78%) e supera os demais modelos com significância estatística, ao custo de treino de 2,44 s sobre a base inteira. A recomendação operacional é usá-lo com calibração isotônica e automação condicionada à confiança, regime em que cerca de dois terços do volume podem ser decididos automaticamente com acurácia próxima de 0,95 e o terço restante encaminhado à revisão humana.

O achado que mais altera a orientação prática é negativo. A reclassificação automática da base histórica produz prejuízo líquido em todos os sete modelos, porque a referência humana confirma a categoria registrada em 95,75% dos casos e o espaço disponível para correção é estreito demais para compensar os erros introduzidos. A classificação automática, neste corpus, serve ao chamado novo e à triagem assistida, não à correção retroativa em massa. Também é negativo, e igualmente útil, o resultado da camada explícita de regras de periodicidade: ela é redundante diante de um classificador estatístico competente, que já captura esses sinais a partir do texto.

A finalização metodológica exige reconhecer o que os dados não respondem. A referência provém de avaliador único, sem medida de concordância entre revisores independentes, e a taxonomia institucional mantém pares de categorias que nomeiam o mesmo objeto sob famílias distintas. A próxima etapa deve incorporar revisão por mais de um avaliador nos pares ambíguos identificados na Subseção 4.6 e submeter a própria taxonomia à revisão. Em paralelo, a validação externa em outras instituições e a execução *out-of-fold* integral do BERTimbau, viável em infraestrutura com acelerador gráfico, poderão testar a estabilidade dos resultados sob taxonomias e volumes distintos. A camada classificada poderá então alimentar modelos de previsão de demanda e de priorização multicritério de intervenções sobre uma base cuja incerteza e origem das decisões permanecem auditáveis.

REFERÊNCIAS

- ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. ABNT NBR 5674: Manutenção de edificações: Requisitos para o sistema de gestão de manutenção. Rio de Janeiro: ABNT, 2012.
- BENAVOLI, A.; CORANI, G.; MANGILI, F. Should we really use post-hoc tests based on mean-ranks? *Journal of Machine Learning Research*, v. 17, n. 5, p. 1–10, 2016.
- BENDER, E. M.; GEBRU, T.; McMILLAN-MAJOR, A.; SHMITCHELL, S. On the dangers of stochastic parrots: can language models be too big? In: *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency (FAccT '21)*. New York: ACM, 2021. p. 610–623.
- BOUABDALLAOUI, Y.; LAFHAJ, Z.; YIM, P.; DUCOULOMBIER, L.; BENNADJI, B. Natural Language Processing Model for Managing Maintenance Requests in Buildings. *Buildings*, v. 10, n. 9, art. 160, 2020.
- BROWN, T. B.; MANN, B.; RYDER, N.; SUBBIAH, M.; KAPLAN, J.; DHARIWAL, P.; NEELAKANTAN, A. et al. Language models are few-shot learners. In: *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*. Red Hook: Curran Associates, 2020. p. 1877–1901.

- CAPRA, F. A teia da vida: uma nova compreensão científica dos sistemas vivos. São Paulo: Cultrix, 1996.
- CHAN, J. Y.-L.; LEOW, S. M. H.; BEA, K. T.; CHENG, W. K.; PHOONG, S. W.; HONG, Z.-W.; CHEN, Y.-L. Mitigating the multicollinearity problem and its machine learning approach: a review. *Mathematics*, v. 10, n. 8, art. 1283, 2022.
- COCHRAN, W. G. The comparison of percentages in matched samples. *Biometrika*, v. 37, n. 3-4, p. 256–266, 1950.
- COCHRAN, W. G. Sampling techniques. 3. ed. New York: John Wiley & Sons, 1977.
- COHEN, J. A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, v. 20, n. 1, p. 37–46, 1960.
- DEMŠAR, J. Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, v. 7, p. 1–30, 2006.
- DEVLIN, J.; CHANG, M.-W.; LEE, K.; TOUTANOVA, K. BERT: Pre-training of deep bidirectional transformers for language understanding. In: CONFERENCE OF THE NORTH AMERICAN CHAPTER OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS, 2019, Minneapolis. Proceedings [...]. Minneapolis: ACL, 2019. p. 4171–4186.
- DICICCIO, T. J.; EFRON, B. Bootstrap confidence intervals. *Statistical Science*, v. 11, n. 3, p. 189–228, 1996.
- DIETTERICH, T. G. Ensemble methods in machine learning. In: INTERNATIONAL WORKSHOP ON MULTIPLE CLASSIFIER SYSTEMS, 1., 2000, Cagliari. Proceedings [...]. Berlin: Springer, 2000. p. 1–15. (Lecture Notes in Computer Science, v. 1857).
- EFRON, B. Bootstrap methods: another look at the jackknife. *The Annals of Statistics*, v. 7, n. 1, p. 1–26, 1979.
- EFRON, B.; TIBSHIRANI, R. J. An introduction to the bootstrap. New York: Chapman & Hall/CRC, 1993.
- GALKE, L.; SCHERP, A. Bag-of-words vs. graph vs. sequence in text classification: questioning the necessity of text-graphs and the surprising strength of a wide MLP. In: ANNUAL MEETING OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS, 60., 2022, Dublin. Proceedings [...]. Dublin: ACL, 2022. p. 4038–4051.
- GRAVES, A.; SCHMIDHUBER, J. Framewise phoneme classification with bidirectional LSTM and other neural network architectures. *Neural Networks*, v. 18, n. 5-6, p. 602–610, 2005.
- GRIMM, N. B.; FAETH, S. H.; GOLUBIEWSKI, N. E.; REDMAN, C. L.; WU, J.; BAI, X.; BRIGGS, J. M. Global change and the ecology of cities. *Science*, v. 319, n. 5864, p. 756–760, 2008.
- GUO, C.; PLEISS, G.; SUN, Y.; WEINBERGER, K. Q. On calibration of modern neural networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING, 34., 2017, Sydney. Proceedings [...]. Sydney: PMLR, 2017. p. 1321–1330.
- HODGE, V. J.; AUSTIN, J. A survey of outlier detection methodologies. *Artificial Intelligence Review*, v. 22, n. 2, p. 85–126, 2004.
- HOLM, S. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, v. 6, n. 2, p. 65–70, 1979.
- JOACHIMS, T. Text categorization with support vector machines: learning with many relevant features. In: EUROPEAN CONFERENCE ON MACHINE LEARNING, 10., 1998, Chemnitz. Proceedings [...]. Berlin: Springer, 1998. p. 137–142.
- KEJRIWAL, M.; SANTOS, H.; SHEN, K.; MULVEHILL, A. M.; MCGUINNESS, D. L. A noise audit of human-labeled benchmarks for machine commonsense reasoning. *Scientific Reports*, v. 14, art. 8609, 2024.

- KOHAVI, R. A study of cross-validation and bootstrap for accuracy estimation and model selection. In: INTERNATIONAL JOINT CONFERENCE ON ARTIFICIAL INTELLIGENCE, 14., 1995, Montreal. Proceedings [...]. San Francisco: Morgan Kaufmann, 1995. p. 1137–1143.
- KORNBROT, D. Point biserial correlation. In: Wiley StatsRef: Statistics Reference Online. Chichester: Wiley, 2014.
- LANDIS, J. R.; KOCH, G. G. The measurement of observer agreement for categorical data. *Biometrics*, v. 33, n. 1, p. 159–174, 1977.
- LIMA, L. F. M.; MAROLDI, A. M.; SILVA, D. V. O. da; HAYASHI, C. R. M.; HAYASHI, M. C. P. I. Métricas científicas em estudos bibliométricos: detecção de outliers para dados univariados. *Em Questão*, Porto Alegre, v. 23, p. 254–273, 2017.
- LIN, J. Divergence measures based on the Shannon entropy. *IEEE Transactions on Information Theory*, v. 37, n. 1, p. 145–151, 1991. DOI: 10.1109/18.61115.
- LI, Y.; LIU, Y.; ZHANG, J.; CAO, L.; WANG, Q. Automated analysis and assignment of maintenance work orders using natural language processing. *Automation in Construction*, v. 165, art. 105501, 2024.
- LIU, Z.; BENGE, C.; JIANG, S. Ticket-BERT: labeling incident management tickets with language models. *arXiv:2307.00108*, 2023.
- MARCUZZO, M.; ZANGARI, A.; GIUDICE, L.; GASPARETTO, A.; SCHIAVINATO, M.; ALBARELLI, A. A multi-level approach for hierarchical Ticket Classification. In: PROCEEDINGS OF THE 8TH WORKSHOP ON NOISY USER-GENERATED TEXT (W-NUT 2022), 2022. *Anais [...]*. Association for Computational Linguistics, 2022. p. 201–214.
- MARQUARDT, D. W. Generalized inverses, ridge regression, biased linear estimation, and nonlinear estimation. *Technometrics*, v. 12, n. 3, p. 591–612, 1970.
- MARTINS, R. F. B.; ESPEJO, M. M. S. B. Análise de custos de manutenção predial em uma universidade federal brasileira com uso do modelo de SES. *ABCustos*, São Leopoldo, v. 19, n. 1, p. 79–98, 2024.
- MCNEMAR, Q. Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, v. 12, n. 2, p. 153–157, 1947.
- MINDERER, M.; DJOLONGA, J.; ROMIJNDERS, R.; HUBIS, F.; ZHAI, X.; HOULSBY, N.; TRAN, D.; LUCIC, M. Revisiting the calibration of modern neural networks. In: CONFERENCE ON NEURAL INFORMATION PROCESSING SYSTEMS, 35., 2021. *Advances in Neural Information Processing Systems*, v. 34, 2021.
- MOHAMMED, A. S.; AMOAH, C. Integration of technology in decision-making in university facilities management: a literature review. *Facilities*, v. 43, n. 13/14, p. 1018–1052, 2025.
- MORAIS, L. S. R. de; PAULA, H. M. de; REIS, R. P. A. Promoção da eficiência da manutenção predial em edificações públicas: abordagem baseada em registros de ordens de serviço. *Paranoá*, Brasília, v. 16, n. 34, p. 1–18, 2023. DOI: 10.18830/issn.1679-0944.n34.2023.08.
- NEMENYI, P. B. Distribution-free multiple comparisons. 1963. Tese (Doutorado em Estatística) — Princeton University, Princeton, 1963.
- NOMA, H.; SHINOZAKI, T.; IBA, K.; TERAMUKAI, S.; FURUKAWA, T. A. Confidence intervals of prediction accuracy measures for multivariable prediction models based on the bootstrap-based optimism correction methods. *Statistics in Medicine*, v. 40, n. 26, p. 5691–5701, 2021.
- O'BRIEN, R. M. A caution regarding rules of thumb for variance inflation factors. *Quality & Quantity*, v. 41, n. 5, p. 673–690, 2007.
- ODUM, H. T. *Environment, power, and society*. New York: Wiley-Interscience, 1971.
- OGUNLEYE, L. I.; OYEJOLA, B. A.; OBISESAN, K. O. Comparison of some common tests for normality. *International Journal of Probability and Statistics*, v. 7, n. 5, p. 130–137, 2018.

- PAMPANA, A. K. et al. Data-driven analysis for facility management in higher education institution. *Buildings*, v. 12, art. 2094, 2022.
- PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.
- PLATT, J. C. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. In: SMOLA, A. J. et al. (Ed.). *Advances in Large Margin Classifiers*. Cambridge: MIT Press, 1999. p. 61–74.
- RAZALI, N. M.; WAH, Y. B. Power comparisons of Shapiro-Wilk, Kolmogorov-Smirnov, Lilliefors and Anderson-Darling tests. *Journal of Statistical Modeling and Analytics*, v. 2, n. 1, p. 21–33, 2011.
- SALTON, G.; BUCKLEY, C. Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, v. 24, n. 5, p. 513–523, 1988.
- SCHWARTZ, R.; DODGE, J.; SMITH, N. A.; ETZIONI, O. Green AI. *Communications of the ACM*, v. 63, n. 12, p. 54–63, 2020.
- SHANNON, C. E. A mathematical theory of communication. *Bell System Technical Journal*, v. 27, n. 3, p. 379–423, jul. 1948; v. 27, n. 4, p. 623–656, out. 1948.
- SHAPIRO, S. S.; WILK, M. B. An analysis of variance test for normality (complete samples). *Biometrika*, v. 52, n. 3-4, p. 591–611, 1965.
- SOKOLOVA, M.; LAPALME, G. A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, v. 45, n. 4, p. 427–437, 2009.
- SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. BERTimbau: pretrained BERT models for Brazilian Portuguese. In: *BRAZILIAN CONFERENCE ON INTELLIGENT SYSTEMS*, 9., 2020. *Proceedings [...]*. Cham: Springer, 2020. p. 403–417. DOI: 10.1007/978-3-030-61377-8_28.
- SPEARMAN, C. The proof and measurement of association between two things. *American Journal of Psychology*, v. 15, n. 1, p. 72–101, 1904.
- SUNDARAM, S.; ZEID, A. Technical Language Processing for Prognostics and Health Management: applying text similarity and topic modeling to maintenance work orders. *Journal of Intelligent Manufacturing*, v. 36, p. 1637–1657, 2025.
- TATE, R. F. Correlation between a discrete and a continuous variable. Point-biserial correlation. *The Annals of Mathematical Statistics*, v. 25, n. 3, p. 603–607, 1954.
- TREVISIO, M. et al. Efficient methods for Natural Language Processing: a survey. *Transactions of the Association for Computational Linguistics*, v. 11, p. 826–860, 2023.
- TUKEY, J. W. *Exploratory data analysis*. Reading: Addison-Wesley, 1977.
- VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; KAISER, L.; POLOSUKHIN, I. Attention is all you need. In: *Advances in Neural Information Processing Systems 30 (NIPS 2017)*. Red Hook: Curran Associates, 2017. p. 5998–6008.
- WONGPAKARAN, N.; WONGPAKARAN, T.; WEDDING, D.; GWET, K. L. A comparison of Cohen’s Kappa and Gwet’s AC1 when calculating inter-rater reliability coefficients: a study conducted with personality disorder samples. *BMC Medical Research Methodology*, v. 13, art. 61, 2013.
- ZHANG, H.; ZHANG, Y.; LI, J.; LIU, J.; JI, L. A survey on learning with noisy labels in Natural Language Processing: how to train models with label noise. *Engineering Applications of Artificial Intelligence*, v. 146, art. 110157, 2025.
- ZUUR, A. F.; IENO, E. N.; ELPHICK, C. S. A protocol for data exploration to avoid common statistical problems. *Methods in Ecology and Evolution*, v. 1, n. 1, p. 3–14, 2010.

APÊNDICE A — CATEGORIAS DO CORPUS E DAS PARTIÇÕES

A Tabela A1 apresenta as 50 categorias históricas presentes nos 14.060 chamados da base congelada, ordenadas por frequência decrescente e distribuídas em dois blocos paralelos para reduzir a extensão do apêndice. As Tabelas A2 e A3 decompõem o denominador das métricas: a primeira lista as 41 categorias que sustentaram suporte nas cinco dobras e compõem as 13.972 linhas avaliadas, e a segunda, as 9 que ficaram de fora.

Tabela A1 Distribuição dos chamados por categoria histórica.

Categoria histórica	Quantidade	Categoria histórica	Quantidade
Manutenção Preventiva > Ar condicionado split	1.798	Manutenção Preventiva > Sistemas de combate a incêndio (extintores, hidrantes)	66
Climatização > Ar condicionado split	1.640	Estrutura Predial > Pintura	58
Estrutura Predial > Alvenaria / Pisos / Estrutura	1.302	Instalação de Acessórios e Mobiliário > Placas de identificação	54
Hidrossanitária > Hidráulica	1.282	Manutenção Preventiva > Telhados, calhas, rufos, etc.	44
Manutenção Preventiva > Gerador	1.215	TI / Dados / Rede > Coleta de dados	40
Estrutura Predial > Esquadrias, porta, portão e janelas	977	Elétrica > Gerador	38
Elétrica > Instalações elétricas	945	Hidrossanitária > Bomba	38
Elétrica > Iluminação	758	Climatização > Ar condicionado central	37
Manutenção Preventiva > Quadros Elétricos	578	Manutenção Preventiva > Esgoto	33
TI / Dados / Rede > Ponto de rede / fibra ótica / Wi-fi	404	Manutenção Preventiva > Hidráulica	33
Instalação de Acessórios e Mobiliário > Instalação/reparo de equipamentos (Suportes de TV, acessórios de banheiro e quadro branco)	290	Outros > Outros	33
Manutenção Preventiva > Reservatório	279	Segurança contra Incêndio > Sistemas de combate a incêndio (extintores, hidrantes)	29
Manutenção Preventiva > Vistoria em Instalações	247	Projetos e Reformas > Projeto	25
Outros > Erro de chamado	245	Equipamentos de Transporte > Elevador	22
Estrutura Predial > Infiltração	215	Elétrica > Subestação	18
Estrutura Predial > Telhados, calhas, rufos, etc.	207	Hidrossanitária > ETA / ETE	16
Manutenção Preventiva > Ar condicionado central	165	Suprimentos / Apoio Técnico > Limpeza de equipamentos, ambiente e mobiliário	14
Estrutura Predial > Forro	146	Manutenção Preventiva > Poços artesianos	13
Manutenção Preventiva > Iluminação	132	Manutenção Preventiva > Nobreak	10
Elétrica > Nobreak	128	Elétrica > Sistema Fotovoltaico (FV)	7
Área Externa e Ambiental > Manutenção área externa / meio ambiente / Poda de árvore / Roçagem	109	Área Externa e Ambiental > Drenagem	4
Posto de trabalho > Contratação de Posto de trabalho	102	Estrutura Predial > Instalações Especiais (gás, ar comprimido, etc.)	3
Manutenção Preventiva > Elevador	86	Manutenção Preventiva > Aplicação cupinizada	3
Suprimentos / Apoio Técnico > Materiais	85	Manutenção Preventiva > Bomba	3
Projetos e Reformas > Reforma	83	Suprimentos / Apoio Técnico > Transporte	1
Total geral	14.060		

Fonte: elaboração própria a partir do corpus analisado.

Tabela A2 Categorias da referência revisada avaliadas na rodada, por tipo de manutenção e classe da curva ABC interna ao tipo (n = 13.972; 41 categorias). O percentual é relativo ao volume do próprio tipo e o F1 corresponde ao LinearSVC. P, preventiva; C, corretiva; NM, não manutenção. Enquadram-se em não manutenção as famílias que não descrevem serviço de manutenção predial, a saber, Outros, Suprimentos / Apoio Técnico, Posto de trabalho e Projetos e Reformas. A família TI / Dados / Rede permanece em manutenção corretiva por consistir predominantemente em reparo de infraestrutura predial.

Categoria de referência	Tipo	n	% do tipo	Classe	F1
Preventiva	P	4.902	100,00		
Manutenção Preventiva > Ar condicionado split	P	1.987	40,53	A	0,9972
Manutenção Preventiva > Gerador	P	1.208	24,64	A	0,9954
Manutenção Preventiva > Quadros Elétricos	P	578	11,79	A	0,9843
Manutenção Preventiva > Reservatório	P	318	6,49	A	0,9139
Manutenção Preventiva > Vistoria em Instalações	P	244	4,98	B	0,9419
Manutenção Preventiva > Ar condicionado central	P	168	3,43	B	0,9970
Manutenção Preventiva > Iluminação	P	132	2,69	B	0,9535
Manutenção Preventiva > Elevador	P	86	1,75	B	0,9655
Manutenção Preventiva > Sistemas de combate a incêndio (extintores, hidrantes)	P	66	1,35	C	0,8905
Manutenção Preventiva > Telhados, calhas, rufos, etc.	P	44	0,90	C	0,2162
Manutenção Preventiva > Esgoto	P	31	0,63	C	0,4286
Manutenção Preventiva > Hidráulica	P	27	0,55	C	0,0000
Manutenção Preventiva > Poços artesianos	P	13	0,27	C	1,0000
Corretiva	C	8.485	100,00		
Climatização > Ar condicionado split	C	1.448	17,07	A	0,9550
Hidrossanitária > Hidráulica	C	1.263	14,89	A	0,8651
Estrutura Predial > Alvenaria / Pisos / Estrutura	C	1.138	13,41	A	0,4610
Estrutura Predial > Esquadrias, porta, portão e janelas	C	1.003	11,82	A	0,8712
Elétrica > Instalações elétricas	C	909	10,71	A	0,7248
Elétrica > Iluminação	C	764	9,00	A	0,8901
TI / Dados / Rede > Ponto de rede / fibra ótica / Wi-fi	C	412	4,86	A	0,7173
Instalação de Acessórios e Mobiliário > Instalação/reparo de equipamentos (Suportes de TV, acessórios de banheiro e quadro branco)	C	405	4,77	B	0,4730
Estrutura Predial > Telhados, calhas, rufos, etc.	C	203	2,39	B	0,4962
Estrutura Predial > Infiltração	C	202	2,38	B	0,6493
Estrutura Predial > Forro	C	168	1,98	B	0,7746
Elétrica > Nobreak	C	150	1,77	B	0,7855
Área Externa e Ambiental > Manutenção área externa / meio ambiente / Poda de árvore / Roçagem	C	103	1,21	C	0,6288
Instalação de Acessórios e Mobiliário > Placas de identificação	C	69	0,81	C	0,6494
Estrutura Predial > Pintura	C	60	0,71	C	0,5890
Elétrica > Gerador	C	43	0,51	C	0,7723
Hidrossanitária > Bomba	C	43	0,51	C	0,7238
Climatização > Ar condicionado central	C	33	0,39	C	0,7324
Segurança contra Incêndio > Sistemas de combate a incêndio (extintores, hidrantes)	C	29	0,34	C	0,4815
Equipamentos de Transporte > Elevador	C	21	0,25	C	0,7692
Elétrica > Subestação	C	19	0,22	C	0,6061
Não manutenção	NM	585	100,00		
Outros > Erro de chamado	NM	258	44,10	A	0,3978
Posto de trabalho > Contratação de Posto de trabalho	NM	102	17,44	A	0,9561
Suprimentos / Apoio Técnico > Materiais	NM	96	16,41	A	0,4790
Projetos e Reformas > Reforma	NM	65	11,11	A	0,2407
Outros > Outros	NM	28	4,79	B	0,3404
Projetos e Reformas > Projeto	NM	23	3,93	B	0,0000
Suprimentos / Apoio Técnico > Limpeza de equipamentos, ambiente e mobiliário	NM	13	2,22	C	0,0909
Total avaliado		13.972			

As nove categorias restantes da taxonomia não sustentam suporte nas cinco dobras e ficam fora das partições, conforme o critério da Subseção 3.5. Somam 88 linhas, ou 0,63% da base congelada, e estão discriminadas na Tabela A3 para que a diferença entre os dois denominadores permaneça auditável.

Tabela A3 Categorias fora das partições canônicas.

Categoria de referência	Linhas	Motivo da exclusão
TI / Dados / Rede > Coleta de dados	40	ausente de ao menos uma dobra após a estratificação
Hidrossanitária > ETA / ETE	15	ausente de ao menos uma dobra após a estratificação
Manutenção Preventiva > Nobreak	9	ausente de ao menos uma dobra após a estratificação
Elétrica > Sistema Fotovoltaico (FV)	7	ausente de ao menos uma dobra após a estratificação
Estrutura Predial > Instalações Especiais (gás, ar comprimido, etc.)	5	ausente de ao menos uma dobra após a estratificação
Área Externa e Ambiental > Drenagem	4	suporte insuficiente para as cinco dobras
Manutenção Preventiva > Aplicação cupinicida	3	suporte insuficiente para as cinco dobras
Manutenção Preventiva > Bomba	3	suporte insuficiente para as cinco dobras
Suprimentos / Apoio Técnico > Transporte	2	suporte insuficiente para as cinco dobras
Total	88	

Fonte: elaboração própria a partir do corpus analisado.